ARTIFICIALMENTE

Una colección para pensar y repensar la inteligencia artificial

Volumen I

La invención de la inteligencia

De las máquinas de símbolos al nacimiento de la inteligencia artificial



María Inés García Betoño | PhD

ARTIFICIALMENTE

Una colección para pensar y repensar la inteligencia artificial

Volumen I

La invención de la inteligencia

De las máquinas de símbolos al nacimiento de la inteligencia artificial

María Inés García Betoño | PhD

Créditos y derechos

ARTIFICIALMENTE · Volumen I
La invención de la inteligencia
De las máquinas de símbolos al nacimiento de la inteligencia artificial

Autora: María Inés García Betoño, PhD.

Primera edición digital, noviembre de 2026.
Idioma: español (Argentina).

© 2026 María Inés García Betoño respecto de los aportes humanos originales, la selección, organización, estructura, edición y demás elementos protegibles de esta obra. Todos los derechos reservados.

La producción de esta edición incluyó el uso de sistemas de inteligencia artificial generativa para determinadas tareas de investigación, organización, edición, revisión, diseño y generación de contenido. La autora dirigió el proceso, seleccionó y revisó los materiales y asume la responsabilidad editorial de la versión publicada. La protección jurídica de elementos generados mediante inteligencia artificial puede variar según la jurisdicción; esta declaración no pretende atribuir derechos donde la legislación aplicable no los reconozca.

Diseño de cubierta: dirección creativa de la autora con herramientas de inteligencia artificial generativa.

Esta edición electrónica ha sido preparada como EPUB 3 reflowable con navegación estructurada, notas finales y criterios de accesibilidad.

Las marcas, nombres comerciales, productos, instituciones y obras de terceros mencionados pertenecen a sus respectivos titulares. Su mención es informativa y no implica afiliación, patrocinio, autorización ni respaldo de esos titulares.

La autora procuró verificar las referencias y datos de esta edición. Para usos académicos, científicos, profesionales, médicos, jurídicos o técnicos que requieran precisión especializada, deben consultarse las fuentes primarias y la documentación vigente.

Nota editorial y declaración de uso de inteligencia artificial

ARTIFICIALMENTE nació como un proyecto personal de aprendizaje, actualización y exploración crítica sobre inteligencia artificial. Esta colección no pretende sustituir un tratado académico, una revisión sistemática de la literatura ni una obra de referencia especializada. Su propósito principal es otro: organizar conocimiento, recuperar fundamentos, relacionar disciplinas y, sobre todo, generar nuevas preguntas.

Los contenidos fueron desarrollados a partir de bibliografía científica, técnica e histórica, junto con la experiencia, los intereses y los materiales producidos por la autora a lo largo de su trayectoria profesional. Se procuró verificar los hechos, referencias y afirmaciones relevantes con el mayor rigor posible; sin embargo, por la amplitud y velocidad de evolución del campo, pueden persistir errores, imprecisiones, referencias incompletas o interpretaciones susceptibles de revisión.

Por ese motivo, este libro debe leerse como una obra de aprendizaje y reflexión basada en evidencia, y no como una fuente primaria ni como sustituto de la consulta de publicaciones originales cuando se requiera precisión académica, técnica, profesional, jurídica, médica o científica.

La inteligencia artificial tuvo una participación sustantiva en el proceso de producción. Diferentes agentes y módulos de una arquitectura desarrollada y configurada por la autora colaboraron en tareas de investigación, organización, contraste, edición, revisión, estructuración, diseño y producción editorial.

Estos sistemas fueron configurados utilizando criterios, instrucciones, materiales y numerosos textos propios —científicos, narrativos, técnicos y de divulgación— con el objetivo de aproximar sus respuestas a la forma de analizar, relacionar ideas y formular preguntas de la autora. Esto no implica que los sistemas de inteligencia artificial posean sus conocimientos, identidad, valores o juicio, ni elimina la posibilidad de error inherente a estas tecnologías.

Las decisiones conceptuales, la selección de los temas, la arquitectura de la colección, los criterios editoriales y la responsabilidad sobre la versión publicada corresponden a **María Inés García Betoño**.

La participación de inteligencia artificial no se oculta deliberadamente: forma parte del objeto mismo de esta colección. Una de las preguntas que atraviesa *ARTIFICIALMENTE* es precisamente cuánto de una obra producida mediante sistemas generativos pertenece a la máquina, cuánto pertenece a quien los configura y dirige, y qué nuevas formas de autoría, colaboración, creatividad y responsabilidad están apareciendo en ese espacio intermedio.

Las tecnologías, modelos, herramientas y conocimientos vinculados con inteligencia artificial cambian rápidamente. Se recomienda contrastar información técnica o sensible con fuentes actualizadas.

Este libro invita a hacer exactamente eso: **leer, preguntar, contrastar, dudar, verificar y volver a pensar.**

Índice

Nota editorial y declaración de uso de inteligencia artificial 4
Prólogo · El verano que cabía en un papel 7
Capítulo 1 · La máquina que podía escribir música 15
Capítulo 2 · El hombre que cambió la pregunta 30
Capítulo 3 · La neurona que se convirtió en una proposición 46
Capítulo 4 · El verano que no fue una epifanía 60
Capítulo 5 · El teorema que una máquina encontró 74
Capítulo 6 · Aprender a ganar 89
Capítulo 7 · La neurona que prometía reconocer el mundo 103
Capítulo 8 · La conversación que devolvía nuestras palabras 116
Capítulo 9 · DENDRAL: las hipótesis que nacían de un espectro 128
Capítulo 10 · Los inviernos que nunca fueron uno 140
Capítulo 11 · Las representaciones que nadie programó una por una 153
Capítulo 12 · Dos tableros, dos inteligencias 164
Capítulo 13 · Un millón de imágenes no es el mundo 181
Capítulo 14 · La atención no apareció para conversar 198
Capítulo 15 · La interfaz que alteró la pregunta 212
Epílogo · La pregunta que sobrevivió 227
Notas finales por capítulo 234
Bibliografía general de consulta 241
Sobre la autora 251
Gracias por leer y colaboración voluntaria 256

Prólogo · El verano que cabía en un papel

En agosto de 1955, la inteligencia artificial todavía no tenía una historia que contar.[1] Tenía, en cambio, una propuesta. Cuatro investigadores habían firmado un documento con una ambición difícil de dimensionar: estudiar durante el verano siguiente si los aspectos del aprendizaje y de otras capacidades intelectuales podían describirse con precisión suficiente para reproducirlos en una máquina. El proyecto duraría dos meses. La previsión era reunir a diez científicos en Dartmouth College, en Hanover, Nuevo Hampshire. La promesa no era construir un artefacto terminado al final del encuentro, sino avanzar en problemas que durante mucho tiempo habían pertenecido a disciplinas distintas.

Una propuesta de investigación puede parecer un lugar poco novelesco para empezar una historia. No hay allí una máquina que se enciende por primera vez ni un público que aplaude ante un descubrimiento. Hay nombres, instituciones, temas y una solicitud de recursos. Pero una propuesta es también una forma de mirar el mundo antes de que los resultados obliguen a corregirla. Conserva algo que los relatos retrospectivos suelen borrar: lo que quienes investigaban todavía no sabían. Su incertidumbre resulta más interesante que nuestra ventaja de conocer parte del desenlace.

Los nombres eran John McCarthy, Marvin Minsky, Nathaniel Rochester y Claude Shannon. Sus trayectorias no eran equivalentes. McCarthy se ocupaba de la naturaleza matemática del pensamiento y de los lenguajes. Minsky había investigado modelos de redes nerviosas. Rochester llegaba desde IBM y la ingeniería de las computadoras. Shannon había construido una teoría matemática de la información y explorado conexiones entre circuitos, lógica y má-

quinas. La colaboración no reunía cuatro versiones del mismo investigador. Reunía maneras diferentes de imaginar qué parte de la inteligencia podía transformarse en un problema técnico.

La diversidad estaba en el propio texto. Sus apartados trataban de computadoras automáticas, uso del lenguaje, redes de neuronas, complejidad de los cálculos, mejora de las máquinas por sus propios procedimientos, abstracción y creatividad. Vista desde hoy, la lista sorprende. A primera vista recuerda algunas de las discusiones contemporáneas sobre modelos de lenguaje, aprendizaje automático y agentes. Sin embargo, esa semejanza debe manejarse con cuidado. Los autores de 1955 no habían diseñado un transformer; tampoco describían un asistente conversacional ni estaban anticipando una plataforma de agentes. Lo que compartían con nosotros eran ciertas preguntas. Sus instrumentos, sus respuestas posibles y las limitaciones materiales de sus computadoras eran otros.

Una de las frases más reveladoras del documento no es la más grandiosa. Los autores reconocían que la velocidad y la memoria de las computadoras disponibles podían ser insuficientes para algunas funciones superiores del cerebro, pero sugerían que el principal obstáculo residía en la incapacidad de escribir programas que aprovecharan plenamente los recursos existentes. Ahí aparece una tensión que atraviesa toda la historia: ¿nos faltan máquinas más potentes, mejores formas de representar el problema o ideas que todavía no sabemos formular? A veces las tres cosas. La dificultad está en descubrir cuál de ellas resulta decisiva en cada momento.

La expresión «inteligencia artificial» aparece en la propuesta como denominación de un campo por organizar. Hoy parece una categoría natural: hablamos de sistemas de inteligencia artificial, industrias de inteligencia artificial, estrategias de inteligencia artificial. Pero un nombre no describe simplemente un territorio que

ya existe. También ayuda a reunir bajo una misma institución preguntas que antes se distribuían entre la psicología, la matemática, la ingeniería, la lógica, la neurofisiología y la filosofía. Al nombrar algo, podemos comenzar a financiarlo, enseñarlo, discutirlo y prometer sus beneficios. También corremos el riesgo de creer que las cosas reunidas bajo la misma palabra constituyen un fenómeno único.

Pensemos en dos máquinas hipotéticas. Una demuestra un teorema siguiendo reglas formales. Otra aprende a reconocer una señal a partir de ejemplos. Si ambas ofrecen un resultado que una persona asociaría con inteligencia, ¿demuestran el mismo tipo de capacidad? La primera quizá no necesite aprender de la experiencia; la segunda puede aprender sin justificar ninguna conclusión en lenguaje lógico. Una tercera máquina podría conversar de forma convincente y equivocarse en una cuenta sencilla. Una cuarta podría resolver una ecuación compleja sin entender la pregunta que llevó a escribirla. Llamarlas inteligentes puede resultar útil. Suponer que esa palabra explica cómo funcionan sería un error.

Ese error no se vuelve menos probable cuando las máquinas empiezan a hablar. Un modelo contemporáneo puede redactar una hipótesis, proponer código, comparar argumentos y sugerir una estrategia. La experiencia de interactuar con él empuja a emplear palabras tomadas de nuestras relaciones con otras personas: sabe, entiende, recuerda, decide, quiere. Algunas son abreviaturas funcionales aceptables. Otras crean confusiones decisivas. Cuando decimos que un sistema «sabe» algo, ¿estamos hablando de su capacidad para producir una frase, de la exactitud de la frase, de un estado interno verificable o de la responsabilidad de quien la utiliza?

Hay una manera cómoda de resolver el problema: prohibir esas palabras o aceptarlas sin reservas. Ninguna de las dos alternativas alcanza. Si las prohibimos, perdemos metáforas que organizan

nuestra práctica. Si las aceptamos sin examinarlas, confundimos rendimiento con comprensión y familiaridad de interfaz con evidencia sobre el mecanismo. La respuesta más fértil consiste en convertir las palabras en preguntas de investigación. Cada vez que una máquina parece realizar una actividad intelectual, preguntarnos qué ha hecho, qué hemos medido y qué inferencia estamos autorizados a extraer.

La historia de la inteligencia artificial está llena de esos desplazamientos. Hubo una época en que realizar operaciones aritméticas largas con precisión parecía una proeza para una máquina. Después la atención pasó a probar teoremas, jugar, reconocer patrones o entender frases. Cuando algunas de esas tareas dejaron de ser extraordinarias, la frontera se trasladó otra vez. No significa que la inteligencia sea una ilusión ni que los avances carezcan de importancia. Significa que nuestra idea de inteligencia se encuentra profundamente vinculada a lo que todavía no sabemos automatizar.

También es tentador describir el desarrollo de esta disciplina como una marcha ascendente desde los mecanismos más simples hasta las herramientas generativas. El relato es seductor porque termina donde estamos y convierte el presente en la respuesta natural a todo lo anterior. Pero los caminos de la investigación no estaban dispuestos en fila. Los programas simbólicos, los modelos neuronales, los métodos estadísticos y las tradiciones de control convivieron, compitieron, se transformaron y en ocasiones fueron relegados. Algunas ideas fueron útiles mucho después de que sus primeros defensores perdieran protagonismo. Otras tuvieron éxito en aplicaciones que sus propios creadores no habrían elegido como ejemplo principal.

Hay otra razón para desconfiar de una historia de triunfadores. Los experimentos científicos no se desarrollan en un vacío. Importan las universidades, las empresas, los programas públicos,

las guerras, la posibilidad de conseguir equipamiento, las políticas de contratación y el prestigio atribuido a ciertas preguntas. Importa quién puede publicar, quién obtiene crédito y quién queda convertido en una nota al pie. Los relatos que reducen el campo a unos cuantos genios solitarios suelen confundir una biografía memorable con una explicación histórica suficiente.

Hay algo más en la forma de aquella propuesta que merece atención. Los investigadores enumeraban problemas diferentes, pero no disponían de una prueba única que permitiera determinar cuándo los habían resuelto. Podían programarse rutinas para manipular palabras; otra cosa era demostrar que el sistema utilizaba lenguaje de una manera general. Podían construirse redes de unidades artificiales; otra cosa era establecer en qué sentido esas redes formaban conceptos. Podía diseñarse una máquina capaz de elegir respuestas entre muchas alternativas; otra cosa era definir si había realizado una inferencia o una búsqueda eficaz. Entre el funcionamiento verificable de una implementación y las palabras con que interpretamos ese funcionamiento se extendía una región de desacuerdo. La investigación no comenzaba después de resolver ese desacuerdo: comenzaba precisamente porque no estaba resuelto.

Esta ambigüedad no pertenece solamente a los inicios. Los informes técnicos actuales pueden publicar métricas exactas y, sin embargo, debatir qué capacidad representan esas métricas. Resolver una prueba de programación no equivale a mantener un sistema durante años. Responder preguntas de conocimiento no garantiza detectar información engañosa. Completar una tarea con herramientas externas no demuestra que la arquitectura sea segura cuando cambian sus permisos. En cada caso hace falta preguntar qué se mide, qué se deja fuera y qué comparación justifica el resultado. La historia de la IA puede leerse como una larga sucesión de instrumentos para responder esas preguntas, acompañada de nuevas razones para reformularlas.

La propuesta de Dartmouth nos obliga a recordar que ninguna disciplina nace ya sabiendo cuáles serán sus fronteras. El texto era un programa de investigación y, como tal, combinaba problemas formulados con precisión con esperanzas difíciles de medir. Los firmantes creían posible conseguir avances significativos durante un verano. Esa expectativa dice mucho acerca de su confianza en la formalización; no nos autoriza a imaginar que el encuentro resolvió el misterio del pensamiento humano. Un acto fundacional puede fundar una comunidad sin resolver el problema que le da nombre.

Lo más interesante aparece cuando cambiamos ligeramente la pregunta. En vez de preguntar si aquellas personas lograron crear inteligencia artificial, preguntamos qué necesitaban creer acerca de la inteligencia para intentar crearla. Había que suponer, al menos como hipótesis de trabajo, que algunas capacidades cognitivas admitían descripciones operativas; que esas descripciones podían traducirse a procedimientos y que ciertos procedimientos podían ejecutarse en máquinas. El salto conceptual es enorme. Para un naturalista, sería comparable a pasar de observar un comportamiento a proponer un mecanismo generativo capaz de reproducirlo bajo condiciones delimitadas. La reproducción de un resultado no demuestra por sí sola que el mecanismo coincida con el del organismo original. Puede revelar una solución diferente para una función semejante.

Ahí se encuentra una advertencia que acompañará el libro: una simulación no es necesariamente una explicación completa. Si diseñamos una máquina que clasifica imágenes con eficacia, habremos demostrado una capacidad bajo ciertas condiciones. No habremos demostrado automáticamente que aprende como un cerebro, que interpreta una escena como una persona o que comprende la relevancia de lo que identifica. La diferencia entre función,

mecanismo e interpretación puede parecer académica hasta que una decisión profesional depende de ella. Entonces se convierte en una cuestión práctica.

En la actualidad, esa distinción afecta a investigaciones, sistemas de selección de personas, análisis de datos, decisiones clínicas, productos digitales y herramientas de creación. Una organización puede incorporar un sistema porque sus respuestas resultan persuasivas; una investigadora puede confiar en una síntesis porque cita nombres correctos; un equipo puede desplegar una automatización porque superó una demostración controlada. La pregunta decisiva siempre llega después: ¿en qué circunstancias dejará de funcionar, quién detectará el fallo y qué sabremos acerca de sus causas?

El documento de 1955 no responde esas preguntas contemporáneas. Nos ofrece algo anterior: el momento en que una comunidad decidió tratar la inteligencia como un conjunto de problemas científicos susceptibles de construcción, comparación y discusión. No había acuerdo suficiente sobre la naturaleza del objeto. Había un proyecto para avanzar a pesar de ello. En cierta medida, esa sigue siendo nuestra situación.

Para comprender cómo pudieron presentar semejante propuesta, tendremos que abandonar por un momento las computadoras electrónicas de mediados del siglo veinte. Es necesario retroceder hacia un mundo de ruedas dentadas, tablas matemáticas, telares programados con tarjetas y correspondencia científica. Allí encontraremos una pregunta extraordinaria, formulada mucho antes de que existiera la inteligencia artificial como disciplina: si una máquina puede obedecer instrucciones sobre números, ¿qué impediría que trabajara con otros símbolos?

La mujer que llevó esa posibilidad a una de sus formulaciones más claras no llegó a escuchar una computadora generar música. Su máquina, de hecho, nunca se construyó completa. Lo que dejó fue una explicación que todavía hoy dificulta cualquier respuesta demasiado sencilla sobre creatividad, instrucciones y autonomía.

Parte I · Antes de que tuviera nombre

Capítulo 1 · La máquina que podía escribir música

Hay una frase extraña en un texto de 1843. No describe una máquina que se hubiera construido ni una melodía que alguien hubiera escuchado. Plantea una posibilidad condicional: si las relaciones fundamentales entre los sonidos pudieran expresarse de una manera adecuada, la máquina analítica podría componer piezas musicales de gran complejidad. La afirmación aparece en las notas que Ada Lovelace añadió a su traducción de un artículo sobre la máquina concebida por Charles Babbage. Es una de esas frases que parecen más actuales cuanto mayor es la distancia histórica que nos separa de ellas.

La tentación consiste en leerla como una profecía sobre los sistemas generativos. Sería una lectura demasiado rápida. Lovelace no afirmaba que una máquina comprendiera música, ni describía redes neuronales entrenadas con grabaciones, ni predecía una industria cultural. Su hipótesis era más rigurosa y más radical en el contexto de su época: el campo de acción de una máquina calculadora no tenía por qué estar limitado a las cantidades si lograba representar otras relaciones mediante símbolos sometidos a operaciones definidas. No era necesario que la máquina oyera una nota para manipular una estructura que la representara. La condición estaba en la representación y en las reglas.

Para entender por qué resultaba tan novedoso, conviene recordar qué significaba calcular antes de la computadora electrónica. Las tablas numéricas constituían una infraestructura del conocimiento. Navegar, observar astros, hacer ingeniería o resolver problemas de comercio exigía disponer de valores obtenidos mediante procedimientos prolongados. Una tabla no era solamente una comodidad: era una forma de convertir un cálculo repetido en algo

que otros podían utilizar sin repetirlo. Pero cada eslabón de esa cadena —calcular, copiar, componer, imprimir— introducía oportunidades de error. Reducir el trabajo repetitivo era una ambición científica, económica y material.

Charles Babbage se propuso mecanizar una parte de esa labor. Su máquina diferencial estaba diseñada para producir tablas mediante el método de las diferencias finitas. El nombre suena intimidante, pero su lógica puede escucharse con facilidad. Imaginemos una serie de números cuadrados: uno, cuatro, nueve, dieciséis, veinticinco. Las diferencias entre términos sucesivos son tres, cinco, siete y nueve. Si calculamos las diferencias entre esas diferencias, obtenemos siempre dos. Una regularidad así permite producir la serie mediante sumas repetidas, sin calcular desde cero cada cuadrado por multiplicación. Para un polinomio de grado fijo, las diferencias sucesivas alcanzan finalmente una fila constante. Una máquina de ruedas y engranajes podía aprovechar ese hecho.

La elegancia era real, pero también lo era su límite. La máquina diferencial estaba concebida para un conjunto restringido de operaciones. Era muy buena candidata para tareas que pudieran reorganizarse como una secuencia apropiada de sumas. No era un dispositivo al que se entregara cualquier procedimiento para que lo ejecutara. El cálculo estaba inscrito en su arquitectura con una especificidad que reducía la flexibilidad. Un mecanismo puede ser extraordinariamente preciso y, a la vez, muy limitado en el tipo de problema que acepta.

Aquí surge una distinción que seguirá siendo útil dos siglos después. La dificultad de una tarea no determina, por sí sola, la generalidad de la máquina que la resuelve. Un artefacto especializado puede superar a una persona en un trabajo agotador sin poder hacer casi nada fuera de ese dominio. En cambio, una máquina programable puede realizar tareas muy distintas si logramos ex-

presarlas en una forma que admita ejecución. La diferencia se encuentra menos en la apariencia del resultado que en la relación entre mecanismo e instrucción.

Cuando el proyecto de la máquina diferencial se estancó, Babbage imaginó un dispositivo de otra naturaleza: la máquina analítica. No se trataba simplemente de una calculadora mayor. La arquitectura separaba un lugar para almacenar números y resultados intermedios —el depósito— de un mecanismo que realizaría operaciones aritméticas —el molino—. El control debía incorporar tarjetas perforadas, inspiradas en las utilizadas para seleccionar patrones de tejido en los telares de Jacquard. Los diseños contemplaban operaciones repetidas y cambios de secuencia condicionados por resultados. Varias de estas ideas recuerdan componentes de la computación posterior, aunque sería anacrónico atribuirles sin matices todos los conceptos de la informática contemporánea.

La comparación con un telar es particularmente fértil. Un telar Jacquard no necesita comprender el dibujo de una flor para producirlo. La secuencia de tarjetas organiza acciones del mecanismo y, al hacerlo, transforma una disposición simbólica en un patrón material. La precisión del tejido depende de la correspondencia entre las tarjetas, el mecanismo y la estructura que se quiere producir. No hay un jardinero oculto dentro de la máquina. Hay una forma de codificar relaciones para que una operación física las ejecute.

En las notas de 1843, Lovelace hizo de esa imagen algo más que una comparación decorativa.[2] Describió la máquina analítica como una especie de telar de relaciones algebraicas. El paso intelectual es decisivo. Un número puede representar una cantidad de objetos, pero también puede funcionar como parte de una codificación más abstracta. Si dos entidades pueden representarse de modo que sus relaciones se conviertan en operaciones, entonces una máquina aritmética podría producir resultados acerca de

esas entidades sin manipular directamente el fenómeno original. La música era un ejemplo poderoso precisamente porque parecía pertenecer a otro reino de experiencia.

No basta, desde luego, con asignar números a las notas. Si escribimos un tres para identificar una nota musical, todavía no hemos explicado por qué multiplicar tres por dos tendría sentido musical. La representación útil debe conservar relaciones pertinentes: intervalos, duraciones, combinaciones, restricciones armónicas u otras estructuras según la finalidad. Dicho de otro modo, una codificación no se vuelve inteligente porque transforma fenómenos en cifras. Su valor depende de que las operaciones disponibles preserven algo significativo del problema representado.

Esta es una pregunta sorprendentemente contemporánea. Cuando un sistema de aprendizaje automático transforma palabras, imágenes o sonidos en vectores numéricos, tampoco basta con anunciar que «todo son números». La cuestión es qué relaciones se conservan, qué distinciones se pierden y qué conductas resultan posibles gracias a esa representación. Entre una tarjeta perforada y una representación vectorial aprendida existen diferencias técnicas inmensas, que otros volúmenes desarrollarán con detalle. Pero ambas nos enseñan a formular una pregunta previa a cualquier demostración espectacular: ¿qué estructura del mundo hemos conseguido convertir en operaciones?

La historia de Lovelace no es, por eso, solamente la historia de una persona que previó la música digital. Es la historia de alguien que distinguió entre las capacidades generales de un mecanismo y los objetos concretos sobre los que puede operar. Esa diferencia resulta invisible cuando juzgamos un sistema por una sola demostración. Una máquina que compone un fragmento musical puede ser un dispositivo rígido con opciones predefinidas, un generador

probabilístico o un sistema capaz de combinar reglas de nuevas maneras. El resultado audible no basta para distinguirlos. Necesitamos comprender el procedimiento.

Ada Byron, luego condesa de Lovelace, había nacido en 1815. Su formación matemática fue inusual para una mujer de su posición y de su tiempo, aunque no debe describirse como una trayectoria aislada de toda ayuda intelectual. Mary Somerville fue una influencia importante y participó en su acercamiento a Babbage. Más tarde, Augustus De Morgan la acompañó mediante una correspondencia de enseñanza matemática. Los documentos conservados permiten ver a una estudiante que avanza, se equivoca, pregunta y trabaja con conceptos difíciles. No ofrecen un retrato simple de genio espontáneo ni respaldan las versiones despectivas que la presentan como incapaz de comprender las matemáticas utilizadas en sus propios escritos.

Esta observación importa porque las biografías de la ciencia suelen organizarse alrededor de etiquetas rápidas. «Visionaria», «primera programadora», «hija de poeta» o «colaboradora de Babbage» son expresiones que condensan una vida y, al mismo tiempo, pueden ocultarla. La etiqueta de primera programadora ha sido defendida, discutida y matizada por historiadores.[3] Babbage había redactado secuencias de operaciones antes de 1843. Lovelace publicó una exposición extraordinariamente influyente de un procedimiento destinado a una máquina de propósito general, y sus notas ampliaron la interpretación conceptual del dispositivo. Es más interesante estudiar las contribuciones concretas que convertir una prioridad histórica disputada en una competencia por una medalla.

Su publicación surgió de una cadena internacional de circulación científica. Luigi Federico Menabrea, ingeniero y militar italiano, había escrito en francés un texto explicativo sobre la máquina de Babbage a partir de las ideas expuestas en Turín. Lovelace lo tra-

dujo al inglés y añadió siete notas identificadas con letras. Las notas excedían ampliamente la extensión del artículo traducido. La traducción era, por tanto, la puerta de entrada a un trabajo intelectual propio que examinaba operaciones, símbolos, ciclos, límites y posibilidades del diseño. La máquina seguía sin existir como dispositivo completo. El texto, en cambio, permitía pensar con ella.

La distinción entre una máquina concebida y una máquina construida debe permanecer a la vista. El proyecto analítico se conoce por planos, notaciones, explicaciones y piezas, no por una demostración completa y estable de su funcionamiento histórico. Podemos estudiar la coherencia de su diseño y reconocer características que anticipan desarrollos posteriores. No podemos atribuirle resultados experimentales obtenidos por un aparato que Babbage y Lovelace nunca llegaron a utilizar terminado. Esta prudencia no empobrece la historia. Hace visible algo que las biografías heroicas suelen pasar por alto: la distancia entre imaginar una arquitectura y resolver los problemas materiales de realizarla.

La distancia es reconocible para cualquiera que haya diseñado un sistema complejo con ayuda de IA. Es posible describir con claridad roles, flujos, permisos y resultados esperados; incluso obtener un prototipo convincente. Otra cosa es asegurar que esos componentes funcionen cuando las entradas cambian, las herramientas fallan o aparecen condiciones no previstas. La arquitectura define posibilidades y restricciones. La implementación revela cuáles de ellas resisten el encuentro con el mundo. Confundir ambos niveles no es una debilidad exclusiva del siglo diecinueve.

Las notas de Lovelace contienen además una demostración extraordinariamente concreta. En la Nota G se desarrolla un procedimiento mediante el cual la máquina podría calcular números de Bernoulli. Estos números forman una sucesión que aparece en diversas relaciones del análisis matemático. Para nuestra historia

importa menos memorizar sus valores que comprender la organización del cálculo: cada término puede construirse a partir de relaciones con términos anteriores, y el procedimiento exige conservar resultados intermedios, seleccionar operaciones y repetir grupos de instrucciones bajo ciertas condiciones.

Imaginemos la diferencia entre resolver un único problema y escribir una descripción capaz de resolver toda una familia de problemas. Si necesito calcular una cantidad una vez, puedo realizar las operaciones en papel y obtener el resultado. Si quiero que una máquina produzca tantos términos de una sucesión como se le solicite, debo especificar cómo cambia el estado después de cada paso, qué valores se conservan, cuáles se reemplazan, cuándo se repite una operación y en qué condición termina. La dificultad se desplaza desde la aritmética hacia la organización del procedimiento. Ya no basta con saber qué resultado es correcto; necesitamos construir una forma general de llegar a él.

La elección de los números de Bernoulli tampoco fue una casualidad ornamental. Para exhibir las posibilidades de la máquina, no convenía elegir una cuenta demasiado simple que cualquier lector pudiera resolver mentalmente. El problema necesitaba suficiente complejidad para que la organización del procedimiento tuviera relevancia. La sucesión permite observar operaciones anidadas, resultados que pasan a ser datos, ciclos que se reutilizan y relaciones entre términos. Es una pequeña representación de algo que después sería central para la informática: la diferencia entre conocer un ejemplo y disponer de un método general para una clase de casos. No son equivalentes. La primera capacidad resuelve el problema que tenemos delante; la segunda modifica los problemas que estaremos en condiciones de enfrentar mañana.

Un procedimiento ejecutable también debe enfrentarse con la precisión de los valores intermedios. Una cadena de operaciones puede ser formalmente correcta y producir resultados poco con-

fiables si la representación numérica no preserva suficiente exactitud. En las máquinas mecánicas proyectadas por Babbage, ese desafío se expresaba en el manejo de cifras, signos y pasos sucesivos. En computación moderna reaparece, con diferencias enormes, en el redondeo, la propagación de errores y la estabilidad numérica. Este puente no convierte la máquina analítica en una computadora contemporánea. Sirve para recordar que la matemática formal y su realización material nunca son idénticas: entre ambas aparecen restricciones que una explicación puramente conceptual puede ocultar.

La tabla publicada junto a la Nota G especifica columnas y transformaciones para el cálculo de un término concreto, mientras que el texto explica cómo la estructura puede reutilizarse sucesivamente. No deberíamos leerla como si fuera un programa de Python trasladado en el tiempo. Sus convenciones corresponden a una máquina que habría manipulado cantidades mediante mecanismos y tarjetas. Pero sí podemos reconocer el parentesco conceptual entre definir una secuencia de acciones sobre un estado y aquello que, mucho después, llamaríamos programar. En ese sentido, el documento es un puente entre una idea matemática y la posibilidad de ejecutar operaciones sin volver a decidir cada paso.

Hay una enseñanza más profunda escondida en esa tabla. Para que el procedimiento sea automatizable, alguien debe separar lo esencial de lo accidental. Debe identificar qué parte de la solución puede repetirse, qué información puede conservarse y qué decisiones pueden representarse mediante condiciones explícitas. Esa capacidad de abstracción no pertenece al engranaje. Forma parte del trabajo intelectual que hace posible diseñarlo. La máquina ejecuta una estructura cuyo valor depende de cómo fue construida y de lo bien que representa el problema.

Esto nos devuelve al primer punto incómodo de la historia. Si una máquina puede operar con símbolos que representan relaciones musicales, ¿puede crear música? Si puede repetir operaciones y producir resultados que nadie había calculado antes, ¿ha producido algo nuevo? ¿Y si combina formas de maneras que sorprenden incluso a quien diseñó el procedimiento? La palabra «crear» empieza a desdoblarse. Puede significar generar un objeto que antes no existía, producir una combinación inesperada, descubrir una relación o ejercer un juicio artístico sobre el valor de lo producido. No hay motivo para suponer que todas esas acepciones coinciden.

Lovelace fue notablemente cautelosa respecto de las atribuciones excesivas. En la Nota G advirtió sobre dos movimientos que acompañan a menudo las tecnologías nuevas: exagerar primero sus posibilidades y minusvalorarlas después cuando descubrimos los límites de nuestras expectativas. Su texto niega a la máquina analítica la capacidad de originar por sí misma verdades o relaciones analíticas, pero también plantea que reorganizar el conocimiento para hacerlo ejecutable podría iluminar relaciones matemáticas y estimular nuevas investigaciones. El resultado es más sutil que una oposición entre una máquina obediente y una persona creadora.

Es posible que un instrumento no origine una teoría y, sin embargo, cambie la manera en que la teoría se construye. Un microscopio no inventa una célula. Tampoco interpreta por sí solo la vida que observamos a través de él. Pero su existencia transforma las preguntas que podemos hacer y los fenómenos que llegan a ser observables. De manera parecida, una máquina capaz de ejecutar combinaciones matemáticas complejas puede volver practicables líneas de investigación que antes eran demasiado laboriosas. La herramienta no ocupa necesariamente el lugar del pensamiento; puede cambiar su espacio de posibilidades.

La analogía tiene límites. Un microscopio produce un tipo de evidencia mediante una interacción física con el objeto observado; una máquina generativa produce contenido a partir de modelos y procedimientos aprendidos o programados. No debemos tratarlos como instrumentos equivalentes de acceso a la verdad. La semejanza está en otro lugar: ambos alteran qué tareas puede emprender una investigadora y qué nuevos errores necesita aprender a reconocer. Cada ampliación instrumental exige una ampliación del criterio con que interpretamos sus resultados.

En 1950, Alan Turing regresaría sobre las palabras de Lovelace al discutir si las máquinas podían pensar. Las situó entre las objeciones importantes a su planteamiento y cuestionó que el comportamiento de un dispositivo debiera quedar reducido a lo que su diseñador pudiera anticipar conscientemente. No era una simple refutación de Lovelace, que había escrito sobre una máquina no terminada y con una arquitectura específica. Era una transformación del problema: el interés se desplazaba hacia lo que sería razonable inferir de la conducta de máquinas diferentes. Entre ambos textos transcurrió más de un siglo y cambió de manera radical el mundo material de la computación.

La discusión, sin embargo, no ha desaparecido. Un modelo generativo puede producir un argumento que nadie introdujo literalmente en su entrenamiento, escribir una melodía inédita o sugerir una solución inesperada. Estas posibilidades no bastan para resolver si comprende, posee intenciones o es creativo en el mismo sentido que una persona. Tampoco justifican negarle todo carácter novedoso a sus resultados. Podemos reconocer originalidad estadística, utilidad práctica o creatividad evaluada por personas sin resolver de una vez el problema filosófico de la experiencia subjetiva.

Conviene evitar otro atajo: decir que una máquina «solo sigue instrucciones» como si esa observación cerrara el debate. Cualquier sistema computacional funciona dentro de procesos materiales y reglas de operación. Pero la relación entre esas reglas, el aprendizaje a partir de datos y los resultados emergentes puede ser muy compleja. Que un sistema esté determinado por una arquitectura y por procesos de entrenamiento no significa que sus diseñadores puedan anticipar cada respuesta. Y que no puedan anticiparla tampoco prueba autonomía intelectual en un sentido humano. La sorpresa de un observador y la independencia de un sistema no son la misma propiedad.

Tomemos un ejemplo que cualquier profesional del conocimiento puede reconocer. Un sistema redacta un informe convincente a partir de una colección de artículos y propone una interpretación que no figuraba literalmente en ninguno de ellos. ¿Ha descubierto una relación? Es posible que haya combinado información de manera útil. También es posible que haya producido una generalización sin sustento. Para distinguir ambas situaciones necesitamos reconstruir las premisas, identificar las fuentes, reconocer posibles alternativas y preguntarnos qué observación refutaría la nueva hipótesis. El valor de la propuesta no se decide por su novedad superficial ni por la elocuencia con que fue presentada. Se decide mediante el trabajo intelectual que permite convertirla, si corresponde, en conocimiento defendible.

A la inversa, sería injusto restar valor a toda colaboración porque el resultado depende de herramientas. La investigación científica lleva siglos ampliando sus capacidades mediante instrumentos, métodos colectivos y sistemas de registro que ninguna persona domina por completo. La autonomía intelectual no ha significado nunca aislamiento absoluto. Significa la posibilidad de formular propósitos, reconocer dependencias, juzgar resultados y responder por las decisiones tomadas. Si delegar una operación nos libera para investigar una pregunta más difícil, esa delegación puede

ampliar nuestras capacidades. Si nos lleva a aceptar conclusiones que ya no podemos someter a crítica, puede debilitarlas. La diferencia no está solamente en la tecnología. Está en la arquitectura de la colaboración y en el juicio que conservamos.

La historia de Lovelace sirve para aprender una forma de prudencia especialmente útil cuando trabajamos con IA generativa. Ante una respuesta sorprendente, la primera pregunta no debería ser si la máquina es genial o si simplemente copia. Debería ser cuál es la clase de novedad que observamos, cómo podría verificarse y qué papel tuvieron la representación, los datos, las reglas y la intervención humana. Este enfoque no extingue la admiración. Permite sostenerla sin abandonar el análisis.

Hay aquí otra paradoja. Las tecnologías que parecen más fáciles de utilizar suelen ocultar mayor complejidad. El telar produce un dibujo que podemos reconocer sin conocer sus tarjetas. La máquina analítica, si se hubiera construido, habría entregado resultados numéricos sin exigir que cada usuario comprendiera sus notaciones. Hoy conversamos con sistemas cuyo lenguaje natural hace que la infraestructura desaparezca de la experiencia inmediata. La interfaz reduce la fricción de acceso, pero también puede aumentar la distancia entre lo que vemos y lo que realmente sabemos sobre la producción del resultado.

Por eso no alcanza con dominar la interfaz. Para utilizar IA a nivel experto debemos aprender a mirar debajo de la superficie de una respuesta y formular preguntas de arquitectura: ¿qué representación está utilizando el sistema?, ¿qué parte del problema se encuentra codificada de antemano?, ¿qué puede generalizar?, ¿qué no?, ¿cuándo está ejecutando una operación determinada y cuándo ofrece una predicción incierta?, ¿qué podría salir mal aunque la demostración haya sido impecable? Estas preguntas no son un manual de instrucciones. Constituyen una forma de pensamiento técnico que puede trasladarse de una plataforma a otra.

La máquina analítica quedó incompleta. Sus diseñadores no pudieron mostrar al mundo un dispositivo que compusiera música. Tampoco podemos afirmar que la hipótesis musical de 1843 equivalía a la generación contemporánea de audio. La analogía, tomada literalmente, sería falsa. Lo que sí quedó fue una intuición de extraordinaria fecundidad: las operaciones mecánicas pueden adquirir nuevos dominios cuando construimos representaciones que conectan el mundo con un sistema de símbolos.

Esa intuición contiene una promesa y un límite. La promesa es la generalidad: no necesitamos una máquina distinta para cada problema si podemos expresar familias de problemas en una estructura ejecutable. El límite es que toda representación selecciona algo y deja algo fuera. Una partitura no es el sonido. Un mapa no es el territorio. Un conjunto de datos no es la experiencia completa de la población que pretende describir. Un texto generado no es automáticamente conocimiento. La capacidad de operar sobre una representación depende, precisamente, de recordar que es una representación.

Para quien proviene de las ciencias naturales, esa advertencia tiene un peso particular. Un modelo biológico puede reproducir una dinámica poblacional y aun así omitir mecanismos ecológicos decisivos. Un mapa de distribución puede mostrar patrones útiles y ocultar sesgos de muestreo. Una clasificación puede organizar organismos y, al mismo tiempo, congelar diferencias que la evolución vuelve continuas. Lo mismo ocurre con los sistemas de IA: toda potencia de generalización tiene condiciones. Reconocerlas no reduce nuestra capacidad de utilizarlos; la vuelve más sofisticada.

Lovelace, Babbage y Menabrea tampoco trabajaban en un mundo donde la tecnología pudiera separarse de las instituciones y del trabajo humano. Los diseños requerían materiales, precisión mecánica, financiamiento y personas capaces de traducir una idea en

planos, notaciones y piezas. La publicación de 1843 necesitó una conferencia, una memoria en francés, una traducción al inglés y notas que discutieran las consecuencias conceptuales. La historia de una tecnología no es la historia de una inspiración aislada, sino la de las condiciones que permiten circular y transformar una idea.

Esto vuelve especialmente significativo el papel de las controversias historiográficas. Durante mucho tiempo se discutió la competencia matemática de Lovelace mediante afirmaciones tan rotundas como las versiones hagiográficas que pretendían defenderla. El estudio de su correspondencia con De Morgan ofrece una imagen mejor documentada: la de un aprendizaje real, exigente, con dificultades y progresos. Otro análisis sobre los números de Bernoulli advierte que el mérito de Lovelace y el de Babbage no tienen por qué distribuirse como si uno excluyera al otro. La colaboración puede ser intelectualmente asimétrica en distintos momentos y, al mismo tiempo, producir una contribución que no se entiende reducida a un solo nombre.

En una historia de máquinas inteligentes, esta cuestión no es un desvío biográfico. Habla de nuestra manera de atribuir agencia, conocimiento y creación. Si nos cuesta describir con justicia una colaboración entre personas cuando los documentos son fragmentarios, resulta razonable exigir todavía más cautela cuando atribuimos creatividad o comprensión a sistemas cuyo funcionamiento interno no es directamente visible para la mayoría de sus usuarios. La precisión histórica se convierte así en una disciplina del juicio contemporáneo.

Ahora podemos regresar a aquella posibilidad de 1843. La máquina podría componer música si las relaciones musicales pudieran expresarse adecuadamente para sus operaciones. La condición es lo esencial de la frase. No da por supuesto que toda experiencia humana pueda reducirse sin pérdida a reglas. No proclama que la

máquina posea oído, sensibilidad o gusto. Invita a investigar hasta dónde llega una forma de representación y qué cambia cuando sus operaciones se vuelven ejecutables.

La historia de la inteligencia artificial podría comenzar aquí, no porque Lovelace hubiera inventado la disciplina futura, sino porque hizo visible una dificultad que la acompaña desde entonces. Antes de preguntarnos cuánto puede hacer una máquina, tenemos que preguntarnos qué significa describir una tarea, qué pierde esa descripción y cuál sería una prueba justa de su ejecución. Cuando dejamos de confundir el resultado con el procedimiento, aparece una nueva capa de comprensión.

Falta todavía una pieza. La máquina analítica mostraba cómo imaginar procedimientos generales, pero no resolvía qué tareas podían describirse mediante reglas y qué límites imponía la propia idea de cálculo. Esas preguntas exigirían otra clase de formalización, desarrollada durante el siglo siguiente, cuando la matemática comenzó a examinar sus propios fundamentos. Allí nos espera Alan Turing. Y la pregunta ya no será solamente si una máquina puede escribir una secuencia de operaciones, sino qué significa que algo sea computable y por qué esa definición cambiaría para siempre el problema de la inteligencia.

Capítulo 2 · El hombre que cambió la pregunta

Hay preguntas que se vuelven difíciles porque ignoramos su respuesta. Otras son difíciles por una razón más incómoda: todavía no sabemos qué tendría que ocurrir para reconocer una respuesta satisfactoria. «¿Pueden pensar las máquinas?» pertenecía, en 1950, a esta segunda categoría. Era una pregunta que parecía perfectamente inteligible mientras nadie exigiera precisar qué debía contar como máquina, qué significaba pensar y quién tendría derecho a decidir si la prueba había sido superada.

Alan Turing no inauguró su artículo de aquel año contando una proeza de ingeniería. Hizo algo menos vistoso y más revolucionario: cuestionó la utilidad de comenzar por las definiciones. El texto apareció en octubre, en la revista filosófica *Mind*, con el título *Computing Machinery and Intelligence*. Turing, que había contribuido a fundar la teoría de la computación y trabajado en la construcción de computadoras electrónicas, elegía intervenir en una discusión que parecía pertenecer a la filosofía de la mente. El movimiento no fue una retirada ante una dificultad metafísica. Fue un intento de cambiar las condiciones bajo las cuales esa dificultad podía investigarse.

Para apreciar la audacia de ese gesto conviene imaginar la discusión que no quiso sostener. Una persona afirma que las máquinas jamás podrán pensar porque carecen de conciencia. Otra sostiene que pensar consiste en resolver problemas y que una máquina ya lo hace. Una tercera señala que comprender una frase es diferente de responderla correctamente. Las tres pueden discutir durante horas sin acercarse siquiera a un desacuerdo comprobable. Cada una utiliza el mismo verbo para referirse a propiedades distintas. Una discrepancia sobre el mundo queda enredada en otra sobre

el lenguaje. Turing sabía que la definición elegida condicionaría la respuesta. Por eso propuso sustituir la pregunta inicial por un juego.

No se trataba de una trivialización. La ciencia recurre con frecuencia a procedimientos que no capturan toda la riqueza del fenómeno investigado. Una prueba de memoria no equivale a una teoría completa del recuerdo; un ensayo de laboratorio no es un organismo viviendo en su ambiente; un índice de biodiversidad no agota la estructura ni la historia de un ecosistema. Sin embargo, cada uno puede producir conocimiento si sabemos con precisión qué aspecto del fenómeno representa, cuál queda fuera y qué inferencia permite. Turing estaba ensayando una operación semejante sobre un concepto mucho más escurridizo. Su elección obligaría a generaciones enteras a preguntarse qué significa medir una capacidad intelectual.

Pero antes de llegar al juego conviene retroceder. La dificultad que lo hizo posible no nació en 1950. Catorce años antes, Turing había formulado una respuesta extraordinariamente rigurosa a otra pregunta que, vista desde lejos, parecía menos espectacular: ¿qué quiere decir calcular siguiendo un procedimiento?

La palabra «calcular» se había utilizado durante siglos sin necesidad de hablar de máquinas electrónicas. Una persona podía resolver una operación obedeciendo una secuencia finita de instrucciones. La operación podía ser tediosa, larga, incluso inabarcable durante una vida humana, pero en principio cada paso estaba especificado. Los matemáticos de comienzos del siglo XX habían convertido esa intuición en una pregunta formal: ¿existe un método efectivo que permita decidir, para cualquier proposición formulada en cierto lenguaje lógico, si se sigue de los axiomas apropiados? El nombre alemán de ese problema, *Entscheidungs-*

problem, puede traducirse como problema de la decisión. Su importancia no dependía de la dificultad de una cuenta concreta, sino de la aspiración de encontrar un procedimiento general.

En 1936, Turing presentó su análisis de los números computables y el modelo que hoy lleva su nombre. Las primeras entregas de la revista que contenían el artículo se publicaron en noviembre y diciembre de 1936, aunque algunas fichas editoriales modernas lo registran como 1937. No era una computadora construida. Era un objeto matemático deliberadamente austero: una cinta dividida en casillas, una cabeza capaz de leer y escribir símbolos, una cantidad finita de estados y reglas que determinan qué hacer a continuación. El mecanismo podía leer una casilla, cambiar un símbolo, moverse a una posición vecina y adoptar un nuevo estado. La simplicidad era precisamente la fuerza de la propuesta. Al retirar la velocidad, el tamaño del dispositivo y cualquier destreza humana especializada, Turing intentaba aislar lo que significa ejecutar una operación conforme a reglas explícitas.

Podríamos compararlo con un protocolo de observación cuidadosamente especificado. Dos personas que se atienen al mismo protocolo deberían poder reproducir cada transición, aunque no compartan intuiciones sobre el fenómeno observado. En una máquina de Turing, el estado siguiente depende de reglas y símbolos, no de una decisión privada del operador. Sin embargo, hay una diferencia decisiva respecto de un protocolo científico ordinario: aquí la pregunta es qué procesos pueden describirse enteramente de esa manera. En la frontera entre una instrucción que funciona y una instrucción imposible se juega una parte fundamental de la computación moderna.

La cinta ideal puede extenderse tanto como exija un cálculo. Esa infinitud es una idealización, no una promesa de recursos físicos infinitos. Tampoco debe confundirse el modelo abstracto con un artefacto dotado de engranajes o circuitos concretos. Su cometido

es describir una clase de operaciones. Una computadora real puede quedarse sin memoria, electricidad o tiempo; una demostración de computabilidad pregunta, en cambio, si existe un procedimiento de este tipo que produzca el resultado pertinente, suponiendo los recursos abstractos permitidos. Cuando preguntamos si un problema se puede resolver en principio, no estamos preguntando cuánto costará resolverlo mañana.

La distinción parece menor hasta que aparece lo imposible. Turing estudió los límites de los procedimientos generales. Hay problemas para los cuales no existe una máquina de ese tipo que siempre ofrezca una respuesta correcta y termine. El ejemplo que se volvió emblemático es el problema de determinar, de manera universal, si la ejecución de un programa dado se detendrá o continuará indefinidamente. Para algunos programas resulta fácil comprobarlo: basta inspeccionar sus reglas o ejecutarlos hasta que terminen. La imposibilidad no se refiere a esos casos particulares. Se refiere a un procedimiento infalible aplicable a todos los programas y entradas posibles.

La intuición de la demostración merece un instante de atención. Supongamos que disponemos de un verificador perfecto al que podemos darle la descripción de cualquier programa junto con una entrada. Ese verificador anuncia siempre si el programa terminará. Entonces imaginemos otro programa que utiliza la respuesta del verificador de manera deliberadamente perversa: si le anuncian que terminará, entra en un ciclo sin fin; si le anuncian que no terminará, termina inmediatamente. ¿Qué sucede al pedirle que se examine a sí mismo? Cualquiera de las dos respuestas lo contradice. Esta reconstrucción es una explicación pedagógica de una idea diagonal; no reemplaza los detalles de la demostración formal de 1936. Su importancia consiste en mostrar por qué ningún perfeccionamiento de la velocidad del hardware arregla el problema general.

Lo que Turing había encontrado era, en parte, una frontera de la formalización. Una máquina capaz de seguir procedimientos no puede resolver mediante un procedimiento único toda pregunta que podamos formular sobre los procedimientos. La computación, desde su origen teórico, no era la promesa de que todo lo inteligible pudiera calcularse. Incluía la demostración de que hay cosas que no pueden decidirse algorítmicamente dentro del marco definido.

Alonzo Church había llegado de manera independiente a resultados estrechamente relacionados mediante una formulación matemática distinta, el cálculo lambda. La historia que atribuye a un individuo solitario el descubrimiento de todos los fundamentos de la computación pierde precisamente aquí una de sus enseñanzas más fértiles: diferentes sistemas formales pueden iluminar una misma clase de procesos desde perspectivas diferentes. La tesis de Church y Turing expresa, en una de sus formulaciones clásicas, la identificación entre cálculo efectivo y computabilidad mediante esos modelos. Es una tesis que articula una noción intuitiva con definiciones matemáticas; no debe confundirse con un teorema que demuestre que el cerebro humano o todo proceso físico es una máquina de Turing.

La misma austeridad que revelaba límites permitió concebir algo extraordinario. Turing describió una máquina universal: una máquina que puede interpretar una descripción codificada de otra máquina y reproducir sus operaciones. Su comportamiento no queda fijado para una tarea única; depende de la descripción que recibe. En cierto sentido abstracto, una máquina puede ejecutar muchas máquinas. Ese desplazamiento anticipa una propiedad central de las computadoras de propósito general: separar la configuración física de los procedimientos que hacemos ejecutar. No significa que el diseño de Turing fuese ya una computadora electrónica con programas almacenados, ni que la historia de los com-

putadores físicos derive de un solo artículo. Significa que la posibilidad lógica de una generalidad programable había quedado expuesta con una claridad sin precedentes.

Para quien hoy escribe una instrucción destinada a un sistema generativo, la historia contiene una advertencia. Un programa explícito y un modelo estadístico entrenado no son lo mismo. En el primero podemos describir reglas de transición de manera directa; en el segundo, el comportamiento depende también de parámetros aprendidos, datos y procedimientos de inferencia. Ambos se implementan en sistemas computacionales, pero comprender la posibilidad de ejecutar un proceso no equivale a comprender cómo adquirió un modelo una determinada regularidad ni a justificar lo que afirma. El salto de las reglas a la inteligencia estaba todavía por investigarse.

Entre el ensayo matemático de 1936 y el artículo filosófico de 1950 hubo una guerra, trabajo de criptografía y el desarrollo acelerado de la computación electrónica. Turing formó parte del esfuerzo británico de desciframiento en Bletchley Park. Después trabajó en el National Physical Laboratory y en Manchester, vinculado con el diseño y uso de nuevas máquinas computadoras. Conviene evitar la versión cinematográfica en la que un único genio resuelve por sí solo una guerra tecnológica. Bletchley Park fue una empresa colectiva, con equipos, métodos, trabajo técnico y restricciones de secreto. También conviene evitar el error inverso: reducir la contribución de Turing a una celebridad retrospectiva. Sus trabajos matemáticos y su participación en la computación de posguerra fueron sustantivos y están documentados.

Hay una paradoja en esta transición. La teoría había preguntado qué podía hacerse mediante instrucciones. Las máquinas electrónicas empezaban a mostrar que procedimientos complejos podían ejecutarse a velocidades antes inimaginables. Pero ahora emergía otra pregunta: si disponemos de una máquina suficientemente fle-

xible para ejecutar una enorme variedad de programas, ¿cómo descubrimos los procedimientos que realizan actividades asociadas con la inteligencia? Los límites de la computación no resolvían esa cuestión. La posibilidad de programar tampoco. Hacía falta investigar las relaciones entre conducta, aprendizaje, representación y evidencia.

En 1948, antes del célebre artículo de *Mind*, Turing escribió para el National Physical Laboratory un informe titulado *Intelligent Machinery*. Allí examinó la posibilidad de construir máquinas capaces de comportamientos inteligentes e introdujo ideas sobre máquinas inicialmente «no organizadas», enseñanza y modificación del comportamiento. No era todavía aprendizaje automático en el sentido que darían después a esa expresión las redes profundas y los grandes modelos estadísticos. Sería anacrónico asignarle las técnicas actuales. Lo interesante es descubrir que, mucho antes de que las interfaces conversacionales popularizaran la IA, Turing ya rechazaba la idea de que toda conducta de una máquina inteligente debiera especificarse mediante una lista exhaustiva de respuestas.

Pensaba en la educación. No es un detalle menor. Una máquina que se limita a ejecutar instrucciones previamente escritas obliga a imaginar a un programador que anticipa cada situación relevante. Una máquina que aprende abre otra posibilidad: que el diseño de un proceso de formación sustituya parcialmente el diseño directo del comportamiento terminado. En lugar de programar cada respuesta que un adulto debería dar, ¿podríamos programar un sistema inicial y modificarlo mediante experiencia? La analogía con la infancia es sugerente, aunque debe conservarse como analogía. El aprendizaje humano ocurre en cuerpos, culturas, relaciones afectivas y entornos ecológicos que las máquinas de Turing no reproducían. Tampoco toda modificación de parámetros en un sistema artificial equivale al desarrollo cognitivo de una persona.

Llegamos así a octubre de 1950. Para ese momento, Turing conocía la amplitud y los límites de las máquinas programables. Sabía que la pregunta sobre pensamiento no se resolvería simplemente indicando que una computadora podía multiplicar números con rapidez. Eligió otro escenario. En su presentación original, el juego de imitación involucra a un hombre, una mujer y una persona interrogadora que no puede verlos. El interrogador intenta determinar cuál es cuál por medio de preguntas y respuestas escritas. Uno de los participantes trata de confundirlo; el otro procura ayudarlo. Turing pregunta qué pasaría si una máquina ocupara una de las posiciones del juego.

Es importante no borrar esa forma histórica. Las versiones populares suelen presentar directamente a un juez que conversa con una persona y una computadora, y decide cuál es humana. Esa simplificación captura una parte decisiva del interés del artículo, pero no reproduce literalmente la primera formulación. La función del juego inicial, el desplazamiento de roles y la interpretación del género han sido objeto de discusión historiográfica y filosófica. Algunas interpretaciones encuentran en esa elección elementos biográficos o una reflexión sobre las convenciones sociales de reconocimiento. Son lecturas posibles; no debemos presentarlas como intenciones privadas demostradas de Turing. Lo verificable es la estructura del texto y la pregunta que formula a continuación.

El interlocutor no observa brazos, rostro, movimientos ni entonación. Recibe respuestas. La restricción no es accidental. Si una computadora perdiera porque no puede correr, no habríamos demostrado que carece de capacidad intelectual; habríamos evaluado otra propiedad. Al limitar la interacción al lenguaje escrito, Turing buscaba evitar ciertos prejuicios vinculados con el cuerpo y concentrarse en capacidades expresadas mediante la conversación. El procedimiento intenta hacer justa una comparación de-

terminada. Al mismo tiempo, introduce un límite inevitable: las capacidades que no se expresan adecuadamente en esa interacción quedan fuera de la prueba.

La elección resulta más sutil de lo que parece. Pensemos en un modelo que formula excelentes hipótesis sobre un conjunto de datos y falla cuando tiene que recordar una instrucción de seguridad. Otro puede sostener una conversación impecable durante cinco minutos pero inventar una referencia bibliográfica. Un tercero puede ser incapaz de parecer humano y, sin embargo, descubrir una regularidad matemática que nadie esperaba. Si reducimos la inteligencia a la capacidad de hacerse pasar por una persona, corremos el riesgo de penalizar capacidades valiosas por no tener una presentación humana o premiar estrategias persuasivas que no mejoran la verdad de las respuestas.

Turing conocía al menos parte de esa dificultad. Él mismo contempló que una máquina pudiera realizar alguna actividad merecedora del nombre de pensamiento de una manera distinta de la humana. Su propuesta no era una descripción exhaustiva de la mente. Era una vía de investigación: si un sistema puede mantener cierta clase de intercambio, esa conducta exige una explicación. La inferencia adicional —por ejemplo, que posee experiencia subjetiva— no se sigue automáticamente de la observación. Aun entre seres humanos, la atribución de estados mentales implica inferencias; pero eso no elimina las diferencias entre tipos de evidencia ni convierte todas las inferencias en igualmente justificadas.

El problema se vuelve especialmente claro cuando analizamos la palabra «prueba». En ciencia, una prueba no es simplemente una situación en la que algo nos impresiona. Es una relación entre un constructo, un procedimiento, un resultado y una conclusión. Si queremos estudiar memoria, debemos decidir qué entendemos por memoria y qué tarea la representa. Si queremos estudiar cooperación, importa si observamos comportamiento cooperativo

bajo condiciones específicas o inferimos una disposición estable. El juego de Turing iluminó esa cuestión antes de que la ingeniería moderna de evaluación de modelos la convirtiera en una actividad profesional cotidiana: ninguna métrica habla por sí sola.

Además, el artículo contiene una predicción famosa que suele describirse sin sus condiciones. Turing estimaba que, aproximadamente cincuenta años después, podrían programarse computadoras con cierta capacidad de almacenamiento para que, tras cinco minutos de interrogatorio, un evaluador medio acertara la identificación no más del setenta por ciento de las veces.[4] No era una profecía acerca de conciencia, ni una promesa de que todo sistema superaría cualquier conversación. Era una conjetura acotada sobre un desempeño particular, bajo un procedimiento particular, en un horizonte temporal determinado. Cambiar duración, participantes, contexto o reglas cambia también la interpretación del resultado.

La ciencia contemporánea ofrece una lección suplementaria. En un estudio publicado en PNAS en 2026, los participantes conversaron durante cinco minutos con dos interlocutores, uno humano y otro artificial, antes de decidir cuál era la persona.[5] GPT-4.5 fue elegido como humano en el setenta y tres por ciento de los ensayos de una condición en la que recibía instrucciones para adoptar una personalidad verosímil; sin ese tipo de instrucciones, su resultado fue considerablemente menor. La diferencia importa tanto como el porcentaje más llamativo: el estudio medía la capacidad de producir una impresión humana bajo un protocolo concreto. No medía experiencia subjetiva, comprensión general ni confiabilidad en tareas profesionales. Incluso los porcentajes publicados sin instrucciones de personaje exigen cautela: el resumen y el desarrollo del artículo presentan de manera inconsistente su asignación a los modelos examinados.

El artículo de 1950 tiene otra virtud poco compatible con su versión mitológica: dedica una parte sustancial a escuchar objeciones. Turing examina argumentos teológicos, matemáticos, de conciencia, sobre limitaciones particulares, sobre continuidad del sistema nervioso y sobre conducta informal, entre otros. Algunas respuestas son más persuasivas que otras. Su importancia histórica no reside en haber clausurado todos los desacuerdos, sino en haber mostrado que una propuesta sobre inteligencia necesita responder a los contraargumentos más fuertes. En la práctica científica, construir una prueba sin escuchar qué podría invalidarla equivale a confundir convicción con investigación.

La objeción matemática merece una atención particular. Si existen límites formales para los sistemas que operan mediante reglas, ¿no queda demostrada la inferioridad intelectual de cualquier máquina frente a la mente humana? El salto es tentador, pero injustificado. Las demostraciones sobre formalismos precisos no autorizan, por sí solas, una comparación ilimitada con todas las capacidades humanas. Para convertir ese resultado en una tesis sobre superioridad cognitiva habría que demostrar además que las personas pueden resolver de manera general los problemas que los procedimientos formales no pueden decidir. Nada de eso queda establecido simplemente por conocer los teoremas de incompletitud o los límites de computabilidad. La distinción entre una limitación formal y una afirmación psicológica vuelve a aparecer.

La objeción sobre conciencia es más difícil de traducir en una prueba definitiva. Una conversación brillante no permite observar directamente la experiencia subjetiva del interlocutor. Pero tampoco tenemos un instrumento simple que observe de manera directa la subjetividad de otra persona. Esto no obliga a declarar que humanos y sistemas artificiales se encuentran en posiciones epistemológicas equivalentes. La atribución de estados mentales a personas integra una enorme cantidad de evidencia fisiológica,

evolutiva, conductual, social y biográfica. Frente a un sistema artificial, la arquitectura, el entrenamiento, la conducta y los datos disponibles son diferentes. La pregunta correcta no es si una pantalla que conversa produce la impresión de una mente, sino qué conjunto de evidencias justificaría qué atribuciones.

Entonces Turing regresa, de un modo sorprendente, a Ada Lovelace. En el capítulo anterior encontramos su advertencia sobre la máquina analítica y su incapacidad para originar algo por sí misma según las operaciones entonces concebidas. Turing recupera esa idea explícitamente y discute la posibilidad de que máquinas diseñadas de otra manera exhiban aprendizajes o comportamientos imprevistos por quienes las programaron. Ya no estamos frente a dos posiciones separadas por un siglo, sino ante una conversación histórica: la cautela de Lovelace es examinada a la luz de tecnologías y preguntas que ella no tuvo ocasión de investigar.

Hay que resistirse a convertir el encuentro en una victoria de Turing. Lovelace observaba lo que se podía afirmar justificadamente sobre un diseño particular del siglo XIX. Turing investigaba una clase mucho más amplia de máquinas y anticipaba otras formas de programación y aprendizaje. Ambas posiciones pueden resultar intelectualmente razonables en sus respectivos contextos. La historia de la ciencia pierde profundidad cuando convertimos desacuerdos sobre evidencias disponibles en una competencia de aciertos personales. Gana, en cambio, cuando vemos cómo cambia el significado de una pregunta al cambiar los instrumentos con que podemos examinarla.

En la parte final de su ensayo, Turing abandona cualquier tentación de esperar a que una definición perfecta de inteligencia resuelva el problema. Vuelve a las máquinas que aprenden. Propone pensar en un sistema infantil, un proceso educativo y una máquina transformada por ese proceso. Interpreta la enseñanza como una vía para construir comportamientos que no sería prác-

tico detallar uno por uno en un programa inicial. También reconoce las limitaciones de los intentos realizados. Lo importante no es presentar sus propuestas como si anticiparan sin fisuras todo el aprendizaje contemporáneo. Lo verdaderamente importante es la continuidad de su razonamiento: la inteligencia no tiene por qué concebirse exclusivamente como un producto terminado; puede investigarse a través de los procesos que la hacen posible.

Esta intuición toca un problema central para cualquier persona que trabaje hoy con sistemas generativos. Cuando un modelo ofrece una respuesta, solemos mirar el resultado final y atribuirle una capacidad. Pero el resultado depende de una historia: arquitectura, datos de entrenamiento, objetivos de optimización, ajustes, instrucciones, herramientas conectadas y condiciones de evaluación. La respuesta aislada no revela toda esa historia. Tampoco una explicación en lenguaje natural producida por el propio modelo constituye una descripción necesariamente fiel de sus mecanismos internos. Comprender un sistema exige observar más que el producto visible.

El concepto de aprendizaje introduce además un problema de responsabilidad. Si un sistema llega a producir algo que no escribimos directamente, ¿qué significa que «lo hizo por sí mismo»? Una conducta no prevista por el programador no equivale a una acción libre ni exime a las personas que diseñaron o desplegaron el sistema de examinar sus consecuencias. Entre control absoluto e independencia completa existe un territorio de diseño: fijar objetivos, delimitar permisos, observar resultados, intervenir ante fallos y revisar las condiciones bajo las que el aprendizaje conduce a comportamientos aceptables. Las máquinas modernas han hecho de ese territorio una profesión técnica, aunque el problema conceptual aparece con claridad en el texto de Turing.

Es aquí donde la historia deja de ser exclusivamente computacional. Turing publicó en 1952 un estudio sobre la base química de la morfogénesis, una investigación acerca de cómo las interacciones entre sustancias y su difusión pueden generar patrones espaciales en sistemas biológicos. La pregunta no era si una máquina podía conversar, sino cómo un tejido inicialmente homogéneo podía dar lugar a estructuras diferenciadas. En determinados modelos, la combinación entre reacción y difusión conduce a inestabilidades capaces de producir patrones. El fenómeno contradice una intuición habitual: tendemos a asociar la difusión con la homogeneización, pero en un sistema de componentes que interactúan pueden aparecer estructuras a partir de condiciones aparentemente uniformes.

La conexión con la inteligencia artificial no es que un patrón de pigmentación sea equivalente a una red neuronal ni que la morfogénesis explique los modelos de lenguaje. Sería una analogía científica defectuosa. La conexión es de actitud intelectual. En ambos campos, Turing investigaba cómo reglas relativamente simples, combinadas con estados y condiciones iniciales, pueden producir resultados difíciles de anticipar mediante la intuición. La explicación del patrón exige conocer el mecanismo y no conformarse con admirar la forma final. Para una persona formada en biología, esa distinción tiene una familiaridad particular: reconocer un patrón fenotípico no es lo mismo que explicar los procesos de desarrollo que lo originaron.

Sería injusto terminar este recorrido dejando fuera el marco político y social en que transcurrió su vida. Turing fue condenado en 1952 por actos homosexuales criminalizados entonces por la legislación británica. Su sentencia implicó tratamiento hormonal forzado como condición de libertad vigilada. Murió en 1954, con cuarenta y un años. Décadas después recibió un perdón póstumo. Estos hechos no explican por sí solos sus teoremas, pero forman parte de la historia institucional de la ciencia: la capacidad de una

sociedad para reconocer el valor intelectual de una persona puede convivir con decisiones legales y culturales que vulneran gravemente sus derechos. Ninguna historia de innovación debería confundir los reconocimientos posteriores con reparación de las oportunidades perdidas.

También aquí conviene resistir un recurso narrativo demasiado frecuente: convertir una vida en una secuencia inevitable orientada hacia una tragedia. Su pensamiento matemático, su trabajo criptográfico, sus propuestas sobre aprendizaje y sus estudios de morfogénesis merecen ser comprendidos como investigaciones con preguntas propias. No son solamente capítulos de una biografía cuyo desenlace ya conocemos. La perspectiva retrospectiva es poderosa, pero puede borrar algo que la investigación exige preservar: en cada momento, los protagonistas desconocían qué futuro se convertiría en pasado.

Volvamos a la pregunta que abrió el capítulo. «¿Pueden pensar las máquinas?» Turing no la eliminó de la filosofía ni demostró que una conversación satisfactoria resolviera la naturaleza de la conciencia. Hizo algo que todavía afecta la investigación y el uso profesional de la IA: mostró que una afirmación grandiosa debe descender al terreno de las observaciones y, al mismo tiempo, que ninguna observación tiene significado fuera de las condiciones que la hacen posible.

Esta lección cambia la manera de escuchar una demostración tecnológica. Cuando alguien anuncia que un modelo «razona», importa preguntar en qué tareas, con qué controles, comparado con qué alternativas y mediante qué criterio. Cuando afirma que un agente «es autónomo», importa saber qué decisiones puede tomar y cuáles requieren aprobación. Cuando anuncia que una herramienta «mejora el conocimiento», importa distinguir desempeño

asistido de aprendizaje posterior. La actitud crítica no es una barrera contra la innovación. Es la condición necesaria para aprovecharla sin confundir el entusiasmo con evidencia.

El mérito de Turing tampoco debería convertirse en una autoridad inmune a cuestionamientos. Su juego no agota la inteligencia. Sus predicciones no son estándares universales. Sus analogías educativas no sustituyen una psicología del aprendizaje. Precisamente por eso continúa siendo fértil: ofrece una forma de plantear problemas sin garantizar de antemano su solución. La historia de la IA avanzará cuando otros investigadores acepten esa invitación y propongan mecanismos que no imiten solamente los resultados, sino que construyan de maneras distintas las capacidades que observamos.

En el capítulo siguiente, la pregunta viajará desde la mesa abstracta de un matemático hacia las relaciones entre nervios, lógica y circuitos. Dos investigadores intentarán representar la actividad neuronal mediante operaciones formales. Será otro salto, más peligroso y más sugestivo de lo que su sencillez inicial permite sospechar: imaginar que una red de elementos capaces de activarse o permanecer inactivos puede producir funciones que reconocemos como pensamiento. Allí la promesa de la máquina universal encontrará una nueva compañera, la neurona artificial. Y deberemos volver a preguntar, con la exigencia que aprendimos de Turing, qué demuestra realmente que un modelo funcione.

Capítulo 3 · La neurona que se convirtió en una proposición

Una neurona no sabe que es una neurona. No conoce los tratados que la describen, no distingue las disciplinas académicas que disputan su significado y no necesita comprender una ecuación para participar en la actividad de un organismo. Sin embargo, durante la primera mitad del siglo XX, algunos científicos empezaron a formular una pregunta desconcertante: ¿sería posible describir una parte de lo que hace el sistema nervioso sin describir todos los procesos físicos que tienen lugar en su interior? ¿Podríamos construir un modelo tan austero que una célula excitada se pareciera, en el lenguaje de las matemáticas, a una afirmación verdadera?

La pregunta parece absurda si confundimos semejanza formal con identidad material. Una neurona es una célula viva; una proposición pertenece al lenguaje de la lógica. La primera tiene membrana, metabolismo, historia de desarrollo y relaciones electroquímicas. La segunda puede afirmarse o negarse. Pero el descubrimiento que nos interesa no consiste en declarar que ambas son lo mismo. Consiste en averiguar si, para responder ciertas preguntas, podemos dejar temporalmente fuera casi todo lo que sabemos de una de ellas y conservar unas pocas propiedades capaces de sostener un cálculo.

Hay una escena que no necesitamos inventar porque está impresa en las primeras páginas de un artículo de 1943. Warren McCulloch y Walter Pitts comienzan enumerando supuestos fisiológicos.[6] Hablan de axones, sinapsis, umbrales, impulsos y retrasos. Después dan un giro: presentan las relaciones entre actividades nerviosas mediante la lógica de proposiciones. Su artículo lleva un título difícil, deliberadamente ambicioso: *A Logical Calculus of the*

Ideas Immanent in Nervous Activity. Puede traducirse, aproximadamente, como *Un cálculo lógico de las ideas inmanentes en la actividad nerviosa*.

El año merece atención. Es 1943: antes de la publicación del ensayo de Alan Turing sobre máquinas e inteligencia, antes de que un encuentro en Dartmouth adoptara el nombre de inteligencia artificial, antes de las arquitecturas de aprendizaje profundo y de los grandes modelos de lenguaje. Volvemos atrás respecto de nuestro capítulo anterior, pero no para corregir la cronología, sino para seguir una segunda vía intelectual que iba a confluir con la computación. Turing había preguntado qué significa ejecutar un procedimiento y qué límites tiene. McCulloch y Pitts explorarían otra posibilidad: que una red idealizada de elementos nerviosos pudiera materializar relaciones lógicas.

No eran dos investigadores formados de la misma manera. Warren Sturgis McCulloch trabajaba en neuropsiquiatría y estaba profundamente interesado en filosofía, anatomía y matemáticas. Walter Pitts poseía una formación matemática singular y colaboraba en el entorno intelectual de Chicago. La historiadora Tara Abraham reconstruyó cómo esas trayectorias, diferentes en edad y procedencia académica, convergieron en problemas compartidos. Su trabajo de 2002 ofrece un correctivo a las historias que presentan el artículo como una inspiración repentina de dos genios aislados. La colaboración fue posible porque durante décadas ya se habían encontrado neurofisiología, lógica, filosofía del lenguaje y biología matemática.

La pregunta no era únicamente si el cerebro se parecía a una máquina. Era cuál de todas las formas posibles de describirlo podía producir conocimiento. La fisiología podía examinar una fibra nerviosa, medir un potencial y descubrir qué cambiaba al aplicar un estímulo. La lógica podía decir bajo qué condiciones una conclusión se sigue de ciertas premisas. McCulloch y Pitts decidieron

ver qué ocurría cuando ambas disciplinas se encontraban en una descripción formal. El resultado no era un pequeño cerebro en miniatura. Era algo más extraño: una teoría sobre qué relaciones de actividad podían realizarse mediante redes de unidades ideales.

Para comprender por qué esa operación resultó atractiva, debemos detenernos en una característica de la excitabilidad nerviosa que los científicos ya conocían: el carácter de todo o nada del potencial de acción. En su formulación clásica, una vez alcanzadas determinadas condiciones de disparo, el impulso propagado no aumenta simplemente de amplitud en proporción al estímulo. Esto no significa que todas las respuestas del sistema nervioso sean binarias, ni que la intensidad del estímulo carezca de efectos sobre la frecuencia, el reclutamiento o la dinámica de poblaciones neuronales. Significa que era posible identificar un aspecto del comportamiento de una célula y convertirlo en la base de una idealización.

Imaginemos dos entradas, A y B, que alcanzan una unidad ideal. En una versión sencilla, la unidad se activa solo si ambas entradas están activas. La relación puede describirse con una palabra de la lógica: «y». Si A vale uno y B vale uno, la salida vale uno; en los demás casos, vale cero. Cambiemos ahora el umbral de la unidad: puede bastar con que se active cualquiera de las entradas. Aparece entonces el «o». Añadamos una entrada inhibitoria que bloquea la respuesta incluso cuando llegan suficientes señales excitadoras: introducimos una forma de negación condicionada. Con redes compuestas por varias unidades, las combinaciones dejan de ser triviales.

Esta explicación es una reconstrucción pedagógica contemporánea, no una escena experimental del laboratorio de 1943. La fórmula mínima es suficiente para captar la intuición: describimos un estado de entrada, aplicamos reglas y observamos un estado

de salida. En el artículo, los autores presentan un tratamiento formal mucho más exigente, expresado en términos de tiempos discretos, relaciones entre neuronas y expresiones lógicas. No diseñaron una red para clasificar fotografías de gatos ni una herramienta para conversar con una persona. Intentaban demostrar una relación general entre una clase de redes y una clase de proposiciones.

Pensemos un momento en lo que cambia cuando una célula ideal puede expresarse como una proposición. Hasta entonces, para averiguar qué hace un sistema nervioso, parecía necesario seguir sus componentes físicos. La nueva propuesta permitía preguntar también qué relaciones eran realizables por una determinada estructura, incluso antes de construirla o encontrarla en un organismo. Un diseño podía examinarse desde dos direcciones: dada una red, calcular qué condiciones producen su actividad; dada una relación lógica, preguntarse qué red podría realizarla. Esa doble dirección —análisis y síntesis— es una de las aportaciones más fértiles de la formalización.

La imaginación científica suele avanzar cuando consigue desplazar un problema de una disciplina a otra sin destruir lo importante durante la traducción. Un mapa no contiene la textura del suelo, la humedad del aire ni la historia de cada árbol, pero puede preservar con notable precisión ciertas relaciones espaciales. Con el nivel de detalle adecuado, permite analizar conectividad o distancia; con otro nivel, esas mismas preguntas pueden exigir una representación distinta. El modelo neuronal de 1943 ofrece un desafío análogo. Si conservamos ciertas relaciones entre entradas y salidas, podemos estudiar algunas propiedades de redes. Si pretendemos estudiar aprendizaje, metabolismo, desarrollo cerebral o experiencia consciente, corremos el riesgo de atribuir al mapa atributos del territorio que nunca fueron representados.

Es importante no convertir esta analogía geográfica en una garantía. Un modelo puede ser internamente impecable y describir mal el fenómeno al que pretende aplicarse. Su coherencia formal es una virtud necesaria para ciertas tareas, pero no reemplaza la validación empírica. Esto vale para una red neuronal binaria y para un modelo actual que produce estimaciones, resúmenes o decisiones: debemos saber qué se ha preservado en la representación y qué se ha dejado fuera.

McCulloch y Pitts pusieron sus cartas sobre la mesa mediante cinco supuestos que todavía hoy resultan reveladores. En su cálculo, la actividad de una neurona es un proceso de todo o nada; existe una cantidad fija de excitaciones suficiente para activar una unidad; y el retraso relevante se simplifica como retraso sináptico. Además, una sinapsis inhibitoria activa impide el disparo en ese momento y la estructura de la red no cambia con el tiempo. Los supuestos no son detalles aburridos escondidos en una nota técnica. Son las condiciones que permiten que el cálculo exista en la forma propuesta.

La cuarta condición es especialmente contundente. La inhibición funciona como un veto absoluto. En una neurona biológica real, la inhibición depende de conductancias, potenciales, localización y tiempo, entre otros factores. Pero en la red ideal de los autores, la posibilidad de impedir la salida permite construir operaciones lógicas con gran limpieza. El precio de esa limpieza es la pérdida deliberada de complejidad fisiológica. La quinta condición tiene consecuencias todavía mayores: si la red no cambia, su modelo básico no describe directamente cómo una persona aprende al modificar las conexiones sinápticas. Es un modelo de funcionamiento de redes bajo supuestos fijos, no una teoría completa de aprendizaje neuronal.

Esa distinción importa porque tendemos a leer el pasado desde las palabras del presente. Vemos «red neuronal» en el título de una historia y suponemos que se trata de un antecedente directo de todo lo que hoy llamamos aprendizaje profundo. Existe un parentesco intelectual, pero las genealogías técnicas no son identidades. Los grandes modelos generativos modernos emplean parámetros numéricos entrenables, operaciones algebraicas de alta dimensión, procedimientos de optimización y una arquitectura que no se reduce al cálculo booleano de 1943. Llamar red neuronal a ambos modelos no convierte a uno en versión ampliada y literal del otro.

La sorpresa está en que los propios autores fueron explícitos sobre el límite de su formalismo. En un pasaje decisivo, distinguieron la equivalencia formal de la explicación factual. Podían sustituir ciertos cambios de comportamiento por redes ideales equivalentes a efectos del cálculo sin afirmar que ese reemplazo describiera el mecanismo físico de aprendizaje o facilitación. Sabían que la fisiología implicaba procesos eléctricos y químicos continuos. Su argumento era que, para ciertas propiedades formales, esas diferencias no destruían las conclusiones que querían demostrar. Esa cautela, a menudo eclipsada por relatos más grandilocuentes, merece ser recuperada.

Si trasladamos esa idea al presente, aparece una exigencia profesional. Una empresa puede construir un sistema de IA cuyo comportamiento se ajuste a una especificación; eso no implica que conozca exhaustivamente sus mecanismos internos, que pueda garantizar igual desempeño en otros contextos o que haya demostrado la validez causal de las decisiones producidas. Un modelo puede reproducir una relación observada sin identificar el mecanismo que la genera. Puede emular una función sin poseer las propiedades del sistema al que emula. Y puede ayudar a tomar decisiones sin que esas decisiones sean siempre justificables. Las

analogías no son equivalencias: hablamos ahora de sistemas muy distintos, unidos por una cuestión epistemológica sobre representaciones y límites.

Volvamos al cálculo. Una red sin ciclos puede examinarse avanzando por etapas desde sus entradas hasta sus salidas. Pero ¿qué ocurre cuando la actividad vuelve a alimentar una parte de la red? En una estructura recurrente, el estado presente puede depender de estados anteriores. El tiempo deja de ser un simple orden externo y empieza a formar parte de la descripción. Los autores dedicaron una sección central a esas redes con círculos y a su relación con funciones recursivas. Aquí nace una intuición que cambiará muchas teorías posteriores: un sistema compuesto por elementos simples puede exhibir propiedades temporales que no pertenecen a ningún elemento considerado de manera aislada.

Conviene evitar otro atajo. Que una red tenga ciclos no significa automáticamente que aprenda. Una configuración recurrente puede mantener o transformar estados sin cambiar sus conexiones. Para hablar de aprendizaje debemos especificar qué variable se modifica, mediante qué mecanismo y en respuesta a qué experiencia. La memoria de un estado y la modificación duradera de un sistema son cosas diferentes, aunque en ciertos modelos y organismos puedan relacionarse. La misma disciplina conceptual que necesitábamos para no confundir comportamiento e inteligencia nos sirve ahora para no confundir persistencia, memoria, plasticidad y aprendizaje.

Podemos pensar en una señal que recorre un circuito y vuelve a encontrar una de sus unidades iniciales. Si nada la interrumpe, la actividad puede continuar durante un tiempo bajo ciertas reglas. No hace falta atribuir pensamientos a las unidades: basta con describir las transiciones. Pero la organización del conjunto permite hablar de secuencias, dependencia temporal y estados que contienen información sobre entradas pasadas. Este desplazamiento

desde el componente hasta la organización es crucial en muchas ciencias. Un organismo no se reduce a una célula; un ecosistema no puede reconstruirse únicamente enumerando especies; una red no se entiende solo catalogando sus nodos. En cada nivel aparecen preguntas que el nivel anterior no resuelve por sí solo.

La palabra «emergencia» puede resultar tentadora, pero conviene utilizarla con cuidado. No necesitamos invocar una fuerza misteriosa para explicar que un conjunto posea propiedades relacionales. Una red puede implementar una operación que ninguna unidad aislada implementa. Esto es un hecho matemático sobre el sistema definido. Sostener que por la misma razón una red adquiere conciencia, intención o comprensión sería otra afirmación, mucho más fuerte, que el cálculo de 1943 no demuestra. Entre una propiedad global y una experiencia subjetiva media un problema científico y filosófico que sigue abierto.

La matemática, entonces, no resuelve automáticamente la biología: permite formularla con otra clase de precisión. En lugar de decir vagamente que el cerebro «asocia ideas», podemos preguntar qué estructura concreta haría posible cierta transformación. En lugar de suponer que algo se ha explicado porque se ha dibujado una red con flechas, podemos exigir una correspondencia entre variables, mecanismos observables y predicciones. La formalización convierte una intuición difusa en una afirmación discutible. Esa es su potencia y también su disciplina: obliga a mostrar exactamente de qué estamos hablando.

No todos aceptaron que una neurona deba representarse principalmente como un dispositivo digital. La historia de la fisiología es, en parte, una historia de resistencias a las simplificaciones útiles. El programa de investigación del Instituto Max Planck para la Historia de la Ciencia documenta debates posteriores entre defensores de la modelización binaria y fisiólogos que subrayaban la complejidad temporal y material del tejido nervioso. Algunas

críticas procedían de personas que estudiaban precisamente la actividad que los modelos querían abstraer. No era una oposición entre ciencia moderna y tradición anticuada, sino entre preguntas científicas diferentes y criterios de adecuación distintos.

Un resultado posterior ilustra esa diferencia sin invalidar retrospectivamente el trabajo de 1943. En 1952, Alan Hodgkin y Andrew Huxley publicaron una descripción cuantitativa de corrientes de membrana y conducción del impulso nervioso. Su modelo, anclado en investigación fisiológica sobre el axón gigante de calamar, incorporaba variables continuas y conductancias dependientes del voltaje y del tiempo. Estudiaban mecanismos electrofisiológicos que no eran el objeto del cálculo lógico de McCulloch y Pitts. Ambos enfoques podían ser fructíferos porque buscaban explicar fenómenos situados a niveles y con preguntas diferentes. Una teoría no se vuelve inútil porque otra incluya más detalles; se vuelve inadecuada cuando le pedimos respuestas que sus supuestos no permiten ofrecer.

La comparación resulta especialmente fértil para quien viene de la biología. Pensemos en el modo en que una descripción taxonómica, un modelo de dinámica poblacional y un análisis genómico pueden referirse al mismo conjunto de organismos sin ser intercambiables. Cada uno recorta variables, escalas y relaciones. En ocasiones, sus conclusiones se refuerzan; en otras, parecen incompatibles hasta que comprendemos que no describen exactamente la misma propiedad. La pregunta experta no es «¿cuál modelo se parece más a la realidad?» en abstracto. Es «¿qué problema pretendemos resolver, con qué evidencias y bajo qué tolerancia al error?».

Esa pregunta permite mirar el trabajo de 1943 sin otorgarle poderes que nunca tuvo. McCulloch y Pitts no demostraron que los pensamientos humanos fueran simplemente proposiciones, ni que las neuronas biológicas operaran siempre como compuertas

digitales. Mostraron, bajo condiciones explícitas, una relación entre redes ideales y cálculos lógicos. Eso fue importante para pensar la computación y el sistema nervioso, y también para imaginar una ciencia en la que las estructuras podían diseñarse para realizar comportamientos formales determinados.

Detengámonos en una consecuencia que hoy parece natural pero no lo era. Si existe una descripción matemática de una operación y sabemos construir una red que la realice, podemos separar la pregunta sobre qué operación queremos de la pregunta sobre el material que la implementará. La misma relación lógica puede expresarse con circuitos, dispositivos electrónicos o unidades neuronales ideales. Este principio de realizabilidad funcional no resuelve toda la filosofía de la mente; hace posible investigar ciertas operaciones con independencia parcial de su soporte material. La palabra «parcial» es decisiva: para cuestiones de velocidad, energía, robustez, desarrollo o experiencia, el soporte vuelve a importar.

A partir de aquí, la historia comienza a poblarse de encuentros. McCulloch y Pitts serían figuras importantes en el ambiente interdisciplinario del que surgió la cibernética. Norbert Wiener publicaría *Cybernetics* en 1948, proponiendo conexiones entre control y comunicación en animales y máquinas. Claude Shannon publicaría ese mismo año su teoría matemática de la comunicación. Sería un error presentar estos aportes como si fueran partes de un único plan, o reducirlos todos a la idea de «el cerebro es un ordenador». Pero sí compartían una ambición histórica: encontrar lenguajes matemáticos capaces de atravesar fronteras disciplinares y hacer tratables problemas antes separados.

La palabra «información», por ejemplo, no significa lo mismo en todos esos contextos. En una teoría matemática de la comunicación, ciertas medidas describen incertidumbre y restricciones de señales. En una explicación biológica, podemos interesarnos por

regulación, función adaptativa, historia evolutiva o significado de estímulos para un organismo. En una conversación cotidiana, información suele equivaler a contenido que alguien comprende. Un mismo término puede circular por disciplinas diferentes y producir una ilusión de identidad. La formación experta en IA requiere desconfiar de estas traducciones automáticas: inteligencia, atención, memoria, aprendizaje y razonamiento también son palabras que cambian de sentido según el modelo y el experimento.

En la actualidad, un ingeniero puede hablar de «neuronas» artificiales y un neurocientífico estudiar neuronas del hipocampo. Ambos trabajan legítimamente con redes, pero los objetos no son intercambiables. Una unidad artificial contemporánea suele calcular una función sobre entradas numéricas y parámetros; una neurona biológica integra procesos de membrana, contactos sinápticos, actividad intracelular y una historia de plasticidad. Incluso dentro de cada campo hay distintas clases de modelos. La metáfora compartida resulta fértil cuando sugiere buenas preguntas. Se vuelve peligrosa cuando permite saltar de una coincidencia lingüística a una conclusión sobre mecanismos.

Lo mismo sucede cuando un modelo generativo produce una respuesta inesperada. Podemos decir que el sistema «reconoció» una relación, «recordó» una información o «prestó atención» a una parte de la entrada. En ciertas explicaciones técnicas estas expresiones tienen significados operativos bien definidos. Pero la interpretación humana tiende a introducir propiedades que el procedimiento no ha demostrado: intención, comprensión consciente, compromiso con la verdad. Ni la belleza de una respuesta ni su corrección ocasional bastan para inferir todas esas propiedades. La lección de McCulloch y Pitts es menos publicitaria y más poderosa: toda descripción necesita declarar las condiciones bajo las cuales resulta válida.

Imaginemos ahora que deseamos construir un sistema capaz de revisar miles de publicaciones científicas y detectar patrones en sus resultados. Podemos representar artículos como vectores, establecer relaciones entre conceptos y entrenar modelos para reconocer similitudes. Esa arquitectura puede resultar útil para explorar hipótesis y recuperar información. Pero ¿qué representa exactamente la similitud entre dos artículos? ¿Proximidad semántica, coincidencia temática, relación causal, calidad metodológica? Son posibilidades diferentes. Un algoritmo puede distinguir algunos patrones sin comprender la diferencia que importa a nuestra investigación. No basta con admirar el mapa de relaciones generado: tenemos que saber qué variable se calculó, qué datos alimentaron la representación y qué validación conecta su resultado con el problema científico.

Esa es una forma contemporánea de una tensión nacida mucho antes de la IA generativa. El modelo simplifica para hacer posible el análisis. Si no simplifica, se vuelve inmanejable; si simplifica de forma inadecuada, deja de responder la pregunta relevante. La destreza consiste en elegir una pérdida de detalle consciente y proporcional al propósito. Por eso una persona experta no reconoce la calidad de un sistema por la cantidad de agentes, capas, parámetros o herramientas que contiene. Pregunta qué necesita conservar la representación y qué evidencia demuestra que esas elecciones funcionan.

La expresión «inteligencia artificial» todavía no existía como denominación institucional cuando McCulloch y Pitts publicaron su artículo. Eso también importa. La historia suele reorganizar el pasado alrededor del nombre de la disciplina que terminó imponiéndose. Así, cada investigación anterior se transforma en «un paso hacia la IA», aunque sus protagonistas perseguían preguntas de fisiología, filosofía, lógica o control. Es una manera cómoda de contar el progreso, pero empobrece el conocimiento. La historia real fue una convergencia contingente de problemas, instrumen-

tos, instituciones y estilos de investigación. Las opciones que entonces permanecían abiertas resultan menos visibles cuando conocemos el desenlace.

Mirar el artículo de 1943 como si hubiera estado destinado a desembocar en los modelos actuales distorsionaría también nuestro juicio técnico. Nadie podía deducir de unas compuertas lógicas binarias el tipo exacto de entrenamiento, escala y capacidades que se desarrollarían décadas después. Lo que sí podemos reconocer es una herencia intelectual: la posibilidad de representar operaciones mediante redes, analizar formalmente su comportamiento y preguntarnos qué puede construirse a partir de componentes simples. No hace falta fingir una continuidad perfecta para identificar una influencia histórica importante.

La historia de Walter Pitts, a menudo contada mediante episodios dramáticos y anécdotas personales difíciles de cotejar, merece además una precaución especial. La tentación del periodismo narrativo consiste en rellenar los silencios del archivo con escenas psicológicas verosímiles. No vamos a hacerlo. Que una biografía resulte fascinante no nos autoriza a conocer pensamientos privados, conversaciones no documentadas ni motivaciones íntimas. Para este capítulo, lo verificable es suficiente: una colaboración que cruzó fronteras disciplinarias, un texto publicado, un conjunto de supuestos y una transformación en las preguntas que se podían formular.

Podemos regresar, finalmente, a la primera frase de este capítulo. Una neurona no sabe que es una neurona. Sin embargo, nosotros podemos describir parte de su actividad como una proposición, siempre que entendamos la distancia entre esa descripción y la célula. No hemos convertido la vida en lógica. Hemos aprendido que algunas de sus relaciones pueden investigarse mediante una lógica. La diferencia es pequeña en palabras y gigantesca en consecuencias.

Después de Lovelace, sabemos que una máquina programable puede operar sobre representaciones y que una instrucción no equivale a una idea original. Después de Turing, sabemos que la computación posee límites formales y que una prueba de comportamiento no resuelve por sí misma todas las preguntas sobre inteligencia. Después de McCulloch y Pitts, podemos formular una tercera conclusión: una red puede realizar operaciones intelectualmente significativas sin que su descripción matemática agote la realidad del sistema que la inspiró.

Todavía faltaba algo para que estas intuiciones se convirtieran en el programa explícito de una nueva disciplina. Hacían falta nombres, instituciones, financiamiento, promesas y una comunidad de investigadores que se reconocieran participantes de una empresa común. En un documento redactado en 1955, cuatro científicos propondrían reunirse durante el verano siguiente para estudiar si diversos aspectos de la inteligencia podían describirse con precisión suficiente como para ser simulados por una máquina. Volveremos a esa propuesta, la misma con la que comenzó este libro. Pero ahora habremos aprendido a leerla de otra manera. Ya no nos impresionará solamente la audacia de su ambición. Podremos preguntar qué entendían sus autores por describir, por simular y por inteligencia; qué partes de la realidad estaban preparados para conservar en sus modelos; y cuáles, inevitablemente, quedarían fuera.

La pregunta que abrió una nueva disciplina no fue «¿podemos construir un cerebro?». Fue más incómoda y más fértil: **¿cuánto de aquello que llamamos inteligencia puede convertirse en una representación que una máquina sea capaz de ejecutar, y qué dejamos de comprender cuando confundimos esa representación con el fenómeno completo?**

Parte II · La promesa toma institución

Capítulo 4 · El verano que no fue una epifanía

Una fotografía puede ser una forma extraordinariamente eficaz de contar una historia falsa sin contener nada falso. Basta con mostrar a varias personas reunidas en un mismo lugar y permitir que los años hagan el resto. Poco importa que se hayan encontrado solo durante una parte del proyecto, que discreparan sobre sus objetivos o que siguieran trabajando por separado. La imagen vuelve simultáneo lo que fue sucesivo. Vuelve unánime lo que estuvo en discusión. Convierte un verano en un instante.

La fotografía asociada al encuentro de Dartmouth de 1956 ha cumplido ese papel. En algunas versiones de la historia de la inteligencia artificial aparece como la prueba visual de un origen: ahí estuvieron los hombres que decidieron construir máquinas inteligentes. Pero ninguna fotografía puede demostrar, por sí sola, quién asistió durante ocho semanas, qué decisiones se tomaron, qué experimentos se completaron ni cuánto compartían quienes aparecen en ella. La imagen conserva una presencia; la historia exige reconstruir relaciones. Para acercarnos a lo que ocurrió, conviene buscar objetos menos impresionantes: una solicitud de financiación, una invitación con fechas, cuadernos de trabajo, informes y correspondencia posterior.

La diferencia entre la foto y esos papeles no es una simple precaución de historiadores. Es uno de los problemas que acompañará a la inteligencia artificial durante toda su existencia. Una demostración puede resultar contundente y seguir siendo insuficiente para sostener la conclusión que pretendemos extraer de ella. Un sistema puede resolver una tarea y no comprender lo que le atribuimos. Una organización puede mostrar un prototipo y no haber construido todavía un producto. En Dartmouth, antes incluso de

que existiera el campo con las instituciones que hoy conocemos, ya estaba presente la tentación de condensar proyectos distintos en una sola palabra.

En el prólogo vimos esa palabra impresa en un documento de agosto de 1955: inteligencia artificial. Volvemos ahora al documento con otra pregunta. No nos interesa solamente qué prometieron sus autores. Queremos saber qué sucede cuando una promesa científica intenta convertirse en trabajo compartido. Es una transición menos espectacular que el nacimiento de una idea, pero mucho más reveladora. Porque la ciencia no ocurre en los títulos de las propuestas. Ocurre cuando las hipótesis se encuentran con el tiempo disponible, las capacidades de las máquinas, las diferencias entre investigadores y la resistencia de los problemas.

Los cuatro firmantes de la propuesta eran John McCarthy, Marvin Minsky, Nathaniel Rochester y Claude Shannon.[7] Sus trayectorias ya sugerían un desacuerdo productivo. Shannon había mostrado cómo hablar matemáticamente de la información sin que fuera necesario resolver el significado de cada mensaje. Rochester conocía desde dentro las limitaciones de los grandes computadores de IBM. Minsky procedía del estudio de redes nerviosas y del problema de cómo podrían aprender. McCarthy buscaba una formulación matemática de los procesos intelectuales y se interesaba por los lenguajes con los que las máquinas podrían operar sobre conceptos. Compartían una ambición general, pero no necesariamente el mismo camino hacia ella.

Lo que firmaron fue una conjetura, y conviene devolverle a esa palabra todo su peso. Una conjetura científica no es un resultado; es una apuesta formulada con suficiente precisión como para orientar una investigación. La conjetura de Dartmouth sostenía, en términos generales, que los rasgos del aprendizaje y de la inteligencia podían describirse tan exactamente que una máquina llegaría a simularlos. La proposición parecía dar un punto de parti-

da común. Pero ocultaba problemas enormes. ¿Qué rasgos? ¿En qué nivel de descripción? ¿Qué significaría simularlos? ¿Cómo distinguir la reproducción de un comportamiento de la explicación del mecanismo que lo produce? Cada respuesta posible organizaba un programa de investigación diferente.

El propio texto lo revelaba en su índice. Había preguntas sobre el lenguaje y la formación de conceptos; redes de neuronas hipotéticas; complejidad de los cálculos; abstracciones; mejora de las máquinas por sí mismas; azar y creatividad. Hoy podemos leer esa lista como una anticipación asombrosa de debates posteriores. Sería, sin embargo, un error convertir la semejanza de vocabulario en continuidad técnica directa. Que dos generaciones se pregunten por la creatividad no significa que investiguen la misma propiedad del mismo modo. Que hablen de redes neuronales no significa que utilicen los mismos modelos. El interés del documento está precisamente en su amplitud: no se había decidido todavía qué clase de ciencia tendría que ser la inteligencia artificial.

La propuesta también contenía una afirmación que no conviene pasar por alto. Sus autores sospechaban que el obstáculo principal no era simplemente la escasez de velocidad o memoria de los computadores disponibles, sino la incapacidad de escribir programas que aprovecharan plenamente lo que ya tenían. La hipótesis puede discutirse retrospectivamente. Hoy sabemos que los recursos de cómputo han sido decisivos para muchos avances posteriores. Pero aquella frase introduce una distinción fundamental: la potencia disponible y el método capaz de aprovecharla no son la misma cosa. Una máquina más rápida puede repetir más veces una estrategia equivocada. Un método mejor puede conseguir que una capacidad limitada alcance resultados que parecían inaccesibles.

La diferencia aparece una y otra vez en el trabajo contemporáneo con sistemas generativos. Es tentador atribuir cualquier fracaso a la necesidad de un modelo mayor, más contexto o más herramientas. A veces hace falta mayor capacidad; otras veces el problema reside en la definición de la tarea, en las fuentes, en la arquitectura del flujo de trabajo o en la ausencia de una prueba que permita reconocer el resultado correcto. Esa comparación es nuestra, no una lección que los participantes de Dartmouth formularan acerca de tecnologías que no existían. Pero nace de una preocupación que sí quedó documentada: cómo relacionar las capacidades de una máquina con los procedimientos mediante los cuales intentamos utilizarla.

Había además una cuestión menos abstracta: los investigadores necesitaban que alguien pagara el verano. La documentación original no se limita a enumerar problemas científicos. Incluye una solicitud de apoyo a la Fundación Rockefeller, con salarios, viajes, alojamiento, gastos de organización y secretaría. Una versión ampliada de la propuesta cifra el presupuesto estimado en trece mil quinientos dólares de la época. Es una cifra histórica nominal; trasladarla a valores actuales sin aclarar el método de conversión produciría una precisión engañosa. Lo importante no es el equivalente moderno, sino lo que la cifra permite ver: la aspiración de describir la inteligencia dependía de decisiones administrativas concretas.

Para convertir una hipótesis en un programa colectivo había que reunir personas que trabajaban en universidades y empresas, permitirles desplazarse, darles un lugar y un tiempo, reproducir documentos y coordinar conversaciones. La inteligencia artificial no nació fuera de las instituciones. Tampoco apareció únicamente gracias a ellas. Surgió en la intersección entre ideas previas, posibilidades técnicas, recursos y relaciones profesionales. Al estudiar ese cruce descubrimos una paradoja familiar en la investigación

científica: la libertad para explorar preguntas abiertas suele requerir una organización suficientemente precisa como para hacer posible la exploración.

Una carta conservada en el archivo de Ray Solomonoff permite reconstruir las condiciones concretas de la convocatoria. En marzo de 1956, John McCarthy le escribió desde Dartmouth College para invitarlo al proyecto, ofrecerle financiación y fijar las fechas previstas entre el 18 de junio y el 17 de agosto. La reproducción facsimilar de esa carta sobrevive dentro del dossier histórico de Grace Solomonoff. El documento confirma un plan, no la presencia simultánea y continua de todos los participantes durante ese período. Esa distancia entre invitación y asistencia efectiva forma parte de la historia del encuentro.

Ahora aparece el problema: esas fechas formaban parte del plan, no de una realidad idéntica para todos. Una reconstrucción posterior de Grace Solomonoff, basada en notas, cartas y testimonios conservados, permite distinguir las personas inicialmente previstas de quienes efectivamente asistieron y de los períodos de presencia. Una lista comunicada en mayo contemplaba once participantes con duraciones desiguales. Algunos no llegaron a asistir. Otros acudieron durante menos tiempo del imaginado. Trenchard More sustituyó parcialmente a Rochester. Lo que la memoria pública tiende a describir como una reunión compacta fue, según la documentación disponible, un encuentro de geometría variable.

Ese matiz no destruye el acontecimiento. Lo vuelve más interesante. La idea de que diez científicos permanecieron sentados durante ocho semanas resolviendo juntos una única pregunta conduce a una decepción inevitable: no dejaron una teoría general de la inteligencia ni un artefacto que la demostrara. Pero si comprendemos Dartmouth como una red temporal de conversaciones, discusiones, presentaciones, proyectos individuales y circulación de ideas, la pregunta cambia. Ya no esperamos encontrar el instante

exacto de un descubrimiento. Buscamos saber qué tipo de comunidad intelectual comenzó a formarse allí y qué trayectorias posteriores se volvieron posibles.

La reconstrucción del calendario requiere la misma cautela. Grace Solomonoff señala que las notas conservadas de Ray comienzan en junio y que el propio Solomonoff dio una presentación final el 17 de agosto. También menciona registros y recuerdos que sitúan el encuentro a lo largo de unas ocho semanas, frente a otras descripciones más breves. El dato históricamente responsable no es una duración pronunciada con falsa exactitud, sino la existencia de fuentes que permiten defender un período aproximado y reconocer los límites de nuestra reconstrucción. Una historia que merece ser leída no necesita fingir que todo quedó perfectamente registrado.

Tampoco podemos tratar una lista de nombres como un retrato transparente de la autoría. En los archivos aparecen McCarthy, Minsky, Shannon, Solomonoff, Selfridge, More, Bigelow, Newell y Simon, entre otros. Pero la relevancia de una persona no se mide por la cantidad de fotografías que la muestran ni por el tiempo exacto que permaneció en Hanover. Algunas contribuciones científicas se habían iniciado antes. Otras maduraron después. Hubo participantes que llevaron ideas en desarrollo y asistentes que ayudaron a modificarlas sin que eso pudiera traducirse en una obra colectiva firmada al final del verano. La historia de la investigación suele ser menos parecida a una lista de vencedores que a una conversación extendida durante años.

Es especialmente revelador observar las diferencias entre quienes querían representar el conocimiento mediante símbolos y quienes intentaban comprender cómo una máquina podía adquirir regularidades a partir de la experiencia. Nuestro capítulo anterior terminó con una neurona convertida en proposición lógica. En Dartmouth esas dos formas de aproximarse a la inteligencia seguían

presentes, pero comenzaban a adquirir relaciones distintas. Una red idealizada podía describir ciertas operaciones; un sistema de reglas podía encadenar deducciones; un procedimiento de búsqueda podía seleccionar caminos entre muchas posibilidades. El problema no era elegir una herramienta favorita. Era decidir qué capacidad merecía llamarse inteligente y qué explicación justificaba esa atribución.

Para percibir el conflicto basta imaginar dos preguntas científicas que parecen parecidas, pero que conducen a métodos opuestos. La primera pregunta es: «Dadas estas premisas y estas reglas, ¿qué conclusión se sigue correctamente?». La segunda es: «Después de observar estos casos, ¿qué debemos esperar del siguiente?». La primera pertenece al corazón de la deducción. La segunda nos coloca ante la inducción. Una demostración lógica puede evaluarse comprobando si cada paso cumple las reglas. Una predicción basada en observaciones exige considerar la incertidumbre, las regularidades del mundo y la posibilidad de que lo que sucedió antes no vuelva a ocurrir.

El problema es que la vida intelectual requiere ambas. Una máquina que solo deduce puede ser impecable dentro de un conjunto de premisas y estar completamente equivocada respecto de los hechos. Una máquina que solo generaliza a partir de ejemplos puede descubrir regularidades útiles y no tener manera de justificar una conclusión como consecuencia necesaria de reglas explícitas. La división nunca fue absoluta, pero permite comprender por qué el nacimiento de la IA no fue el triunfo de una teoría única. En aquel espacio coincidieron investigadores que imaginaban diferentes relaciones entre símbolos, datos, experiencias y comportamientos.

Ray Solomonoff es una figura especialmente útil para escuchar esta tensión. Sus papeles y trabajos de 1956 muestran un interés persistente en la inferencia inductiva: cómo construir un sistema

capaz de extraer regularidades de secuencias y utilizarlas para anticipar lo que vendrá. Su propuesta no era idéntica a los modelos probabilísticos actuales, y tampoco debe presentarse como si en aquel verano hubiera completado una teoría acabada de probabilidad algorítmica. Pero su trayectoria ayuda a recuperar un problema que a veces se pierde cuando la historia de la inteligencia artificial se escribe únicamente desde sus éxitos simbólicos: aprender no es solo aplicar reglas. También es enfrentarse con la posibilidad de estar equivocado después de haber observado muchas veces lo mismo.

El archivo conservado permite acercarse a esa búsqueda mediante materiales de extraordinario valor: apuntes de actividades, informes sobre inducción y versiones del trabajo titulado «An Inductive Inference Machine». Que existan esos documentos no significa que todo el proceso se encuentre plenamente reconstruido. Hay notas manuscritas difíciles de interpretar, testimonios posteriores y diferencias entre las versiones de un mismo trabajo. Precisamente por eso nos interesa su procedencia. Una idea de 1956 conservada en un texto corregido meses después no proporciona exactamente la misma evidencia que una nota tomada durante una reunión. Las dos pueden ser importantes, pero responden preguntas distintas.

En sus apuntes aparece una discusión que anticipa un problema de gran actualidad: ¿conviene estudiar muchas tareas diferentes para encontrar lo que comparten, o concentrarse intensamente en un problema bien delimitado hasta resolverlo? La pregunta atraviesa la investigación en inteligencia artificial desde entonces. Un programa especializado puede producir resultados impresionantes dentro de su dominio y fallar cuando cambian las condiciones. Un programa general puede prometer flexibilidad y resultar incapaz de alcanzar la precisión de los especialistas. Ni la amplitud ni

la profundidad son virtudes absolutas. Dependen del problema, de los recursos y de la forma en que pensamos evaluar los resultados.

La distinción importa especialmente cuando hablamos de inteligencia general. Resolver muchas tareas diferentes no demuestra, por sí solo, que exista un mecanismo universal capaz de comprenderlas de la misma manera. Resolver una tarea difícil tampoco demuestra que la capacidad se transfiera a otras. Para hacer afirmaciones sobre generalidad necesitamos examinar qué cambia entre problemas, cuáles son las condiciones de entrenamiento, qué información se mantiene constante y cómo se mide la transferencia. Esta exigencia pertenece al vocabulario metodológico actual, pero la inquietud más profunda —qué permanece de una estrategia cuando cambia el problema— ya estaba circulando entre investigadores tempranos de la IA.

El ajedrez ofrece un ejemplo. Sus reglas son precisas, las posiciones pueden describirse formalmente y el resultado de una partida es observable. Esa nitidez lo volvía atractivo como laboratorio de inteligencia. Pero no todos estaban convencidos de que aprender a jugar bien explicara cómo una máquina podría comprender el mundo. Las notas sobre una discusión de agosto de 1956 muestran diferencias respecto de la importancia de los juegos para el proyecto general. El desacuerdo merece atención: una tarea puede ser excelente para investigar búsqueda y planificación, y a la vez resultar insuficiente como modelo de todas las capacidades que denominamos inteligencia.

Hay algo profundamente pedagógico en esa discusión. Si queremos evaluar un sistema generativo actual, debemos resistir la misma tentación. Un benchmark puede funcionar como el ajedrez: delimita un problema, fija reglas y permite comparar resultados. Su utilidad es extraordinaria, siempre que recordemos la frontera que lo sostiene. Una calificación elevada en un conjunto

de pruebas no certifica automáticamente capacidad para actuar con criterio en situaciones nuevas, respetar restricciones o reconocer una fuente falsa. El instrumento puede medir algo importante sin medirlo todo. En ese punto, la historia del campo se convierte en una lección de diseño de evaluaciones, pero la lección no necesita interrumpir la historia: surge de ella.

Otra dificultad era menos filosófica y más material. Los investigadores debían representar procedimientos suficientemente complejos para que un computador de su época pudiera ejecutarlos. Los lenguajes de programación disponibles estaban todavía en desarrollo. Las interfaces, el acceso a las máquinas y el costo de probar hipótesis condicionaban la elección de problemas. No se trataba simplemente de tener ideas audaces. Había que traducirlas a instrucciones, almacenarlas, ejecutarlas, comprobarlas y modificarlas. En esa traducción se perdían muchas formulaciones atractivas. La distancia entre describir una máquina imaginaria y hacerla funcionar ocupó una parte importante de los primeros años de la disciplina.

Rochester encarna bien ese encuentro entre idealización y limitaciones técnicas. Había participado en el diseño de computadores de IBM y había trabajado en simulaciones de redes nerviosas. No hablaba desde una mesa de filosofía aislada de la ingeniería. En la propuesta de 1955 se interesaba por el problema de la originalidad en las máquinas: cómo introducir una desviación útil respecto de los procedimientos disponibles sin convertir el proceso en una sucesión de actos arbitrarios. Su discusión distinguía el azar indiscriminado de un azar guiado por restricciones y expectativas. Esa diferencia no equivale a una teoría completa de creatividad; sí muestra que el problema de cómo producir novedades valiosas ya exigía separar variación, selección y contexto.

La distinción conduce a una intuición fértil. Producir resultados variados es sencillo si no nos preocupa su calidad. También es posible obtener resultados coherentes repitiendo siempre lo que ya sabemos hacer. La dificultad está en generar alternativas que no sean simples repeticiones, y al mismo tiempo conservar criterios para distinguir una posibilidad valiosa de una ocurrencia inútil. Esa tensión no quedó resuelta en Dartmouth. Continúa siendo una cuestión central en sistemas generativos, diseño asistido y exploración científica. Pero no debemos cometer el anacronismo de leer los mecanismos actuales dentro de las propuestas de entonces. Es legítimo reconocer una pregunta compartida; no sería legítimo suponer identidad entre las respuestas.

La célebre lista de temas del proyecto también mencionaba la mejora de las máquinas por ellas mismas. En un documento tan temprano, esa ambición puede provocar una sensación de anticipación casi profética. Sin embargo, conviene enfriar el entusiasmo suficiente para comprender qué estaba en discusión. La expresión no definía una arquitectura concreta, ni un procedimiento automático validado para revisar cualquier sistema, ni una capacidad demostrada de autoperfeccionamiento general. Designaba un terreno de investigación. Una promesa formulada con palabras familiares no es evidencia de que se hubiera alcanzado la tecnología que hoy asociamos con ellas.

Esa diferencia entre programa, demostración y resultado estable es una de las habilidades más necesarias para leer la historia de la IA sin quedar cautivos de su publicidad. Un programa propone metas. Un prototipo demuestra una posibilidad bajo condiciones determinadas. Un resultado reproducible muestra que esa posibilidad no depende solamente de un episodio favorable. Un sistema confiable exige todavía algo más: comprobar su desempeño en contextos relevantes, identificar sus límites y responder a los fallos previsibles. La historia de Dartmouth ocupa sobre todo el pri-

mer lugar de esa secuencia: ayudó a poner nombres, problemas y comunidades en relación. Su importancia no requiere que le atribuyamos las etapas siguientes.

De hecho, la propia reconstrucción de Grace Solomonoff sostiene que el encuentro no produjo una dirección colectiva clara. Los investigadores desarrollaron materiales y discusiones de diverso alcance, y algunos resultados se comunicaron más tarde. Una parte de la literatura posterior ha valorado particularmente el auge de métodos simbólicos; otras historias han destacado las continuidades con la cibernética, las redes neuronales y la inferencia inductiva. Esa diversidad historiográfica no debe tratarse como una molestia que hay que eliminar eligiendo un vencedor. Constituye evidencia de que el campo no nació con una arquitectura definitiva. Sus disputas fundacionales siguen apareciendo, reformuladas, cuando intentamos decidir qué significa representar, aprender o razonar.

La ausencia de una epifanía única no vuelve a Dartmouth un fracaso. Nos obliga a revisar qué consideramos un éxito científico. A veces una investigación culmina con un instrumento que funciona. Otras veces termina con una clasificación más precisa de preguntas, una colaboración que continuará en otro laboratorio o un lenguaje común para discutir problemas que antes pertenecían a comunidades separadas. Ninguno de esos resultados es equivalente a demostrar una hipótesis central. Pero todos pueden modificar la trayectoria de un campo. En Dartmouth, la palabra inteligencia artificial proporcionó un punto de encuentro para actividades que no se habían convertido en una ciencia unificada.

En los relatos institucionales, ese gesto aparece con frecuencia como el nacimiento de una disciplina. Es una descripción defendible si especificamos qué nació: un nombre, un programa reconocible y una comunidad de investigación en formación. No nació allí el interés por las máquinas inteligentes, que era mucho más anti-

guo. Tampoco se descubrió allí una teoría general de la mente. Ni se demostró que la inteligencia humana pudiera reproducirse de forma completa en una máquina. La precisión no destruye la fuerza de la historia; la dirige hacia su verdadero objeto. El acto fundacional fue, en gran medida, una decisión acerca de qué preguntas merecían organizar una investigación común.

Quizá esa sea la lección más difícil de extraer cuando miramos una disciplina desde el futuro. Nuestra tendencia natural consiste en ordenar a sus protagonistas según los logros que después asociamos con ellos. Sabemos qué ramas progresaron, cuáles cambiaron de nombre y qué métodos reaparecieron décadas más tarde. En consecuencia, corremos el riesgo de escribir el pasado como si cada decisión hubiera apuntado inevitablemente hacia nuestro presente. Pero para quienes trabajaban en 1956, el futuro estaba abierto. Esa incertidumbre no era una deficiencia de su época. Era la condición real de su investigación.

También está abierta la pregunta sobre quién queda fuera de nuestras narraciones. La propuesta fue firmada por cuatro hombres vinculados a universidades y laboratorios estadounidenses, y el grupo convocado respondió a redes profesionales concretas. Eso no agota la historia de la inteligencia artificial ni de sus antecedentes. La cibernética soviética, la estadística, las tradiciones de automatización, la lógica europea, la neurofisiología y muchos desarrollos técnicos se entrecruzaron de formas que ninguna foto de Dartmouth podría representar. Una historia centrada en ese verano puede iluminar un proceso importante, pero se convierte en distorsión si lo confunde con el origen exclusivo de todas las ideas relacionadas con la inteligencia artificial.

Hay una última razón para no terminar este capítulo con una celebración triunfal. Cuando observamos proyectos ambiciosos de IA en la actualidad, solemos encontrar los mismos componentes narrativos que hacían atractiva la propuesta de 1955: una gran hi-

pótesis, un grupo de especialistas, un nombre memorable, una promesa de transformación y recursos para explorarla. Es razonable entusiasmarse con todo eso. También es necesario conservar una pregunta más exigente: ¿qué parte de la promesa ha pasado de la formulación a la prueba? Comprender la diferencia no nos vuelve enemigos de la innovación. Nos vuelve capaces de acompañarla sin renunciar al juicio.

Dartmouth no fue el momento en que una máquina comenzó a pensar. Fue uno de los momentos en que investigadores con proyectos distintos decidieron examinar, bajo un nombre común, si la inteligencia podía convertirse en un problema de ingeniería y ciencia. El verano no les entregó una respuesta final. Les dio un territorio en disputa, una agenda compartida de manera imperfecta y un conjunto de relaciones cuyo efecto solo se volvería visible con los años.

Entre los visitantes de aquel verano había investigadores que trabajaban en un programa capaz de manipular símbolos para encontrar demostraciones. La posibilidad era seductora por una razón muy específica: si el resultado de una máquina era una prueba matemática, no bastaba con que sonara convincente. Sus pasos podían verificarse. Frente a una máquina que simplemente afirmara conocer la solución, empezaba a aparecer otra capaz de producir una secuencia que alguien más pudiera examinar. Esa diferencia abriría un nuevo capítulo en la historia de la inteligencia: el paso de las ambiciones generales a los problemas donde la corrección podía ponerse a prueba.

Capítulo 5 · El teorema que una máquina encontró

Una demostración matemática no necesita resultar hermosa para ser correcta. Puede ser larga, incómoda y poco elegante. Puede ocupar varias páginas en las que el lector apenas reconozca, entre símbolos y referencias, la intuición que la hizo posible. Pero posee una propiedad que muchas respuestas inteligentes no tienen: en principio, podemos examinar cada paso y preguntar si está autorizado por las premisas y por las reglas del sistema. No tenemos que confiar en el prestigio de quien la presenta. Podemos revisar el camino.

Esa diferencia convirtió a la lógica en un territorio especialmente seductor para los primeros investigadores de inteligencia artificial. Si una máquina afirmaba haber reconocido una imagen, interpretado una frase o comprendido un problema, quedaba abierta una pregunta difícil: ¿cómo decidir qué había hecho en realidad? Una prueba formal ofrecía una respuesta parcial, pero precisa. Ante una cadena de inferencias, era posible distinguir entre haber alcanzado la conclusión correcta y haber llegado a ella por operaciones legítimas. El resultado no dependería únicamente de lo convincente que sonara una explicación.

En el capítulo anterior dejamos Dartmouth mientras distintos investigadores intentaban dar forma a una disciplina. Volvemos ahora a un proyecto que no nació exactamente en ese verano, aunque estuvo presente en sus discusiones. Lo impulsaban Herbert Simon y Allen Newell, con una contribución técnica decisiva de John Clifford Shaw. Querían construir un sistema capaz de encontrar demostraciones dentro de una parte de la lógica matemática. No buscaban que recitara teoremas ya conocidos. Querían que encontrara recorridos hacia ellos. El problema parecía delimi-

tado: había reglas, símbolos y objetivos. Precisamente por eso sería posible descubrir una dificultad que atraviesa hasta hoy la inteligencia artificial: **saber cuáles son los pasos permitidos no nos dice cuáles conviene intentar**.

Para comprender la magnitud de aquella idea, conviene visitar primero el mundo intelectual de Simon. Antes de convertirse en una figura central de la inteligencia artificial, había estudiado decisiones organizacionales, administración y economía. Le interesaba una incomodidad que las teorías ideales de la elección solían dejar en segundo plano. Se puede definir a un decisor perfectamente racional como alguien capaz de considerar todas las alternativas relevantes, anticipar sus consecuencias y seleccionar la mejor. Pero ¿qué persona real dispone del tiempo, la memoria y la información necesarios para hacerlo?

Las organizaciones no resuelven problemas desde una posición de omnisciencia. Sus integrantes trabajan con datos parciales, plazos, recursos escasos, procedimientos heredados y errores posibles. Si una solución exige revisar millones de opciones, la pregunta no es solamente cuál sería la opción óptima. La pregunta previa es cómo empezar a buscar sin quedar atrapados en el propio espacio de posibilidades. El interés de Simon por la racionalidad limitada encontró aquí un puente inesperado hacia la computación. Una máquina tampoco puede explorar indefinidamente. La forma de representar el problema y de seleccionar qué camino merece atención influye en aquello que finalmente consigue resolver.

Allen Newell llegó a ese encuentro desde otra trayectoria. Trabajaba vinculado a RAND, un centro de investigación donde los problemas de estrategia, organización, tecnología y cálculo compartían espacio institucional. La historia habitual tiende a describir el nacimiento de un programa mediante una iluminación individual. Las reconstrucciones documentales muestran algo mucho

más interesante: una sucesión de decisiones, cambios de objeto y restricciones materiales. Simon recordó que la idea inicial había girado alrededor del ajedrez, pasó por la geometría y terminó en lógica. No es necesario convertir esa sucesión en un relato de errores. Cada cambio permitía encontrar una tarea cuya estructura fuera más manejable y cuyas soluciones pudieran examinarse.

El ajedrez ofrecía un universo de reglas precisas, pero una cantidad abrumadora de partidas posibles. La geometría añadía dificultades de representación: para una persona, una figura puede sugerir relaciones casi inmediatamente, mientras que para una máquina de mediados del siglo veinte esas relaciones debían convertirse en símbolos y procedimientos explícitos. La lógica proposicional permitía recortar parte del problema. En ella, las expresiones están formalizadas, y los pasos admisibles pueden especificarse sin apelar a una percepción visual o a significados cotidianos. Eso no convertía la demostración en una tarea trivial. Solamente hacía más visible su verdadera dificultad.

El tercer nombre, Cliff Shaw, es indispensable. En numerosas historias populares el proyecto aparece como una obra de Newell y Simon; no es enteramente falso referirse a ellos como sus principales impulsores intelectuales, pero se vuelve engañoso cuando la simplificación borra la construcción del sistema. Shaw trabajaba como programador en RAND. Su conocimiento de las máquinas reales y de los procedimientos necesarios para dar vida al modelo permitió transformar una descripción de razonamiento en un programa ejecutable. No fue un servicio accesorio, como si el trabajo intelectual hubiera terminado cuando alguien formuló una idea y la programación consistiera únicamente en copiarla. En este proyecto, elegir cómo representar símbolos, almacenar estructuras y ejecutar operaciones formaba parte del descubrimiento.

Esta cuestión importa particularmente cuando hablamos de sistemas de IA contemporáneos. Separamos con facilidad las palabras «modelo», «producto» y «arquitectura». Imaginamos que primero existe una inteligencia abstracta y después un equipo la conecta con herramientas, bases de datos y usuarios. Pero las condiciones de implementación cambian lo que el sistema puede hacer y lo que los investigadores pueden observar. La historiadora Stephanie Dick mostró que, en el Logic Theory Machine, las exigencias del computador JOHNNIAC obligaron a modificar las representaciones y prácticas que los investigadores habían imaginado. La máquina física no era un escenario neutral para poner a prueba una teoría ya terminada. Intervenía en su forma.

Detengámonos en el problema de una demostración. Supongamos que tenemos dos proposiciones: si llueve, la calle se moja; está lloviendo. De esas premisas podemos inferir que la calle se moja. Esta operación sencilla ilustra una regla conocida como modus ponens. Si escribimos «si P, entonces Q» y disponemos de P, obtenemos Q. La validez del paso no depende de que llueva realmente, ni de que la calle esté mojada en una ciudad concreta. Depende de la forma lógica y de la aceptación de las premisas. El contenido puede variar; la regla conserva su estructura.

Para un sistema que pretende demostrar teoremas, esa regularidad resulta poderosa. Podemos almacenar fórmulas, reconocer patrones y aplicar transformaciones admisibles. Sin embargo, en cuanto le entregamos muchos axiomas, muchas expresiones y una conclusión por demostrar, aparece la dificultad que el ejemplo cotidiano ocultaba. ¿Cuál de las reglas conviene aplicar primero? ¿Sobre qué fórmula? ¿Qué sustitución de variables es relevante? ¿Cuánto tiempo debemos seguir una vía que parece prometedora antes de probar otra? Aunque cada operación individual sea válida, la sucesión de operaciones posibles puede crecer de manera descomunal.

Un mapa de rutas ofrece una analogía útil, con una advertencia. Tener todas las calles de una región no significa que podamos encontrar inmediatamente el camino más conveniente entre dos ciudades. Si examinamos cada desvío posible, el procedimiento puede resultar impracticable. Necesitamos indicios para seleccionar rutas. Una carretera principal suele ser más prometedora que un sendero que parece alejarse del destino, aunque ninguna de esas intuiciones garantice por sí sola el mejor recorrido. En matemáticas ocurre algo parecido: las reglas definen qué caminos son legales, mientras que las heurísticas ayudan a decidir cuáles recorrer. La analogía deja de funcionar cuando olvidamos que, en una prueba formal, las reglas de inferencia tienen un papel distinto del criterio usado para ordenar la búsqueda.

La diferencia entre una regla y una heurística es uno de los conceptos más decisivos de la historia de la IA. Una regla deductiva autoriza una inferencia bajo condiciones explícitas. Una heurística es una orientación para buscar soluciones con recursos limitados. Puede ahorrar cantidades enormes de trabajo. También puede conducir a un callejón sin salida o dejar sin explorar una vía que sí llevaba al objetivo. No convierte una inferencia inválida en válida, pero sí condiciona cuáles inferencias válidas llegaremos a encontrar. El Logic Theorist combinaba ambas cosas: un dominio lógico formalizado y procedimientos de búsqueda inspirados, en parte, por la manera en que las personas resuelven problemas.

Esta idea tenía una consecuencia extraordinaria. El programa no necesitaba conocer previamente la secuencia completa de una demostración particular. Sus diseñadores le entregaban símbolos, reglas y estrategias para explorar alternativas. Si lograba construir una cadena adecuada, el resultado podía ser una prueba que no hubiera sido incorporada como una lista cerrada de pasos. La expresión «encontrar un teorema» exige aquí una precisión: en la mayoría de sus experimentos el enunciado objetivo era conocido, tomado de una obra matemática. Lo que el sistema buscaba era

una demostración. Descubrir una prueba para una proposición ya formulada no equivale a formular una nueva conjetura ni a desarrollar una teoría matemática inédita.

La obra elegida como campo de pruebas fue *Principia Mathematica*, de Alfred North Whitehead y Bertrand Russell. Publicada originalmente en los primeros decenios del siglo veinte, intentaba fundamentar amplias porciones de la matemática mediante un aparato lógico formal. Su importancia histórica es difícil de exagerar; su notación, en cambio, no es la puerta de entrada más amistosa para un lector contemporáneo. En sus páginas, resultados que parecen evidentes pueden requerir largas cadenas de definiciones e inferencias. Esa distancia entre la familiaridad de una conclusión y la complejidad de su demostración hacía del libro un laboratorio particularmente revelador.

Resultaba tentador describir el proyecto como una máquina destinada a repetir el trabajo de Russell y Whitehead. Pero tampoco sería exacto. Un matemático humano puede reconocer una estructura, recurrir a la intuición, recordar un teorema, abandonar un intento y reformular la pregunta. Un programa de 1956 necesitaba que esas posibilidades fueran representadas mediante operaciones concretas. El objetivo era estudiar si algunas estrategias que parecían caracterizar la resolución humana de problemas podían convertirse en procedimientos manipulables por una máquina. La lógica servía tanto de terreno de evaluación como de objeto para una hipótesis psicológica: quizás una parte del pensamiento pudiera describirse como búsqueda selectiva entre representaciones simbólicas.

La primera versión del sistema no apareció inmediatamente en la pantalla de un computador. La cronología es más interesante que la leyenda condensada. Según el recuerdo publicado por Simon y la reconstrucción de los archivos, hacia el 15 de diciembre de 1955 el diseño podía simularse manualmente. Personas siguiendo

los procedimientos propuestos ejecutaban, sobre papel, las operaciones de lo que pretendía ser un programa. El paso era significativo: mostraba que la arquitectura podía describirse con suficiente precisión para producir resultados sin depender de intuiciones improvisadas en cada movimiento. Pero no era todavía una ejecución automática sobre la máquina a la que estaba destinado.

Existe una diferencia científica entre las dos afirmaciones. «Hemos especificado un procedimiento» significa que podemos describir las operaciones que debería ejecutar un sistema. «Podemos simular el procedimiento» significa que esas operaciones pueden seguirse en una representación concreta, incluso con intervención humana. «El computador lo ha ejecutado» implica que existe una implementación capaz de realizarlas bajo determinadas condiciones. Y «funciona de forma confiable» exige todavía otras pruebas. Una disciplina nueva puede necesitar todos esos pasos, pero no tiene derecho a confundirlos.

El registro archivístico permite observar que el proyecto generó notas a fines de 1955 y documentos de trabajo durante los primeros meses de 1956. También conserva la complejidad menos celebrada de esta fase: era necesario construir un lenguaje adecuado para manipular expresiones y estructuras variables. Los lenguajes de programación disponibles no ofrecían todavía las abstracciones cómodas que hoy damos por sentadas. Resolver un problema simbólico requería inventar parte del medio donde ese problema podía representarse. De ese esfuerzo surgirían los *Information Processing Languages*, o IPL, pioneros del procesamiento de listas.

Una lista puede parecer un objeto informático demasiado modesto para protagonizar una historia de inteligencia. Pero pensemos qué ocurre cuando queremos representar una demostración. No guardamos simplemente un número. Necesitamos conservar una expresión compuesta de otras expresiones, registrar relaciones entre símbolos, localizar fragmentos, sustituir elementos y recons-

truir la cadena de pasos de una búsqueda. Si cada formula fuera tratada como una secuencia rígida sin estructura, muchas operaciones serían torpes o costosas. Las listas enlazadas ofrecían una forma de organizar componentes y referencias capaz de acompañar el crecimiento del problema. La arquitectura de los datos se convirtió así en una condición de posibilidad del razonamiento automatizado.

En este punto, la historia de la inteligencia artificial se encuentra con otra historia: la de la ingeniería de software. Una idea puede ser intelectualmente coherente y, aun así, resultar difícil de ejecutar porque el lenguaje de programación, la memoria disponible o el diseño de los datos no permiten expresarla de forma eficiente. En lugar de preguntar únicamente «¿qué algoritmo resuelve el problema?», es necesario preguntar también «¿en qué representación puede operar ese algoritmo?». La pregunta volverá una y otra vez: en sistemas expertos, en bases de conocimiento, en motores de búsqueda, en programación asistida por modelos generativos y en agentes que intentan coordinar documentos, herramientas y acciones.

El nombre JOHNNIAC aparece ahora en la historia con la importancia que merece. Era el computador de RAND en el que finalmente se ejecutó una versión del Logic Theorist. No necesitamos imaginar una escena con luces parpadeantes, técnicos emocionados o un silencio ceremonial en la sala: no contamos con evidencia suficiente para atribuir esos detalles a la primera demostración. Lo que sí podemos afirmar es que la implementación llegó a producir una prueba formal en esa máquina. En su memoria biográfica sobre Newell, Simon fecha la primera demostración computacional completa de un teorema de *Principia Mathematica*, el número 2.01, el 9 de agosto de 1956.

La fecha importa porque obliga a revisar dos relatos simplificados. El primero hace nacer el programa completo en Dartmouth, como si todas sus piezas hubieran sido ensambladas durante el encuentro. No lo fueron. Su concepción y simulación manual lo antecedieron; su ejecución efectiva se documenta después. El segundo toma un artículo publicado en septiembre de 1956 como prueba autosuficiente de esa ejecución. Pero el propio trabajo de Newell y Simon, titulado *The Logic Theory Machine—A Complex Information Processing System*, aclara que se concentra en la especificación y no en la realización computacional. Para conocer resultados de las pruebas hay que acudir, entre otras fuentes, al trabajo empírico firmado por Newell, Shaw y Simon en 1957.[8]

En ese segundo artículo, los tres investigadores dejaron atrás la mera especificación y describieron experimentos realizados con el programa en la computadora JOHNNIAC. El estudio de 1957 examina pruebas concretas, procedimientos de búsqueda y casos en que los recursos se agotaban sin encontrar una demostración. En una de sus pruebas, los autores mencionan treinta y ocho teoremas ya disponibles para intentar demostrar el número 2.45; ese dato no debe confundirse con un porcentaje de éxito calculado sobre todos los problemas matemáticos. La cifra histórica más difundida —treinta y ocho demostraciones entre los primeros cincuenta y dos objetivos del capítulo segundo de *Principia Mathematica*— aparece detallada en reconstrucciones posteriores. Para ese recuento se considera un conjunto limitado de teoremas, presentados en secuencia y con la posibilidad de reutilizar los ya demostrados. No mide inteligencia general ni la capacidad de resolver cualquier problema matemático: describe el rendimiento atribuido a un programa concreto bajo condiciones específicas.

Los resultados del artículo permiten ir más lejos que el porcentaje. Describen demostraciones alcanzadas mediante diferentes números de pasos y métodos de transformación, incluidas sustituciones y encadenamientos. El resultado no fue un veredicto binario

sobre si la máquina «pensaba». Fue una colección de observaciones sobre el comportamiento de un sistema concreto. Algunas tareas podían resolverse de forma directa; otras requerían la creación de subproblemas; otras no quedaban demostradas mediante los procedimientos empleados. Lo que parecía una declaración filosófica gigantesca comenzaba a convertirse en una investigación empírica sobre mecanismos y límites.

Una persona puede reconocer aquí un eco de los sistemas contemporáneos, siempre que la comparación no borre las diferencias. Cuando un modelo generativo resuelve una tarea compleja, también necesitamos saber en qué tipos de problemas fue evaluado, con qué recursos, qué errores cometió y qué ocurrió cuando las condiciones cambiaron. Sin embargo, un modelo de lenguaje actual no es simplemente un Logic Theorist gigantesco. Sus mecanismos de entrenamiento y generación son distintos. Su representación del lenguaje, sus posibilidades de generalización y sus modos de fallo exigen otras explicaciones. La continuidad histórica está en la pregunta que hacemos sobre la evidencia, no en una identidad entre arquitecturas.

Hay un segundo matiz que suele desaparecer detrás del entusiasmo por los resultados. Cuando el sistema encuentra una prueba dentro de una lógica formal, el valor epistémico de esa prueba depende de que cada paso sea válido según las reglas aceptadas. Si la secuencia está bien construida, puede comprobarse sin aceptar las intuiciones del programa. Pero que una inferencia sea válida no demuestra que sus premisas describan correctamente el mundo. La matemática formal y la investigación empírica comparten exigencias de rigor, aunque no prueban sus afirmaciones del mismo modo. Un sistema puede ser impecable aplicando reglas y estar trabajando con supuestos que no representan bien el fenómeno que queremos entender.

Consideremos un caso contemporáneo muy simple. Una IA produce un cálculo preciso a partir de una base de datos de recursos humanos. Las operaciones pueden ser correctas: sumas, promedios, intervalos y porcentajes sin errores aritméticos. Pero tal vez la base haya omitido a quienes abandonaron el proceso de selección, clasificado incorrectamente una variable o medido una competencia mediante un indicador que apenas guarda relación con ella. La corrección del procedimiento no rescata la validez de las premisas. En 1956 el problema aparecía como una frontera entre reglas lógicas y heurísticas de búsqueda. Hoy reaparece en una escala mayor, entre datos, modelos, decisiones y consecuencias.

Newell, Shaw y Simon no estaban construyendo un juez universal de la verdad. Estaban investigando una forma de realizar tareas intelectuales específicas mediante representaciones y procedimientos computables. Su ambición podía extenderse a preguntas mayores sobre el pensamiento, pero el experimento no resolvía por sí solo esas preguntas. La distinción es relevante porque el éxito de una máquina en una prueba verificable puede generar un prestigio que luego se proyecte sobre tareas donde no existe un verificador igualmente claro. Esa transferencia de confianza es comprensible; también puede ser peligrosa.

Los investigadores contaban, además, con una ventaja que hoy rara vez hacemos explícita. En la lógica formal, la regla de evaluación no depende de que un jurado encuentre persuasivo el estilo de la respuesta. No hace falta calificar si el texto «suena profesional». Una prueba permite examinar operaciones. Cuando se abandona ese territorio y se pide al sistema que proponga una política científica, evalúe una contratación, resuma una investigación o anticipe un riesgo, los criterios se vuelven múltiples y parcialmente disputados. Algunos elementos pueden comprobarse de forma directa; otros requieren evidencia empírica, interpretación normativa o juicio profesional. El tipo de verificador debe cambiar con la naturaleza del problema.

La colaboración con Cliff Shaw abre otra pregunta que merece quedarse con nosotros. ¿Dónde se localiza una contribución intelectual en un sistema tecnológico? En la idea que origina el proyecto, en las reglas que lo describen, en el código que lo ejecuta, en la máquina que lo hace posible, en las pruebas que revelan sus límites o en la organización que proporciona recursos para construirlo. La historia de la IA está llena de innovaciones cuya explicación popular se concentra en dos o tres nombres. El registro histórico muestra equipos, lenguajes, bibliotecas, herramientas y prácticas. Shaw no desaparece de los trabajos técnicos principales: figura como autor del artículo empírico de 1957. Su ausencia de ciertos relatos abre una cuestión sobre el modo en que distribuimos el mérito científico.

Bertrand Russell recibió noticias del programa que buscaba demostraciones en la lógica asociada a su propia obra.[9] El archivo de McMaster conserva el registro de una carta dirigida a Herbert Simon, fechada el 2 de noviembre de 1956. La ficha reproduce una breve observación de Russell favorable a la posibilidad de mecanizar la lógica deductiva, pero no permite acceder públicamente a la transcripción completa. Existe también una segunda carta catalogada, del 21 de septiembre de 1957, cuyo resumen dice que Russell estaba encantado con la máquina dedicada a comprobar demostraciones de Principia. Las dos fichas acreditan correspondencia e interés; no autorizan a inventar una conversación ni a reconstruir íntegramente el contenido de las cartas. Ya resulta notable que uno de los autores del sistema lógico que las máquinas exploraban respondiera por escrito a sus constructores.

La correspondencia de Bertrand Russell con Herbert Simon conserva una pieza valiosa de esta historia, aunque no todas sus páginas sean de acceso público. Los catálogos del archivo de McMaster registran respuestas de 1956 y 1957 relacionadas con la mecanización de la lógica. Sabemos que existió ese intercambio; no deberíamos atribuirle frases extensas, una reacción íntima o detalles

editoriales que las fichas públicas no permiten examinar. El cuidado resulta especialmente apropiado: si el mérito del Logic Theorist estaba en producir pasos verificables, también su historia debe sostenerse sobre documentos que podamos identificar con precisión.

Hay algo casi irónico en esa necesidad de cautela. La primera gran historia sobre una máquina capaz de construir pruebas se convirtió, con el tiempo, en una fuente de afirmaciones que nosotros mismos necesitamos comprobar. El episodio ofrece una enseñanza más exigente que una celebración tecnológica. Una prueba formal es poderosa porque sus pasos pueden someterse a examen; una historia científica también merece una cadena de evidencias que permita reconstruir sus conclusiones. Si confiamos en la segunda únicamente porque nos emociona, traicionamos la lección de la primera.

En 1976 Newell y Simon volvieron sobre estas preguntas en una conferencia que desarrollaba la hipótesis de los sistemas físicos de símbolos y el papel de la búsqueda heurística. Dos décadas después del comienzo del Logic Theorist, sostenían que manipular estructuras simbólicas y buscar soluciones constituía una vía central para comprender la acción inteligente. La afirmación debe leerse como una hipótesis científica ambiciosa, elaborada desde una tradición de investigación concreta, no como una descripción universalmente aceptada de toda inteligencia ni como una explicación completa de los modelos generativos actuales. El desarrollo posterior de enfoques estadísticos y conexionistas obligaría a discutir nuevamente sus alcances.

Lo extraordinario del Logic Theorist, entonces, no reside en que haya resuelto de una vez la pregunta de si las máquinas piensan. Reside en haber desplazado una parte de esa pregunta hacia un terreno donde se podían construir mecanismos, ejecutar programas y comparar resultados. Permitió estudiar el razonamiento

como una actividad que requiere representar estados, seleccionar operadores, generar subproblemas, administrar memoria y verificar conclusiones. Al hacerlo, mostró que la inteligencia de una solución no depende solamente de lo que se produce al final, sino de la relación entre el problema, los recursos disponibles y el camino elegido.

Quizá por eso el término «heurística» merece acompañarnos mucho más allá de los años cincuenta. Cuando diseñamos un flujo de investigación asistido por IA, establecemos qué fuentes conviene consultar primero. Cuando programamos un agente, definimos qué herramientas puede utilizar y en qué orden. Cuando decidimos dividir un proyecto en pasos, alteramos el espacio de opciones que el sistema explorará. En todos esos casos existe una pregunta anterior a la respuesta: ¿cómo organizamos la búsqueda para no desperdiciar recursos ni quedar ciegos ante alternativas importantes? La buena arquitectura no consiste siempre en agregar complejidad. A menudo consiste en descubrir qué complejidad puede omitirse sin perder lo esencial.

Pero la heurística también nos impone una obligación. Si elegimos dónde mirar, necesitamos saber qué podríamos estar dejando fuera. La solución rápida no es necesariamente la mejor; la primera demostración válida no es necesariamente la más breve; un modelo que responde bien en los casos habituales puede fallar precisamente cuando cambia el contexto. El pensamiento experto consiste en reconocer cuándo una estrategia de búsqueda es razonable, cuándo es insuficiente y cuándo el costo del error exige una exploración más amplia o una verificación independiente.

A mediados de los años cincuenta, Newell, Shaw y Simon habían conseguido dar un paso notable: construir una máquina que no se limitaba a ejecutar una secuencia prefijada de operaciones aritméticas, sino que buscaba demostraciones mediante procedimientos seleccionados para un problema intelectual. No habían demos-

trado que toda inteligencia pudiera reducirse a ese método. Habían abierto una forma nueva de estudiarla. Entre la promesa de Dartmouth y la prueba producida por JOHNNIAC existía ahora una cadena de decisiones que otros podían discutir, reproducir parcialmente, modificar y evaluar.

La siguiente frontera sería distinta. Encontrar una demostración supone trabajar dentro de un universo cuyas reglas conocemos con precisión. Jugar una partida también exige reglas, pero introduce adversarios, consecuencias estratégicas y la necesidad de decidir antes de explorar todos los movimientos. Algunos investigadores comenzaron a preguntarse si una máquina podía no solo buscar una buena jugada, sino modificar con la experiencia el modo en que elegía. Para entrar en esa historia tendremos que abandonar, por un momento, los teoremas y acercarnos a un tablero. Allí el problema ya no será únicamente encontrar un camino válido. Será aprender cuáles caminos merecen intentarse.

Capítulo 6 · Aprender a ganar

El problema de construir una máquina que juegue bien al ajedrez contiene una pequeña trampa filosófica. Antes de decidir qué movimiento debe hacer, alguien tiene que explicar qué significa que una posición sea buena. Hay situaciones en las que la respuesta es indiscutible: si un rey está en jaque mate, la partida terminó. Pero entre el primer movimiento y ese final se extiende un territorio donde las certezas escasean. Un alfil puede parecer perdido y estar preparando un ataque. Una torre aparentemente segura puede quedar inmovilizada. Un peón sacrificado puede abrir una línea decisiva. El movimiento que hoy parece sensato puede volverse absurdo cuando el adversario revela una respuesta inesperada.

Una computadora conoce las reglas si se las hemos programado. Puede identificar movimientos legales, actualizar el tablero y reconocer ciertos finales. Nada de eso basta para jugar bien. Lo mismo sucedía con la máquina de los teoremas del capítulo anterior: disponer de reglas para operar no implica saber por dónde empezar a buscar. Pero el juego introduce una dificultad adicional. En una demostración formal, las inferencias se juzgan mediante reglas explícitas de validez. En una partida todavía inconclusa, la conveniencia de una decisión depende de un futuro que nadie ha recorrido por completo.

Claude Shannon convirtió esa dificultad en un programa de investigación antes de que la inteligencia artificial recibiera oficialmente su nombre. En marzo de 1950 publicó en *Philosophical Magazine* un artículo sobre cómo programar una computadora para jugar ajedrez. La propuesta había sido presentada públicamente el año anterior, en una convención del Institute of Radio Engineers. El objetivo inmediato era modesto si se lo compara con nuestras expectativas contemporáneas: establecer un método plausible, no anunciar un campeón mecánico. Su ambición intelectual, en cam-

bio, era considerable. El ajedrez podía convertirse en una cuña para abrir problemas más amplios de elección, planificación y manipulación simbólica.

El comienzo del artículo ofrece una lista que hoy resulta sorprendente. Shannon pensaba que técnicas similares podrían emplearse para diseñar circuitos, traducir lenguajes, organizar decisiones estratégicas e incluso orquestar melodías. No estaba afirmando que todas esas máquinas ya existieran ni que compartieran idénticos mecanismos. Estaba identificando una familia de problemas en los que no basta con calcular un número siguiendo una fórmula fija: es necesario representar situaciones, comparar alternativas y escoger entre resultados de distinta calidad. Su diagnóstico anticipaba una transición decisiva en la historia de la computación. Los números seguirían siendo indispensables, pero aquello sobre lo que operarían los números sería cada vez más variado.

Para comprender su propuesta conviene imaginar el tablero como el comienzo de un árbol invisible. Desde la posición inicial existen veinte movimientos legales posibles. Cada elección abre las respuestas del adversario, y cada respuesta abre nuevas posibilidades. La cantidad exacta de ramificaciones cambia de una posición a otra, pero basta avanzar unas pocas jugadas para que el árbol de posibilidades crezca con una velocidad formidable. No podemos suponer que una computadora, por el solo hecho de calcular muy rápido, recorra siempre hasta el final todas las partidas posibles. El límite material no desaparece porque el problema esté definido con precisión.

Aquí aparece una de las intuiciones más duraderas de Shannon: buscar exige decidir qué vale la pena buscar. Su artículo distinguía una estrategia de exploración más uniforme, a la que llamó tipo A, y otra más selectiva, tipo B. La primera profundizaba el examen de movimientos de manera relativamente sistemática; la segunda intentaba invertir los recursos allí donde parecían existir

posibilidades prometedoras. No se trataba de dos mentes rivales, sino de dos formas de distribuir un recurso escaso: tiempo de cálculo. El problema central de la inteligencia artificial empezaba a parecerse menos a una pregunta sobre máquinas infinitamente poderosas y más a una pregunta sobre qué hacer cuando ninguna máquina tiene tiempo para examinarlo todo.

¿Pero cómo decide el programa qué posiciones merecen explorarse? Shannon propuso evaluar los estados del tablero mediante una función. Puede pensarse como un número que resume diferentes características: material disponible, movilidad de las piezas, exposición del rey, estructura de los peones. No es una ley de la naturaleza que dicte cuál es la jugada correcta. Es un modelo construido para aproximar una propiedad que todavía no podemos observar directamente: la probabilidad práctica de llegar a un resultado favorable, dadas ciertas respuestas y un horizonte de búsqueda. Su utilidad depende de las variables seleccionadas, de cómo se ponderan y de las posiciones en las que se aplica.

Una función así tiene algo en común con muchos indicadores científicos. Podemos medir con precisión una característica y equivocarnos al interpretar lo que representa. Un índice de diversidad biológica, por ejemplo, puede registrar cambios de composición sin capturar todas las dimensiones de la salud de un ecosistema. Un indicador de productividad puede subir mientras se deteriora la calidad del trabajo. Una puntuación de contratación puede ordenar personas de acuerdo con variables observables sin medir adecuadamente su capacidad futura. Estas analogías no hacen equivalentes al ajedrez, la ecología y el reclutamiento; muestran que el acto de reducir una realidad compleja a un número introduce decisiones teóricas que ese número no puede justificar por sí mismo.

Shannon conocía un defecto todavía más sutil. No conviene evaluar una posición en medio de una secuencia de capturas como si ya fuera estable. Si una reina captura otra y al movimiento siguiente es recapturada, la ventaja material que aparece entre ambos movimientos puede ser ilusoria. El programa necesita extender su análisis hasta alcanzar lo que en ajedrez se llama una posición relativamente tranquila. De allí la idea de buscar *quiescencia*: no basta con mirar una profundidad fija si ese corte deja una operación táctica a medias. Una máquina puede equivocarse no porque su cálculo sea aritméticamente falso, sino porque detuvo la observación en un momento inadecuado.

Conviene detenerse aquí. En esta escena no hay aprendizaje todavía. La máquina compara posibilidades utilizando reglas y criterios que alguien le proporcionó. Puede encontrar movimientos sorprendentes, incluso sacrificios brillantes, sin modificar por eso sus principios de evaluación. Cuando Shannon describió la debilidad de esa aproximación, fue muy preciso: la máquina no aprendería de sus errores a menos que el programa fuera modificado. También consideró la posibilidad de un programa superior que ajustara términos y coeficientes a partir de los resultados de partidas anteriores. En 1950 esa idea aparecía como una vía concebible, pero todavía poco práctica según su análisis.

Cinco años después, mientras una disciplina naciente empezaba a tomar forma alrededor de Dartmouth, otro investigador se estaba acercando al mismo problema desde un tablero distinto. Arthur Lee Samuel había llegado a IBM en 1949 con una trayectoria en ingeniería eléctrica y válvulas de vacío.[10] Su interés por las damas no respondía simplemente a un entusiasmo recreativo: el juego ofrecía un laboratorio compacto para examinar una capacidad que las máquinas programadas de manera convencional tenían dificultades para exhibir. Samuel quería que parte de su desempeño mejorara por la experiencia, sin que el diseñador debiera reescribir manualmente cada decisión.

Las damas tenían ventajas metodológicas. Sus reglas eran explícitas, las partidas producían resultados reconocibles y el número de elementos relevantes era menor que en el ajedrez. Lo que en un problema de la vida real puede confundirse con ruido, objetivos ambiguos, decisiones humanas o cambios de contexto, aquí aparecía de forma controlable. Sin embargo, esa sencillez era relativa. Había suficientes posibilidades para hacer impracticable la exploración completa con los recursos de la época. El campo experimental no era trivial; estaba deliberadamente delimitado.

La decisión de elegir un juego nos enseña algo sobre el diseño de investigaciones: un laboratorio no necesita contener toda la complejidad del mundo para revelar un mecanismo. Pero precisamente por eso no permite generalizar sin condiciones. El resultado de Samuel no demostraría que una computadora podía aprender cualquier tarea. Demostraría que ciertos procedimientos de actualización podían mejorar el desempeño de un programa dentro de un entorno reglado, con estados definidos y señales de éxito relativamente claras. Parece una afirmación más pequeña. En realidad, es una afirmación mucho más útil porque sabemos qué significa y podemos examinar sus límites.

En julio de 1959 Samuel publicó en el *IBM Journal of Research and Development* los resultados de sus estudios. El título ya contenía una expresión que se haría central en la disciplina: *machine learning*. En el artículo describió dos vías de aprendizaje. Una descansaba en recordar posiciones y puntuaciones obtenidas previamente. La otra buscaba generalizar, es decir, ajustar criterios de evaluación para enfrentarse a situaciones que no habían sido almacenadas exactamente como tales. El contraste entre ambas ocupa el corazón de nuestra historia.

La primera vía era lo que Samuel denominó aprendizaje por memorización. El programa conservaba posiciones del tablero junto con valoraciones calculadas durante búsquedas anteriores. Si más

adelante encontraba un estado conocido, podía reutilizar lo almacenado y dedicar recursos a mirar más profundamente hacia el futuro. En cierto sentido, una decisión pasada se convertía en una pequeña inversión. El cálculo no desaparecía: quedaba disponible para otra ocasión. Una memoria de experiencias podía aumentar el horizonte efectivo de la búsqueda.

Sin embargo, recordar no equivale necesariamente a comprender una regularidad. Una máquina capaz de almacenar todas las partidas que ha visto podría seguir desconcertada por una configuración distinta. Y además la memoria es un recurso físico. En el IBM 704, almacenar y recuperar grandes cantidades de posiciones tenía límites muy concretos. Samuel tuvo que pensar en qué conservar, cómo organizarlo, cuándo recuperarlo y qué desechar. El aprendizaje no era una cualidad mágica que aparecía por acumular datos. Requería ingeniería de representación, criterios de selección y procedimientos de olvido.

La memoria también podía producir mejoras difíciles de interpretar. Una máquina podría ganar más porque recuerda aperturas frecuentes, pero seguir siendo débil en el medio juego. Podría evitar una trampa conocida y caer en otra que se parece mucho. Podría reconocer posiciones de entrenamiento sin haber capturado el principio general que las hace favorables. Una persona que estudia con IA enfrenta un problema metodológicamente distinto, pero intelectualmente emparentado: responder con fluidez una pregunta que ya ha visto no demuestra que pueda resolver otra nueva. En ambos casos, el éxito repetido necesita separarse de la transferencia de conocimiento.

Samuel buscó entonces reducir la dependencia de registros individuales. La segunda vía consistía en modificar una función de evaluación. En lugar de guardar cada tablero, el programa debía identificar propiedades de las posiciones que correlacionaran con un mejor juego y ajustar su peso relativo. Entre las características

potenciales figuraban la movilidad, la distribución de las piezas, ciertas amenazas y configuraciones que restringían las opciones del adversario. Un conjunto de treinta y ocho parámetros candidatos alimentaba la selección de dieciséis términos modificables en la función de evaluación, mientras la ventaja material conservaba un tratamiento separado. La selección y los pesos no eran una descripción objetiva de todo el juego: eran una apuesta computacional sobre qué señales merecían atención.

El cambio parece técnico, pero encierra una transición epistemológica. En el primer enfoque, la máquina conserva respuestas asociadas a casos particulares. En el segundo, intenta construir una regla general a partir de su experiencia. Ambas estrategias pueden ser útiles. También pueden fallar de maneras diferentes. Memorizar demasiados casos puede consumir recursos y dejar poca capacidad para enfrentar novedades; generalizar demasiado pronto puede producir una regla elegante pero incorrecta. La inteligencia práctica no consiste en escoger dogmáticamente una de las dos opciones, sino en comprender qué aporta cada una y en qué circunstancias resulta confiable.

Samuel organizó parte de su experimento mediante dos versiones del programa a las que llamó Alpha y Beta. La primera ajustaba su función de evaluación durante el aprendizaje. La segunda conservaba temporalmente un sistema de puntuación de referencia. Las versiones podían enfrentarse en partidas, y los resultados permitían decidir qué ajustes merecían preservarse. Es importante no confundir estos nombres con el procedimiento de poda alfabeta que aparece también en la historia de la búsqueda en juegos. Aquí Alpha y Beta designaban dos contrincantes experimentales, no dos parámetros matemáticos del algoritmo de poda.

El procedimiento tenía un componente que hoy reconoceríamos como evaluación comparativa. No bastaba con que Alpha hubiera modificado sus coeficientes; necesitaba mostrar que esos cambios

producían un juego mejor que el de una referencia. Pero la comparación también encerraba riesgos. Si la referencia era débil, superarla no garantizaba calidad externa. Si ambos programas compartían errores, uno podía vencer al otro sin corregir los defectos comunes. Si una posición se repetía con frecuencia en los ensayos, el resultado podía exagerar la capacidad frente a partidas nuevas. Samuel no disponía de los instrumentos de evaluación contemporáneos, pero formuló problemas que siguen acompañando a cualquier sistema adaptativo.

Había incluso una dificultad circular más profunda. ¿Con qué criterio debería modificarse la función que determina si una posición es favorable, cuando esa misma función participa en la evaluación de las modificaciones? Samuel abordó el problema aprovechando búsquedas de mayor profundidad, comparaciones de desempeño y mecanismos de corrección. Ningún procedimiento lo liberaba por completo de los supuestos iniciales. La elección de indicadores, las reglas del juego, los métodos de actualización y los límites de cálculo habían sido establecidos por humanos. El programa podía ajustar sus criterios dentro de ese mundo; no definía por sí solo el propósito último de aprender.

La comparación con la ciencia experimental aparece aquí casi sin pedir permiso. Cuando un instrumento de medida participa en la calibración de otro, necesitamos puntos de referencia independientes. Cuando un modelo se evalúa con los mismos ejemplos que guiaron su ajuste, puede parecer más preciso de lo que será fuera del laboratorio. Cuando una organización mide una intervención solamente con el indicador utilizado para optimizarla, corre el riesgo de premiar el número en lugar del fenómeno. Los sistemas generativos contemporáneos agregan dificultades nuevas, pero la pregunta esencial permanece: ¿el procedimiento mejora aquello que decimos valorar, o solamente aprende a producir mejores puntuaciones según una medición limitada?

Los resultados de Samuel fueron prometedores y desiguales. En su artículo observó que el aprendizaje por memorización podía reproducir jugadas de apertura semejantes a las de buenos jugadores y evitar ciertas trampas en finales; en cambio, su desempeño en el medio juego era menos satisfactorio. La variante que generalizaba mostraba una pauta distinta: podía desarrollar un medio juego competente, pero conservar aperturas poco convencionales y fallar en finales que a un jugador experto le parecerían elementales. Samuel documentó incluso que, tras veintiocho partidas, esa modalidad todavía no había aprendido a ganar una configuración particular de dos damas coronadas contra una.

Es difícil imaginar una escena más instructiva. Un sistema mejora una capacidad, fracasa en otra y obliga a revisar qué entendemos por aprender. Si nos limitamos a anunciar que «una computadora aprendió a jugar», borramos precisamente la información que hace interesante el experimento. ¿Aprendió patrones locales? ¿Aprendió a valorar posiciones? ¿Aprendió reglas de estrategia transferibles? ¿Mejoró ante una clase de adversarios y empeoró frente a otra? Cada pregunta requiere observaciones diferentes. La palabra *aprendizaje* puede designar un mecanismo técnico concreto, pero no debe convertirse en un certificado general de competencia.

Samuel fue igualmente claro sobre la inestabilidad. Los coeficientes podían cambiar de manera errática, y los intentos de optimización quedar atrapados en soluciones locales. Una modificación que parecía prometedora podía dejar de serlo al acumular nuevas partidas. El artículo concluía que los experimentos no habían abarcado suficientes juegos para demostrar inequívocamente la estabilidad del procedimiento o su capacidad de encontrar los mejores parámetros posibles. En una época que invitaba a declaraciones grandilocuentes sobre las máquinas, la advertencia más importante tal vez fuera esa negativa a confundir una demostración experimental con una garantía.

Algunas narraciones posteriores condensan el episodio en una historia triunfal: Samuel construyó una máquina que jugaba mejor que él, la máquina aprendió por sí sola y acabó derrotando a un maestro. Hay elementos documentados detrás de esa secuencia, pero deben mantenerse separados. El propio resumen de 1959 sostenía que el programa podía superar el nivel de juego de su diseñador bajo las condiciones examinadas. IBM relata que, en 1962, el sistema derrotó a Robert Nealey, quien se describía como maestro de damas, y también señala que sus resultados posteriores frente a personas fueron mixtos. Ni ese episodio ni las pruebas de 1959 demostraron dominio general del juego, mucho menos inteligencia general. Una victoria es una observación; una capacidad estable necesita una historia de evaluaciones más amplia.

La distinción tiene consecuencias profesionales inmediatas. Imaginemos que una herramienta generativa produce en minutos un análisis que a una persona le habría llevado una tarde. El resultado puede ser correcto y valioso. Pero todavía ignoramos si la herramienta funcionará de la misma manera con datos incompletos, definiciones ambiguas, casos extremos o nuevos requisitos. Una arquitectura de agentes puede completar un flujo de trabajo cuidadosamente delimitado y fallar cuando recibe una instrucción contradictoria. Un sistema de selección puede predecir adecuadamente una variable histórica y, aun así, no haber demostrado que mide las competencias pertinentes ni que generaliza a otras poblaciones. La mejora de una tarea es una evidencia limitada, no una licencia para extender conclusiones sin pruebas.

A esta altura es tentador establecer una genealogía demasiado limpia: Shannon enseñó a las máquinas a buscar, Samuel les enseñó a aprender y los modelos generativos actuales serían simplemente la combinación de ambos descubrimientos multiplicada por enormes cantidades de datos. Esa narración tiene cierta elegancia, pero sería engañosa. Los sistemas modernos utilizan arquitecturas, objetivos de entrenamiento, representaciones y re-

cursos computacionales que no pueden reducirse a aquellas experiencias. Los modelos de lenguaje, además, no suelen actualizar automáticamente sus parámetros a partir de cada conversación individual. Algunas aplicaciones poseen memoria externa; otras utilizan recuperación de información; otras incorporan herramientas; otras ejecutan procesos de entrenamiento separados. Llamar aprendizaje a todos esos fenómenos sin diferenciarlos oscurece más de lo que aclara.

Lo que sí persiste es una estructura de preguntas. Primero: ¿cómo representamos el estado del problema? Segundo: ¿qué alternativas podemos considerar con los recursos disponibles? Tercero: ¿qué función, señal o criterio nos permite compararlas? Cuarto: ¿de dónde proviene la experiencia que modifica el sistema? Quinto: ¿cómo sabremos si una modificación representa una mejora fuera de las situaciones ya conocidas? Shannon y Samuel no respondieron definitivamente estas preguntas. Mostraron que podían convertirse en programas de investigación, capaces de producir resultados observables y nuevas dificultades.

Hay una ironía histórica en todo esto. El juego fue elegido porque simplificaba el mundo; la simplificación reveló, precisamente, cuán difícil es construir criterios de evaluación confiables. En damas, las reglas son estables y el resultado final puede establecerse. En una investigación científica, la variable que importa tal vez no sea directamente observable. En una organización, los objetivos pueden entrar en conflicto. En una vida humana, el significado de una buena decisión puede cambiar mientras tratamos de tomarla. Si aprender ya exigía tanta prudencia sobre un tablero de sesenta y cuatro casillas, cuánto más la exige en entornos donde las consecuencias no caben en una puntuación.

Sin embargo, sería un error convertir esa prudencia en escepticismo inmóvil. El trabajo de Samuel fue importante precisamente porque mostró que un sistema podía modificar aspectos de su

conducta utilizando experiencia acumulada. No necesitaba recibir una orden nueva para cada posición que encontraba. Sus resultados fueron modestos según muchos estándares actuales, pero abrieron una posibilidad de enorme alcance: parte del conocimiento operativo de una máquina podía resultar de un proceso de ajuste, no solamente de instrucciones particulares redactadas de antemano.

Con esa posibilidad, la relación entre programador y programa comenzó a cambiar. Cuando una persona escribe todas las reglas, puede inspeccionar los criterios explícitos que gobiernan el sistema, aunque no siempre pueda anticipar todas sus consecuencias. Cuando diseña un procedimiento que ajusta sus propios parámetros, la persona conserva responsabilidad sobre el marco de aprendizaje, pero ya no elige individualmente cada valoración adquirida. El comportamiento final surge de una interacción entre arquitectura, datos, señales de evaluación y restricciones. Lo que la máquina hace depende de las decisiones humanas, sin ser siempre una reproducción literal de ellas.

En cierto sentido, volvemos a Ada Lovelace. La cuestión ya no es solamente si una máquina ejecuta operaciones que alguien especificó, sino qué significa especificar un procedimiento capaz de producir nuevas regularidades a partir de la experiencia. Samuel no resolvió el problema filosófico de la originalidad, y sus experimentos tampoco pretendieron demostrar conciencia. Pero modificó la manera de formular la pregunta. Si un sistema encuentra criterios de evaluación que su autor no conocía previamente en esa combinación, ¿en qué consiste exactamente el aporte de cada uno? La respuesta requiere distinguir entre elegir un objetivo, diseñar un mecanismo, proporcionar experiencias, optimizar parámetros y validar resultados.

La metáfora educativa es tentadora, aunque merece sus límites. Ninguna computadora de Samuel tenía motivación, historia personal o una biografía de aprendiz. Las diferencias entre aprendizaje humano y actualización algorítmica son profundas. Podemos, no obstante, extraer una lección metodológica sin antropomorfizar el programa: la experiencia solo adquiere valor formativo cuando existe un procedimiento para interpretarla, y ese procedimiento puede equivocarse. Acumular conversaciones con IA no garantiza aumentar nuestro criterio. Repetir tareas asistidas tampoco demuestra comprensión. La transformación aparece cuando podemos reconocer patrones, identificar condiciones de error, contrastar resultados y modificar justificadamente nuestras decisiones futuras.

Shannon había mostrado la importancia de escoger bien entre innumerables caminos posibles. Samuel añadió que algunas de las señales utilizadas para escoger podían modificarse durante la marcha. Juntos no construyeron una inteligencia humana de silicio. Construyeron dos maneras de enfrentar la ignorancia computacional: buscar de forma inteligente donde no podemos explorar todo, y aprender de la experiencia cuando no podemos anticipar de antemano cada situación.

Pero todavía faltaba otro paso. ¿Y si, en lugar de elegir cuidadosamente características de una posición, pudiéramos construir una máquina que ajustara sus propias conexiones y reconociera regularidades en ejemplos? ¿Y si el problema de aprender no se limitara a decidir qué jugada conviene, sino que incluyera percibir el mundo? Esa pregunta nos lleva hacia un nuevo protagonista, hacia la promesa de los perceptrones y hacia una controversia que dividiría a los investigadores durante décadas. La inteligencia artificial estaba a punto de descubrir que aprender a decidir y aprender a reconocer no eran exactamente el mismo problema.

Parte III · Lo que parecía inteligencia

Capítulo 7 · La neurona que prometía reconocer el mundo

Una máquina puede jugar una partida porque alguien ha definido con precisión qué movimientos están permitidos. Puede buscar una demostración porque el problema viene acompañado de símbolos y reglas de transformación. Pero reconocer algo parece una tarea de otra naturaleza. Una persona distingue un rostro conocido en una habitación mal iluminada, reconoce un ave aunque la observe desde un ángulo inesperado y descubre una palabra incluso cuando la tipografía dificulta su lectura. No recibe una lista completa de posibilidades ni examina conscientemente cada combinación de trazos. Hay una familiaridad casi inmediata entre ciertas formas del mundo y la experiencia acumulada de quien las percibe.

Esta aparente facilidad humana ocultaba uno de los problemas más difíciles de la naciente inteligencia artificial: cómo convertir variaciones sensoriales en categorías estables. Si una máquina ve un triángulo grande y después uno pequeño, ¿qué tendría que conservar de ambas experiencias para tratarlos como instancias de una misma clase? Si cambia la iluminación, la posición, el fondo o el tamaño, ¿qué parte de la imagen importa y cuál debe ignorarse? El problema no podía resolverse simplemente añadiendo más reglas a un manual de instrucciones. Una lista exhaustiva de las posibles apariencias del mundo crecería hasta volverse impracticable.

Cuando Frank Rosenblatt comenzó a trabajar en el perceptrón durante los años cincuenta, no partía exclusivamente de ese problema de ingeniería.[11] Lo inquietaba también una pregunta biológica. ¿Cómo puede un sistema nervioso conservar los efectos de experiencias pasadas y utilizarlos para reconocer situaciones

nuevas? ¿La memoria consiste en guardar copias internas de aquello que percibimos, o en modificar las conexiones que hacen más probable una respuesta futura? En esa diferencia se cruzaban la psicología experimental, la neurofisiología y un proyecto matemático que apenas comenzaba a tomar forma.

En 1958 Rosenblatt publicó en *Psychological Review* un artículo cuyo título completo anunciaba su ambición: un modelo probabilístico para el almacenamiento y la organización de información en el cerebro. Las primeras páginas no comienzan con promesas sobre robots inteligentes, sino con tres preguntas acerca de la detección del mundo físico, la forma en que la información se almacena y la influencia de esa información sobre la conducta. La segunda y la tercera preguntas eran, para él, las más abiertas. Su teoría pretendía ofrecer un marco donde investigarlas, no una descripción ya demostrada de todos los mecanismos cerebrales.

Conviene imaginar lo que significaba formular esa propuesta en aquel momento. McCulloch y Pitts habían demostrado que podían representarse ciertas operaciones mediante redes de unidades idealizadas. Shannon había enseñado a pensar la búsqueda como un problema de recursos limitados. Samuel había mostrado procedimientos por los que un programa podía modificar su desempeño a partir de partidas anteriores. Rosenblatt quería unir varias intuiciones: un sistema formado por unidades simples, una estructura de conexiones y un mecanismo por el cual la experiencia alterara algunas de esas conexiones. En ese punto, el problema de reconocer dejaba de exigir que el diseñador anticipara cada patrón posible. La máquina podría adquirir criterios a partir de ejemplos.

La palabra *perceptrón* hoy suele evocar un diagrama escolar: entradas a la izquierda, pesos en el centro y una salida a la derecha. Es un esquema útil, pero empobrece el programa original. Rosenblatt estudiaba una familia de redes y se interesaba por su organi-

zación, por el carácter probabilístico de ciertas conexiones y por las propiedades que podían emerger de configuraciones diferentes. En su obra de 1962, *Principles of Neurodynamics*, insistió en que perceptrón era el nombre de una clase de modelos, no el nombre propio de un único artefacto. La simplificación posterior tuvo ventajas didácticas y un costo historiográfico: hizo parecer idénticos una idea teórica, una arquitectura matemática específica y una máquina física concreta.

Para comprender lo decisivo de aquella idea necesitamos entrar un momento en su matemática, pero sin perder de vista el problema biológico. Imaginemos que representamos un objeto mediante unas pocas propiedades medibles. En un ejemplo deliberadamente esquemático, podría ser el ancho de una forma, su altura y la intensidad promedio de cierta región. La máquina recibe esos valores, multiplica cada uno por un peso y suma los resultados. Si la suma supera un umbral, produce una respuesta; si no lo supera, produce otra. El modelo se parece a una balanza a la que se han asignado distintas importancias a cada señal.

El aspecto revolucionario no estaba en sumar ni en comparar con un umbral. Eso podía programarse de muchas maneras. Estaba en el procedimiento para cambiar los pesos. Si el sistema identificaba mal un ejemplo que debía pertenecer a una clase, podía modificar las conexiones en una dirección que aumentara la probabilidad de producir la respuesta esperada la próxima vez. Si emitía una respuesta positiva ante un ejemplo negativo, podía corregirlas en sentido contrario. Repetido con distintos casos, ese ajuste hacía aparecer una frontera de decisión que el programador no necesitaba escribir explícitamente mediante una larga colección de condiciones.

La palabra *aprender* adquiere aquí un significado verificable: modificar parámetros según una regla de actualización y unos ejemplos, de manera que cambie la conducta futura del sistema. No

implica, por sí misma, comprensión semántica, intención, conciencia ni una representación fiel del cerebro. Tampoco significa que el programa haya descubierto la única respuesta posible. Los pesos registran cómo una arquitectura concreta ha respondido a un conjunto de experiencias y a una señal de corrección. Esa precisión, que puede parecer excesivamente cautelosa, es la que permite distinguir un avance experimental de una metáfora atractiva.

Para verlo con mayor claridad podemos reducir el mundo a dos señales: presencia o ausencia de dos rasgos. Un perceptrón elemental puede aprender a activar su respuesta cuando aparece cualquiera de ellos; también puede aprender a activarla solamente cuando aparecen ambos, siempre que fijemos correctamente los pesos y el umbral. Podemos representar estos problemas en una superficie donde cada ejemplo ocupa un punto. El perceptrón elemental traza una línea —o, con más dimensiones, un hiperplano— que separa una clase de otra. Aprende dónde colocar esa frontera dentro de la familia de fronteras que su arquitectura permite representar.

Pero no todas las categorías admiten una separación semejante. Consideremos una regla extraña: responder afirmativamente cuando aparece uno de los dos rasgos, pero no cuando aparecen ambos ni cuando no aparece ninguno. Esta es la operación conocida como disyunción exclusiva, o XOR. Los dos casos positivos quedan en esquinas opuestas de un pequeño cuadrado y los negativos ocupan las dos restantes. Ninguna línea recta puede dejar los positivos de un lado y los negativos del otro. Por más ejemplos que presentemos y por más veces que ajustemos los mismos pesos, ese perceptrón elemental no podrá resolver perfectamente el problema en su representación original.

La enseñanza no es que la operación XOR sea especialmente importante para la vida cotidiana de una máquina. Es que el fracaso tiene una estructura. No se debe necesariamente a falta de datos, a torpeza del programador o a una mala elección del coeficiente de aprendizaje. Procede de una restricción en el conjunto de funciones que ese modelo puede representar. Existe una diferencia radical entre un sistema que aún no encontró la solución y otro cuya arquitectura no contiene ninguna solución del tipo requerido.

Conocemos esta distinción en otros campos, aunque no siempre la aplicamos con el mismo rigor. Si construimos un modelo ecológico que presupone relaciones lineales entre variables, podemos ajustar magníficamente algunos datos y fallar ante interacciones no lineales decisivas. Si intentamos estimar competencias profesionales a partir de un conjunto estrecho de indicadores, la precisión aparente puede ocultar un problema de validez del constructo. Si pedimos a un modelo generativo que resuelva una tarea que necesita acceso a una fuente privada que no posee, insistir con la redacción de la instrucción no crea la información faltante. Cada caso requiere un diagnóstico distinto. A veces conviene mejorar el entrenamiento; otras, la representación; otras, cambiar el diseño completo del sistema.

Hay una advertencia adicional, y es histórica. El teorema de convergencia asociado al perceptrón ofrece una garantía bajo condiciones precisas: si los ejemplos de un problema están separados linealmente y se aplica una regla adecuada de corrección de errores, el procedimiento alcanza una solución en un número finito de actualizaciones. El resultado es matemáticamente hermoso porque transforma una intuición sobre el aprendizaje en una afirmación demostrable. Pero la garantía no dice que cualquier problema sea separable, que los ejemplos del mundo real estén libres de ruido, que la clasificación sea justa ni que la solución encontrada

generalice automáticamente a situaciones diferentes. Una garantía poderosa puede ser muy limitada. Aprender a leer sus condiciones es parte de comprenderla.

Esa combinación de ambición y delimitación se manifestó también en el hardware. El Mark I Perceptron, construido en el Cornell Aeronautical Laboratory de Buffalo, era una máquina física financiada por organismos militares estadounidenses, entre ellos la Office of Naval Research. El Smithsonian conserva el equipo y describe sus componentes: unidades sensoriales que recibían estímulos, unidades de asociación conectadas mediante circuitos y unidades de respuesta que producían señales observables. Había cables, interruptores, paneles y dispositivos para ajustar conexiones. Era un experimento material sobre el aprendizaje, no una conciencia encerrada en un armario.

Las fotografías de la época muestran algo que hoy puede resultar extraño: la idea de una red neuronal convertida en aparatos, conexiones visibles y trabajo manual de laboratorio. La historia posterior de la IA suele representarse mediante imágenes de circuitos abstractos o centros de datos; el Mark I recuerda que una teoría necesita atravesar decisiones de ingeniería para convertirse en experiencia. ¿Qué unidades pueden construirse realmente? ¿Cómo se modifica un peso? ¿Qué señal cuenta como error? ¿Cómo se observa el resultado? ¿Qué recursos cuestan esas decisiones? La distancia entre una arquitectura formulada en papel y un dispositivo que funciona no desaparece en la era del software: cambia de forma.

Es fundamental, además, no fusionar episodios que ocurrieron en momentos distintos. La presentación pública de 1958 se apoyó en una simulación del perceptrón sobre una computadora IBM 704; el Mark I físico fue otra realización del programa de investigación. El Smithsonian fecha su construcción hacia 1958, y el manual operativo publicado en 1960 documenta un dispositivo experimental

ya desarrollado. En periodismo histórico, estos matices importan. Si imaginamos a los periodistas de 1958 contemplando una versión posterior del Mark I como si fuera la única escena posible, convertimos una sucesión real de avances en una demostración inventada.

La prensa, sin embargo, encontró desde muy temprano una historia irresistible. Una máquina inspirada en el cerebro que aprendía a distinguir patrones parecía anunciar un futuro inmediato de percepción artificial. En noviembre de 1958, *The New Yorker* hablaba del perceptrón como un rival extraordinario para el cerebro humano, al tiempo que aclaraba que la primera máquina física aún estaba por construirse y que el sistema había sido simulado en una IBM 704. La distancia entre la cautela del dato y la exuberancia de la interpretación era visible dentro de la misma pieza periodística.

Rosenblatt conocía ese problema. En el prefacio de su libro de 1962 escribió, con ironía, sobre la dificultad de convencer a los divulgadores de que *perceptrón* no era el nombre propio de una máquina. También atribuyó parte de las reacciones negativas a la cobertura sensacionalista del anuncio de 1958 y a la falta inicial de rigor matemático en algunos informes. Señaló, además, malentendidos entre su programa de investigación y los proyectos de reconocimiento de patrones más orientados a aplicaciones inmediatas. Su explicación es un testimonio directo de cómo interpretaba la polémica; no es, por sí sola, una sentencia definitiva sobre quién tenía razón.

Pensemos en el cambio de escala que introduce un titular. En el laboratorio, alguien puede afirmar que una red aprende a clasificar un conjunto acotado de patrones bajo condiciones controladas. En una nota de prensa, esa frase puede convertirse en la promesa de una máquina que reconocerá el mundo. En una discusión pública, la promesa puede llegar a entenderse como la inminente cons-

trucción de un cerebro artificial. Cada transformación añade supuestos que el experimento no verificó. La cadena no exige mala fe: basta con que la fascinación sea más rápida que la revisión de las condiciones.

Algo semejante ocurre cuando observamos un modelo generativo actual. Un sistema resuelve una tarea difícil, obtiene un resultado destacado en una evaluación o produce una respuesta que sorprende a especialistas. La observación puede ser perfectamente real. El salto a declarar que comprende todas las tareas de esa clase, que reemplazará una profesión o que actúa como un experto humano no se desprende automáticamente de ella. La historia del perceptrón enseña a identificar el lugar exacto donde una demostración deja de informar y comienza a prometer.

Sería demasiado sencillo atribuir el problema exclusivamente a la prensa. Los científicos también participan en la construcción del significado de sus descubrimientos, al elegir términos, analogías y escenarios de aplicación. Las instituciones que financian una tecnología tienen expectativas; las universidades compiten por reconocimiento; los laboratorios buscan continuidad presupuestaria. Las narraciones públicas no son un adorno que aparece después de la investigación. Pueden influir sobre qué líneas reciben recursos, qué problemas parecen interesantes y cuáles quedan relegados. Eso no demuestra que la ciencia sea solamente política. Significa que la ciencia real ocurre en comunidades, con recursos limitados y sistemas de legitimación.

En este terreno apareció una disputa que sería recordada durante décadas. Marvin Minsky, que había trabajado también en redes y mecanismos de aprendizaje, desarrolló con Seymour Papert un análisis matemático de las capacidades de ciertos perceptrones. Su libro *Perceptrons*, publicado en 1969, examinó con rigor límites de arquitecturas definidas formalmente. Parte de su importancia consiste precisamente en hacer visible qué problemas no pueden

resolver determinadas familias de modelos. No necesitamos convertir una crítica matemática en un ataque personal para reconocer su relevancia.

El problema comienza cuando confundimos los límites de una arquitectura con el fracaso de una disciplina completa. Un perceptrón elemental puede no resolver XOR sobre las entradas originales; una red con representaciones adicionales o suficientes niveles de transformación puede abordar funciones que quedan fuera de ese caso sencillo. No significa que cualquier red multicapa sea universalmente poderosa o fácil de entrenar. Significa que debemos describir qué clase de sistema estamos evaluando antes de anunciar qué puede o no puede hacer. Los resultados negativos también tienen condiciones de aplicación.

La explicación popular según la cual Minsky y Papert publicaron un libro y las redes neuronales desaparecieron de inmediato tiene una fuerza dramática que la vuelve sospechosamente cómoda.[12] El sociólogo de la ciencia Mikel Olazaran estudió esa controversia y argumentó que la llamada historia oficial se construyó en un contexto de legitimación de la IA simbólica, disputas de autoridad y distribución de recursos. Su análisis no implica que los teoremas de Minsky y Papert fueran erróneos. Propone examinar cómo ciertas conclusiones técnicas fueron interpretadas institucionalmente y por qué la explicación de un período de declive no puede reducirse a una causa única.

Las cronologías también contradicen la versión más simple. Los debates y dificultades de los programas conexionistas venían acumulándose antes de 1969; algunas líneas experimentales continuaron después. Las condiciones de financiamiento, las capacidades de hardware, las prioridades de investigación y las dificultades matemáticas contribuyeron de maneras que no pueden reducirse a una sola publicación. Más adelante llegarían arquitecturas multicapa, nuevas técnicas de entrenamiento y recursos computa-

cionales que permitirían resultados distintos. Pero esa parte de la historia merece su propio desarrollo, sin hacer pasar el desenlace posterior por algo que sus protagonistas de los años sesenta podían prever con claridad.

La controversia permite formular una pregunta epistemológica más profunda. ¿Qué significa refutar una idea científica? Cuando un experimento falla, podemos haber refutado una hipótesis concreta, una elección de parámetros o una expectativa de rendimiento. Cuando un teorema muestra una imposibilidad, la imposibilidad se refiere a una clase de sistemas y a supuestos explícitos. Ninguno de esos resultados autoriza, sin trabajo adicional, a declarar imposible todo lo que una comunidad imaginó bajo el mismo nombre. La precisión formal no debe abandonarse cuando pasamos de la matemática a la historia; debe aumentar.

Volvamos ahora a la biología que inspiró a Rosenblatt. Una neurona viva no es un sumador silencioso separado del organismo. Su membrana participa en procesos eléctricos y bioquímicos, sus conexiones cambian en múltiples escalas temporales y su actividad depende de una organización celular y tisular extraordinariamente compleja. Un cerebro no aprende solamente ajustando una frontera lineal entre dos categorías. Tiene estados internos, neuromodulación, historia de desarrollo, interacción corporal y ambientes que transforman aquello que el organismo percibe y necesita hacer. La analogía entre neuronas naturales y unidades artificiales puede orientar hipótesis; no otorga identidad de mecanismos.

Rosenblatt era consciente, al menos en su programa teórico, de que estaba trabajando con modelos. Su artículo de 1958 describe un sistema hipotético para investigar propiedades de organización y memoria. La simplificación era una elección metodológica. Y toda elección metodológica produce una deuda: aquello que decidimos dejar afuera puede resultar irrelevante para el problema

que estamos resolviendo, o puede ser justamente lo que expliquemos mal. La calidad del modelo depende de identificar esa diferencia, no de parecerse superficialmente a su objeto.

Aquí tu experiencia científica ofrece un punto de comparación particularmente fértil. En biología es habitual trabajar con modelos que sacrifican detalle para aislar relaciones. No necesitamos reproducir cada organismo de un ecosistema para estudiar una dinámica poblacional; tampoco bastan unas pocas ecuaciones para explicar toda la vida de ese ecosistema. Un mapa de vegetación puede resultar excelente para una escala espacial e inadecuado para otra. Un índice puede detectar una tendencia y no explicar su causa. Los modelos son instrumentos para interrogar la realidad; su utilidad no debería convertirse en una excusa para olvidar las condiciones de su construcción.

Cuando una aplicación generativa actual clasifica currículums, analiza documentos científicos o sugiere decisiones de una organización, conviene recordar la distinción entre representación, predicción, comprensión y acción. Que un modelo separe correctamente ejemplos históricos no garantiza que sus categorías sean científicamente válidas. Que reconozca una regularidad tampoco prueba que haya descubierto una causa. Que produzca una clasificación útil no responde quién debe decidir sobre las personas afectadas. Pasar de la percepción modelizada a la decisión institucional añade problemas que ninguna frontera matemática resuelve por sí sola.

Existe, además, una lección sobre el entrenamiento. El perceptrón aprendía de ejemplos que representaban aquello que se quería reconocer. Pero esos ejemplos no aparecen por generación espontánea. Alguien decide cuáles reunir, cómo etiquetarlos y qué equivocaciones importan. El sistema puede optimizar una respuesta respecto de esa colección y continuar siendo frágil frente a contextos que no estuvieron representados. La capacidad no reside

únicamente en el algoritmo: depende también de la relación entre los datos, el problema y el entorno de aplicación. En los sistemas contemporáneos esa relación se ha hecho inmensamente más sofisticada, pero no ha dejado de ser decisiva.

Pensar en términos de criterio experto cambia la pregunta que hacemos cuando vemos un resultado impresionante. En lugar de preguntar solamente «¿funciona?», preguntamos: «¿para qué distribución de casos?, ¿respecto de qué definición del problema?, ¿con qué nivel de error?, ¿comparado con qué alternativa?, ¿y cuáles son las consecuencias de equivocarse?». En vez de elegir una arquitectura porque su nombre inspira confianza, examinamos qué capacidades aporta y qué limitaciones introduce. En vez de exigir una certeza imposible, aprendemos a relacionar la confianza con las evidencias que la sostienen.

Eso no vuelve menos emocionante la historia de Rosenblatt. Al contrario. En sus comienzos, el perceptrón planteó una posibilidad de enorme alcance: en lugar de escribir una regla particular para cada imagen imaginable, podíamos diseñar procedimientos que adquirieran regularidades a partir de la experiencia. Era una nueva manera de pensar la relación entre quien construye una máquina y el comportamiento que la máquina desarrolla. La promesa trascendía los aparatos de su época, pero sus logros eran siempre concretos y sus límites, reales.

Es difícil contemplar la fotografía del Mark I conservado por el Smithsonian sin advertir cuánto cambió la materialidad de esta investigación. Hoy algunos sistemas aprenden a partir de cantidades inmensas de datos y contienen parámetros cuya escala habría resultado inconcebible en aquel laboratorio. Sin embargo, la distancia entre los dos momentos no borra el parentesco intelectual. Seguimos decidiendo cómo representar entradas, cómo ajustar parámetros, cómo establecer señales de calidad y cómo interpre-

tar el resultado. También seguimos expuestos a la tentación de atribuir a la máquina más de lo que nuestras pruebas demuestran.

La máquina de Rosenblatt prometía reconocer patrones. La discusión que produjo terminó revelando algo más amplio: las capacidades de una inteligencia artificial no pueden separarse de la arquitectura que las hace posibles ni de las narraciones humanas que explican su alcance. Un resultado matemático puede delimitar un modelo; una noticia puede exagerarlo; una controversia puede reorganizar una comunidad científica. Ninguno de esos hechos agota la historia.

Y mientras los investigadores discutían cuánto podían aprender las máquinas observando el mundo, otra línea de trabajo estaba a punto de mostrar que ni siquiera necesitábamos una percepción sofisticada para producir una impresión desconcertante de inteligencia. Bastaría con una conversación. Unas reglas de sustitución, algunas preguntas y la inclinación humana a encontrar una mente detrás de las palabras abrirían una nueva controversia. La próxima máquina no tendría que reconocer un rostro para parecer que reconocía a una persona. Tendría que responderle.

Capítulo 8 · La conversación que devolvía nuestras palabras

Una conversación puede ser profundamente reveladora aunque una de sus partes diga muy poco. A veces basta con que alguien nos pida que precisemos una palabra, nos devuelva una pregunta o permanezca en silencio el tiempo suficiente para que encontremos un sentido que no habíamos formulado antes. En semejantes situaciones, el trabajo de interpretar no está repartido de manera uniforme. Quien habla puede terminar atribuyendo a quien escucha una comprensión mucho mayor que la efectivamente demostrada. No se trata necesariamente de ingenuidad. Es una posibilidad inscrita en el lenguaje: las palabras no transportan su significado como un paquete cerrado. Lo reconstruimos al recibirlas.

A mediados de los años sesenta, Joseph Weizenbaum convirtió esa característica de la conversación en uno de los episodios más perturbadores de la historia de la computación. El programa que desarrolló en el Instituto Tecnológico de Massachusetts no necesitaba resolver problemas filosóficos, representar emociones ni poseer una teoría psicológica de la persona que tenía delante. Le bastaba con analizar algunas estructuras lingüísticas, identificar determinadas palabras y producir respuestas mediante reglas. Su nombre era ELIZA. El artículo con el que Weizenbaum describió el programa apareció en enero de 1966 en *Communications of the ACM*. No lo presentaba como una inteligencia general, sino como un sistema para estudiar ciertas formas de comunicación en lenguaje natural entre personas y computadoras.

La historia suele resumirse en una escena cómoda: alguien se sentaba frente a una terminal, hablaba con una máquina que imitaba a un psicoterapeuta y terminaba creyendo que era comprendido. La versión tiene una fuerza narrativa innegable. También simpli-

fica demasiado. Mezcla testimonios retrospectivos, interpretaciones posteriores y diferentes versiones de un programa que durante décadas conocimos sobre todo por su artículo y por recreaciones imperfectas. Para comprender lo que ocurrió, conviene comenzar por algo más humilde que la leyenda: una descripción técnica y un archivo de código.

Weizenbaum había construido ELIZA en el entorno de tiempo compartido del proyecto MAC del MIT. La importancia de ese detalle no se reduce a una fecha de la historia informática. Cuando una computadora deja de parecer una máquina que recibe un lote de instrucciones y devuelve resultados mucho después, y pasa a responder durante una interacción, cambia la experiencia de quien la utiliza. Un resultado puede ser leído como cálculo. Una respuesta inmediata, especialmente si retoma algo que acabamos de escribir, empieza a parecer una intervención. El soporte de la relación condiciona lo que creemos estar viendo.

En su publicación de 1966, Weizenbaum enumeró problemas que siguen resultando reconocibles: localizar palabras relevantes, descubrir un contexto mínimo, elegir transformaciones apropiadas, responder cuando ninguna palabra activa una regla y permitir editar los guiones que controlan el comportamiento del sistema. [13] La solución era ingeniosa precisamente porque no intentaba resolver primero todo el lenguaje. Dividía el problema en decisiones manejables. La máquina no tenía que descubrir el significado profundo de una historia familiar para responder a una frase que mencionara a la madre; podía disponer de una regla que tratara ese término como un indicio para continuar la conversación.

La diferencia es enorme, pero desde el lado humano puede hacerse invisible. Cuando un programa recoge una expresión y la devuelve transformada, reconocemos nuestra propia información en la respuesta. El sistema parece acordarse de nosotros porque utiliza palabras nuestras. Parece prestar atención porque la pre-

gunta llega en el momento oportuno. La persona aporta la biografía, el contexto y la expectativa de sentido; el programa organiza ciertas señales superficiales para sostener el intercambio. No es que la interacción no produzca nada. Produce una experiencia real. Lo que no demuestra por sí misma es la clase de comprensión que solemos atribuirle.

El guion más famoso fue DOCTOR. Su orientación imitaba ciertos rasgos de una conversación terapéutica no directiva: devoluciones, reformulaciones, invitaciones a continuar. La elección tenía una ventaja técnica poderosa. Un interlocutor que formula preguntas abiertas y ofrece pocos datos propios puede sostener el diálogo sin verse obligado a demostrar conocimientos específicos sobre el mundo. Cuando no sabe lo suficiente, la conversación no se interrumpe necesariamente; vuelve hacia la persona. El dispositivo funciona porque distribuye la carga del significado de manera peculiar: gran parte queda en manos del usuario.

Podemos imaginar, como ejemplo inventado y no como transcripción histórica, una frase: «No consigo decidir si debo cambiar de trabajo». Un programa que detectara la palabra «decidir» o la estructura «no consigo» podría contestar «¿Qué le impide decidir?» o «¿Por qué es importante para usted ese cambio?». La respuesta podría resultar oportuna. Podría incluso ayudar a alguien a ordenar sus ideas. Pero esa utilidad no permite concluir que el programa comprende el mercado laboral, las motivaciones de la persona, su situación económica o el costo de equivocarse. La calidad subjetiva del intercambio y la competencia del sistema son preguntas diferentes.

Durante mucho tiempo, la historia de ELIZA se contó sobre todo a partir de su artículo de 1966 y de recreaciones posteriores. En 2021, un equipo encontró en el archivo de Joseph Weizenbaum, conservado en el MIT, un listado del programa escrito en MAD-SLIP con una versión temprana del guion DOCTOR. La recupera-

ción permitió comparar implementaciones de 1965 a 1968 que no tenían exactamente las mismas funciones. La investigación publicada por el equipo en 2026 añadió otra incomodidad al archivo: ciertas conversaciones que la literatura había tratado como transcripciones canónicas aparecen editadas entre el registro de 1965 y las publicaciones posteriores.[14] No significa que el experimento fuera ficticio. Significa que la conversación divulgada también era un texto seleccionado y presentado por una persona, y que debemos estudiarla como tal.

La aparente sencillez de DOCTOR esconde una decisión de diseño extraordinariamente influyente. El programa no necesitaba conocer la historia de quien escribía para conseguir que esa persona construyera una historia con sus respuestas. Su participación consistía, en parte, en devolver fragmentos de la frase inicial transformados en preguntas. El trabajo lingüístico del programa estaba en las reglas; gran parte del trabajo de interpretación sucedía del otro lado de la terminal. Es importante no confundir esos dos procesos: una interfaz puede facilitar que una persona organice su experiencia sin poseer un modelo profundo de esa experiencia.

La arquitectura era deliberadamente separable. ELIZA constituía el mecanismo que buscaba términos, aplicaba transformaciones y mantenía cierto contexto mínimo; DOCTOR era un guion particular que definía cómo responder ante determinadas expresiones. Esa separación permitía imaginar otros usos sin reescribir todo el programa. El artículo de 1966 explica además por qué ciertas respuestas aparentemente banales podían ser apropiadas para el experimento: una pregunta abierta ofrecía continuidad conversacional sin comprometerse con una interpretación específica. Lo que para una persona podía sentirse como tacto, para el programa era una estrategia computacional para sostener el intercambio.

Podemos entenderlo mediante una comparación que no pretende describir literalmente el código. Si una puerta automática se abre cuando alguien se acerca, su conducta puede parecernos atenta: detectó nuestra presencia y facilitó el paso. Pero no necesitamos atribuirle una intención hospitalaria para explicar lo sucedido. Con ELIZA, el fenómeno se volvió más ambiguo porque el estímulo y la respuesta estaban compuestos por lenguaje, el mismo medio en el que los seres humanos expresamos dudas, deseos, recuerdos y emociones. La conversación invita a inferir una mente donde quizá solo hemos observado una transformación de símbolos.

El experimento también obliga a distinguir varios significados de la palabra memoria. Conservar una palabra durante algunos turnos, recuperar un fragmento y mantener una representación duradera de una persona son capacidades diferentes. El estudio del código recuperado permite precisar la cronología: la versión 1965b conservada en el archivo no incluye la función NEWKEY descrita para 1966; el mecanismo y el repertorio de guiones continuaron cambiando después. También contiene un editor interactivo denominado CHANGE. Nada de esto equivale a autobiografía, comprensión psicológica o aprendizaje autónomo. La arqueología del programa convierte una metáfora en una pregunta técnica: qué versión podía hacer qué operación.

Esta precisión altera nuestra lectura de las interfaces actuales. Cuando una herramienta dice que «recuerda», debemos preguntar qué persiste, durante cuánto tiempo, bajo qué permisos y con qué consecuencias si el dato es erróneo. Una memoria operativa puede ser excelente para retomar un documento y pésima para fundamentar una decisión científica. Una memoria personal puede facilitar continuidad y, simultáneamente, introducir riesgos de privacidad o contaminación de contexto. La cuestión no se resuel-

ve preguntando si la máquina «tiene memoria»; se resuelve identificando el mecanismo, su procedencia y aquello que permite comprobar.

La arqueología informática tiene algo en común con la arqueología de un laboratorio biológico. Un artículo registra la versión pública de una investigación; un cuaderno, un instrumento o una preparación conservada pueden mostrar cómo se realizó realmente. En el caso de ELIZA, el código recuperado contiene mecanismos que la descripción publicada no detallaba del mismo modo. El equipo de Finding ELIZA identificó, por ejemplo, una rutina de recuperación de recuerdos basada en un contador y en un procedimiento determinista ligado a las palabras introducidas. No era una memoria autobiográfica ni una facultad de evocación humana. Era una decisión computacional específica. La historia se vuelve más rica cuando reemplazamos la palabra «recordaba» por la pregunta «¿qué operación realizaba cuando parecía recordar?».

También aparece una capacidad menos difundida: la posibilidad de modificar partes del guion mientras el programa estaba en funcionamiento. En una versión del código había un editor interactivo. No significaba que ELIZA se reprogramara autónomamente ni que hubiera desarrollado una teoría de su propio comportamiento; permitía intervenir sobre las reglas del sistema. Pero cuestiona la representación de ELIZA como una pieza puramente fija, con un único comportamiento diseñado para siempre. La tecnología histórica era, a su manera, una familia de experimentos sobre qué significa construir y modificar una interfaz conversacional.

Los archivos mencionan además otros guiones vinculados con enseñanza de aritmética, investigación psiquiátrica, poesía y sátira política. DOCTOR se convirtió en el rostro público del proyecto, pero no agota sus posibilidades. Esta diferencia entre la historia de un artefacto y la historia de su ejemplo más famoso aparece re-

petidamente en la ciencia. Una demostración sencilla puede ser tan memorable que termina reemplazando en nuestra memoria el programa de investigación que debía ilustrar. Algo semejante ocurre cuando reducimos los modelos generativos contemporáneos a la pantalla de un chatbot, como si las interfaces visibles agotaran las arquitecturas y procesos que las hacen posibles.

ELIZA es una oportunidad para estudiar con cuidado una palabra que utilizamos con demasiada facilidad: «contexto». Para una persona, el contexto de una frase puede incluir relaciones de años, gestos que no se expresan, experiencias previas, conocimientos del entorno y expectativas sobre lo que se dirá después. Para el programa de Weizenbaum, el contexto operativo podía ser una estructura mucho más restringida, compuesta por palabras clave, patrones, transformaciones y ciertos mecanismos de continuidad. Esa restricción no era necesariamente un defecto del experimento. Era su condición de posibilidad: un problema complejo se volvía tratable al elegir qué aspectos podían representarse computacionalmente.

La lección no es que toda conversación informática sea superficial. Sería una extrapolación ilegítima. Los grandes modelos de lenguaje actuales se entrenan sobre enormes corpus, aprenden representaciones distribuidas y producen respuestas mediante procesos muy distintos de las reglas escritas para ELIZA. Pueden razonar acertadamente sobre numerosos problemas, utilizar herramientas y analizar documentos que ELIZA no habría podido procesar. Pero la diferencia de mecanismo no elimina el problema epistemológico abierto por aquella interfaz: ¿qué inferimos de la respuesta, y con qué justificación?

Cuando un modelo contemporáneo cita correctamente un artículo, tenemos evidencia de que produjo una referencia correcta en ese caso. Cuando encuentra un error en nuestro código y explica cómo corregirlo, tenemos evidencia de una intervención útil.

Cuando sostiene durante varias páginas una discusión filosófica, observamos una capacidad lingüística que puede resultar extraordinariamente sofisticada. Ninguno de esos hechos, por sí solo, decide qué experiencia subjetiva tiene la máquina, si comprende exactamente como una persona o si corresponde confiar en ella ante una decisión de alto impacto. Las preguntas no son intercambiables; tampoco requieren todas el mismo tipo de prueba.

Parte de la fascinación de ELIZA reside en el modo en que una conversación transforma al observador. No somos instrumentos de medición neutrales. Llegamos con hábitos sociales: esperamos turnos, interpretamos intenciones, buscamos coherencia y reparamos las ambigüedades del otro. Si una frase nos resulta extraña, con frecuencia atribuimos la rareza a una interpretación que todavía no entendimos. Esa generosidad conversacional sostiene vínculos humanos; frente a una máquina puede convertirse en un sesgo de atribución. No es exclusivamente un problema de usuarios poco expertos. Una persona con amplios conocimientos técnicos también puede sentirse persuadida por una respuesta elegantemente formulada.

Pero sería un error oponer a esa inclinación humana una frialdad supuestamente científica que nos obligara a desconfiar de cualquier diálogo. Hay un aspecto productivo en la situación. Una buena pregunta, aun cuando provenga de un sistema sin conocimiento personal de nuestra vida, puede conducir a una reflexión genuina. Una respuesta generada puede señalar una contradicción que habíamos pasado por alto. La utilidad intelectual del intercambio no exige que atribuyamos a la máquina todas las propiedades que hacen posible una relación humana. Podemos obtener valor sin inventar una persona detrás de la interfaz.

La distinción importa especialmente cuando hablamos de autonomía. Si una conversación nos permite examinar alternativas, identificar supuestos y ampliar el repertorio de preguntas, puede

fortalecer nuestra capacidad de decidir. Si, por el contrario, la fluidez de las respuestas nos conduce a delegar conclusiones que no hemos evaluado, puede debilitar nuestro juicio. No hay una consecuencia universal que podamos deducir del simple hecho de utilizar IA. Depende del problema, de las condiciones de uso, de los mecanismos de comprobación y de la manera en que conservemos nuestra responsabilidad sobre las decisiones.

Hay una diferencia entre sentirse escuchado, ser comprendido y recibir una intervención adecuada. Son tres dimensiones que pueden coincidir, pero no se implican necesariamente. Una persona puede encontrar alivio al escribir sus pensamientos, incluso si nadie los interpreta; otra puede recibir una explicación precisa sin sentirse reconocida; una tercera puede ser persuadida por una respuesta amable que contenga información falsa. El legado de ELIZA permite separar estos resultados sin despreciar ninguno. La experiencia subjetiva es un dato legítimo acerca de la interacción, pero no demuestra por sí sola la exactitud de una afirmación ni la competencia clínica, jurídica o científica del sistema.

Esta separación resulta particularmente importante cuando el modelo contemporáneo produce referencias bibliográficas. Una cita perfectamente formateada, presentada con serenidad y acompañada por una explicación elegante puede aumentar mucho la impresión de competencia. Sin embargo, las pruebas pertinentes son otras: ¿existe el documento?, ¿describe realmente el procedimiento atribuido?, ¿los resultados provienen de una muestra compatible con la afirmación?, ¿hay datos contradictorios? El tono no debe ocupar el lugar del contraste. La conversación puede ser el inicio de una investigación; no debería convertirse en su tribunal de última instancia.

Weizenbaum terminaría dedicando buena parte de su reflexión pública a estas diferencias. Su libro de 1976 no fue una denuncia de que las computadoras fueran inútiles, sino una intervención en

la discusión sobre los límites de convertir problemas humanos en operaciones calculables. Conviene evitar el retrato simplista del inventor arrepentido que de pronto descubre su error. La tensión que hace fecunda su historia es que alguien capaz de construir una herramienta ingeniosa podía reconocer, al mismo tiempo, que la utilidad del instrumento no justificaba utilizarlo para cualquier fin. La responsabilidad de elegir los fines continuaba siendo humana.

El criterio profesional aparece aquí como una arquitectura de la confianza. No se trata de sospechar de toda frase ni de aceptar cualquier respuesta plausible. Se trata de asignar a cada resultado el tipo de evidencia que corresponde. Si una IA ayuda a encontrar nuevas maneras de explicar un problema, la creatividad puede evaluarse por su utilidad y su originalidad. Si propone un tratamiento, una política laboral o una interpretación estadística, la exigencia cambia. El error de mayor costo sería usar el mismo patrón de confianza para las tres situaciones. ELIZA no resolvió esa cuestión; ayudó a revelar por qué sería imposible ignorarla.

En 1976 Weizenbaum publicó *Computer Power and Human Reason*, una obra cuyo subtítulo, «De juicio a cálculo», condensaba una preocupación que no había desaparecido con el éxito técnico de ELIZA. La cuestión ya no era solamente qué podían hacer las computadoras. También era qué tareas debíamos confiarles, cuáles requerían deliberación humana y qué riesgos aparecían cuando la autoridad de una decisión se desplazaba hacia un procedimiento formal. Esa posición provocó discusiones intensas en la comunidad de IA. El debate no puede despacharse suponiendo que Weizenbaum estaba sencillamente a favor o en contra de las máquinas; planteaba una pregunta sobre la legitimidad de determinados usos.

Esa pregunta se vuelve concreta cuando trasladamos la conversación a ámbitos como salud, educación o selección de personal. Un sistema puede brindar información accesible y reducir barreras. Puede ayudar a una persona a comprender documentos difíciles o preparar preguntas para una consulta. Pero las mismas características que lo vuelven cómodo —disponibilidad, paciencia, lenguaje familiar— pueden crear una impresión de conocimiento personal o autoridad que no está suficientemente justificada. El problema no se resuelve prohibiendo la tecnología ni celebrándola sin reservas. Exige diseñar contextos de uso, límites de confianza y mecanismos de contraste adecuados para las consecuencias de cada tarea.

Hay otra dimensión, más incómoda, que la historia recuperada de ELIZA permite ver. No solo interpretamos el resultado de una máquina: interpretamos una versión particular, producida en condiciones particulares. Si el código cambia, si el guion se modifica, si los mecanismos de recuperación difieren, cambian también las capacidades que estamos examinando. No existe «el comportamiento de ELIZA» al margen de sus implementaciones, del entorno informático y de las situaciones en las que se utilizó. Con los modelos generativos modernos sucede algo análogo cuando una misma denominación comercial engloba versiones distintas, configuraciones de herramientas, contextos y restricciones. Comparar sistemas sin identificar qué se comparó es una forma de producir conclusiones aparentemente precisas sobre objetos inestables.

La diferencia entre un registro de terminal y la versión de una conversación publicada importa. En el primero encontramos trazas de lo que ocurrió en una ejecución concreta; en la segunda encontramos, además, decisiones acerca de qué fragmentos mostrar y cómo presentarlos. Esa mediación editorial no es una falta por definición: también los artículos científicos seleccionan ejemplos. Pero obliga a distinguir una demostración ilustrativa de una muestra representativa del comportamiento del sistema. El mis-

mo cuidado resulta necesario cuando una empresa publica diez conversaciones exitosas de un asistente actual sin decir cuántas pruebas realizó, qué versiones utilizó o cuáles quedaron fuera de la selección.

Tal vez el descubrimiento más fecundo de aquel programa no haya sido una capacidad de la máquina, sino una característica de la relación entre una persona y una interfaz. Descubrimos que la apariencia de comprensión puede emerger de mecanismos mucho más modestos de lo esperado, porque el ser humano colabora activamente en la interpretación del intercambio. No se sigue de ello que toda comprensión artificial sea ilusoria. Se sigue algo más prudente y más útil: observar una conversación nos obliga a investigar tanto el mecanismo que produce las respuestas como la manera en que nosotros construimos su significado.

ELIZA había mostrado que una máquina podía sostener un diálogo aparentemente personal sin representar en profundidad a la persona. Casi al mismo tiempo, otros investigadores eligieron el camino opuesto: renunciar a hablar de cualquier cosa para conocer muchísimo sobre un problema delimitado. En lugar de devolver las palabras humanas, intentarían reducir un universo de hipótesis científicas mediante conocimiento especializado. La siguiente historia no transcurre en el terreno ambiguo de una conversación, sino entre moléculas que se fragmentan y datos experimentales que necesitan explicación.

Capítulo 9 · DENDRAL: las hipótesis que nacían de un espectro

En ciencia, no siempre observamos aquello que queremos conocer. Vemos sus efectos. Registramos una señal, medimos una variación, encontramos un patrón entre datos dispersos y tratamos de reconstruir el objeto que podría haberlo producido. Una huella permite imaginar un animal que ya no está presente; un conjunto de secuencias genéticas sugiere parentescos que nadie observó directamente; la distribución de ciertos elementos en un territorio revela procesos que una fotografía aislada no mostraría. Gran parte de la investigación consiste en pasar de las consecuencias a las causas posibles, y después encontrar una manera de distinguirlas.

La química orgánica ofrece una versión particularmente elegante de ese problema. Dos moléculas pueden contener los mismos tipos y cantidades de átomos y, sin embargo, tener estructuras distintas. Su fórmula informa de la composición, pero no siempre revela cómo están conectadas las partes. Es como recibir una caja con piezas de un mecanismo y saber cuántos tornillos, ruedas y varillas contiene sin saber cómo se organizan. La dificultad no consiste solamente en imaginar una configuración posible. Consiste en reducir las posibilidades hasta obtener aquellas compatibles con las observaciones.

En Stanford, durante la década de 1960, Joshua Lederberg, Edward Feigenbaum y un grupo interdisciplinario comenzaron a investigar cómo trasladar ese trabajo de inferencia científica a una computadora. Bruce Buchanan, Carl Djerassi, Georgia Sutherland y otros colaboradores participaron en distintas etapas de una empresa que terminaría conociéndose como DENDRAL. No se tra-

taba de construir un programa capaz de conversar libremente sobre cualquier asunto. El problema era, a primera vista, mucho más modesto: utilizar conocimientos de química y datos experimentales para proponer estructuras moleculares plausibles.

Pero a veces la ambición científica se reconoce precisamente en el modo de elegir un problema delimitado. Si una máquina podía formular y ordenar hipótesis químicas, quizá podríamos aprender algo general sobre cómo funciona la investigación cuando el espacio de posibilidades es inmenso. La pregunta ya no era si una computadora podía simular un diálogo inteligente, sino si podía colaborar en una actividad intelectual reconocible: razonar desde datos incompletos hacia explicaciones candidatas.

Para comprender el experimento debemos entrar, aunque sea brevemente, en la lógica de la espectrometría de masas. Una muestra se convierte en iones y el instrumento produce información asociada con relaciones entre masa y carga. En muchas condiciones, las moléculas generan fragmentos. El patrón de señales ofrece pistas sobre la estructura original, pero la relación no es una lectura directa, como si cada pico fuese una letra que pudiera traducirse sin ambigüedad. Diferentes estructuras pueden producir fragmentos semejantes; ciertos fragmentos aparecen con mayor probabilidad que otros; las condiciones instrumentales y las reglas químicas delimitan qué interpretaciones son razonables.

El desafío se parece al de reconstruir un animal a partir de rastros, con una diferencia importante: en química existen restricciones formales sobre qué enlaces y valencias pueden admitir determinadas especies de átomos. Una estructura candidata no puede proponer conexiones arbitrarias sin respetar esas restricciones. La información empírica ayuda a discriminar, y el conocimiento teórico impide considerar como equivalentes todas las combina-

ciones imaginables. En otras palabras, el programa necesitaba tanto capacidad para generar hipótesis como conocimiento para descartarlas.

DENDRAL estaba relacionado con un algoritmo destinado a enumerar configuraciones estructurales no redundantes bajo ciertas condiciones. Sin restricciones, el número de posibilidades crece rápidamente. El problema es combinatorio: cada decisión sobre cómo conectar una parte modifica las opciones restantes y multiplica los caminos posibles. No basta con disponer de una computadora rápida si la búsqueda se expande de manera incontrolable. Hace falta introducir principios que recorten el espacio de exploración sin eliminar, por error, las soluciones relevantes.

Los primeros capítulos de este libro habían mostrado cómo Allen Newell y Herbert Simon comprendieron el valor de las heurísticas para orientar la búsqueda en demostraciones matemáticas. En DENDRAL ese principio encontró una expresión particularmente fértil. La heurística dejó de ser solamente una estrategia general para elegir el siguiente paso: incorporó conocimientos de un dominio científico específico. Ciertas configuraciones químicas eran plausibles; otras violaban reglas; algunas predicciones sobre fragmentación hacían preferible una estructura frente a otra. Lo que un químico había aprendido a reconocer durante años podía traducirse, al menos parcialmente, en restricciones y reglas computables.

Este cambio tuvo un costo intelectual. El saber experto no aparece en una enciclopedia perfectamente ordenada, esperando ser copiado. Incluye regularidades, excepciones, aproximaciones y decisiones prácticas que sus propios usuarios no siempre explicitan. Una persona experimentada puede descartar una hipótesis porque «no encaja», pero convertir esa intuición en una regla requiere averiguar qué dato no encaja, bajo qué condiciones y con qué

grado de seguridad. La ingeniería del conocimiento, que posteriormente recibiría gran atención, surgía aquí como una tarea de investigación sobre el propio razonamiento experto.

La dificultad recuerda un problema frecuente en la biología de campo. Una investigadora puede reconocer un ave por una combinación de silueta, vocalización, patrón de vuelo y hábitat antes de ser capaz de enumerar todas las pistas. Si intenta describir el procedimiento para otra persona, descubre que algunas señales son decisivas en una estación y engañosas en otra; que ciertos rasgos sólo funcionan en combinación; que la experiencia transforma la importancia relativa de los indicios. Programar una clasificación exige convertir parte de ese conocimiento situado en representaciones explícitas. El proceso puede revelar conceptos útiles y, a la vez, perder matices.

DENDRAL no resolvió universalmente esa dificultad. La enfrentó mediante una colaboración entre informática, química y conocimiento experimental. El grupo no podía limitarse a pedir a un especialista que escribiera unas reglas y retirarse a programarlas. Debía discutir el problema, revisar predicciones, analizar casos donde el sistema fracasaba y modificar las restricciones. Su historia muestra que la inteligencia artificial aplicada nació, en buena medida, como una forma de trabajo interdisciplinario. La calidad no dependía únicamente del código, sino de las preguntas que el equipo sabía hacer a la ciencia del dominio.

El problema químico puede describirse con una palabra que aparece una y otra vez en inteligencia artificial: restricciones. Una fórmula molecular no identifica necesariamente una estructura. Indica qué átomos están presentes y cuántos de cada tipo, pero no agota las posibilidades de enlace. El espectro de masas aporta otra clase de evidencia: ciertos patrones de fragmentación son más compatibles con unas estructuras que con otras. La máquina podía generar candidatas y eliminar algunas mediante regularida-

des químicas disponibles. Para comprender el logro no necesitamos imaginar que el programa contemplaba las moléculas como lo haría una investigadora ante un modelo tridimensional. Necesitamos entender el problema de búsqueda y la manera de reducirlo con conocimiento del dominio.

Supongamos, como analogía y no como experimento histórico, que alguien entrega una lista de especies observadas, un clima regional y unas pocas fotografías de hábitat. Una investigadora de campo no propone cualquier ecosistema imaginable. Utiliza restricciones sobre distribución, estacionalidad, relaciones tróficas y métodos de detección. Algunas posibilidades son incompatibles con los datos; otras siguen abiertas. DENDRAL convertía ese principio en procedimientos computacionales para un dominio limitado. La fuerza del programa dependía de la calidad de esas restricciones, de la capacidad de generar alternativas y de la posibilidad de contrastarlas con nuevos datos.

Pero toda restricción tiene una ambivalencia. Si es correcta, descarta ruido; si es incorrecta, puede excluir justamente la respuesta buscada. Un sistema que simplifica un espacio de millones de configuraciones resulta impresionante, pero la reducción no garantiza que la configuración correcta haya sobrevivido. La validez del resultado depende de una cadena de supuestos: la fórmula inicial, la interpretación del espectro, el repertorio de reacciones consideradas y el procedimiento de enumeración. El problema de evaluar DENDRAL no es muy diferente del de evaluar una arquitectura moderna que combina recuperación documental, un modelo de lenguaje y validadores automáticos. Cada componente puede introducir errores, y una salida convincente puede ocultar que una alternativa fue descartada demasiado pronto.

Aquí se comprende por qué «conocimiento experto» no es lo mismo que una base extensa de datos. La especialización es, en buena medida, conocimiento acerca de qué detalles importan y cómo

cambian las conclusiones cuando ese detalle es distinto. Una sola condición química válida puede reducir más el espacio de búsqueda que miles de ejemplos no discriminantes. En otros dominios la relación será diferente, pero la lección persiste: la acumulación de información no reemplaza la arquitectura de inferencias que nos permite utilizarla. El valor de un sistema inteligente puede residir tanto en lo que se atreve a excluir como en lo que consigue generar.

En 1969, un artículo del *Journal of the American Chemical Society* documentó el análisis de éteres alifáticos mediante Heuristic DENDRAL. Su resumen registra un caso en el que el programa redujo 989 estructuras teóricamente posibles a diez candidatas utilizando exclusivamente información de espectrometría de masas.[15] Los autores señalaban que añadir datos de resonancia magnética nuclear podía restringir aún más las alternativas, generalmente hasta una sola estructura. La precisión del episodio está en sus condiciones: una familia de compuestos, determinadas reglas químicas y datos experimentales disponibles. No demuestra que DENDRAL identificara cualquier molécula por sí mismo. Sí documenta una reducción útil y comprobable del espacio de hipótesis.

Esa distinción merece atención. Una lista de diez hipótesis ordenadas es un producto científico valioso, pero no constituye una demostración final. El programa podría omitir una posibilidad correcta si las reglas fueran incompletas, ordenar mal las alternativas por una hipótesis física defectuosa o responder con falsa seguridad si las condiciones de la muestra no coincidieran con sus supuestos. Es mucho más interesante comprender qué reducción logró que convertirlo retrospectivamente en una máquina infalible. La ciencia avanza a menudo gracias a instrumentos que no reemplazan el juicio, sino que vuelven ciertas decisiones mejores y más manejables.

El trabajo de DENDRAL permite recuperar una diferencia epistemológica central. Deducir consiste en establecer qué consecuencias se siguen de ciertas premisas. Inducir implica generalizar a partir de observaciones. Abducir, en una formulación clásica, consiste en proponer una explicación capaz de dar cuenta de lo observado. La inferencia de estructuras moleculares utiliza estos movimientos de manera entrelazada. A partir de un espectro se generan explicaciones posibles; las reglas químicas permiten excluir contradicciones; nuevos datos discriminan entre candidatas. No hay una sola operación mágica denominada «pensar». Hay procedimientos distintos, cada uno con sus condiciones de validez.

Esta observación ayuda a comprender los sistemas generativos actuales sin forzar una continuidad tecnológica que no existe. Una IA contemporánea puede sugerir varias hipótesis para explicar un cambio en indicadores empresariales, un resultado experimental inesperado o una anomalía espacial. La abundancia de hipótesis no es en sí una ventaja si todas parecen igualmente plausibles. Necesitamos restricciones procedentes del conocimiento especializado, datos capaces de discriminar entre alternativas y procedimientos para comprobar qué explicación resiste el contraste. La colaboración con IA se vuelve más fértil cuando el sistema no produce solamente respuestas, sino candidatos que una investigación pueda evaluar.

Pero hay una diferencia decisiva entre pedirle a un modelo que imagine posibles explicaciones y diseñar un sistema que compruebe restricciones formales. Si una estructura química viola una condición fundamental, un verificador apropiado puede rechazarla con criterios explícitos. Si una respuesta generativa sobre recursos humanos incluye una generalización demográfica dudosa, la evaluación requiere además análisis estadísticos, fundamentos normativos y juicio sobre consecuencias. Algunas res-

tricciones pueden formalizarse; otras exigen deliberación. El criterio experto consiste, entre otras cosas, en reconocer qué tipo de comprobación necesita cada afirmación.

La investigación de DENDRAL dio lugar también a META-DENDRAL, una línea destinada a explorar la formación automática de reglas a partir de espectros y estructuras conocidos. En 1976, un artículo del Journal of the American Chemical Society describió un programa que buscaba regularidades de fragmentación mediante procedimientos heurísticos. En su resumen, los autores informaron ensayos con espectros de baja resolución de aminas alifáticas y espectros de alta resolución de esteroides estrogénicos; también declararon haber obtenido nuevas reglas para cetoandrostanos. Esos son resultados comunicados por los investigadores, no una prueba de validez general de las reglas fuera de los conjuntos estudiados. Sin el cotejo íntegro de métodos y resultados, tampoco corresponde asignar una tasa de acierto. El desplazamiento conceptual merece atención: además de utilizar reglas de un dominio, los investigadores empezaban a estudiar cómo obtener algunas de ellas a partir de ejemplos. Aprender reglas no elimina la necesidad de someterlas después al contraste científico.

La reconstrucción histórica obliga además a recordar a quienes desempeñaban papeles que las historias de grandes inventos suelen comprimir. Joshua Lederberg aportó conocimiento químico y una visión de la investigación científica; Edward Feigenbaum y Bruce Buchanan trabajaron sobre representación de conocimiento y programas; otros integrantes contribuyeron con reglas, datos, instrumentos y pruebas de dominio. La lista de autores y las fechas de publicaciones distintas impiden convertir el proyecto en una escena única de iluminación. DENDRAL fue una práctica de colaboración: una disciplina aprendía a formular parte de sus problemas en términos manipulables por otra, y esa traducción cambiaba lo que ambas podían hacer.

El intercambio no era simétrico ni automático. Para que una regla química pudiera utilizarse en el sistema, alguien tenía que identificarla, expresarla de manera operacional y comprobar que sus excepciones no la volvían peligrosa. Para que una salida del programa sirviera a la química, otra persona debía situarla frente a las propiedades de los instrumentos y las limitaciones de las muestras. Esta tarea de traducción entre dominios tiene su propio costo intelectual. A menudo es invisible porque se entrega una lista final de estructuras, como si el conocimiento hubiera nacido ya en formato computacional.

Cuando apareció la investigación sobre META-DENDRAL, la pregunta cambió de escala.[16] Si era difícil codificar manualmente el conocimiento del dominio, ¿podría un programa contribuir a inducir reglas a partir de pares conocidos de espectros y estructuras? La propuesta abría otra forma de colaboración, pero también multiplicaba los riesgos de circularidad. Si las reglas aprendidas se evaluaban únicamente con ejemplos del mismo tipo, podían parecer extraordinarias sin demostrar utilidad fuera de ese conjunto. Había que preguntar por nuevos compuestos, por variación instrumental, por supuestos físicos no incluidos y por la posibilidad de refutar las reglas propuestas. Aprender reglas no libera de la metodología científica; modifica el lugar donde debemos aplicarla.

También aquí existe una conexión fértil con IA generativa. En una organización, una IA puede sugerir criterios de selección de personal a partir de registros históricos. Pero los registros contienen las decisiones anteriores, con sus aciertos y posibles barreras. Si el sistema aprende exclusivamente a reproducirlas, quizá mejore su precisión para imitar el pasado y empeore su capacidad para identificar talento ignorado. La diferencia entre reproducir una práctica y descubrir una regla válida resulta crucial. No se corrige

agregando un aviso genérico sobre sesgos; se corrige examinando qué variable se quiere predecir, qué resultado merece valorarse y qué evidencia sería suficiente para justificar el cambio.

La pregunta contiene una paradoja práctica. Para obtener conocimiento confiable a partir de datos necesitamos supuestos acerca de cómo interpretarlos. Pero si esos supuestos son demasiado estrictos, el sistema no descubrirá nada que contradiga nuestras expectativas. Un algoritmo puede convertirse en excelente reproductor de reglas viejas. O puede producir novedades que nadie sabe validar. Entre ambos extremos se encuentra la tarea difícil de diseñar mecanismos capaces de proponer, contrastar y corregir. Es un equilibrio que reaparece en todas las disciplinas donde utilizamos modelos para investigar fenómenos complejos.

En las décadas siguientes, los sistemas expertos adquirieron una identidad comercial más amplia. Muchas organizaciones intentaron convertir procedimientos profesionales en reglas. Algunas aplicaciones resultaron valiosas; otras descubrieron lo difícil que era mantener representaciones actualizadas cuando cambiaban las condiciones de trabajo. DENDRAL suele aparecer en esa historia como uno de los antecedentes más importantes. Pero conviene no proyectar sobre el proyecto científico todas las promesas posteriores de una industria. Su contribución más interesante no depende de que los sistemas expertos hayan conquistado o no el mercado; depende de haber mostrado con claridad el valor y el costo de incorporar conocimiento especializado a una arquitectura computacional.

En un sistema moderno de asistencia científica, el equivalente conceptual de esa lección no es necesariamente escribir miles de reglas a mano. Puede consistir en conectar un modelo generativo con bases de datos de calidad, motores de búsqueda documental, validadores de unidades, bibliotecas estadísticas y fuentes científicas trazables. Puede requerir una cadena de herramientas donde

una operación propone hipótesis y otra verifica restricciones. Puede exigir que el sistema reconozca sus límites y solicite intervención cuando falte información. Estas son extrapolaciones de diseño contemporáneo, no funciones históricas que DENDRAL ya realizara.

Consideremos un ejemplo cercano a la investigación aplicada. Un conjunto de datos registra cambios en la distribución de especies en un territorio a lo largo de varios años. Un asistente generativo puede construir una narración coherente: el cambio climático desplazó las poblaciones. Pero una narración coherente no basta. Tal vez variaron los esfuerzos de muestreo, cambió la detectabilidad, se modificaron los límites de observación o existieron transformaciones de uso del suelo. Antes de aceptar una explicación necesitamos reconstruir el universo de posibilidades y determinar qué datos permiten descartar alternativas. DENDRAL nos recuerda el valor de esas restricciones disciplinarias: una hipótesis gana fuerza cuando sobrevive a pruebas capaces de hacerla fracasar.

En ese sentido, los sistemas especializados pueden alcanzar una competencia muy alta sin poseer una inteligencia de propósito general. Esto también corrige una intuición frecuente: una máquina que conversa de cualquier tema puede parecer más inteligente que otra que sólo trabaja con química, aun cuando la segunda cuente con mecanismos de validación extraordinariamente sólidos en su dominio. La amplitud del lenguaje y la profundidad de la competencia no son dimensiones equivalentes. Un sistema de usos generales puede ser flexible; uno especializado puede ser confiable en tareas delimitadas; ninguno tiene por qué dominar todas las propiedades deseables al mismo tiempo.

La historia documentada de DENDRAL tampoco es la historia de un solo inventor. Su logro exigió unir tradiciones científicas, infraestructuras, datos, reglas de interpretación e interlocutores capa-

ces de corregirse mutuamente. El artículo retrospectivo de 1993, firmado por Robert Lindsay, Bruce Buchanan, Edward Feigenbaum y Joshua Lederberg, analizó dos décadas de trabajo y destacó la estrategia de utilizar conocimientos detallados del problema como fuente de heurísticas. Ese registro retrospectivo ayuda a ordenar los logros, pero debe leerse junto con trabajos contemporáneos que muestran qué podía hacer el sistema en distintos momentos. La reconstrucción responsable no comprime veinte años de investigación en un descubrimiento instantáneo.

Si ELIZA enseñaba que un programa puede parecer que comprende mucho mientras utiliza recursos relativamente limitados, DENDRAL mostraba que una máquina puede contribuir a un problema científico difícil precisamente por conocer —en una representación deliberadamente restringida— determinadas propiedades de un dominio. La apariencia y la capacidad dejaban de coincidir con facilidad. Una interfaz conversacional atractiva podía ocultar mecanismos simples; un sistema que producía una lista de estructuras químicas podía encerrar una sofisticada organización del conocimiento experto. Para evaluar una IA, no bastaba con observar qué tan humana parecía.

Sin embargo, la confianza en los sistemas capaces de razonar mediante reglas y conocimiento especializado también preparó nuevas promesas. Si un programa podía ayudar a interpretar espectros, ¿por qué no codificar el saber de todas las profesiones? Si ciertas tareas podían formalizarse, ¿cuántas más estaban esperando el mismo tratamiento? Entre las demostraciones específicas y las ambiciones generales comenzó a crecer una distancia que la historia de la IA pagaría de manera desigual. La próxima etapa no sería simplemente una sucesión de fracasos. Sería una disputa por decidir qué debíamos esperar de la tecnología, quién financiaba esas expectativas y qué merecía llamarse progreso.

Capítulo 10 · Los inviernos que nunca fueron uno

Hay una metáfora que aparece casi inevitablemente cuando se cuenta la historia de la inteligencia artificial: el invierno. Su atractivo es evidente. Después de un período de grandes promesas, el entusiasmo se enfría, los presupuestos se contraen, las empresas desaparecen y los investigadores tienen que justificar por qué merece la pena seguir trabajando. Entonces, años después, una primavera tecnológica demostraría que las ideas habían sobrevivido bajo la nieve. Es una historia fácil de recordar. Precisamente por eso merece nuestra desconfianza.

El tiempo histórico no funciona como una estación meteorológica que llega de manera uniforme a todas las instituciones. Una comunidad puede atravesar dificultades presupuestarias mientras otra publica resultados importantes. Un paradigma puede perder prestigio sin desaparecer de los laboratorios. Una tecnología puede fracasar como producto y, sin embargo, dejar métodos que transforman disciplinas enteras. Llamar «invierno» a todas esas situaciones ayuda a ordenar la narración, pero también corre el riesgo de ocultar las diferencias que necesitamos comprender.

La explicación según la cual un informe británico habría apagado por sí solo la inteligencia artificial mundial resulta demasiado cómoda. El informe Lighthill de 1973 existió y cuestionó duramente varios programas de investigación, pero una revisión parlamentaria británica de 2018 señaló que no estaba clara la relación causal directa entre el informe y una eventual reducción de la financiación.[17] El mismo documento recuerda que en Estados Unidos también creció el escepticismo por su propia trayectoria. Hablar

de un invierno uniforme oculta decisiones institucionales, límites técnicos y controversias que no ocurrieron del mismo modo en todos los lugares.

Para entender su origen hay que mirar a Edimburgo. La universidad había desarrollado una comunidad de investigación en inteligencia artificial durante la década de 1960. Donald Michie, vinculado durante la Segunda Guerra Mundial a los trabajos criptográficos de Bletchley Park, participó en la formación de un grupo que comenzó en 1963 y adquirió reconocimiento institucional a mediados de la década. En 1966 se creó un departamento que reunía investigadores interesados en percepción, razonamiento, aprendizaje y máquinas capaces de actuar en el entorno. No era un espacio homogéneo. Sus integrantes discutían la naturaleza de la inteligencia y los métodos apropiados para estudiarla.

La historia oficial de la propia Universidad de Edimburgo documenta tanto los logros de investigación como los desacuerdos entre sus responsables. Entre los proyectos figuraba FREDDY II, un robot que podía realizar determinadas tareas de manipulación y ensamblaje. Para quienes desarrollaban esas máquinas, construir inteligencia implicaba relacionar percepción, acción y un mundo que no se acomodaba dócilmente a las reglas del programa. Para otros investigadores, el centro de la disciplina debía estar en los procesos de razonamiento o en modelos de funciones psicológicas. Las discrepancias no eran simples cuestiones de temperamento. En el fondo había teorías incompatibles sobre qué problemas debían resolverse primero.

En un laboratorio, la competencia entre programas de investigación puede ser productiva: obliga a formular mejores preguntas, comparar métodos y examinar límites. Pero cuando las instituciones compiten por recursos, plazas y legitimidad, esos desacuerdos adquieren otras consecuencias. El financiamiento no es un fondo neutral que acompaña a la mejor idea de manera automática.

Pasa por organismos, evaluadores, agendas políticas y expectativas de utilidad. La ciencia necesita demostrar resultados, pero también necesita negociar qué cuenta como resultado suficientemente valioso y en qué horizonte temporal debería aparecer.

Sir James Lighthill recibió el encargo de examinar el campo. Su informe, elaborado a comienzos de los años setenta y difundido en 1973, dividía los trabajos en tres grandes categorías. La primera reunía aplicaciones de automatización avanzada; la segunda, simulaciones computacionales relacionadas con procesos del sistema nervioso. La tercera ocupaba un territorio intermedio: integrar métodos para construir robots o sistemas inteligentes capaces de actuar. Lighthill reconocía ciertos avances en los extremos y se mostraba particularmente escéptico respecto de la ambición integradora. Parte de su crítica se relacionaba con un problema matemático que ya conocemos: el crecimiento explosivo del número de posibilidades cuando una tarea aparentemente sencilla se generaliza.

Una máquina puede clasificar una colección limitada de objetos bajo condiciones controladas. Otra puede resolver un pequeño problema de búsqueda. Pero trasladar esos éxitos a un entorno lleno de excepciones, relaciones cambiantes y objetivos simultáneos es mucho más difícil. Los investigadores no ignoraban ese problema; discutían cómo enfrentarlo. Lighthill consideraba insuficientes muchas de las soluciones propuestas. Su evaluación tenía una dimensión técnica que merece ser discutida, aunque no compartamos todas sus conclusiones. Un crítico no se convierte en enemigo de una ciencia simplemente porque cuestione sus promesas.

En junio de 1973, la controversia llegó a un debate televisado en la Royal Institution, con Lighthill, Donald Michie, Richard Gregory y John McCarthy. El registro conservado por el centro de investigación de Edimburgo permite comprobar quiénes participaron y de

qué se trató la discusión. No necesitamos inventar el ambiente de la sala ni reproducir palabras no cotejadas para advertir la importancia del acontecimiento. Una disciplina naciente debía explicar públicamente qué significaba su nombre, qué había conseguido y por qué los resultados parciales justificaban continuar invirtiendo en objetivos ambiciosos.

La crítica de Lighthill contenía una pregunta técnica que no desapareció con el avance de la potencia de cálculo. Los problemas de una máquina podían ser relativamente fáciles si el universo de opciones era pequeño y estaba bien descrito. Pero una combinación de decisiones sencillas podía producir una cantidad de alternativas que creciera más rápido que los recursos disponibles. No era solo una cuestión de optimismo o pesimismo personal: detrás del desacuerdo existía una dificultad matemática auténtica, asociada con los costos de búsqueda en espacios combinatorios. De esa constatación no se deducía que toda IA general fuera imposible, ni que la investigación careciera de valor. Se deducía que una promesa tecnológica necesitaba explicar cómo administraría ese crecimiento.

Imaginemos un sistema que debe elegir diez acciones y dispone de cien opciones para cada decisión. Si examinara todas las secuencias posibles sin podar alternativas, el número de combinaciones resultaría inmenso. En la práctica usamos heurísticas, restricciones, representaciones y mecanismos de aprendizaje precisamente porque la enumeración exhaustiva suele resultar inviable. La dificultad es que esos recursos introducen sus propios supuestos. Una heurística ahorra tiempo, pero puede pasar por alto una vía útil; un modelo estadístico reduce esfuerzo de búsqueda, pero puede cometer errores sistemáticos; una arquitectura agentiva reparte tareas, pero agrega dependencias y oportunidades de fallo. El desacuerdo histórico sobre «escala» reaparece hoy como decisión concreta de ingeniería.

Podemos reconocer allí un problema de política científica. Quien financia una investigación no siempre quiere saber si una idea tiene interés a largo plazo: quizá necesite determinar si producirá un resultado fiable dentro de un plazo presupuestario. Una crítica honesta a un programa exagerado puede proteger recursos y mejorar el diseño de experimentos. También puede provocar efectos de reputación que desalienten líneas prometedoras antes de que existan las herramientas para evaluarlas. Para comprender un invierno de la IA necesitamos observar ambas posibilidades. No toda crítica fue injusta, pero tampoco toda retirada de apoyo constituyó una conclusión científica sobre los límites definitivos de la inteligencia artificial.

Los documentos británicos ofrecen interpretaciones diferentes sobre la magnitud del efecto del informe en las decisiones posteriores de financiación. El archivo de Edimburgo destaca la pérdida de confianza institucional, mientras que un comité parlamentario de 2018 advirtió que no estaba claro si el informe causó por sí mismo una reducción del financiamiento. No necesitamos elegir uno de los relatos para descartar al otro. Hablan desde fuentes, momentos y preguntas distintas. El trabajo historiográfico consiste en separar aquello que los documentos prueban —la existencia de la evaluación y del debate, el desacuerdo y los cambios de clima intelectual— de las relaciones causales que siguen siendo discutibles.

La discusión tenía un problema adicional: no todos los participantes estaban prometiendo exactamente lo mismo. Si una investigadora buscaba comprender mecanismos de percepción, su éxito debía medirse de manera distinta al de un ingeniero que intentaba construir un brazo robótico útil. Si un equipo pretendía resolver problemas matemáticos formales, no era razonable evaluar su trabajo como si hubiera prometido un asistente conversacional de propósito general. La palabra «inteligencia» reunía programas

con criterios de éxito diferentes. Una crítica general podía revelar limitaciones comunes, pero también pasar por alto avances importantes en trabajos cuya finalidad era otra.

La situación británica no agota la historia. En Estados Unidos, otros programas atravesaron frustraciones y evaluaciones propias. El informe ALPAC de 1966, elaborado en el ámbito de la Academia Nacional de Ciencias, examinó las perspectivas de la traducción automática en un contexto donde las expectativas comerciales y estratégicas eran elevadas. La publicación permite comprender que las dificultades de procesamiento del lenguaje no aparecieron por una simple pérdida de entusiasmo filosófico. Había problemas concretos de calidad, costo y evaluación, y quienes financiaban estos esfuerzos necesitaban decidir si sus resultados justificaban nuevas inversiones.

Aquí reaparece una lección que resultará muy familiar a cualquier persona que haya implementado IA en una organización. La demostración de una capacidad no resuelve automáticamente su viabilidad. Una herramienta puede producir una traducción sorprendente y, aun así, resultar demasiado costosa para el volumen de trabajo requerido. Puede responder correctamente en una muestra y fallar cuando cambia el dominio. Puede reducir ciertos tiempos mientras introduce tareas de revisión que no estaban previstas. La evaluación profesional exige comparar el sistema completo con una alternativa real, no solamente mostrar su mejor ejemplo.

Tampoco conviene reducir los años setenta a un paisaje de proyectos cancelados. DENDRAL y otras investigaciones sobre sistemas expertos continuaron desarrollándose. Había trabajos en robótica, lógica, representación del conocimiento y percepción. Las disciplinas no se detuvieron al mismo tiempo ni por los mismos motivos. La metáfora del invierno es especialmente engañosa cuando la utilizamos para explicar retrospectivamente por qué

una línea de investigación, que hoy consideramos central, ganó o perdió visibilidad. El hecho de que una idea triunfe décadas después no prueba que sus críticos anteriores ignoraran pruebas concluyentes; puede significar que cambiaron los datos, la capacidad computacional, las técnicas o la definición misma del problema.

Lo ocurrido con los perceptrones ofrece una advertencia. La crítica matemática a determinados tipos de redes fue real, pero atribuir el declive de toda una tradición de investigación a un solo libro convierte una historia compleja en un drama personal. La historiografía de Mikel Olazaran muestra cómo se formaron relatos oficiales en torno a aquella controversia. No significa que las rivalidades o los efectos institucionales fueran imaginarios. Significa que necesitamos más que un villano y una fecha para explicar por qué cambia una comunidad científica.

En paralelo, otras tradiciones científicas formularon preguntas diferentes. En la Unión Soviética, las investigaciones sobre cibernética, gestión y control de sistemas complejos adquirieron rasgos propios. La historiadora Olessia Kirtchik ha analizado el programa de Dmitry Pospelov y sus enfoques de gestión situacional durante las décadas de 1970 y 1980. Allí la cuestión de la inteligencia no se organizaba únicamente alrededor de reproducir el razonamiento individual. También aparecía vinculada con decisiones en sistemas complejos, coordinación y representaciones de situaciones que no podían formalizarse completamente.

Para comprender el alcance de ese enfoque, pensemos en una ciudad, una cuenca hidrográfica o una gran organización. Ninguna regla aislada describe todas sus dinámicas. Hay actores con objetivos diferentes, información incompleta, procesos materiales y decisiones que modifican el sistema mientras intentamos comprenderlo. Modelar y gobernar esas situaciones requiere algo más que encontrar una solución óptima en un espacio estático de opciones. La noción de «situación» introduce historia, contexto, cambios y

agentes que interactúan. No era la misma arquitectura de los sistemas generativos actuales, pero sí otra respuesta al problema de cómo representar inteligencia en entornos complejos.

La investigación de Kirtchik debe leerse como una interpretación historiográfica fundada en archivos y publicaciones, no como una descripción exhaustiva de todas las líneas soviéticas. Justamente esa precisión impide convertir la diversidad geográfica en un complemento decorativo. Una historia global de la IA no consiste en agregar nombres de países a una cronología estadounidense. Consiste en reconocer que las instituciones plantearon problemas distintos y que sus prioridades científicas y políticas configuraron técnicas distintas. La pregunta por la inteligencia puede llevarnos a un programa de ajedrez, a una red de neuronas ideales o a un sistema destinado a representar decisiones de gestión, sin que uno de esos caminos sea necesariamente el destino natural de los demás.

A comienzos de los años ochenta, la inteligencia artificial volvió a convertirse en objeto de grandes expectativas comerciales y estatales. Los sistemas expertos prometían hacer disponibles conocimientos especializados en ámbitos donde pocas personas podían ofrecerlos. Empresas y gobiernos encontraron atractiva la posibilidad de incorporar reglas de decisión a computadoras de uso profesional. La combinación de problemas concretos y resultados tangibles parecía ofrecer aquello que las ambiciones más generales habían dejado pendiente: aplicaciones económicamente defendibles.

Pero el crecimiento trajo sus propias dificultades. Una base de reglas puede funcionar en un conjunto de casos conocidos y volverse frágil cuando aparecen excepciones. Cada ampliación del conocimiento requiere revisar relaciones con reglas anteriores. Extraer conocimiento tácito de especialistas consume tiempo. Un programa diseñado para una configuración de hardware o de una

organización puede resultar costoso de mantener cuando ambas cambian. La especialización que proporciona precisión también puede dificultar la adaptación. Nada de esto demuestra que la representación mediante reglas sea inútil. Demuestra que una arquitectura puede tener ventajas decisivas en determinadas tareas y restricciones severas cuando cambia el contexto.

En 1982 Japón lanzó oficialmente el proyecto de las computadoras de quinta generación. La iniciativa, coordinada mediante ICOT, buscaba nuevas tecnologías orientadas al procesamiento de información basada en conocimiento, incluyendo máquinas de inferencia paralela. El museo de la Information Processing Society of Japan conserva una descripción de sus objetivos, prototipos y trayectoria hasta 1992. No fue una mera reacción tardía a una supuesta primavera estadounidense; representaba una apuesta nacional, con sus propias instituciones, ambiciones tecnológicas y criterios de desarrollo.

Su historia permite formular otra pregunta incómoda. Cuando un país invierte durante años en una tecnología que no produce la revolución comercial anunciada, ¿debemos considerar el programa un fracaso completo? La respuesta depende de lo que evaluemos. Si solo contamos el cumplimiento de determinadas promesas, podemos ignorar herramientas, conocimientos técnicos, formación de investigadores e infraestructura. Si solo destacamos esos beneficios indirectos, podemos ocultar costos y objetivos incumplidos. La evaluación responsable necesita distinguir resultados esperados, logros reales y efectos secundarios, sin elegir después del hecho el indicador que mejor defiende nuestra posición.

La experiencia japonesa obliga a resistir otra simplificación: la de confundir un proyecto de investigación con una promesa de producto comercial. El programa de quinta generación comenzó en 1982 con una ambición nacional de computación orientada al conocimiento. Su centro de investigación, ICOT, desarrolló prototi-

pos de máquinas de inferencia paralela y trabajó con programación lógica. Los registros del museo de la Information Processing Society of Japan describen varios prototipos y una inversión sostenida durante once años. Sería históricamente falso narrarlo simplemente como una iniciativa que no produjo nada porque no desembocó en la máquina universal que algunos imaginaban.

Sin embargo, sería igualmente problemático confundir prototipos extraordinarios con adopción masiva o con utilidad económica demostrada. Una evaluación publicada en 1993 señala avances en sistemas de programación lógica paralela y hardware de inferencia, pero también aplicaciones limitadas a demostraciones y escaso encaje con ciertas necesidades de los usuarios. Ambas observaciones pueden sostenerse a la vez. La historia de las tecnologías no divide sus proyectos en vencedores y perdedores absolutos. Un programa puede crear conocimiento técnico, formar especialistas y producir herramientas experimentales mientras fracasa en sus objetivos comerciales o de difusión.

Este contraste ayuda a precisar una distinción necesaria para usar IA en empresas o instituciones científicas. Un prototipo demuestra una posibilidad bajo determinadas condiciones; un piloto investiga su utilidad en un contexto acotado; una operación estable exige mantenimiento, seguridad, documentación y continuidad; una mejora organizacional requiere además medir efectos sobre personas, costos y calidad. La distancia entre esos niveles no desaparece porque un agente ejecute una tarea impresionante una sola vez. Tampoco se elimina por la cantidad de módulos de una arquitectura. La pregunta senior no es cuánto parece poder hacer la máquina, sino qué desempeño podemos sostener de manera confiable, reproducible y beneficiosa.

Quizás por eso la metáfora del invierno sea tan persistente y tan insuficiente. Nos permite transformar una serie de cambios institucionales heterogéneos en una estación natural, como si el entu-

siasmo creciera solo en primavera y la financiación se retirara inevitablemente en invierno. Pero las decisiones tienen responsables, hipótesis, instrumentos de medición, incentivos e intereses. Explicar un invierno es investigar un sistema socio-técnico, no describir el clima. Y en esa investigación encontramos algo útil para nuestro presente: las expectativas se vuelven más peligrosas cuando se separan demasiado tiempo de los mecanismos que permitirían refutarlas.

A fines de los ochenta se intensificaron las dificultades de muchos proyectos comerciales basados en sistemas expertos y máquinas especializadas para ejecutar programas de IA. El mercado de las estaciones Lisp sufrió transformaciones profundas frente a computadoras de propósito general cada vez más potentes y accesibles. Las tecnologías dedicadas podían perder competitividad aun cuando los algoritmos que ejecutaban conservaran valor. La arquitectura de un producto, los costos de mantenimiento y la evolución del hardware modificaban las posibilidades comerciales tanto como las cualidades intelectuales del sistema.

El llamado segundo invierno, por tanto, tampoco fue una sola noche fría. Fue una combinación de promesas sobreextendidas, costos, cambios de mercado, limitaciones técnicas y expectativas institucionales. Los proyectos de investigación no desaparecieron al mismo ritmo que ciertos productos. Algunas ideas quedaron marginadas; otras se incorporaron silenciosamente a herramientas que ya nadie llamaba inteligencia artificial. A veces la adopción exitosa vuelve invisible la tecnología que la hizo posible: cuando un método se convierte en parte de la infraestructura corriente, pierde su condición de novedad incluso mientras aumenta su influencia.

Para una profesional que trabaja con IA generativa, esta historia no es un recordatorio melancólico de fracasos pasados. Es un instrumento de interpretación del presente. Cada vez que un provee-

dor anuncia una capacidad extraordinaria, podemos separar la demostración de su despliegue; el desempeño en un conjunto de pruebas de la utilidad en un proceso concreto; la posibilidad técnica de la sostenibilidad económica; el experimento exitoso de la gobernanza necesaria para utilizarlo. Ninguna de estas distinciones requiere cinismo. Exigen curiosidad disciplinada.

También conviene sospechar de los relatos en los que el futuro de la IA se presenta como una curva ascendente sin conflictos, o como una sucesión de burbujas destinadas a estallar. Ambos simplifican. La evolución de una tecnología combina mejoras medibles, expectativas que se adelantan a la evidencia, decisiones económicas y descubrimientos imposibles de predecir con exactitud. Una arquitectura puede progresar mientras su ecosistema comercial atraviesa dificultades. Otra puede dominar el mercado antes de que comprendamos sus límites. El éxito de una empresa y la madurez de un campo científico nunca fueron sinónimos perfectos.

La pregunta más útil quizá sea qué aprendieron los investigadores de los períodos difíciles. Una parte de la respuesta se encuentra en los límites de los sistemas que intentaban construir: la complejidad combinatoria, la fragilidad de reglas demasiado rígidas, la dificultad de adquirir conocimiento y el costo de trabajar con representaciones inadecuadas. Otra parte está en la política de la ciencia: la necesidad de sostener investigaciones cuyo valor no aparece de inmediato, sin convertir esa incertidumbre en una autorización para prometer cualquier cosa.

La tercera respuesta aparece cuando preguntamos qué quedó disponible después de las crisis. El hardware dedicado de una empresa podía dejar de ser competitivo, mientras las técnicas de búsqueda, los lenguajes o los procedimientos de evaluación desarrollados en su laboratorio seguían circulando. Un informe crítico podía cambiar prioridades sin detener todas las investigaciones del

campo. El saldo de un período difícil no se mide únicamente por las compañías que sobreviven: también por las herramientas que otros investigadores pueden reutilizar y por las preguntas que la escasez obligó a formular mejor.

Los inviernos de la inteligencia artificial nunca fueron uno solo. Fueron experiencias diferentes de incertidumbre, crítica y reorganización, que nuestra memoria condensó en una metáfora sencilla. Y mientras algunos laboratorios discutían cómo representar conocimiento de forma explícita, otros investigadores seguían una pista distinta: tal vez no necesitábamos describir una a una todas las regularidades del mundo. Tal vez podíamos construir sistemas capaces de ajustar internamente sus representaciones a partir de los ejemplos. Las redes neuronales no regresarían de un silencio absoluto; desarrollarían nuevas posibilidades técnicas en un paisaje científico que nunca había dejado de moverse.

Parte IV · Aprender de lo que el mundo deja registrado

Capítulo 11 · Las representaciones que nadie programó una por una

Hay una diferencia entre decirle a una máquina cómo reconocer algo y construir una máquina capaz de descubrir qué debe reconocer. La primera posibilidad exige que alguien haya identificado antes las propiedades importantes. La segunda parece más audaz, pero también es más difícil de comprender: si el sistema encuentra por sí mismo una representación útil, ¿dónde se encuentra ese conocimiento? ¿En una regla que podamos leer? ¿En una serie de números? ¿En una combinación de operaciones que ningún investigador previó de manera individual? Buena parte de la historia posterior de la inteligencia artificial puede recorrerse siguiendo las respuestas, siempre parciales, a esas preguntas.

La historia no comienza en 1986, aunque esa fecha aparezca habitualmente en los relatos abreviados. Comienza con la incomodidad que dejaron los primeros perceptrones y con una dificultad que parecía casi administrativa: para ajustar las conexiones de una red necesitamos saber cuáles contribuyeron a su error. En una sola capa de unidades, el camino entre una entrada y una respuesta puede ser relativamente visible. Cuando interponemos varios niveles de procesamiento, las decisiones se dispersan. Una conexión intermedia influye en otras; sus efectos dependen de las conexiones posteriores; la respuesta final no nos dice por sí sola a cuál de todas debemos atribuir la equivocación.

Supongamos que queremos construir un sistema que distinga fotografías de aves. Podríamos empezar por escribir una lista de características: forma del pico, longitud de las patas, disposición de las alas, proporciones del cuerpo, color del plumaje. Esa lista puede parecer natural para una zoóloga entrenada. Pero observemos

todo el conocimiento que contiene antes de que el programa realice una sola operación. Alguien ha elegido cuáles son las variables, ha decidido cómo medirlas, ha separado rasgos que quizá cambien con la edad o la estación y ha aceptado que algunos caracteres son difíciles de distinguir en determinadas fotografías. La inteligencia del procedimiento reside, en buena medida, en el trabajo previo de quien diseñó esa representación.

Una red de varias capas promete reorganizar el problema. En lugar de exigir que cada rasgo relevante sea definido de manera explícita por una persona, ciertas unidades intermedias pueden adquirir configuraciones de actividad que ayudan a distinguir categorías. Una unidad puede responder a combinaciones locales de información; otras pueden integrar señales anteriores y permitir una separación que antes parecía imposible. Pero hablar de «descubrir rasgos» exige cautela. Una representación aprendida es útil si contribuye a resolver una tarea en las condiciones de entrenamiento y evaluación. No necesitamos imaginar que el sistema ha descubierto el mismo concepto que utilizaría una especialista humana.

El obstáculo era conseguir que esas conexiones intermedias aprendieran. Había que modificar números de acuerdo con el resultado final, sin conocer de antemano qué modificación específica produciría una mejora. En el núcleo de la solución existe un concepto matemático antiguo, la regla de la cadena del cálculo diferencial. Si el resultado de una operación depende de otra, y esta a su vez depende de una tercera, podemos estudiar cómo cambia el resultado final cuando modificamos cada componente de la secuencia. La operación no inventa la noción de derivada ni convierte a la máquina en una criatura que reflexiona sobre sus errores. Proporciona una manera sistemática de distribuir información acerca del error a través de una composición de funciones.

Podemos imaginar una ruta de investigación hecha de varios instrumentos conectados. Un sensor registra una magnitud, una fórmula la transforma, otro procedimiento combina esa transformación con datos auxiliares y un modelo produce una estimación final. Si la estimación es incorrecta, conocer el error total no basta para descubrir qué parte del procedimiento debe ajustarse. Para evaluar la contribución de cada paso necesitamos examinar cómo sus variaciones afectan a los siguientes. La analogía es imperfecta —un instrumento científico real puede tener errores no diferenciables y causas que no se reducen a una función—, pero ayuda a comprender la intuición matemática: el error final puede recorrerse en sentido inverso para calcular sensibilidades locales.

Una formulación sencilla lo expresa sin necesidad de convertir el relato en un manual de álgebra. Supongamos que la salida de una unidad es una función de una suma ponderada de señales; la suma depende de pesos ajustables; una medida de pérdida indica cuán distinta fue la salida respecto del objetivo. El algoritmo calcula cómo cambia esa pérdida cuando varía cada peso. Después utiliza esas derivadas para modificar los parámetros en una dirección que, al menos localmente, debería reducir el error. En redes de varias capas, el procedimiento encadena esas relaciones desde la salida hacia las capas previas. La palabra «retropropagación» describe ese flujo de información de gradientes; no describe una reflexión consciente de la máquina sobre sus experiencias.[18]

Esta precisión importa porque incluso el nombre del procedimiento puede sugerir una explicación biológica demasiado literal. Las neuronas reales no son simples operaciones diferenciables organizadas en capas idénticas a las de una red artificial. El sistema nervioso aprende mediante múltiples mecanismos plásticos, temporales, químicos y anatómicos. Que una red artificial utilice unidades inspiradas remotamente en neuronas no demuestra que el encéfalo implemente el mismo algoritmo. La retropropagación fue poderosa como método de entrenamiento de modelos compu-

tacionales; su parecido con el aprendizaje biológico es una hipótesis que requiere pruebas adicionales, no una consecuencia del nombre.

Las raíces de este procedimiento fueron más dispersas de lo que sugiere una historia centrada en 1986. La regla de la cadena pertenecía desde hacía siglos al cálculo diferencial. En control y optimización se habían desarrollado técnicas para transmitir información de sensibilidad hacia atrás. Seppo Linnainmaa describió en 1970 una forma eficiente de diferenciación automática en modo inverso, sin presentarla como un método para entrenar redes neuronales; Paul Werbos examinó en su tesis doctoral de 1974 la propagación de derivadas en modelos de predicción y análisis. También hubo aportes posteriores de David Parker y Yann LeCun. La revisión histórica de Andreas Griewank muestra por qué asignar la invención a una sola persona borra líneas técnicas diferentes. Rumelhart, Hinton y Williams no inventaron las derivadas ni ese modo de calcularlas; contribuyeron decisivamente a divulgar y demostrar su utilidad para aprender representaciones en redes con unidades ocultas.

En octubre de 1986, David Rumelhart, Geoffrey Hinton y Ronald Williams publicaron en *Nature* un artículo breve cuyo título señalaba la cuestión crucial: aprender representaciones mediante la propagación retrospectiva de errores. El texto describía cómo ajustar repetidamente los pesos de una red para reducir una diferencia entre salidas deseadas y obtenidas, y cómo las unidades ocultas podían llegar a representar características importantes del dominio de la tarea. Fue una contribución extraordinariamente influyente, pero no una prueba de que cualquier red, con cualquier dato y cualquier problema, pudiera aprender una solución adecuada. La eficacia dependía de la arquitectura, los datos, la función objetivo, las condiciones de optimización y muchos otros factores.

Imaginemos una sala de investigación donde nadie entrega al programa una lista completa de propiedades. No hace falta inventar los gestos de los científicos ni sus conversaciones privadas para comprender lo que estaba en juego. La documentación técnica alcanza: si una red tiene variables internas modificables y podemos estimar cómo cada una afecta al error final, entonces podemos entrenar representaciones que no fueron programadas carácter por carácter. El acontecimiento decisivo no es que una máquina «haya visto» como vemos nosotros, sino que una representación previamente diseñada dejó de ser el único lugar donde se depositaba el conocimiento humano acerca de una tarea.

Este paso también cambia nuestra relación con la interpretación. En un sistema de reglas, al menos idealmente, podemos seguir la condición que provocó una decisión. En una red entrenada, el resultado puede depender de un patrón distribuido entre muchísimos parámetros. No significa que el sistema carezca de estructura o que sus decisiones sean inaccesibles a todo análisis. Significa que las explicaciones requieren otros instrumentos. Podemos estudiar activaciones, modificar entradas, observar sensibilidad, comparar ejemplos y probar hipótesis sobre las representaciones aprendidas. Pero debemos distinguir entre describir correlaciones internas y demostrar qué mecanismo causó una respuesta.

Hay otro detalle fascinante en el mecanismo matemático: la retropropagación no necesita evaluar por separado todas las pequeñas alteraciones imaginables de todos los pesos. Al organizar los cálculos desde la salida hacia atrás, reutiliza derivadas intermedias y hace posible estimar de manera eficiente la sensibilidad de una pérdida respecto de numerosos parámetros. La diferencia puede parecer un ahorro técnico menor, pero determina si cierto entrenamiento resulta manejable o imposible con los recursos disponibles. La historia de la inteligencia artificial está llena de ideas teóricamente disponibles que necesitaban un cambio en la organiza-

ción del cálculo para volverse útiles. La elegancia de un procedimiento no siempre reside en hacer algo que antes era lógicamente inconcebible; a veces reside en hacerlo con un costo viable.

Conviene detenerse en la noción de sensibilidad. Si modificamos mínimamente un peso, el gradiente indica, bajo condiciones matemáticas específicas, cómo cambiaría la pérdida. No nos dice que ese peso sea una causa social o biológica de la respuesta en el sentido habitual de esos términos. Tampoco demuestra que un gran gradiente garantice una mejora en cualquier paso de actualización. Una función puede tener regiones irregulares, mínimos locales, mesetas y geometrías difíciles. La optimización mediante gradientes depende de tamaños de paso, inicialización, estructura de los datos y otras elecciones. En una máquina que aprende hay una cadena de decisiones humanas e instrumentos matemáticos, no una fuerza interior que la dirija espontáneamente hacia la verdad.

También puede resultar desconcertante que una misma red deba representar distinciones diferentes para resolver un problema. Reconocer una forma no exige necesariamente asignarle una etiqueta verbal en cada etapa; ciertos patrones pueden conservar información útil para la tarea sin tener nombres comprensibles. Una bióloga acostumbrada a construir caracteres diagnósticos puede advertir inmediatamente la tensión: ¿cómo identificar una propiedad interna que no fue seleccionada por criterio taxonómico ni coincide con un rasgo anatómico? Podemos estudiar respuestas de unidades ante estímulos, construir perturbaciones controladas y comparar salidas; pero la interpretación sigue siendo una hipótesis sobre el mecanismo. La representación aprendida no se convierte automáticamente en concepto científico solo porque podamos visualizarla.

Esta tensión explica parte del interés y parte de la dificultad de la interpretabilidad moderna. Un mapa de activaciones espectacular puede ayudarnos a formular preguntas. También puede inducir a narrar explicaciones plausibles que el experimento no distingue de alternativas competidoras. Para hablar de mecanismo debemos preguntarnos qué sucede cuando intervenimos, no solo cuando contemplamos una correlación. Esta distinción no convierte a las herramientas interpretativas en inútiles; las coloca dentro de la misma disciplina de pruebas, supuestos y controles que aplicamos a cualquier instrumento científico. En una historia de la IA, el aprendizaje de representaciones es a la vez una conquista técnica y el comienzo de un problema epistemológico que todavía nos acompaña.

La noción de representación distribuida posee una elegancia que puede volverse engañosa cuando la tratamos como una solución universal. Un concepto no necesita corresponder a una única unidad localizada; puede emerger como un patrón de actividad en un conjunto de unidades. Esta capacidad permite compartir componentes entre tareas y recombinar propiedades. También dificulta asignar significados simples a cada número. Una red puede resolver de manera notable una distinción visual y fallar frente a cambios de iluminación, de contexto o de procedencia de las imágenes. El resultado no es contradictorio: haber aprendido regularidades útiles no equivale a haber adquirido todas las invariancias que una persona reconoce como pertinentes.

En ciencias biológicas, la distinción entre una variable observada y un mecanismo causal es cotidiana. Una especie puede aparecer asociada con un tipo de vegetación sin que la vegetación sea la causa directa de su presencia. Puede estar actuando como indicador de humedad, historia de uso del suelo o disponibilidad de alimento. Una red neuronal puede aprender esa asociación y predecir correctamente dentro de una muestra. Pero si el contexto cambia, una señal que parecía excelente deja de ser informativa. Este

problema no se resuelve preguntando simplemente cuántos parámetros posee el modelo. Exige investigar qué información utilizó y si seguirá siendo útil en el entorno de aplicación.

Por eso, incluso cuando el entrenamiento consigue reducir una función de pérdida, aún no sabemos si el modelo aprendió lo que queríamos que aprendiera. Una función objetivo es una formalización parcial de un interés humano. Si buscamos distinguir aves en fotografías y todas las imágenes de una especie proceden de un mismo dispositivo, un programa puede usar características del dispositivo o del fondo en lugar de propiedades anatómicas. Obtendremos una precisión alta en un conjunto de pruebas mal construido y una competencia pobre en el mundo real. El error de predicción se redujo, pero el sistema no adquirió la capacidad biológica que creíamos estar midiendo.

Es tentador pensar que la mejora de una red equivale al aprendizaje de una verdad acerca del mundo. En realidad, una red entrenada optimiza una tarea definida por datos, arquitectura y objetivo. Puede aprender relaciones causales en ciertas condiciones, pero una predicción correcta no demuestra por sí misma que identifique las causas. Esta diferencia conecta la historia de la retropropagación con el problema epistemológico central de nuestra colección: una representación puede ser útil, poderosa y sorprendente sin constituir conocimiento justificado en todos los sentidos en que usamos esa expresión para hablar de investigación científica.

La técnica también revela que diseñar una IA implica tomar decisiones antes del aprendizaje. Alguien elige una arquitectura, prepara los datos, define qué cuenta como error y establece cuándo detener el entrenamiento. El sistema modifica parámetros, pero lo hace dentro de un espacio de posibilidades que ya fue delimitado. No es correcto decir que cada rasgo de una representación fue «programado a mano»; tampoco lo es afirmar que la red se creó a

sí misma. Entre ambos extremos existe una ingeniería de las condiciones de aprendizaje. Y cuanto más sofisticado sea el sistema, más importante será comprender esas condiciones antes de atribuirle independencia.

En los años posteriores aparecieron problemas técnicos que impidieron una victoria instantánea. Algunas redes resultaban difíciles de entrenar; los gradientes podían hacerse muy pequeños o muy grandes en ciertas composiciones; las arquitecturas disponibles y el poder de cómputo imponían restricciones; los datos de calidad eran escasos para muchas tareas. La retropropagación proporcionó una herramienta fundamental, pero no resolvió automáticamente el aprendizaje profundo. La historia que la presenta como la llave perdida que abrió todas las puertas confunde una pieza decisiva con la totalidad del edificio.

Se volvió necesario también distinguir entrenar de utilizar un modelo entrenado. Durante el entrenamiento se comparan respuestas con objetivos o señales de aprendizaje y se actualizan parámetros. Durante la inferencia, en un modelo típico ya entrenado, esos parámetros permanecen fijos mientras se calcula una respuesta. Cuando una persona conversa hoy con un sistema generativo y este responde mejor después de recibir una explicación adicional, no podemos concluir automáticamente que sus pesos hayan cambiado. Puede haber utilizado un contexto más preciso, una herramienta externa, información recuperada o una secuencia de razonamiento distinta. Aprendizaje del modelo, aprendizaje en contexto y recuperación de información son mecanismos conceptualmente diferentes.

Esta distinción es una de las competencias más valiosas para quien diseña sistemas de IA generativa. Si la calidad aumenta al aportar mejores documentos, quizá necesitábamos recuperación y organización de contexto. Si el sistema falla por no seguir una especificación, quizá necesitamos una instrucción comprobable o

un flujo de validación. Si la tarea exige reconocer regularidades que el modelo no adquirió, puede ser pertinente evaluar un entrenamiento adicional o cambiar de modelo. Si el problema procede de datos sesgados, ninguna de estas soluciones funcionará sin revisar cómo definimos el objetivo. El criterio experto comienza cuando dejamos de llamar «mejorar la IA» a intervenciones técnicamente distintas.

La matemática del gradiente también puede enriquecer nuestra manera de pensar los errores de una organización. No porque las instituciones sean redes diferenciables, sino porque obliga a distinguir efectos locales de resultados finales. Un indicador global puede mejorar mientras se deteriora una etapa del proceso; una acción aparentemente eficiente puede desplazar costos a otras personas. En programación y en ciencia, el seguimiento de dependencias nos protege de confundir una salida con el mecanismo que la produjo. La analogía termina allí: la causalidad social no se reduce a derivadas, y un efecto institucional no puede interpretarse como si fuera un peso de red.

Uno de los logros intelectuales de las redes multicapa fue permitir que aparecieran representaciones intermedias que los investigadores podían utilizar sin haberlas especificado por completo. Uno de sus costos fue hacer menos transparente la relación entre una decisión y la cadena de operaciones que la produjo. Los dos hechos forman parte del mismo movimiento histórico. La potencia de una representación aprendida no borra la pregunta por su procedencia; la vuelve más importante. Si aceptamos que una máquina reconozca patrones a partir de una estructura interna difícil de interpretar, debemos reforzar la evaluación externa de su comportamiento.

También conviene resistir una tentación retrospectiva: escribir toda la historia de las redes como una marcha que necesariamente desembocaría en los grandes modelos de lenguaje. En 1986 no

existía una hoja de ruta hacia los sistemas generativos actuales. Había investigadores, líneas distintas, limitaciones técnicas, hipótesis científicas y resultados parciales. Algunas ideas sobrevivieron porque funcionaron en problemas nuevos; otras debieron esperar infraestructuras diferentes; varias fueron abandonadas o transformadas. La historia resulta más interesante cuando no la contamos desde el desenlace como si todo hubiera sido evidente desde el comienzo.

El artículo de Rumelhart, Hinton y Williams terminó por ofrecer una imagen persuasiva: las conexiones de una red pueden modificarse a partir de la información de error y las unidades ocultas pueden adquirir estructuras útiles para una tarea. Esa imagen no explica por sí sola la evolución completa del aprendizaje automático, pero nos permite reconocer una ruptura en la distribución del trabajo intelectual. El ingeniero ya no necesita definir cada característica final; la máquina puede optimizar representaciones dentro de condiciones creadas por personas. La responsabilidad científica se desplaza en parte desde enumerar reglas hacia diseñar objetivos, examinar datos y evaluar generalización.

La transición hacia los años siguientes no sería una consecuencia mecánica de 1986. Habría que conseguir datos comparables, ampliar la capacidad de cálculo, mejorar arquitecturas y demostrar aplicaciones en problemas donde la complejidad real no pudiera ser disimulada. Por eso el próximo giro de nuestra historia no ocurrirá cuando una máquina anuncie que ha aprendido, sino cuando podamos contrastar su aprendizaje frente a un mundo que se resiste a ser descrito por reglas sencillas. Una representación útil no está terminada cuando reduce el error en una prueba; empieza a demostrar su valor cuando sobrevive a los cambios que la prueba todavía no había imaginado.

Capítulo 12 · Dos tableros, dos inteligencias

Una victoria puede ser un hecho incontestable y, al mismo tiempo, admitir interpretaciones radicalmente diferentes. En un tablero de ajedrez, una posición termina en jaque mate, abandono o tablas. En un tablero de Go, dos jugadores pueden contar el territorio conquistado y reconocer un resultado. Ninguna metáfora hace falta para determinar quién ganó. El desacuerdo comienza después, cuando tratamos de explicar qué clase de capacidad ha demostrado el vencedor. ¿Pensó mejor? ¿Calculó más? ¿Aprendió una estrategia? ¿Hizo algo que ninguna persona habría considerado? ¿Y qué parte de esa respuesta puede trasladarse fuera del tablero?

El 11 de mayo de 1997, una máquina de IBM venció en Nueva York al campeón mundial de ajedrez Garry Kaspárov. La serie había durado seis partidas. El resultado fue de tres puntos y medio para Deep Blue y dos y medio para su adversario. Diecinueve años después, en marzo de 2016, AlphaGo, desarrollado por DeepMind, derrotó en Seúl a Lee Sedol, una de las grandes figuras del Go profesional, por cuatro partidas a una. Ambos acontecimientos fueron presentados como momentos en que las máquinas habían cruzado una frontera reservada a la inteligencia humana. La semejanza era suficientemente poderosa para ocupar portadas. La diferencia técnica, sin embargo, es mucho más interesante que la fotografía de dos derrotas.

Para reconocerla tendremos que evitar una imagen cómoda de progreso. No ocurrió que la máquina de 1997 jugara mediante reglas rígidas, mientras que la de 2016 se liberara por completo de cualquier regla. Deep Blue combinaba búsqueda intensiva con una función de evaluación compleja y conocimiento ajedrecístico

suministrado por especialistas. AlphaGo combinaba aprendizaje estadístico con búsqueda, reglas del juego y enormes cantidades de cálculo. Ninguno improvisaba en un vacío. Ninguno era una inteligencia general disimulada bajo la forma de un jugador. Y ninguno aprendió de la misma manera que su rival humano.

La tradición de utilizar juegos para investigar máquinas inteligentes era mucho más antigua que ambos encuentros. Claude Shannon había propuesto en 1950 distintos métodos para buscar jugadas de ajedrez; Arthur Samuel investigó poco después programas de damas que modificaban sus criterios mediante experiencia. Los capítulos anteriores nos enseñaron que conocer las reglas no equivale a elegir el mejor movimiento, y que modificar una función de evaluación no garantiza una capacidad general. Entre esas ideas tempranas y los encuentros de los años noventa y dos mil diez creció una industria técnica de computadoras, lenguajes, algoritmos y pruebas competitivas. Las victorias no pueden explicarse sin esa acumulación de trabajo.

En el ajedrez, cada posición tiene un número definido de movimientos legales. El adversario observa el mismo tablero y dispone de la misma información pública sobre las piezas. No es un juego de azar oculto, como una partida en la que las cartas ajenas permanecen desconocidas. La dificultad procede de las combinaciones: cada jugada abre varias respuestas, cada respuesta modifica las posibilidades posteriores y la mayor parte de las consecuencias no puede examinarse hasta el final de la partida. Para jugar con competencia hace falta seleccionar y valorar caminos sin recorrerlos todos.

Deep Blue llevaba esa tarea a una escala que ninguna persona podía igualar mecánicamente. Según la historia institucional de IBM, la versión de 1997 evaluaba en condiciones típicas del sistema alrededor de doscientos millones de posiciones por segundo. La cifra es extraordinaria, pero dice menos de lo que suele suponerse.

Evaluar posiciones no significa comprender doscientos millones de planes ni comparar una cantidad equivalente de ideas humanas. Una posición es una representación computable del tablero; el sistema calcula propiedades y devuelve estimaciones siguiendo procedimientos específicos. Su velocidad modifica qué partes del árbol de juego puede examinar, pero no sustituye la necesidad de decidir cómo organizar esa exploración.

El diseño de Deep Blue integraba procesadores generales, componentes especiales para buscar movimientos de ajedrez y un sistema altamente paralelo. Murray Campbell, A. Joseph Hoane y Feng-hsiung Hsu lo describieron en una publicación técnica posterior a la victoria. Su inventario de ingredientes se resiste a las versiones simplistas: motores de búsqueda especializados, paralelismo en varios niveles, extensiones selectivas de búsqueda, una compleja función de evaluación y bases de partidas de grandes maestros. El resultado fue una arquitectura donde el rendimiento dependía tanto de las decisiones de ingeniería como de los conocimientos propios del ajedrez.

En ocasiones se presenta a Deep Blue como una máquina de fuerza bruta. La expresión es útil si queremos destacar la escala de cálculo; se vuelve inadecuada cuando sugiere que el programa recorría a ciegas todas las partidas posibles. En una búsqueda adversarial, una posición que parece favorable para un jugador puede ser desastrosa si el otro dispone de una respuesta táctica. El sistema debe organizar alternativas bajo la hipótesis de que el rival también intentará jugar bien. Una manera clásica de expresar el problema es maximizar la ventaja propia suponiendo que el otro jugador procurará reducirla. Ese principio inspira la búsqueda minimax, con variantes y optimizaciones capaces de descartar ramas que no modificarían la decisión pertinente.

La poda alfa-beta es una de esas ideas. No hace falta imaginar una tijera atravesando miles de jugadas: el programa mantiene límites sobre los valores que todavía podrían importar. Si una rama no puede mejorar la mejor opción disponible bajo ciertas condiciones, continuar explorándola sería desperdiciar cálculo. Con ello cambia profundamente la cantidad de estados que deben examinarse. La ventaja no consiste en inventar otra regla de ajedrez, sino en reconocer que una búsqueda puede producir la misma decisión útil sin mirar con igual profundidad todo lo que permite el reglamento.

Pero aparece un problema que Shannon ya había señalado: ¿qué valor concedemos a una posición cuando debemos detener la búsqueda antes del final? Podemos contar material, medir seguridad del rey, movilidad de piezas o estructura de peones. Podríamos asignar una importancia diferente a cada señal. La suma de esos elementos produce una estimación, no una verdad absoluta. En ocasiones una ventaja material aparente es una trampa; un sacrificio puede conducir a un ataque decisivo; una jugada que parece pasiva conserva recursos que otra sacrifica. La calidad de Deep Blue dependía también de la manera en que su función de evaluación y sus extensiones de búsqueda respondían a esas complicaciones.

Los expertos humanos no desaparecen de esta arquitectura. En el proyecto trabajaron ingenieros, programadores y especialistas en ajedrez. La preparación para la segunda serie incluyó revisiones de la evaluación y de los datos de aperturas y finales, además de asesoramiento ajedrecístico especializado. Decir que Kaspárov se enfrentó a «una computadora» es correcto como forma breve de identificar al contrincante. Decir que estaba compitiendo contra un mecanismo puramente automático, aislado de todo saber humano, sería falsear las condiciones de construcción del sistema. La máquina ejecutaba un procedimiento; ese procedimiento tenía una genealogía intelectual y colectiva.

La cronología también importa. En febrero de 1996, una versión anterior de Deep Blue ganó la primera partida de su encuentro con Kaspárov, pero perdió la serie por cuatro puntos a dos. IBM utilizó el período posterior para mejorar el sistema. En mayo de 1997, el campeón ganó el primer juego; Deep Blue se impuso en el segundo; las tres partidas siguientes terminaron en tablas. La sexta, disputada el 11 de mayo, se cerró con la retirada de Kaspárov tras diecinueve movimientos. El marcador final está documentado. Las explicaciones de lo sucedido, en cambio, deben tratarse con una prudencia que a veces se pierde cuando un episodio se transforma en símbolo cultural.

Es fácil escribir que el campeón fue derrotado porque la máquina había adquirido intuición. También resulta fácil narrar el encuentro como una humillación de la creatividad humana frente a un cálculo sin alma. Las dos versiones ofrecen una emoción inmediata y poca precisión. Las partidas contienen decisiones que pueden examinarse con herramientas ajedrecísticas, pero convertir una jugada extraña en una señal de pensamiento humano o de superioridad psicológica requiere evidencias adicionales. Algunas reconstrucciones posteriores discuten errores informáticos, elecciones inesperadas y controversias acerca de la preparación del sistema. Ninguna de esas historias debe sustituir el hecho técnico central: una arquitectura especializada había alcanzado un nivel de juego suficiente para vencer, en una serie delimitada, a un campeón vigente.

Lo desconcertante no es que Deep Blue pudiera calcular más que una persona. Las calculadoras llevaban décadas superándonos en aritmética. Lo desconcertante era que una actividad considerada emblema del pensamiento estratégico pudiera descomponerse en representaciones, búsquedas, evaluaciones y decisiones de ingeniería capaces de obtener un resultado superior al de uno de sus mejores practicantes. Pero la conclusión correcta no es que toda inteligencia humana fuera ahora computable a la velocidad de un

procesador. Es que ciertas funciones de alto nivel pueden realizarse mediante mecanismos que no reproducen la experiencia ni los procedimientos de quienes las ejecutan biológicamente.

En ese punto aparece una distinción filosófica casi inevitable. Si dos sistemas eligen la misma jugada excelente, ¿han utilizado la misma estrategia? Un gran maestro puede reconocer patrones estudiados durante años, percibir tensiones de la posición y anticipar respuestas significativas sin enumerar explícitamente millones de variantes. Deep Blue podía recorrer una cantidad colosal de alternativas y evaluarlas conforme a criterios de programación y conocimiento experto incorporado. Una coincidencia en el movimiento final no implica identidad de mecanismo. Tampoco obliga a declarar que uno de los resultados carece de valor intelectual. Una comparación conductual muestra qué hizo cada sistema; entender cómo lo consiguió requiere otra clase de investigación.

La pregunta se vuelve más difícil cuando abandonamos el ajedrez y llegamos al Go. Sobre una cuadrícula de diecinueve por diecinueve líneas, las piedras negras y blancas se colocan en intersecciones. Los jugadores tratan de controlar territorio mediante relaciones espaciales que se extienden, se conectan, se rodean y se transforman a lo largo de la partida. Las reglas básicas pueden explicarse con relativa brevedad; las consecuencias estratégicas son prodigiosamente difíciles. Una piedra puede parecer localmente insignificante y alterar una estructura amplia del tablero. Una zona prometedora puede desaparecer cuando su conexión con otras resulta insostenible.

La escala no es idéntica a la del ajedrez. En muchas posiciones de Go existen muchas más jugadas candidatas, y valorar un tablero a mitad de la partida puede resultar más difícil mediante unos pocos indicadores construidos a mano. Una pieza capturada en ajedrez altera de manera directa el material disponible; en Go, el valor de colocar o sacrificar piedras depende intensamente de la

geometría de conexiones y territorios aún inestables. No significa que el Go sea intrínsecamente una medida superior de inteligencia ni que sus jugadores posean capacidades generales más amplias. Significa que presenta dificultades distintas para determinadas arquitecturas de búsqueda y evaluación.

Durante años, la diferencia favoreció una lectura cómoda: las máquinas podían imponerse en ajedrez gracias a su fuerza de cálculo, pero el Go requería una intuición posicional que se resistía a la programación. La afirmación contenía una observación legítima sobre los límites de métodos disponibles; se volvía una predicción arriesgada cuando se transformaba en una prohibición absoluta. Los límites de una familia de programas no son necesariamente límites de lo computable. La historia del perceptrón ya nos había mostrado cuánto cuesta confundir ambas cosas.

La respuesta que desarrolló DeepMind no consistió simplemente en construir un Deep Blue para un tablero más grande. En enero de 2016, David Silver y sus colaboradores publicaron en *Nature* una descripción de AlphaGo que combinaba redes neuronales profundas con búsqueda en árboles. El artículo distinguía dos funciones: una red de política, destinada a asignar probabilidades a posibles jugadas en una posición, y una red de valor, destinada a estimar qué posibilidades tenía una posición de conducir a una victoria. Es difícil comprender el cambio sin observar que estas dos operaciones responden preguntas distintas.

Una política no dice necesariamente cuánto vale el estado actual. Propone dónde conviene mirar o qué acción tiene sentido considerar. Si el tablero admite numerosos movimientos, una política bien entrenada permite concentrar la exploración en alternativas prometedoras. Una función de valor, en cambio, estima el resultado esperable de una situación sin necesidad de jugar efectivamente toda la partida hasta el último movimiento. Ambas pueden equivocarse. Una puede descartar demasiado pronto una jugada

extraordinaria; la otra puede sobrevalorar una posición cuyo riesgo aún no comprende. Su combinación intenta compensar algunas de esas debilidades con cálculos adicionales.

El entrenamiento de la versión original de AlphaGo tampoco empezó en un mundo sin ejemplos humanos. El trabajo de 2016 describe una etapa de aprendizaje supervisado a partir de partidas de jugadores expertos, que enseñó al sistema a predecir movimientos humanos. Después incorporó aprendizaje por refuerzo, incluido el juego contra versiones de sí mismo, para mejorar el desempeño según los resultados de las partidas. De allí surgieron redes capaces de guiar la búsqueda con mayor utilidad que una simple colección de consejos escritos manualmente. Es importante conservar la secuencia. La versión que derrotó a Lee Sedol no fue el sistema llamado AlphaGo Zero, presentado en 2017 como una arquitectura entrenada sin utilizar esas partidas humanas supervisadas.[19]

El aprendizaje por refuerzo introduce una clase particular de señal. No necesitamos decir al programa que una piedra situada en una intersección merece exactamente tantos puntos de mérito en cada contexto. Podemos definir un objetivo relacionado con ganar partidas y utilizar la experiencia de juegos completos para ajustar una política. El desafío es que la relación entre una jugada temprana y el resultado final puede ser muy indirecta. Una elección parece excelente durante docenas de turnos y acaba contribuyendo a una derrota. Otra parece extraña y prepara una estructura favorable a largo plazo. El sistema debe aprender regularidades a partir de consecuencias que no siempre revelan inmediatamente cuál decisión fue decisiva.

En eso consiste una de las diferencias relevantes con la programación de una evaluación ajedrecística artesanal, pero sería engañoso establecer un contraste absoluto entre «reglas humanas» y «aprendizaje autónomo». El equipo de AlphaGo eligió el juego, re-

presentó el tablero, definió reglas, diseñó arquitecturas, preparó datos, fijó objetivos de entrenamiento y evaluó resultados. Las redes aprendieron numerosos parámetros que sus diseñadores no habían especificado uno por uno. La construcción del problema y de su entorno de aprendizaje siguió siendo una intervención humana extraordinariamente elaborada.

La búsqueda era el tercer elemento. AlphaGo utilizó una variante de búsqueda de árbol Monte Carlo, una estrategia que explora movimientos y actualiza estimaciones conforme acumula simulaciones y evaluaciones de resultados. A diferencia de un recorrido exhaustivo de todas las partidas posibles, administra la exploración según información sobre jugadas prometedoras y valores estimados. Algunas ramas reciben más atención; otras menos. La selección no demuestra por sí sola que la política sea correcta, pero puede permitir utilizar de manera eficaz un presupuesto finito de cómputo. Para entender la fuerza del sistema, hay que mirar la cooperación entre una estimación aprendida y un procedimiento de búsqueda que sigue poniendo a prueba alternativas.

La palabra Monte Carlo no hace que el programa se convierta en una ruleta. Remite a métodos que utilizan muestreo o simulaciones para aproximar cantidades difíciles de calcular exactamente. En un juego con muchísimas continuaciones posibles, examinar simulaciones informativas puede producir una estimación práctica de qué opciones merecen atención. El resultado depende de cómo se eligen las simulaciones y de cómo se actualizan los valores. Las redes de política y de valor alteran precisamente esas decisiones. AlphaGo no había eliminado la búsqueda: había aprendido a orientar parte de ella.

El artículo publicado en enero de 2016 reportó que AlphaGo había derrotado por cinco partidas a ninguna al campeón europeo Fan Hui, en un encuentro disputado antes de la publicación. La afirmación debe fecharse correctamente. No es una descripción re-

trospectiva del enfrentamiento con Lee Sedol, que aún no había sucedido cuando el artículo pasó por evaluación científica. Es la evidencia presentada sobre un sistema que ya había alcanzado un nivel profesional en el Go de tablero completo. Ese resultado bastaba para desafiar expectativas sobre cuánto demoraría lograrlo, aunque no demostrara que cualquier persona destacada en el juego sería vencida en cualquier condición.

En marzo de ese mismo año llegó el encuentro que convirtió el proyecto en un acontecimiento global. Lee Sedol, jugador surcoreano de trayectoria excepcional, se enfrentó a AlphaGo en cinco partidas en Seúl. El programa ganó las primeras tres y, con ellas, aseguró el resultado de la serie. Lee ganó la cuarta; AlphaGo venció en la quinta y cerró el encuentro por cuatro a una. Las fechas, los marcadores y las jugadas conservadas pertenecen a la documentación del acontecimiento. No necesitamos inventar el silencio del salón ni describir pensamientos íntimos que las fuentes no pueden mostrar. La tensión histórica está en las decisiones visibles y en lo que los observadores creían posible antes de verlas.

Una jugada se convirtió en símbolo del enfrentamiento. En la segunda partida, AlphaGo colocó una piedra en una posición que numerosos comentaristas consideraron muy inusual; es la célebre jugada treinta y siete. Los relatos posteriores la presentan como una evidencia de creatividad, incluso como una ruptura con siglos de conocimiento estratégico. Conviene tratar esas interpretaciones como interpretaciones. Que un movimiento sea improbable dentro de un repertorio de partidas humanas no significa que sea necesariamente mejor, ni que el sistema haya sentido inspiración. Lo que puede estudiarse son las razones estratégicas que los especialistas identificaron después y el modo en que la jugada contribuyó al desarrollo de la partida.

La cuarta partida agregó un contrapunto indispensable. Lee Sedol encontró una secuencia extraordinaria cuyo movimiento setenta y ocho recibió especial atención y que precedió a errores de respuesta del programa. Lee ganó ese encuentro. La victoria humana no refutó las redes neuronales, así como la victoria de AlphaGo en la serie no demostró que el aprendizaje por refuerzo resolviera la inteligencia. Juntas, ambas observaciones revelan algo más informativo: había un sistema muy fuerte, capaz de decisiones sorprendentes, y seguía habiendo configuraciones que exponían sus debilidades.

Un episodio así es una oportunidad para distinguir sorpresa de evidencia. Un movimiento puede parecernos inhumano porque los mejores jugadores no suelen elegirlo. También puede parecernos genial porque conocemos el resultado posterior y tendemos a organizar la secuencia como si todo hubiera sido inevitable. El análisis serio exige examinar alternativas, posiciones y consecuencias, no extraer la inteligencia de la rareza. A veces una decisión estadísticamente improbable es una innovación. Otras veces es un error. Su rareza no determina su valor; es la evaluación posterior, correctamente diseñada, la que permite discutirlo.

En el Go, además, el aprendizaje de una política transforma parcialmente aquello que consideramos «estilo». Un algoritmo puede asignar alta probabilidad a configuraciones que una tradición de juego considera poco elegantes o poco ortodoxas. Si esas decisiones conducen a buenos resultados, pueden ampliar el repertorio humano de alternativas examinables. Pero debemos evitar otra inferencia apresurada: que el sistema haya producido una teoría explícita de la estrategia. Ser capaz de elegir una jugada eficaz no equivale a poder justificarla mediante una explicación causal independiente ni a enseñar sin errores sus principios a un estudiante.

Aquí vuelven las representaciones internas del capítulo anterior. El trabajo de Rumelhart, Hinton y Williams había abierto caminos para que las redes multicapa adquirieran características intermedias sin que alguien escribiera a mano cada una de ellas. AlphaGo mostró el valor práctico de representar posiciones y decisiones mediante funciones aprendidas y utilizarlas en un problema de planificación. El parentesco conceptual es real. La equivalencia técnica no lo es: los métodos de entrenamiento, los entornos de evaluación, la escala de cómputo y las configuraciones de búsqueda de los años ochenta y de 2016 eran muy diferentes. Una buena historia no necesita borrar esas discontinuidades para reconocer una genealogía.

El contraste entre Deep Blue y AlphaGo no es, por tanto, una competencia entre una inteligencia falsa y una auténtica. Ambos son sistemas artificiales que realizaron tareas difíciles bajo condiciones delimitadas. Deep Blue destacó por combinar una exploración especializada de altísima velocidad con conocimientos ajedrecísticos codificados y procedimientos de evaluación. AlphaGo aprovechó representaciones y políticas aprendidas, estimaciones de valor y simulaciones de búsqueda. En uno, gran parte de la pericia aparece condensada en los métodos y criterios construidos por expertos; en el otro, una parte adicional se obtiene ajustando parámetros a partir de datos y partidas. En ambos, la tarea está acotada por reglas precisas.

Ese último detalle resulta fácil de olvidar. El tablero no es el mundo. En ambos juegos existen estados permitidos, movimientos legales y resultados observables. Puede discutirse si una jugada fue buena, pero no necesitamos negociar qué significa que una torre se mueva en diagonal o que una piedra haya sido capturada. No sucede lo mismo al evaluar una política pública, seleccionar personal, explicar un resultado biológico o decidir cómo intervenir en una organización. En esos contextos los objetivos pueden ser múltiples, las reglas están sometidas a interpretación, los datos

son incompletos y el impacto de una decisión afecta a personas cuyas necesidades no caben en una función de recompensa simple.

La incertidumbre también cambia de naturaleza. En ajedrez y Go, la mayor dificultad estratégica no consiste en desconocer las piezas del adversario: ambos jugadores observan el tablero. En un sistema organizacional, una variable puede estar mal medida, una base incompleta o una persona puede cambiar de conducta porque sabe que está siendo evaluada. Una buena evaluación bajo información completa no garantiza una buena intervención bajo incertidumbre social. Este no es un argumento contra utilizar IA en problemas abiertos. Es una advertencia metodológica sobre la clase de inferencia que necesitamos para extrapolar resultados.

El diseño de los indicadores se vuelve entonces parte del problema, no un detalle que aparece al final. Si un equipo utiliza una IA para seleccionar candidatos y mide el éxito únicamente por la rapidez de contratación, puede optimizar una consecuencia administrativa sin mejorar el ajuste entre competencias, oportunidades y necesidades. Si usa una herramienta para resumir investigaciones y evalúa solo la fluidez verbal, puede premiar respuestas convincentes que omiten evidencia decisiva. El tablero cerrado de una prueba técnica es útil porque permite observar el desempeño. El peligro aparece cuando tratamos su marcador como certificado universal de competencia profesional.

También debemos preguntarnos qué significa comparar capacidades entre dos sistemas que utilizan recursos distintos. Deep Blue examinaba grandes cantidades de posiciones, pero no aprendía del encuentro de 1997 mediante una actualización de pesos comparable al entrenamiento profundo de AlphaGo. AlphaGo había sido entrenado mediante un proceso costoso antes de las partidas; su actuación incorporaba tanto parámetros aprendidos como decisiones de búsqueda durante el juego. ¿Qué comparamos enton-

ces: la cantidad de operaciones durante la partida, el costo total del entrenamiento, el trabajo humano dedicado al diseño, la solidez en distintas posiciones o el resultado final? Todas esas medidas pueden ser relevantes, pero ninguna sustituye automáticamente a las demás.

Una comparación profesional de IA generativa enfrenta exactamente esa dificultad. Dos modelos pueden obtener el mismo resultado en una tarea y demandar cantidades muy diferentes de tiempo, datos, energía o intervención humana. Una arquitectura con herramientas puede resolver un problema gracias a un motor matemático externo; otra puede aproximarlo mediante generación de texto. Un agente puede parecer autónomo porque coordina varios pasos predefinidos, mientras que otro actúa bajo una política aprendida. La comparación solo se vuelve informativa cuando describimos qué operaciones son propias del modelo, cuáles dependen de instrumentos y qué validadores permiten establecer el resultado.

La derrota de un campeón también introduce una cuestión de prestigio. Durante siglos, los juegos de estrategia fueron espacios donde se reconocía habilidad intelectual. Cuando una computadora vence a un maestro humano, cambia el modo en que distribuimos ese reconocimiento. Algunas personas sienten que un territorio exclusivamente humano se ha reducido; otras descubren un nuevo instrumento para examinar variantes y perfeccionar su práctica. Ninguna reacción es obligatoria. Pero la historia tecnológica resulta incompleta si solo mide victorias y olvida que las comunidades reinterpretan qué significa ser experto cuando aparecen herramientas capaces de superarles en tareas específicas.

Después de Deep Blue, el ajedrez no dejó de interesar a las personas. Los programas se convirtieron en herramientas de análisis, preparación y descubrimiento de líneas que los jugadores revisan, discuten y utilizan críticamente. Después de AlphaGo, sus partidas

ofrecieron material de estudio a la comunidad del Go. Esta apropiación humana no demuestra que la colaboración sea siempre superior ni que todos los profesionales puedan beneficiarse de igual manera. Muestra una posibilidad históricamente importante: una máquina puede transformar las prácticas de aprendizaje y evaluación de quienes antes eran sus únicos intérpretes legítimos.

La historia posterior obliga a una precisión adicional. En octubre de 2017, otro trabajo de *Nature* describió AlphaGo Zero, un sistema que aprendía a jugar Go mediante aprendizaje por refuerzo a partir de partidas contra sí mismo, sin la etapa de aprendizaje supervisado sobre partidas humanas utilizada en el AlphaGo original. Ese desarrollo es importante, pero no debemos insertarlo retrospectivamente en el tablero de Seúl. La máquina que derrotó a Lee Sedol tenía otra historia de entrenamiento. Si mezclamos versiones sucesivas de un sistema, construimos una inteligencia imaginaria que nunca existió en una fecha concreta. El mismo riesgo aparece hoy cuando utilizamos el nombre de un modelo comercial para describir capacidades que corresponden a versiones, herramientas o configuraciones diferentes.

Por eso una pregunta aparentemente administrativa —¿qué versión estamos evaluando?— se convierte en pregunta epistemológica. Un resultado puede pertenecer a una arquitectura precisa, con unos datos y un conjunto de parámetros determinado. Si esos elementos cambian, el significado del resultado puede cambiar. Un récord de 1997 no define todos los programas de ajedrez posteriores. Un artículo de enero de 2016 no describe sin más el sistema de octubre de 2017. La trazabilidad de versiones no es un capricho del software: es una condición para que nuestras afirmaciones científicas tengan un objeto reconocible.

Hay otra consecuencia menos visible de estos enfrentamientos. Los juegos permiten repetir ensayos, conservar registros completos y determinar resultados con relativa claridad. Son laborato-

rios extraordinarios para estudiar planificación. Pero esa misma claridad puede crear una ilusión de madurez cuando trasladamos el lenguaje de victorias a campos donde no existe un verificador universal. En una redacción científica, por ejemplo, una respuesta puede ser formalmente elegante y estar sustentada en una fuente inexistente. En una predicción ecológica, una puntuación elevada puede depender de sesgos de muestreo. En reclutamiento, un indicador puede reproducir decisiones históricas sin demostrar validez para las competencias que pretendemos identificar.

El especialista en IA no debería limitarse a admirar un resultado ni buscar inmediatamente la próxima tecnología capaz de superarlo. Debería examinar la estructura del problema que lo hizo medible: qué cuenta como estado, qué acciones se permiten, quién define la recompensa, cuánto cuesta explorar, qué datos hacen falta, qué intervención humana permanece oculta y qué tipo de error sería aceptable. Son preguntas de arquitectura, pero también de filosofía y de método científico. La historia de Deep Blue y AlphaGo nos permite aprenderlas sin convertir el libro en un manual: aparecen como condiciones reales de dos logros que el mundo observó.

Una victoria no pierde importancia al describir su mecanismo. La diferencia entre Deep Blue y AlphaGo reside, entre otras cosas, en dónde se concentró el trabajo de diseño. Deep Blue combinaba una búsqueda muy extensa con evaluaciones afinadas por especialistas y hardware destinado al ajedrez; AlphaGo empleaba redes entrenadas para proponer movimientos y valorar posiciones, integradas con búsqueda. Ninguno operaba fuera de las reglas de su juego. La comparación más fértil no pregunta cuál de los dos parecía más humano, sino qué información había que suministrarle a cada sistema antes de que pudiera seleccionar una jugada.

Al cerrar ambos encuentros queda una paradoja. Para comprender mejor máquinas capaces de jugar, hemos debido estudiar no solo movimientos y victorias, sino fuentes, arquitecturas, decisiones de diseño y criterios de evaluación. Los dos tableros permitieron observar capacidades extraordinarias porque recortaban una parte del mundo donde las reglas eran claras. El próximo giro de esta historia consistirá en abandonar parcialmente esa protección: enseñar a las máquinas a reconocer objetos que aparecen en fotografías tomadas por personas distintas, bajo condiciones variables, con etiquetas imperfectas y distribuciones que nunca representan toda la realidad.

En esa transición, las redes neuronales encontrarán una materia prima mucho más vasta que una colección de partidas. Millones de imágenes serán reunidas, clasificadas y convertidas en pruebas comparables. La escala de los datos permitirá ver avances que habían permanecido fuera de alcance. Pero habrá una trampa semejante a la del tablero: confundir un resultado en un conjunto definido con una comprensión del mundo entero. Cuando lleguemos a ImageNet y AlexNet tendremos que formular de nuevo la pregunta que quedó abierta después de Kaspárov y Lee Sedol: **¿qué ha aprendido realmente una máquina cuando supera nuestra mejor puntuación, y qué parte de la realidad seguimos dejando fuera de la prueba?**

Capítulo 13 · Un millón de imágenes no es el mundo

Reconocer un ave parece un problema sencillo hasta que intentamos explicar qué significa reconocerla. Una bióloga de campo puede escuchar un reclamo apenas audible, observar una silueta durante dos segundos y descartar varias especies antes de enfocar los binoculares. Quizá el plumaje no alcance para decidir; tal vez importen la estación, el ambiente, la manera de volar y la posibilidad de que dos especies semejantes compartan territorio. La identificación no ocurre dentro de una fotografía. Ocurre en un encuentro entre un organismo, un observador y un mundo que contiene información distribuida de maneras desiguales. Si reducimos ese encuentro a una imagen y una etiqueta, ganamos algo extraordinario: un problema que puede repetirse miles de veces. También perdemos algo que no conviene olvidar.

Durante décadas, la visión artificial avanzó construyendo formas de detectar bordes, reconocer geometrías, describir texturas y combinar indicios. Ninguna de esas estrategias era trivial. Las fotografías cambian con la luz, con la escala, con el punto de vista y con los objetos que interrumpen nuestra visión. Una superficie que refleja la luz puede alterar por completo los valores de los píxeles sin que el objeto haya cambiado. El mismo animal parece diferente frente a un fondo blanco o entre ramas; dos objetos distintos pueden proyectar contornos semejantes. Para reconocer patrones de manera estable, una máquina necesita aprender qué variaciones importan y cuáles no. Y antes de pedirle que aprenda, alguien debe ofrecerle una experiencia de entrenamiento.

La palabra «experiencia» resulta cómoda, pero debemos escucharla con cautela. En una persona puede involucrar movimiento, memoria episódica, cuerpo, emoción y consecuencias de actuar.

En un sistema de clasificación de imágenes designa, de manera mucho más acotada, un conjunto de ejemplos junto con señales acerca de las respuestas que se esperan. El problema que transformaría la visión artificial no consistía solamente en inventar una arquitectura más poderosa. También exigía construir un mundo de ejemplos suficientemente amplio para que un procedimiento de entrenamiento encontrara regularidades útiles. La decisión parece administrativa: reunir imágenes y asignarles nombres. En realidad, implica una teoría sobre qué cuenta como un objeto y qué significa reconocerlo.

A mediados de la primera década del siglo veintiuno, Fei-Fei Li y sus colaboradores comenzaron a perseguir una posibilidad que entonces exigía una notable inversión de trabajo: si los conjuntos disponibles resultaban demasiado pequeños para representar la variabilidad visual, quizá la comunidad necesitara una infraestructura de datos radicalmente mayor. El proyecto se desarrolló en torno a Princeton antes de que Li se trasladara a Stanford. No surgió de la nada ni inauguró la recopilación de imágenes para investigación. Existían colecciones fundamentales y programas activos de reconocimiento visual. La ambición de ImageNet era distinta por su escala, su organización semántica y su vocación de recurso común.[20]

El documento publicado en 2009 permite recuperar aquella ambición antes de convertirla en mito. Sus seis autores —Jia Deng, Wei Dong, Richard Socher, Li-Jia Li, Kai Li y Li Fei-Fei— describieron una base organizada sobre la estructura de WordNet, un recurso léxico que reúne sentidos de palabras en conjuntos de sinónimos relacionados. En su estado de entonces, ImageNet comprendía doce subárboles, 5.247 conjuntos conceptuales y 3,2 millones de imágenes. Entre aquellos subárboles figuraban mamíferos, aves, peces, reptiles, anfibios, vehículos, muebles, instrumentos musicales y flores. El objetivo declarado era mucho mayor: poblar buena parte de los conceptos nominales de WordNet con cientos o miles

de ejemplos visuales. Lo que hoy recordamos como una victoria de las redes neuronales había comenzado, en parte, como un proyecto de catalogación.

¿Por qué organizar fotografías con un diccionario? Porque aprender a identificar objetos exige decidir previamente cómo los nombramos. La palabra «perro» puede contener muchas razas, tamaños y posiciones. Una fotografía de un husky pertenece simultáneamente a categorías más amplias: canino, carnívoro, mamífero. Una imagen de un velero se conecta de otra manera con embarcaciones y vehículos. La jerarquía proporciona relaciones que pueden resultar útiles para explorar familias de conceptos. Pero el hecho de que una palabra exista en una ontología no significa que todos sus sentidos sean entidades visuales fácilmente distinguibles. Tampoco que las categorías sociales y naturales compartan la misma clase de límites.

Esta dificultad debería resultar familiar a cualquier persona que haya trabajado con clasificación biológica. Las categorías son herramientas del conocimiento, no recipientes que se llenan espontáneamente. Una especie se define mediante debates, evidencias genéticas, criterios morfológicos, historia evolutiva y convenciones que cambian con los métodos disponibles. Un nombre popular puede agrupar organismos que no forman un conjunto filogenético; dos especies pueden ser casi indistinguibles en una fotografía. En una colección destinada a la visión artificial, el problema reaparece de otra manera: si el nombre elegido no se corresponde con una distinción perceptible en la imagen, el algoritmo será evaluado contra una pretensión que ni los datos pueden sostener con claridad.

El desafío material era enorme. No bastaba con buscar una palabra en Internet y guardar todas las imágenes obtenidas. Los resultados de búsqueda podían incluir ilustraciones, duplicados, objetos secundarios y asociaciones ajenas al concepto. Había que se-

leccionar candidatas y conseguir que personas decidieran cuáles ilustraban realmente la categoría. El artículo de ImageNet documenta el uso de Amazon Mechanical Turk para distribuir tareas de anotación entre trabajadores remotos. Esa decisión permitió reunir una escala antes muy costosa. También hizo visible una infraestructura humana frecuentemente borrada de las historias posteriores: para que una máquina aprendiera a reconocer, miles de personas tuvieron que mirar, comparar, aceptar, rechazar y etiquetar.

No existe aquí una contradicción entre automatización y trabajo humano. El aprendizaje supervisado depende, justamente, de que exista alguna señal que diferencie los ejemplos considerados correctos de los incorrectos. Lo importante es reconocer dónde se origina esa señal y cómo se controla su calidad. Si tres personas ven una misma imagen y discrepan, la discrepancia puede ser ruido, una fotografía deficiente o evidencia de que la categoría es ambigua. Resolverla mediante una votación no transforma necesariamente la etiqueta ganadora en una verdad ontológica. Puede convertirla en una decisión práctica suficiente para el experimento. La diferencia importa cuando más tarde medimos si una red neuronal «se equivocó».

La construcción de ImageNet fue, por tanto, un experimento sobre representación tanto como sobre almacenamiento. Cada imagen añadida parecía aumentar la diversidad del mundo disponible para las máquinas, pero esa diversidad dependía de quién fotografiaba, qué circulaba en la red, qué devolvían los buscadores y qué filtros imponían las anotaciones. Una fotografía de un ave en una guía de campo, una imagen comercial de un objeto sobre fondo blanco y una captura casual de una escena urbana no son ejemplos intercambiables de cómo aparece el mundo. La variación de fuentes podía enriquecer la colección, pero también introducir regularidades accidentales que un modelo aprendería a utilizar sin que nosotros las hubiéramos elegido.

La historia de la ciencia está llena de instrumentos que modifican las preguntas que pueden investigarse. El microscopio reveló estructuras antes invisibles; la secuenciación masiva convirtió en abordables comparaciones genéticas que habrían sido prohibitivas; un sistema de información geográfica permite explorar relaciones espaciales imposibles de inspeccionar caso por caso. Una base de datos puede operar como instrumento en un sentido semejante, aunque no mida directamente un fenómeno físico. Define qué observaciones estarán disponibles y cuáles podrán compararse bajo reglas comunes. ImageNet fue una infraestructura de ese tipo: no resolvió el reconocimiento visual, pero cambió las condiciones materiales para estudiarlo.

La segunda transformación llegó cuando esa colección se convirtió en un desafío compartido. A partir de 2010, el ImageNet Large Scale Visual Recognition Challenge ofreció tareas y procedimientos de evaluación sobre subconjuntos delimitados. Aquí aparece una confusión histórica que conviene deshacer. ImageNet no era idéntico al conjunto utilizado en cada edición de la competición. El archivo más amplio creció hasta reunir alrededor de quince millones de imágenes agrupadas en unas veintidós mil categorías. En cambio, la tarea de clasificación que se hizo célebre trabajaba con mil categorías y aproximadamente 1,2 millones de imágenes de entrenamiento, además de conjuntos reservados para validar y probar los modelos. Mezclar estas cantidades permite escribir frases grandiosas, pero impide comprender qué fue exactamente evaluado.

La existencia de una prueba común modificó la investigación de una manera profunda. Los equipos podían dejar de describir sus resultados sobre colecciones distintas, construidas con criterios incompatibles, y competir bajo una medida compartida. Esa estandarización no garantizaba que el problema estuviera perfectamente definido, pero permitía identificar avances que antes eran difíciles de comparar. Una diferencia en la puntuación dejaba de

ser, al menos parcialmente, una disputa sobre qué imágenes había elegido cada laboratorio. Había un conjunto de ejemplos y un protocolo. La comunidad podía concentrar la discusión en cómo los sistemas aprendían y qué errores persistían.

La medición incluía un detalle que sería decisivo para interpretar los resultados de 2012. La tarea utilizaba tasas de error conocidas como top uno y top cinco. En la primera, la predicción más probable debe coincidir con la etiqueta esperada. En la segunda, se considera acertada la imagen si esa etiqueta aparece entre las cinco categorías con mayor puntuación. La diferencia puede parecer generosa: ¿por qué conceder cinco oportunidades a la máquina? Porque algunas fotografías muestran varios objetos y porque distinguir entre categorías cercanas puede ser difícil incluso cuando el sistema reconoce aspectos relevantes de la escena. Pero una métrica top cinco no equivale a una respuesta correcta única, y mucho menos a una comprensión completa de la fotografía. El número solo tiene significado cuando conocemos las reglas que lo producen.

Mientras ImageNet construía una infraestructura de datos y evaluación, las redes neuronales profundas acumulaban décadas de trabajo desigual. No habían sido inventadas de repente para participar en una competición. Los modelos convolucionales tenían antecedentes en investigaciones sobre visión y reconocimiento de patrones, y Yann LeCun y sus colaboradores habían mostrado aplicaciones destacadas en reconocimiento de caracteres. También existían límites bien conocidos: entrenar modelos con numerosas capas podía exigir recursos costosos, conjuntos de datos adecuados y procedimientos de optimización que evitaran problemas prácticos. El capítulo anterior dedicado a la retropropagación nos permitió comprender una parte del mecanismo de aprendizaje. Ahora veremos por qué conocer ese mecanismo no bastaba para convertirlo en una tecnología dominante.

La convolución ofrece una idea elegante sobre las imágenes. En vez de conectar cada píxel con todos los demás desde el comienzo, una red puede aplicar pequeñas operaciones locales que buscan regularidades en regiones próximas. El mismo filtro se desplaza por distintas zonas de la imagen. Así, una pauta que resulta útil para detectar determinada orientación o contraste puede reconocerse aunque aparezca en posiciones diferentes. A medida que avanza el procesamiento, las capas combinan características de niveles anteriores. La arquitectura incorpora una hipótesis acerca del mundo visual: las relaciones locales importan y ciertas transformaciones pueden aprovecharse repetidamente. No es un cerebro humano reducido a circuitos; es una elección matemática que restringe y organiza el aprendizaje.

Esta restricción merece atención porque a menudo se habla de las redes profundas como si aprendieran sin ningún conocimiento previo. No es así. La estructura convolucional introduce una preferencia por patrones locales y por el uso compartido de parámetros. El entrenamiento puede descubrir qué filtros resultan útiles, pero el diseñador ha decidido de antemano cómo se aplicarán y qué tipo de transformaciones estarán disponibles. Una arquitectura que aprende representaciones no parte de una página completamente en blanco. Su capacidad depende de supuestos incorporados, recursos materiales y ejemplos observados. La discusión de 1943 sobre neuronas ideales y su distancia de la biología vuelve aquí bajo una forma mucho más sofisticada.

En la Universidad de Toronto, Alex Krizhevsky, Ilya Sutskever y Geoffrey Hinton desarrollaron un sistema que llevaría esa combinación a una prueba pública. Su trabajo de 2012 describió una red con cinco capas convolucionales y tres capas completamente conectadas, aproximadamente sesenta millones de parámetros y centenares de miles de unidades artificiales. La escala era enorme para la época, pero no constituye por sí sola la explicación del resultado. Los investigadores combinaron una implementación efi-

ciente sobre procesadores gráficos, funciones de activación que facilitaban la optimización y procedimientos para reducir el ajuste excesivo a los ejemplos de entrenamiento. La victoria no pertenece a una cifra única, sino a una arquitectura que hizo colaborar varias decisiones técnicas.

Los procesadores gráficos merecen salir de la nota al pie. Habían sido desarrollados principalmente para operaciones visuales y podían ejecutar grandes cantidades de cálculos numéricos en paralelo. Esa propiedad resultó útil para entrenar redes mediante operaciones matriciales y convoluciones repetidas. El artículo de Toronto informa que una configuración de su red podía entrenarse durante cinco o seis días utilizando dos tarjetas GTX 580 de tres gigabytes de memoria. No eran máquinas ilimitadas. La división de cómputo y datos entre dos dispositivos estaba condicionada por una limitación física precisa: la memoria disponible. Un resultado científico que parece ocurrir dentro de una ecuación dependía también de qué piezas de hardware podían adquirirse y programarse.

La función de activación rectificada, conocida como ReLU, fue otro elemento importante. En términos sencillos, deja pasar valores positivos y convierte los negativos en cero. Su utilidad no consiste en parecerse más a una neurona biológica, sino en facilitar determinados procesos de optimización frente a activaciones que pueden saturarse. Krizhevsky y sus colegas no inventaron de la nada todas las funciones rectificadas ni toda la investigación previa sobre ellas. Demostraron la eficacia de combinarlas con una red profunda, un conjunto de imágenes masivo y herramientas de cálculo suficientes para entrenarla. Una innovación decisiva puede ser una recombinación demostrada bajo condiciones nuevas, no necesariamente el nacimiento simultáneo de todas sus piezas.

El sistema también debía enfrentarse con un enemigo conocido: el sobreajuste. Una red de enorme capacidad puede aprender regularidades particulares del conjunto de entrenamiento que no serán útiles en nuevas imágenes. Para reducir esa dependencia, los autores emplearon transformaciones de las fotografías y un método llamado dropout, que durante el entrenamiento suprime aleatoriamente la participación de ciertas unidades. La idea no es que una neurona artificial olvide como una persona. Consiste en dificultar que la red dependa demasiado de combinaciones específicas de activaciones. La capacidad de memorizar ejemplos y la de generalizar a ejemplos nuevos no son idénticas, aunque se influyan.

Cuando llegaron los resultados del desafío de 2012, la diferencia fue considerable. La mejor presentación del equipo de Toronto obtuvo una tasa de error top cinco del 15,3 por ciento, frente al 26,2 por ciento del siguiente equipo.[21] Esos números deberían leerse con la precisión que merecen: se refieren al conjunto de prueba de clasificación y a un criterio top cinco. Además, el resultado ganador no procedió simplemente de una única red idéntica a la que aparece en el diagrama más difundido. El artículo distingue el desempeño de modelos individuales y el de combinaciones de redes, algunas preentrenadas con datos adicionales de la colección ImageNet más amplia. Describir el 15,3 por ciento como el error de una sola red sin matices sería perder una de las enseñanzas del experimento.

La ventaja de casi once puntos porcentuales respecto del segundo lugar fue suficiente para alterar las expectativas del campo. No significa que el reconocimiento visual hubiera quedado resuelto. Sí mostró que una familia de modelos entrenados para aprender características podía alcanzar un desempeño antes difícil de conseguir con las estrategias predominantes. Fue un acontecimiento medible, reproducible en aspectos importantes y estimulante para

equipos que trabajaban en arquitecturas relacionadas. La potencia del resultado estaba en la comparación concreta, no en atribuirle propiedades que ninguna prueba había examinado.

¿Por qué esa diferencia tuvo tanto impacto? Porque cuestionaba una división del trabajo relativamente estable. Durante años, muchas soluciones de visión artificial habían dependido de diseñar manualmente descriptores que capturaran bordes, texturas, esquinas o patrones locales. Después se entrenaban clasificadores sobre esas representaciones. Con la red de Toronto, una porción mucho mayor de la representación se ajustaba mediante el aprendizaje a partir de ejemplos. No desapareció el diseño humano. Cambió de lugar. En vez de decidir todos los rasgos que debían extraerse, el equipo eligió la arquitectura, el objetivo de entrenamiento y los mecanismos por los que el sistema modificaría sus filtros. La autonomía del modelo era real en ese sentido técnico limitado; la responsabilidad del diseño no se había evaporado.

Aquí conviene recordar a Frank Rosenblatt. Su perceptrón había puesto en el centro la posibilidad de que una máquina modificara conexiones a partir de ejemplos. Las redes profundas de 2012 no eran un Mark I ampliado, ni podían deducirse directamente del cálculo lógico de McCulloch y Pitts. Entre ambos momentos hubo técnicas nuevas, críticas formales, investigación dispersa, aplicaciones industriales y décadas de cambios de hardware. Pero la pregunta intelectual seguía siendo reconocible: ¿qué características del mundo debería adquirir una máquina mediante un procedimiento de aprendizaje, en lugar de recibirlas como una lista cerrada de instrucciones? ImageNet convirtió esa pregunta en una comparación a gran escala.

Tampoco sería justo contar 2012 como el triunfo repentino de tres individuos contra todo un campo equivocado. La victoria dependió de investigadores que habían desarrollado algoritmos, bibliotecas, técnicas de reconocimiento y recursos computacionales pre-

vios. Dependió del trabajo de quienes diseñaron ImageNet y de quienes anotaron sus imágenes. Dependió de organizadores que establecieron conjuntos de evaluación y permitieron comparar métodos distintos. También dependió de debates anteriores sobre cómo medir la capacidad de generalizar. Cuando la historia de la inteligencia artificial reduce un resultado a un nombre propio, pierde la red de condiciones que lo hicieron posible. Un descubrimiento puede ser extraordinario sin ser solitario.

Sin embargo, los números de ImageNet comenzaron a adquirir una autoridad peligrosa cuando salieron de su contexto. Una red puede distinguir entre mil categorías de un conjunto de imágenes y seguir siendo incapaz de reconocer una situación cotidiana que exige inferir relaciones, intenciones o causas. Puede acertar el nombre de un perro sin comprender si el animal está asustado, enfermo o a punto de cruzar una ruta. Puede detectar la presencia de un instrumento quirúrgico sin comprender la decisión médica que lo rodea. La clasificación de objetos es una función específica. La comprensión visual general implica otras capacidades y otros modos de evaluación. La frontera entre ambas no desaparece porque el puntaje mejore.

En 2011, antes incluso del resultado de AlexNet, Antonio Torralba y Alexei Efros habían publicado una crítica cuyo título contenía una paradoja: una mirada sin sesgos sobre los sesgos de los conjuntos de datos. Demostraban que las colecciones de imágenes poseían características reconocibles y que la transferencia de modelos entre conjuntos podía revelar limitaciones ocultas por las evaluaciones habituales. La advertencia era sencilla de formular y difícil de resolver: una base de datos puede terminar funcionando como un pequeño mundo cerrado. Los sistemas compiten por reconocer ese mundo y nosotros corremos el riesgo de olvidar el exterior.

La idea tiene consecuencias particularmente claras en ecología y ciencias de la observación. Un mapa de distribución elaborado exclusivamente con registros accesibles desde caminos puede aprender más sobre los recorridos de quienes muestrean que sobre los límites ecológicos de una especie. Una red entrenada con fotografías donde ciertos animales aparecen sobre fondos característicos puede usar indicios ambientales que no forman parte de la identidad biológica del organismo. En ocasiones esa asociación contextual resulta útil, porque el ambiente ofrece información legítima; en otras produce errores cuando las condiciones cambian. La tarea experta consiste en distinguir entre una señal correlacionada, un mecanismo pertinente y una dependencia accidental que no resistirá el uso fuera del conjunto de datos.

En 2019, Benjamin Recht y sus colaboradores sometieron a una prueba incómoda los resultados de los clasificadores de ImageNet. Construyeron un nuevo conjunto de evaluación siguiendo procedimientos cercanos a los del original y observaron caídas de exactitud de entre once y catorce puntos porcentuales en los modelos estudiados. Sin embargo, el orden relativo de desempeño se conservaba en gran medida: las mejoras anteriores no habían sido inútiles. La conclusión no es que todas las evaluaciones sean engañosas, sino que una puntuación puede ser válida dentro de su distribución de prueba y no describir completamente lo que ocurrirá ante nuevas imágenes.

Esa observación requiere un juicio más fino que declarar que todos los benchmarks son inútiles. Sin pruebas comunes, comparar sistemas se vuelve difícil y los anuncios tecnológicos pueden convertirse en una sucesión de demostraciones elegidas por sus propios autores. Con pruebas comunes, en cambio, podemos comparar avances, reproducir resultados y detectar límites. El problema aparece cuando olvidamos que la prueba fue construida con una distribución de ejemplos, decisiones de anotación y un concepto particular de éxito. Una métrica es una ventana sobre una capaci-

dad; no es una descripción completa de ella. Mejorar la ventana no significa haber modificado necesariamente todo lo que queda afuera.

Existe además una cuestión más delicada que la generalización estadística: quién posee autoridad para construir las categorías. Una ontología que ordena tipos de embarcaciones o instrumentos musicales puede ser imperfecta, pero las consecuencias de una etiqueta inadecuada suelen ser diferentes de las que aparecen cuando una clasificación pretende describir personas. El proyecto ImageNet reconoció públicamente en 2019 problemas en su subárbol de categorías humanas, incluidos términos ofensivos y clases que no podían identificarse de manera visual defendible. El equipo anunció medidas de revisión y restricciones de acceso a partes de la colección. No es correcto afirmar, a partir de ese episodio, que toda la base era inútil. Sí es necesario reconocer que la escala no protege contra decisiones conceptuales dañinas.

Cuando una categoría presupone que un atributo moral, psicológico o social puede leerse en un rostro, el problema no consiste únicamente en conseguir etiquetas más exactas. Tal vez la variable no deba construirse como una clasificación visual. Una fotografía puede contener información sobre objetos, posiciones y rasgos observables; no otorga automáticamente acceso a la honestidad, la inteligencia o las competencias profesionales de quien aparece en ella. El error puede existir antes del algoritmo, en la decisión de tratar una propiedad compleja como si fuera visible de manera directa. Un sistema entrenado diligentemente sobre categorías mal planteadas puede automatizar con enorme eficacia un supuesto que nunca estuvo justificado.

Hay una diferencia entre usar una taxonomía biológica para estudiar organismos y convertir una etiqueta social en una supuesta esencia perceptible. En el primer caso, las categorías también requieren crítica y pueden modificarse con evidencia. En el segun-

do, ciertas inferencias pueden carecer de fundamento científico y producir daños reales si se utilizan para evaluar personas. La lección no se resuelve con una prohibición general de clasificar. Exige identificar qué constructo representa cada etiqueta, qué observaciones permiten validarlo y quién soportará las consecuencias de que el modelo se equivoque. La competencia técnica necesita una teoría del objeto estudiado y una responsabilidad sobre el contexto en que se aplica.

También queda el trabajo humano oculto detrás del conjunto de datos. Durante años, la cultura de la inteligencia artificial celebró la autonomía de sistemas que aprendían a partir de millones de imágenes. Esa capacidad es genuina dentro de su definición técnica. Pero las imágenes fueron seleccionadas, organizadas, filtradas y etiquetadas mediante decisiones humanas y condiciones laborales concretas. La distribución de tareas a través de plataformas de anotación permitió escalar el proyecto, pero no transformó el criterio de quienes clasificaban en una propiedad espontánea de la máquina. La automatización siempre tiene una historia material, y esa historia forma parte de lo que debemos examinar cuando evaluamos sus resultados.

La investigación contemporánea se extiende mucho más allá de la clasificación de fotografías. Los sistemas multimodales pueden relacionar texto e imágenes, describir escenas, recuperar documentos visuales y combinar herramientas. Algunos modelos trabajan con video, acciones y relaciones espaciales. No es necesario describirlos como simple consecuencia inevitable de AlexNet; sus arquitecturas y objetivos son diferentes. Pero el debate que ImageNet volvió visible continúa: ¿qué representación se aprende, a partir de qué datos, mediante qué tarea, y cómo sabemos que una puntuación resume una capacidad transferible? Esa pregunta no se vuelve menos importante cuando la interfaz produce oraciones fluidas en lugar de etiquetas.

Imaginemos que un asistente examina fotografías aéreas para identificar cambios de cobertura vegetal. Si supera una evaluación construida sobre imágenes similares, el resultado puede justificar un piloto. Todavía deberemos estudiar qué sucede con otra estación, otro sensor, nubes, suelos expuestos o nuevos patrones de uso del territorio. Si el sistema identifica una pérdida de vegetación, habrá producido una observación o predicción en un marco definido. La explicación causal de esa pérdida podría exigir series temporales, registros climáticos, inspección de campo y conocimiento ecológico. Pedirle que nombre el patrón y pedirle que explique el fenómeno son tareas relacionadas, no equivalentes.

La misma disciplina corresponde a un sistema de inteligencia artificial que analiza currículums, fotografías de documentos o gráficos empresariales. Una buena respuesta puede indicar que el modelo extrajo correctamente información visible. No demuestra que la información sea verdadera, que la variable represente el concepto relevante o que una decisión resultante sea justa. Los datos son evidencia de algo bajo condiciones concretas; nunca contienen todas las premisas que necesitamos para decidir. Lo que ImageNet nos enseña sobre el mundo visual es inseparable de esta distinción. Una máquina puede aprender a clasificar magníficamente dentro de un universo construido y fallar precisamente cuando confundimos ese universo con la realidad que queremos comprender.

Volvamos a la escena de la primera página: la identificación de un ave. Un modelo puede asignar una categoría correcta a una fotografía y ofrecer información valiosa para una investigadora. Puede reducir horas de clasificación manual y ayudar a explorar colecciones que nadie podría revisar a mano. No necesita tener la experiencia de un naturalista para aportar valor. Pero también puede clasificar una silueta por el color del cielo, confundir plumajes estacionales o reproducir los sesgos de las imágenes que recibió. En lugar de preguntar si la máquina «ve como nosotros», re-

sulta más fértil preguntar qué clase de indicios utiliza, cuáles son sus condiciones de fiabilidad y cuándo el conocimiento de campo debe corregir el resultado.

Ese modo de pensar permite apreciar la grandeza histórica del proyecto sin disolver sus límites. ImageNet cambió la escala de una infraestructura científica compartida. El desafío volvió comparables arquitecturas y estrategias. El trabajo de Toronto mostró que redes profundas entrenadas con suficientes datos y cálculo podían superar de manera notable métodos anteriores en esa evaluación. Las investigaciones posteriores revelaron, sin invalidarlo todo, que el desempeño dependía de los datos, de las etiquetas y de las condiciones de prueba. No hay contradicción entre reconocer un avance extraordinario y exigir pruebas más amplias para las afirmaciones que ese avance inspira.

ImageNet amplió de una manera extraordinaria el laboratorio de la visión artificial, pero cada imagen había entrado en él por alguna vía: una búsqueda, una descarga, una selección, una etiqueta, un acuerdo entre anotadores. Esa cadena de decisiones daba a los experimentos una escala nueva y, al mismo tiempo, marcaba su perímetro. Un clasificador podía mejorar año tras año en las mil categorías de una competición sin que nadie hubiera demostrado qué ocurriría frente a objetos que no figuraban allí, fotografías de otras procedencias o categorías cuya definición se volvía discutible. El gran hallazgo no fue que los datos representaran el mundo entero: fue que una infraestructura común permitió observar cambios reales en la capacidad de los modelos y, después, estudiar dónde terminaba esa capacidad.

La clasificación visual constituyó una de las pruebas más influyentes de las redes profundas. Sin embargo, cuando las máquinas comenzaron a producir traducciones, resúmenes y respuestas en lenguaje natural, un nuevo problema desplazó el centro del escenario. Ya no se trataba solamente de encontrar patrones locales

en una imagen. Había que relacionar elementos distantes de una secuencia, conservar dependencias y decidir qué partes de una entrada eran pertinentes para producir otra. Las redes recurrentes habían ofrecido caminos importantes, pero sus límites estimularon búsquedas de arquitecturas distintas. En ese terreno surgió una palabra que, como «neurona», correría el riesgo de ser interpretada demasiado literalmente: atención.

Antes de que una máquina pareciera conversar sobre cualquier tema, otras máquinas intentaban algo tan cotidiano y tan difícil como traducir una oración. Tenían que decidir qué palabra de la frase original importaba cuando estaban a punto de producir una palabra nueva en otra lengua. Esa dificultad nos lleva al siguiente capítulo: una historia de secuencias, alineamientos y memoria computacional que comenzó lejos de las interfaces de chat.

Parte V · Cuando la inteligencia adquirió una interfaz

Capítulo 14 · La atención no apareció para conversar

Hay una forma de perder el significado de una frase sin equivocarse en ninguna de sus palabras. Basta con trasladarlas a otra lengua una por una y olvidar las relaciones que las mantienen unidas. El problema no se presenta solamente en los textos literarios. También aparece en una instrucción de seguridad, en el resumen de una investigación y en un documento administrativo donde una negación modifica el alcance de una obligación. Dos oraciones pueden contener casi los mismos términos y exigir interpretaciones opuestas. Para traducirlas, una máquina necesita algo más que un diccionario: debe conservar relaciones mientras transforma una secuencia en otra.

En 2017, ocho investigadores publicaron *Attention Is All You Need*, un trabajo que introdujo la arquitectura transformer. La publicación original describe un diseño para procesamiento de secuencias —con resultados centrales en traducción automática— que prescindía de la recurrencia y de las convoluciones empleadas en arquitecturas anteriores, organizando el cálculo alrededor de mecanismos de atención. No era todavía una interfaz de conversación general, ni la invención de la atención neuronal. Su importancia exige leer el problema técnico que intentaba resolver antes de proyectar sobre él las aplicaciones que vendrían después.

Una traducción automática es un problema extraordinariamente exigente para una máquina porque el orden y la estructura de las palabras no permanecen intactos entre idiomas. El sujeto puede aparecer en otra posición, un verbo puede depender de información distante y una palabra ambigua puede necesitar varias frases de contexto para ser interpretada. Si el sistema conserva solamente un reemplazo local de cada término, producirá oraciones gra-

maticalmente extrañas o directamente incorrectas. El desafío consiste en transformar una representación lingüística sin perder aquello que permite reconstruir el sentido relevante para la tarea. Esa última precisión importa: ninguna arquitectura convierte el significado humano completo en una variable transparente simplemente porque traduzca bien.

Durante años, los sistemas de traducción automática combinaron diccionarios, reglas, modelos probabilísticos y grandes colecciones de textos paralelos. Las técnicas estadísticas permitieron aprender correspondencias a partir de ejemplos reales, en lugar de depender exclusivamente de instrucciones redactadas por especialistas en lingüística. Pero las dificultades de representar orden, dependencia y contexto persistían. El problema se hizo especialmente visible con la traducción neuronal: una red podía transformar una frase en una representación numérica y otra red podía utilizarla para producir una frase de salida. La arquitectura parecía elegante. Su punto débil estaba precisamente en el lugar donde pretendía reunir toda la información.

En 2014, Ilya Sutskever, Oriol Vinyals y Quoc Le presentaron un enfoque de aprendizaje de secuencia a secuencia basado en redes con memoria a largo y corto plazo, conocidas como LSTM. Un componente leía la oración de entrada y construía una representación; otro generaba la salida. El trabajo mostraba que una red podía aprender transformaciones entre secuencias sin disponer de un procedimiento lingüístico particular para cada frase. También revelaba dificultades de optimización que no siempre obedecían a lo que intuitivamente esperaríamos. Invertir el orden de las palabras de entrada, por ejemplo, mejoraba el aprendizaje en las condiciones del experimento porque acortaba algunas dependencias entre elementos relacionados. El orden era un recurso técnico, no solamente una propiedad de la lengua.

La solución de comprimir una oración en un vector de longitud fija tenía un precio. Pensemos en una descripción breve: «La investigadora encontró el informe». Ahora añadamos observaciones, nombres, aclaraciones, referencias a hipótesis anteriores y una excepción formulada al final. Un mismo espacio limitado debe conservar información suficiente para reconstruir cada parte relevante de la nueva secuencia. No es que un vector de dimensión fija sea incapaz, por definición, de representar oraciones extensas; sería una conclusión matemática demasiado fuerte. La dificultad era práctica: aprender y recuperar dependencias útiles se volvía más problemático cuando aumentaba la longitud y complejidad del material. El cuello de botella estaba en la relación entre arquitectura, entrenamiento y acceso a la información.

Dzmitry Bahdanau, Kyunghyun Cho y Yoshua Bengio propusieron una modificación decisiva en un trabajo difundido en 2014 y presentado en 2015. En lugar de exigir que el decodificador extrajera todo de una única representación fija, podía consultar diferentes partes de la oración de origen mientras generaba cada palabra. El procedimiento aprendía a asignar pesos distintos a posiciones distintas, según cuál resultara relevante para el paso presente. La atención era una manera de seleccionar información dentro de una representación distribuida. No era atención consciente, una experiencia de concentración ni una prueba de que la máquina comprendía el texto como su traductor humano.

Imaginemos que traducimos una oración con dos sustantivos y un pronombre posterior. Para decidir cómo resolver ese pronombre, necesitamos identificar a qué entidad se refiere. En un modelo con atención, el decodificador puede calcular una relación entre su estado actual y las representaciones de distintas palabras de origen. Los pesos obtenidos ayudan a construir un contexto para elegir el siguiente símbolo. El ejemplo ilustra la mecánica, no certifica que cada peso individual revele una referencia gramatical

verdadera. Las distribuciones de atención pueden ser útiles y, al mismo tiempo, no equivaler a una explicación causal completa del resultado.

La modificación alteraba una idea central: la información relevante no tenía que quedar almacenada como una cápsula final que el decodificador intentaría abrir después. Podía permanecer distribuida en una secuencia de representaciones a la que se consultaba repetidamente. La traducción seguía siendo una actividad computacional concreta; sus autores no declaraban resuelta la naturaleza general del lenguaje. Pero el procedimiento proporcionaba una forma diferenciable de aprender qué partes de una entrada convenía recuperar en cada momento. Esa capacidad tenía consecuencias que excederían ampliamente la tarea que ayudó a investigar.

En 2015, Minh-Thang Luong, Hieu Pham y Christopher Manning compararon variantes de atención global y local para traducción neuronal. El hecho histórico merece conservarse porque contradice la explicación según la cual en 2017 alguien descubrió de pronto que una máquina podía «prestar atención». La atención ya era un campo activo de investigación, con arquitecturas alternativas y evaluaciones específicas. La contribución posterior consistió en llevar una intuición a otra escala arquitectónica: preguntarse qué sucedería si la atención dejara de ser un complemento de las redes recurrentes y pasara a organizar la transformación de secuencias desde el centro del sistema.

La recurrencia tenía una virtud evidente: se ajustaba a la intuición de leer una frase en orden. Un estado se actualiza al recibir el siguiente elemento y conserva información de los anteriores. Pero esa dependencia secuencial también condiciona el procesamiento. Para calcular el estado de una posición puede ser necesario haber calculado el de la anterior. Las redes recurrentes modernas habían desarrollado mecanismos sofisticados para conservar infor-

mación y mitigar dificultades de entrenamiento, pero seguían enfrentando costos de procesamiento y trayectorias largas por las que debía propagarse una relación entre palabras distantes. La cuestión no era si esas redes eran malas, sino si su organización temporal era necesaria para todas las tareas.

La propuesta de 2017 respondió con una combinación audaz: prescindir de operaciones recurrentes y convolucionales en el modelo presentado y organizar los cálculos mediante atención. El artículo llevaba ocho firmas: Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan Gomez, Łukasz Kaiser e Illia Polosukhin. La nota de autoría del propio trabajo identifica aportes diferenciados de los integrantes, incluyendo el impulso inicial de explorar la autoatención, el diseño de componentes matemáticos, la implementación, la experimentación y las herramientas de entrenamiento. No fue la obra terminada de un visionario solitario, sino una investigación colaborativa cuyo diseño cambió a través de decisiones de ingeniería.

A primera vista, «autoatención» puede sonar como una palabra más del vocabulario psicológico. En el transformer describe una operación formal sobre elementos de una misma secuencia. Cada posición produce representaciones que participan en tres papeles: consulta, clave y valor. Una consulta se compara con las claves para estimar qué posiciones resultan relevantes; los pesos normalizados se utilizan después para combinar los valores. El resultado es una nueva representación de cada posición, informada por las relaciones calculadas con otras posiciones. La descripción exige cierta abstracción, pero no magia: operaciones lineales, productos escalares, normalizaciones y parámetros entrenados.

Tomemos una frase inventada: «La científica archivó las muestras porque estaban contaminadas». El adjetivo final necesita relacionarse con aquello que describe. No basta con observar la palabra situada justo antes. Una arquitectura que pueda comparar repre-

sentaciones a través de la oración dispone de un mecanismo para incorporar señales distantes. Eso no garantiza que resuelva correctamente cualquier referencia ni implica que todos los cabezales aprendan estructuras lingüísticas interpretables. Pero ayuda a comprender por qué una red que combina información entre posiciones puede representar dependencias que una lectura estrictamente local trataría de manera más torpe.

En el cálculo más conocido del transformer, las consultas se multiplican por las claves transpuestas. El resultado se divide por la raíz cuadrada de la dimensión de las claves. Después, una función transforma esas puntuaciones en pesos que se aplican a los valores. No hace falta leer esa fórmula en voz alta para apreciar su lógica. Primero se calculan compatibilidades; después se normalizan para establecer proporciones; finalmente se combinan contenidos de acuerdo con ellas. La división por la raíz de la dimensión ayuda a evitar que los productos escalares aumenten excesivamente de magnitud al crecer el tamaño de los vectores, lo que podría dificultar el entrenamiento mediante gradientes. El diseño es una solución concreta a un problema numérico, no una metáfora cerebral.

El artículo no se limitó a calcular una distribución de atención por posición. Introdujo la atención de múltiples cabezales. En lugar de obligar a toda la representación a pasar por una sola comparación, el modelo podía proyectar las entradas de varias maneras y producir varias combinaciones en paralelo. Cada cabezal trabaja sobre subespacios aprendidos; sus resultados se reúnen y se transforman otra vez. Es tentador decir que uno aprende sujetos, otro tiempos verbales y otro relaciones semánticas. Algunas visualizaciones muestran patrones sugerentes, pero no existe una obligación de que cada cabezal corresponda a una categoría lingüística humana estable. La arquitectura permite distintos modos de combinación; el significado de esos modos exige investigación empírica adicional.

La palabra «atención» es entonces útil y peligrosa. Es útil porque comunica la idea de ponderar información según el contexto. Es peligrosa porque invita a inferir una selección consciente, un propósito psicológico o una explicación transparente de lo que el modelo hace. Un peso de atención no es un testimonio. Una visualización de conexiones intensas no demuestra que el sistema haya considerado una razón del modo en que lo haría una persona. Tampoco autoriza la conclusión opuesta de que las relaciones calculadas carezcan de valor representacional. Lo que tenemos es una operación cuyos resultados pueden examinarse y cuya interpretación depende de pruebas apropiadas.

Hay un detalle que vuelve aún más interesante la arquitectura: si procesamos todos los elementos mediante comparaciones de contenido, ¿cómo sabe el modelo cuál llegó primero? Dos frases con las mismas palabras en distinto orden pueden significar cosas radicalmente diferentes. Una atención que no incorpora información posicional podría tratar muchas permutaciones de forma equivalente, dentro de su esquema de transformación. El equipo introdujo codificaciones de posición que se combinaban con las representaciones de los elementos. En el trabajo original se utilizaron funciones sinusoidales con diferentes frecuencias y también se compararon representaciones posicionales aprendidas. El orden no emergía automáticamente del nombre «atención»: había que representarlo.

Esta decisión nos devuelve al primer capítulo de la colección. Ada Lovelace había comprendido que las operaciones de una máquina dependen de cómo traducimos un problema a símbolos. Más de un siglo y medio después, una arquitectura neuronal podía aprender relaciones enormemente complejas, pero seguía necesitando decisiones explícitas sobre qué información sería accesible. El modelo no podía trabajar con distancias, posiciones o restricciones que su estructura ignorara por completo. Aprender no elimina el

problema de representar; desplaza parte de sus decisiones desde las reglas escritas hacia los datos, los parámetros y los objetivos de entrenamiento.

La publicación de 2017 utilizó una arquitectura con codificador y decodificador. El codificador procesaba la secuencia de entrada y construía representaciones contextuales. El decodificador generaba la secuencia de salida, atendiendo tanto a sus posiciones anteriores como a la información del codificador. En su autoatención, las posiciones de salida futuras debían permanecer ocultas durante la predicción de cada nuevo elemento. Esa máscara causal evita que el entrenamiento se beneficie indebidamente de símbolos que el sistema aún no debería conocer al generar. No es un detalle marginal: es una forma arquitectónica de respetar qué información está disponible en cada momento.

En ese diseño conviven tres mecanismos que a veces se confunden al hablar informalmente de transformers. La autoatención del codificador permite combinar posiciones dentro de la entrada; la autoatención enmascarada del decodificador organiza relaciones entre las posiciones de salida ya disponibles; la atención entre codificador y decodificador conecta la generación con las representaciones de la secuencia original. No todos los modelos posteriores conservan esta organización completa. Algunos utilizan principalmente codificadores; otros, principalmente decodificadores causales. Reducir todas las arquitecturas a «un transformer» sin identificar sus posibilidades de acceso a la información haría desaparecer diferencias decisivas.

También había redes de transformación posición por posición, conexiones residuales, normalización y métodos de entrenamiento que permitían estabilizar la optimización. El título del artículo podía interpretarse como una proclama de simplicidad absoluta, pero no describía un sistema compuesto únicamente por una operación desnuda de atención. Su argumento técnico se refería a la

posibilidad de abandonar la recurrencia y las convoluciones utilizadas por arquitecturas competitivas en ese contexto, conservando un conjunto de componentes necesarios para aprender de manera eficaz. La expresión memorable funcionó como nombre de un desplazamiento, no como inventario exhaustivo de piezas.

Lo que volvió especialmente atractivo el cambio fue su relación con el hardware. Muchas operaciones de autoatención sobre posiciones de una secuencia podían organizarse para aprovechar cálculos matriciales en paralelo durante el entrenamiento. En comparación con ciertos modelos recurrentes, esto reducía dependencias secuenciales y facilitaba utilizar aceleradores gráficos. No significaba que el costo computacional hubiera desaparecido. La atención completa entre todos los pares de posiciones puede requerir recursos que crecen aproximadamente con el cuadrado de la longitud de la secuencia. Un método puede reducir una limitación y crear otra distinta. El progreso tecnológico suele consistir en modificar la geometría de los costos, no en abolirlos.

Esa distinción importa para comprender lo que vino después. Cuando los modelos comenzaron a procesar textos largos, archivos, conversaciones y código, la gestión del contexto y de la memoria se volvió un problema de arquitectura, infraestructura y evaluación. Una ventana grande no garantiza que cada elemento dentro de ella reciba la atención útil para la tarea. Y una ventana pequeña no vuelve automáticamente incompetente a un sistema si existe recuperación externa o una representación adecuada del trabajo. La longitud del contexto es una capacidad técnica con costos y condiciones; no es una medida universal de comprensión ni un sustituto del criterio que decide qué información conviene presentar.

El experimento de 2017 ofreció resultados medidos. En la tarea de traducción del inglés al alemán del conjunto WMT de 2014, la configuración grande del transformer alcanzó una puntuación BLEU

de 28,4, superando resultados de referencia presentados en el trabajo.[22] BLEU es una métrica basada en coincidencias entre fragmentos de traducciones automáticas y traducciones de referencia, con ajustes específicos. Es útil para comparaciones bajo condiciones establecidas, pero no agota la fidelidad semántica, la corrección pragmática ni el juicio de una traductora experta. Un resultado mejor en BLEU es una evidencia acerca de una tarea y una medición, no una demostración universal de competencia lingüística.

La propia bibliografía del transformer exige una precaución poco llamativa y muy instructiva. Distintas versiones accesibles del artículo consignan cifras distintas para el resultado inglés-francés en el resumen: la ficha de publicación de Google mantiene 41,0, mientras una versión posterior del registro de arXiv presenta 41,8. La tabla técnica de la versión de conferencia permite identificar configuraciones y resultados específicos. Cuando una cifra es central para una afirmación histórica, necesitamos indicar edición y tabla en lugar de escoger la más espectacular. Por eso aquí basta el resultado inglés-alemán y el contexto del experimento: son suficientes para explicar la contribución sin convertir un cambio de versión en un triunfo adicional.

Las condiciones materiales del entrenamiento también importan. El trabajo describió el uso de ocho unidades gráficas Nvidia P100 y conjuntos de millones de pares de oraciones para aprender traducciones. El modelo grande se entrenó durante varios días en la configuración informada. Esos datos no deberían transformarse en un mensaje publicitario del tipo «con unas pocas horas y ocho tarjetas se creó la IA moderna». El experimento aprovechó años de investigación previa, herramientas de programación, colecciones de datos, infraestructura de laboratorio y un trabajo interdisciplinario considerable. Medir el costo de una corrida no equivale a medir el costo de descubrir una arquitectura.

Los resultados tampoco obligaban a abandonar de inmediato todas las demás técnicas de secuencia. Las redes recurrentes continuaron siendo útiles para distintos problemas, los modelos convolucionales mantuvieron aplicaciones y las estrategias híbridas se exploraron durante años. La historia real no fue una sucesión de reemplazos perfectos. Fue el descubrimiento de que cierta combinación de operaciones podía entrenarse eficazmente, competir en traducción y transferirse a otras tareas. La posibilidad de reutilizar esa arquitectura, más que un triunfo aislado sobre una métrica, abriría las preguntas que dominaron los años siguientes.

Una de esas preguntas era qué sucede si dejamos de entrenar una red para una sola transformación entre idiomas y buscamos aprender representaciones mediante tareas mucho más amplias. En 2018 aparecieron trabajos que reutilizaron elementos de la familia transformer con objetivos diferentes. El enfoque conocido como GPT combinó preentrenamiento generativo sobre texto con adaptación a tareas posteriores. BERT, publicado como preprint en octubre de ese año, exploró representaciones bidireccionales con un objetivo de predicción sobre palabras ocultas y se presentó formalmente en una conferencia de 2019. Ni GPT ni BERT eran simples ampliaciones del traductor original. Elegían distintas restricciones de acceso al contexto y distintos modos de aprovechar el entrenamiento previo.

Aquí emerge una distinción decisiva para comprender los asistentes contemporáneos. Un decodificador causal aprende a predecir el siguiente elemento teniendo acceso a los anteriores, no a las posiciones futuras de la respuesta que todavía debe producir. Un codificador bidireccional puede integrar información de ambos lados de una posición dentro de una entrada disponible. Los sistemas pueden combinar estas ideas o conectarlas con otras herramientas. La palabra «transformer» identifica parentescos arqui-

tectónicos, pero no determina por sí sola el objetivo del entrenamiento, las capacidades del modelo ni el comportamiento que observamos al conversar con él.

Tampoco la capacidad para producir lenguaje implica que el modelo consulte una base de hechos certificados antes de responder. Una distribución de probabilidades sobre símbolos puede capturar regularidades útiles de las fuentes y, al mismo tiempo, producir afirmaciones falsas. El aprendizaje de representaciones internas puede permitir operaciones complejas sin proporcionar una garantía universal de veracidad. La historia de ELIZA nos había advertido sobre la apariencia de comprensión; DENDRAL, sobre la necesidad de restricciones expertas; los juegos de Deep Blue y AlphaGo, sobre la diferencia entre una victoria y una capacidad general. El transformer no invalida esas lecciones. Las vuelve más importantes porque facilita construir sistemas cuya fluidez puede superar ampliamente la transparencia de sus mecanismos.

El cambio también reordena nuestra relación con las fuentes. Antes, una traducción automática se juzgaba principalmente frente a una frase de origen y una referencia. Un asistente generativo puede responder preguntas para las que no existe una única solución correcta, sintetizar documentos, proponer hipótesis e intervenir en procesos organizacionales. La evaluación debe adaptarse. No basta con contar coincidencias entre palabras si el resultado pretende ofrecer recomendaciones basadas en evidencia, explicar un fenómeno causal o producir código seguro. Necesitamos pruebas apropiadas para la tarea: referencias comprobables, ejecución de programas, contrastes estadísticos, revisión experta y criterios de error relacionados con las consecuencias.

La autoatención introduce además un riesgo interpretativo peculiar.[23] Las personas suelen buscar en mapas de atención una explicación de por qué el sistema eligió un resultado. Podemos encontrar regularidades útiles: que ciertas posiciones pesan más en

un contexto, que algunos patrones cambian de una capa a otra. Pero no debemos equiparar el gráfico con la cadena completa de causas de una predicción. Las representaciones pasan por múltiples transformaciones y rutas residuales; una distribución de pesos puede alterarse sin producir el cambio interpretativo que imaginábamos. La transparencia requiere experimentos, intervenciones y métodos adecuados. Visualizar no es lo mismo que demostrar.

Todo esto puede sonar demasiado cauteloso para una arquitectura que produjo una transformación genuina. Pero el valor de una innovación aumenta cuando somos capaces de describirla sin atribuirle lo que no hizo. Los transformers no inventaron la atención humana, no fueron la primera forma de traducir mediante redes neuronales y no aparecieron como un sistema conversacional listo para utilizar. Propusieron una solución arquitectónica a dificultades concretas de modelización de secuencias. Su organización hizo posible explorar escalas y objetivos de entrenamiento nuevos. Las capacidades conversacionales que llegarían después dependieron de una cadena adicional de investigación, datos, optimización, interacción y decisiones de producto.

Para una investigadora habituada a trabajar con mapas, la lección tiene una forma familiar. Un mapa de gran resolución permite observar relaciones espaciales que antes permanecían ocultas. Pero también puede inducir una ilusión de omnisciencia: porque vemos muchos detalles, creemos tener el territorio completo. La atención opera sobre representaciones, no directamente sobre el mundo. Una relación calculada entre palabras no equivale a una relación causal entre fenómenos. Un contexto disponible no equivale a todo lo relevante para decidir. La precisión del instrumento debe ir acompañada de una comprensión de sus fronteras.

El transformer no llegó al mundo como un interlocutor. En su presentación de 2017 era una arquitectura para trabajar con secuencias, puesta a prueba en traducción automática. Lo decisivo fue la organización de sus operaciones: el sistema podía relacionar posiciones diferentes sin depender, en ese diseño, de procesarlas exclusivamente mediante recurrencia. Esa posibilidad modificó el espacio de arquitecturas que los equipos podían construir. El resto de su historia dependería de problemas y decisiones que el artículo original no pretendía resolver.

El título Attention Is All You Need fue memorable precisamente porque comprimía una apuesta arquitectónica en una frase breve. La atención de la que hablaban sus autores era una operación entre representaciones numéricas, no una teoría completa de percepción, conciencia o razonamiento. Convertir el título en eslogan universal le restaría precisión a su aportación más importante: mostrar que una decisión concreta de diseño podía alterar de manera profunda lo que resultaba práctico entrenar.

La historia del transformer comenzó en gran medida como la historia de una máquina que buscaba traducir mejor. Su efecto más visible para el público llegaría cuando otras máquinas usaran arquitecturas relacionadas para sostener conversaciones. En ese momento, muchas personas dejaron de percibir la IA como un conjunto de programas especializados y comenzaron a encontrarla en una interfaz familiar: escribir una pregunta y recibir una respuesta. El cambio parecía inmediato porque la conversación lo era. En realidad, detrás de la pantalla convergían décadas de investigación y decisiones recientes sobre aprendizaje, datos, escalado y despliegue. El siguiente capítulo nos llevará a esa interfaz. No para celebrar el momento en que una máquina empezó a hablar, sino para investigar qué comenzó a cambiar en nosotros cuando se volvió tan sencillo pedirle que respondiera.

Capítulo 15 · La interfaz que alteró la pregunta

El 30 de noviembre de 2022 no apareció una máquina capaz de responder todas las preguntas humanas.[24] Apareció una invitación a hacerlas. La página con que OpenAI presentó ChatGPT anunciaba un sistema conversacional disponible como vista previa de investigación y pedía a quienes lo utilizaran que compartieran sus impresiones, incluidos sus errores. El acontecimiento merece leerse desde ese detalle. No se comunicaba el cierre de un problema científico, sino la apertura pública de una experiencia: una persona podía escribir una pregunta en lenguaje ordinario y recibir una respuesta que mantenía, con frecuencia, una continuidad sorprendente con lo que había escrito antes.

El relato de la inteligencia artificial suele otorgar a los nuevos modelos la mayor parte del protagonismo. Sin embargo, en aquella fecha cambió algo que no estaba localizado únicamente en sus parámetros. Cambió la puerta de entrada. A lo largo de los capítulos anteriores encontramos máquinas que requerían especialistas para formular símbolos, ensamblar circuitos, diseñar reglas, organizar datos y seleccionar procedimientos de búsqueda. La interfaz de ChatGPT trasladó una parte de esa tarea al intercambio de palabras. Una investigadora no necesitaba aprender un lenguaje de programación para pedir una explicación inicial. Una persona sin experiencia técnica podía experimentar con una reformulación o solicitar otra versión de un texto. Que el acceso fuera sencillo no significaba que el mecanismo lo fuera; significaba que la complejidad empezaba a desaparecer de la experiencia inmediata del usuario.

La historia anterior importa porque impide confundir esa facilidad con un origen absoluto. ELIZA ya había enseñado, en los años sesenta, cuánto puede atribuir una persona a una interfaz que le devuelve sus propias palabras. Los modelos de lenguaje, por su parte, venían desarrollándose mediante tradiciones matemáticas y técnicas que no nacieron en 2022. En 2020, el trabajo sobre GPT-3 mostró que un modelo autorregresivo de gran escala podía adaptarse a varias tareas mediante instrucciones y ejemplos ofrecidos en el propio texto de entrada, sin modificar sus parámetros para cada una. Era una demostración importante y limitada: la amplitud de tareas no equivalía a conocer la verdad de todas las respuestas, y una misma instrucción podía producir resultados de calidad desigual según el problema.

La expresión «predecir el siguiente token» se convirtió después en un recurso tan repetido que a veces dejó de explicar nada. Un token es una unidad del texto que el sistema maneja según su representación: puede coincidir con una palabra, una parte de ella o un signo. Durante el entrenamiento, un modelo aprende parámetros que le permiten asignar probabilidades a continuaciones condicionadas por el contexto. Durante la generación, utiliza ese aprendizaje y las condiciones de la interacción para producir una secuencia. No consulta por principio un catálogo de verdades certificadas antes de cada frase. Tampoco es correcto inferir de esa descripción mínima que todo lo que hace equivale a pegar fragmentos del pasado. La estructura aprendida puede sostener transformaciones complejas; lo que no proporciona, por sí sola, es una garantía de validez factual.

Había un obstáculo adicional. Un sistema que completa texto con soltura no necesariamente sabe qué clase de respuesta necesita una persona que le está pidiendo ayuda. Puede continuar un ensayo cuando debería contestar una pregunta, imitar un estilo sin respetar una restricción o producir una explicación con un tono que parece apropiado y un contenido incorrecto. El trabajo publi-

cado sobre InstructGPT en enero de 2022 examinó esa distancia entre modelar lenguaje y seguir instrucciones humanas. Su procedimiento combinaba ejemplos de respuestas deseadas, comparaciones realizadas por personas y una fase de optimización que utilizaba esas preferencias como señal. No inventó la idea general de aprender a partir de retroalimentación humana. Mostró una aplicación concreta de ese enfoque a modelos de lenguaje para mejorar su utilidad según criterios definidos experimentalmente.

Aquí se encuentra una paradoja crucial. Enseñar a un sistema a responder de un modo que las personas prefieren puede volverlo más útil. Pero la preferencia no es idéntica a la verdad. Dos explicaciones pueden resultar igualmente claras y solo una ser correcta. Una respuesta larga y segura puede ganar una comparación subjetiva frente a otra más cautelosa, aunque sea menos confiable. La propia publicación de InstructGPT advertía que la alineación de sus modelos se refería a las preferencias de grupos específicos de evaluadores e investigadores, no a una noción universal y finalmente resuelta de valores humanos. La señal de entrenamiento es un instrumento. Interpretarla como la definición completa de una buena respuesta sería atribuirle un alcance que no tiene.

ChatGPT se apoyó en esa tradición de modelos ajustados mediante demostraciones y preferencias. Su lanzamiento también hizo visible una cuestión que muchas discusiones sobre modelos dejaban fuera: el producto no se reduce al modelo. Importan la interfaz, la longitud de contexto disponible, las reglas de interacción, el modo en que se gestionan los turnos, la existencia de herramientas externas, las políticas de uso y los procesos de actualización. Dos productos pueden utilizar modelos emparentados y ofrecer experiencias radicalmente distintas. Un mismo nombre comercial puede reunir sistemas que cambian con el tiempo. Por eso no sería

responsable atribuir al ChatGPT de noviembre de 2022 capacidades de navegación, análisis multimodal o ejecución de acciones que llegarían en etapas posteriores.

La publicación original resulta especialmente instructiva cuando la leemos sin la ventaja del desenlace. OpenAI reconocía que el sistema podía dar respuestas plausibles pero equivocadas, responder de manera diferente ante formulaciones ligeramente distintas y ser excesivamente verboso. También admitía dificultades para gestionar ambigüedades y rechazar solicitudes inadecuadas. Estas limitaciones no fueron descubiertas únicamente después de la popularización del producto. Parte de ellas estaban escritas junto a la invitación a probarlo. La fascinación pública convivía desde el primer día con advertencias técnicas que pedían no confundir una experiencia conversacional convincente con un mecanismo confiable en cualquier circunstancia.

Ese contraste nos devuelve a Joseph Weizenbaum, aunque la comparación exija respetar sus límites. ELIZA operaba con guiones, palabras clave y transformaciones de texto; ChatGPT generaba respuestas mediante una arquitectura entrenada sobre grandes corpus y ajustada para seguir instrucciones. Las diferencias técnicas son profundas. Lo compartido no es la ingeniería del programa. Es una dificultad humana: el lenguaje resulta un medio tan natural para atribuir comprensión que una respuesta fluida puede hacer olvidar la pregunta sobre su procedencia. La interfaz no inventa la capacidad técnica, pero transforma la interpretación social de esa capacidad. Aquello que en un artículo de investigación aparece rodeado de condiciones empieza a circular como una conversación cotidiana.

A lo largo de 2023 la discusión cambió otra vez de escala. GPT-4, presentado en marzo, fue descrito como un modelo multimodal que podía recibir texto e imágenes y producir respuestas textuales, aunque su disponibilidad efectiva y sus modalidades depen-

día de los productos y las versiones. El informe técnico destacaba desempeños elevados en determinadas pruebas académicas y profesionales; también advertía sobre errores factuales, limitaciones de fiabilidad y riesgos de uso. Algunas métricas llamaron especialmente la atención porque permitían una comparación familiar con exámenes humanos. Pero una puntuación en una prueba estandarizada no equivale a la aptitud profesional integral de una persona, con su experiencia situada, obligaciones éticas, responsabilidades y capacidad para reconocer cuándo una tarea no debería realizarse.

El problema de comparar inteligencia mediante un examen tiene una larga historia dentro de este libro. Alan Turing nos mostró que toda prueba selecciona una conducta observable y deja otras fuera. Deep Blue y AlphaGo consiguieron resultados incontestables sobre tableros con reglas precisas, sin que eso demostrara competencia universal. ImageNet permitió comparar clasificadores bajo condiciones controladas, pero no convirtió sus imágenes en el mundo entero. Los exámenes contemporáneos de lenguaje prolongan esa lógica: son instrumentos útiles para estudiar capacidades, no representaciones completas de lo que significa comprender un dominio y actuar responsablemente dentro de él. La tentación no consiste en medir; consiste en olvidar lo que nuestra medición no representa.

La evolución hacia sistemas multimodales hizo más difícil mantener esa distinción. En mayo de 2024 se presentó GPT-4o como un modelo diseñado para trabajar con combinaciones de texto, imágenes y audio, y se anunciaron interacciones de voz más naturales. La transición no fue solamente añadir una cámara o un micrófono a una caja de texto. Nuevas formas de entrada y salida alteraron las tareas que podían plantearse y las expectativas acerca de la respuesta. Una persona podía mostrar una imagen y formular una pregunta sobre lo observado; la interfaz permitía unir el gesto de señalar con el acto de conversar. Sin embargo, percibir

una señal visual y realizar una inferencia correcta sobre su significado seguían siendo operaciones distintas. La historia de Rosenblatt e ImageNet reaparecía detrás de la pantalla.

Una imagen compartida puede servir para identificar una especie probable, describir un gráfico o traducir un cartel. También puede contener detalles ambiguos, información faltante o señales que el modelo interprete incorrectamente. El riesgo aumenta cuando la naturalidad de la conversación hace que la persona olvide esa incertidumbre. Una descripción segura de un ave observada desde un ángulo difícil no reemplaza el contraste con caracteres diagnósticos ni con la distribución geográfica. Una lectura de una figura científica no constituye el análisis de los datos originales. Un comentario sobre una lesión visible no equivale a un diagnóstico clínico. La innovación habilita nuevas posibilidades de observación asistida, pero la evidencia necesaria para sostener una conclusión sigue dependiendo del dominio.

De la percepción a la acción hay otro salto. En marzo de 2025, OpenAI presentó herramientas de desarrollo para sistemas que podían combinar modelos con búsqueda, consulta de archivos y operaciones sobre entornos informáticos. En julio de ese año anunció un agente de ChatGPT capaz de realizar tareas en línea mediante herramientas y una computadora, bajo determinadas formas de supervisión. La palabra «agente» adquirió entonces una prominencia nueva en el discurso de producto. Pero tampoco la inventó aquella empresa ni estaba ausente de la investigación anterior: durante décadas, distintas tradiciones de informática e IA la utilizaron para describir sistemas que perciben condiciones y ejecutan acciones. Lo que cambió fue la accesibilidad pública de determinadas implementaciones y la amplitud de tareas propuestas.

Conviene distinguir las tres preguntas que esa transición suele mezclar. ¿Puede un modelo formular un plan? ¿Puede un sistema ejecutar las acciones del plan con herramientas reales? ¿Puede hacerlo de manera confiable, segura y responsable cuando aparecen excepciones? Una demostración de planificación en texto no responde automáticamente la segunda. Completar una tarea conocida mediante una herramienta no responde automáticamente la tercera. Al pasar de escribir una recomendación a enviar un mensaje, editar un archivo o modificar un registro, los errores dejan de ser solamente afirmaciones equivocadas. Pueden convertirse en acciones con consecuencias que no desaparecen porque la máquina las haya ejecutado.

Si una herramienta propone una consulta estadística incorrecta, una persona puede examinarla antes de ejecutarla. Si un agente ejecuta esa consulta, guarda los resultados en un archivo compartido y los distribuye sin revisión, el problema ha cambiado de naturaleza. Se suman permisos, destinatarios, reversibilidad y registro de lo sucedido. El diseño profesional requiere decidir qué operaciones pueden realizarse automáticamente, cuáles necesitan autorización y cómo se detectan fallos. Estos no son detalles administrativos añadidos después del razonamiento: forman parte de la arquitectura de un sistema que actúa. La separación entre producir una buena respuesta y producir una acción adecuada es una de las fronteras más importantes de la IA aplicada.

Desde fuera, todas esas innovaciones podían parecer la expansión continua de una sola facultad: la máquina ya conversa, mira y trabaja. Pero las palabras esconden sistemas heterogéneos. Conversar depende de un modelo, de reglas de interacción y de un contexto disponible. Mirar requiere representaciones de señales que pueden tener limitaciones propias. Trabajar exige herramientas, acceso a información y mecanismos de coordinación. En cada transición aparece un modo nuevo de fallo. La fluidez del lengua-

je puede unificar la experiencia de usuario sin unificar la solidez de los componentes. Por eso una interfaz coherente no constituye prueba suficiente de una arquitectura confiable.

En 2025, un grupo de investigadores publicó un estudio sobre los usos reales de ChatGPT.[25] Sus autores analizaron una muestra amplia de conversaciones mediante procedimientos automatizados concebidos para preservar la privacidad, y distinguieron entre solicitar información, recibir orientación, escribir y otras actividades. El trabajo, difundido como documento de investigación del National Bureau of Economic Research, estimó que las conversaciones de uso no laboral crecían más rápido que las laborales y que la escritura ocupaba un lugar central entre las tareas profesionales. Los resultados sirven para comprender una transformación de hábitos, pero el diseño, el período analizado y la participación de investigadores vinculados con el propio proveedor deben acompañar cualquier interpretación. Un documento de trabajo no es, por el solo hecho de estar en un repositorio prestigioso, una revisión independiente definitiva de sus conclusiones.

Esa evidencia permite desmontar dos imágenes igualmente simplistas. La primera representa a la IA conversacional como una herramienta utilizada casi exclusivamente por programadores. La segunda supone que todo intercambio con un asistente consiste en pedirle que haga trabajo que una persona habría hecho por sí sola. El estudio documenta una variedad mucho mayor: solicitar orientación práctica, informarse, redactar, aprender y explorar. La capacidad de preguntar también tiene valor. Una herramienta que ayuda a formular una hipótesis o examinar alternativas no necesariamente está sustituyendo una tarea; puede estar alterando las posibilidades de quien la utiliza. Pero la existencia de valor subjetivo o de adopción masiva no demuestra la corrección de todos los consejos producidos.

Los estudios experimentales permiten observar una parte más delimitada del fenómeno. Shakked Noy y Whitney Zhang publicaron en 2023 un experimento prerregistrado con profesionales universitarios que realizaban tareas incentivadas de escritura.[26] En ese contexto, el acceso a ChatGPT redujo el tiempo promedio empleado y mejoró la evaluación de calidad de los textos según los criterios del estudio. En esas tareas, el tiempo promedio disminuyó alrededor del cuarenta por ciento y la calidad evaluada aumentó un dieciocho por ciento. No deben leerse como una ley universal de productividad aplicable a cada profesión o como evidencia de que el resultado sería igual bajo responsabilidades legales, políticas o científicas distintas. La contribución del experimento consiste, justamente, en haber definido una tarea y una comparación.

Un estudio posterior, publicado en 2025 por Erik Brynjolfsson, Danielle Li y Lindsey Raymond, examinó el despliegue escalonado de asistencia generativa en un servicio de atención a clientes.[27] A partir de datos de más de cinco mil trabajadores, observó una mejora promedio de productividad medida en casos resueltos por hora, con diferencias importantes entre grupos. Los beneficios más grandes se registraron entre trabajadores menos experimentados, mientras que para algunos trabajadores altamente experimentados las mejoras eran menores o podían acompañarse de deterioros en ciertos indicadores de calidad. Esa heterogeneidad importa más que un titular sobre el porcentaje promedio. La tecnología puede redistribuir conocimiento práctico, facilitar aprendizaje y, a la vez, alterar qué habilidades son valiosas o cómo las evaluamos.

Hay una lección especialmente importante en los resultados laborales. Acelerar una tarea no es lo mismo que mejorar la capacidad profesional de quien la realiza. En ocasiones ambas cosas ocurren juntas. En otras, una persona entrega más rápido un resultado cuya lógica ya no puede reconstruir. Un sistema puede ayudar a

redactar una síntesis de estudios y permitir dedicar más tiempo a diseñar una investigación; también puede multiplicar las citas falsas si nadie contrasta las fuentes. Para distinguir los efectos necesitamos observar qué cambia en el tiempo, qué capacidades se transfieren y qué sucede cuando la herramienta deja de estar disponible. Una mejora de productividad no se convierte automáticamente en aprendizaje duradero.

En investigación científica, la diferencia aparece de forma tangible. Supongamos que una investigadora desea comprender por qué cambió la distribución de una especie en una región. Un asistente puede ordenar antecedentes, localizar variables candidatas, proponer modelos estadísticos y escribir un primer borrador de interpretación. Puede reducir trabajo mecánico y revelar preguntas útiles. Pero la distribución observada depende también del esfuerzo de muestreo, la detectabilidad, los cambios de hábitat y los métodos de registro. El sistema no conoce esas condiciones por el solo hecho de producir una explicación plausible. Si la investigadora acepta la narración más fluida sin examinar los datos, la facilidad de acceso habrá ampliado la velocidad de su error, no su conocimiento.

La misma lógica se aplica a recursos humanos y decisiones organizacionales. Un modelo puede clasificar perfiles, sintetizar entrevistas o sugerir preguntas de evaluación. Sin embargo, la calidad de su recomendación depende de cómo se definieron las competencias, de quiénes quedaron representados en los datos y de qué barreras contiene el proceso de selección. Una respuesta elegante puede reproducir criterios que nunca fueron validados y presentar esa reproducción como una mejora técnica. No basta con disponer de una puntuación ni con afirmar que el sistema es imparcial. Hay que examinar qué se está midiendo, con quién se comparó el resultado y qué personas sufrirían las consecuencias de un error. La responsabilidad no se delega con un botón.

El Informe sobre Inteligencia Artificial de Stanford correspondiente a 2026 muestra hasta qué punto estas preguntas habían dejado de pertenecer exclusivamente a laboratorios especializados. Reúne evidencias de la expansión de las capacidades técnicas y de la adopción organizacional, pero también identifica diferencias entre desempeño en pruebas, robustez y despliegues de agentes. Una de sus cifras más citadas es que el ochenta y ocho por ciento de las organizaciones relevadas declaró utilizar alguna forma de inteligencia artificial en al menos una función durante 2025.[28] El alcance debe decirse completo: es un resultado de encuestas y autorreporte, no un censo universal ni una certificación de que esas implementaciones generan beneficios positivos.

El mismo informe distingue la expansión del uso organizacional del despliegue todavía acotado de agentes en numerosas funciones. Esa separación evita confundir dos estados muy diferentes: una empresa puede utilizar herramientas de IA para resumir documentos y no haber construido un sistema que actúe con permisos sobre procesos críticos. Cuando las cifras de adopción se presentan sin su definición, parecen medir avance técnico. En realidad, suelen medir presencia declarada de algún uso. El grado de integración, la evidencia de eficacia y la seguridad operacional son otras preguntas, y pueden tener respuestas distintas aun dentro de una misma organización.

Tampoco el progreso de los benchmarks elimina los problemas que motivaron aquellas advertencias de 2022. El capítulo de IA responsable del índice de Stanford 2026 señala que las evaluaciones de capacidades avanzan más deprisa que los instrumentos para medir responsabilidad y seguridad.[29] Sus ejemplos muestran modelos que responden de manera diferente cuando una afirmación falsa se presenta como creencia de otra persona o como creencia del usuario. No debemos universalizar el porcentaje de una prueba a todas las respuestas de todas las versiones. El

fenómeno relevante es que una arquitectura puede mostrar gran competencia técnica y seguir siendo vulnerable a la forma social en que aparece formulado un error. Una conversación no es un laboratorio neutral: el modo en que preguntamos también altera qué sistema estamos evaluando.

A estas alturas, la tentación consiste en organizar el período entre 2022 y 2026 como una carrera con un vencedor inevitable. Cada lanzamiento reemplazaría al anterior, cada nueva puntuación corregiría la incertidumbre del día previo y la historia terminaría en el modelo situado al frente de una clasificación. Es un relato publicitario eficaz y una explicación histórica pobre. Los modelos cambian de versión, los conjuntos de evaluación envejecen, los criterios de uso divergen y los resultados pueden depender del idioma, el tipo de problema, la herramienta disponible y el costo de una equivocación. El rendimiento que interesa a una organización no siempre coincide con el que produce mayor entusiasmo en una demostración pública.

La competencia entre laboratorios también tiene consecuencias que las cifras no capturan fácilmente. Requiere capital, energía, centros de datos, trabajo de anotación, infraestructura de cómputo y mecanismos para distribuir productos. El recorrido desde el proyecto de Babbage hasta los sistemas generativos muestra que la historia de las ideas nunca estuvo separada de la materialidad de las máquinas. Ada Lovelace podía razonar sobre una arquitectura no construida; el Logic Theorist necesitó listas y programación sobre JOHNNIAC; las redes profundas encontraron nuevas posibilidades con datos y procesadores adecuados. En el presente, el costo de entrenar, servir y evaluar sistemas condiciona quién puede investigar, qué se publica y qué opciones tecnológicas llegan al público.

Hay un problema adicional que la rapidez de los lanzamientos vuelve menos visible: cuando una empresa ofrece una respuesta, las personas reciben un producto terminado pero raramente conocen todos sus componentes. Parte de la información sobre datos de entrenamiento, evaluaciones y decisiones de despliegue puede ser pública, parcial o reservada. Para sostener una afirmación científica necesitamos saber qué evidencia está disponible y cuáles son sus límites. Una ficha técnica puede describir propiedades importantes y omitir detalles necesarios para reproducir íntegramente el entrenamiento. La falta de transparencia no convierte automáticamente todo resultado en falso; sí restringe las conclusiones que podemos justificar de forma independiente.

La palabra «alineación» también requiere disciplina. Puede describir métodos para mejorar el seguimiento de instrucciones, reducir respuestas nocivas o ajustar una conducta a preferencias humanas definidas. No garantiza por sí misma que la respuesta sea verdadera ni que coincida con todos los valores legítimos en conflicto. Una decisión sobre políticas públicas, por ejemplo, puede requerir equilibrar derechos, recursos, evidencia y representación democrática. Una clasificación de perfiles profesionales puede demandar accesibilidad, validez estadística y mecanismos de apelación. Esas condiciones no pueden comprimirse en la instrucción genérica de «ser útil». La utilidad tiene destinatarios y consecuencias; la aceptabilidad de un resultado depende de cuáles sean.

El marco de gestión de riesgos de IA publicado por el NIST en 2023 representa una respuesta institucional a este desafío. No intenta resolver en una fórmula qué es la inteligencia. Propone un lenguaje para considerar confianza, riesgos, evaluación y gobernanza durante el diseño, el desarrollo y el uso de sistemas. Es voluntario y no equivale a una garantía universal de cumplimiento. Su importancia en esta historia es mostrar que la cuestión deja de ser únicamente si una máquina puede realizar una tarea. También

debemos preguntarnos cómo una organización construye las condiciones para detectar errores, asignar responsabilidades y corregir decisiones. La evaluación forma parte de la práctica, no aparece únicamente al final.

El recorrido que empezó con una interfaz conversacional termina, por tanto, en un problema de arquitectura institucional. Un modelo no es una política de uso. Un agente no es una persona responsable. Una respuesta no es una evidencia. Una evaluación tampoco es una explicación causal completa. Cada elemento puede contribuir a un sistema de trabajo valioso si comprendemos qué función cumple, cómo se comprueba y quién conserva el derecho de intervenir. El desafío no consiste en proteger una supuesta pureza del pensamiento humano frente a toda automatización; consiste en diseñar colaboraciones capaces de ampliar lo que sabemos hacer sin volver opacas las razones por las que actuamos.

Este principio no exige que toda persona comprenda internamente cada parámetro de un modelo. Sería una exigencia irreal, como pedir a quien utiliza un microscopio que fabrique cada lente o a quien consulta una base de datos que haya escrito todo su software. Exige algo más específico: conocer las condiciones bajo las cuales una herramienta proporciona evidencia útil, reconocer las operaciones que han sido delegadas y disponer de métodos para cuestionar los resultados que importan. Una persona experta puede apoyarse profundamente en instrumentos complejos sin renunciar al juicio. La pericia consiste, en parte, en saber qué puede delegarse con confianza y qué debe seguir siendo objeto de revisión.

Lo que cambió en noviembre de 2022 fue la relación cotidiana entre esa complejidad y las palabras. La pregunta dejó de presentarse como una instrucción técnica reservada a especialistas y pasó a formar parte de una conversación. En cuatro años la interfaz adquirió nuevas modalidades, fuentes y posibilidades de actuación.

También reunió nuevas dependencias, nuevas oportunidades de error y nuevas formas de confianza. El acontecimiento fue real, y sería mezquino minimizarlo. Sería igualmente engañoso describirlo como el momento en que quedó resuelto el problema de la inteligencia.

Volvamos a un gesto sencillo: alguien escribe una pregunta y recibe una respuesta. El intercambio puede servir para pensar, investigar, programar o tomar una decisión. Pero esas actividades no comparten un único criterio de éxito. Una frase puede estar bien escrita y ser falsa; una hipótesis puede resultar interesante y no haber sido contrastada; un programa puede ejecutarse y no ser seguro en el entorno donde se lo utiliza. La interfaz reúne estas actividades bajo una misma apariencia conversacional. Distinguirlas vuelve a ser trabajo de quien pregunta.

Las máquinas de esta historia no se parecen entre sí. Una ejecutaba tablas, otra buscaba teoremas, otra aprendía a mover piezas, otra devolvía preguntas y otra producía lenguaje con una fluidez extraordinaria. Lo que las conecta no es una esencia demostrada de la inteligencia, sino una sucesión de intentos por definir tareas, construir mecanismos y observar resultados. Con una pantalla conversacional, esa historia se volvió cotidiana. Para comprender lo que cambió —y lo que no— necesitamos regresar al papel donde una comunidad científica decidió, en 1955, que la inteligencia podía convertirse en un problema de investigación.

Epílogo · La pregunta que sobrevivió

Una propuesta de investigación no suele conservar su forma original cuando se convierte en una historia de éxito. Los años depositan sobre ella descubrimientos posteriores, imágenes memorables y nombres que ya conocemos. Lo que en el momento de redactarse era una posibilidad termina presentándose como el comienzo inevitable de algo que estaba destinado a ocurrir. Por eso necesitamos regresar a Dartmouth. No para repetir la historia del verano de 1956, sino para observar cuánto cambió nuestra manera de leer aquel documento después de atravesar las máquinas, las dudas y las controversias de este libro.

Cuatro investigadores habían reunido bajo una expresión nueva problemas que pertenecían a tradiciones distintas. Hablaban de lenguaje, aprendizaje, abstracción, redes nerviosas y creatividad, sin disponer de una teoría única de aquello que proponían estudiar. Sabemos ahora que sus expectativas no culminaron en una explicación general de la inteligencia al terminar el verano. Sabemos también que la ausencia de una epifanía no impidió que el nombre organizara instituciones, recursos y disputas durante décadas. La disciplina adquirió historia antes de adquirir consenso sobre su objeto.

Desde la distancia del presente podríamos considerar esa falta de acuerdo una señal de inmadurez. Sería una conclusión apresurada. Muchas ciencias investigan objetos complejos mediante modelos que conservan propiedades diferentes. Una ecóloga puede describir una comunidad mediante abundancias, relaciones tróficas, flujos de energía o dinámicas espaciales. Ninguna de esas descripciones agota por sí sola el ecosistema; cada una revela algo bajo condiciones apropiadas. La dificultad aparece cuando una medida

útil se convierte en una definición total del fenómeno. La inteligencia artificial heredó desde el comienzo esa tensión entre una palabra amplia y una multitud de pruebas particulares.

Ada Lovelace nos dejó una posibilidad formulada en condicional: una máquina analítica podría trabajar con relaciones más allá de los números si consiguiéramos representarlas de una manera adecuada. No vimos una máquina completa producir música en 1843. Vimos a una investigadora analizar qué podría seguirse de un diseño y cuáles eran sus límites. La historia enseñó que una arquitectura puede ampliar las tareas concebibles sin que eso demuestre que domina el significado de aquello sobre lo que opera. Una representación abre caminos y deja otros fuera. Esa doble condición reaparece cada vez que describimos el mundo para hacerlo computable.

Alan Turing desplazó la discusión hacia las condiciones de una pregunta. Antes de decidir si una máquina pensaba, propuso examinar qué tipo de conducta aceptaríamos como evidencia y qué conclusiones resultarían justificadas. También mostró que computar no significa poder resolver mediante un procedimiento universal cualquier problema imaginable. Su legado no fue una prueba eterna de humanidad artificial. Fue una manera de convertir afirmaciones grandiosas en preguntas que pudieran investigarse, y una advertencia sobre los límites de nuestras propias definiciones.

McCulloch y Pitts encontraron una relación formal entre ciertas redes idealizadas y operaciones de la lógica. Rosenblatt exploró la posibilidad de ajustar conexiones para reconocer patrones a partir de la experiencia. En ambos episodios apareció la tentación de confundir un modelo con el organismo que lo había inspirado. La matemática podía ser exacta mientras la correspondencia biológi-

ca permanecía parcial. Reconocer esa diferencia no obligaba a despreciar los modelos. Permitía comprender por qué eran valiosos y qué preguntas no podían responder.

El Logic Theorist ofreció una escena más acotada y, por eso mismo, extraordinaria: un programa podía buscar una demostración cuyos pasos fueran comprobables dentro de un sistema formal. Shannon y Samuel mostraron otros caminos para enfrentar espacios de decisiones que no pueden explorarse por completo. Sus algoritmos no aportaban una inteligencia única, sino mecanismos que relacionaban representación, búsqueda, criterios de evaluación y experiencia. Allí aprendimos que resolver una tarea depende tanto del problema formulado como del método elegido para aproximarse a él.

ELIZA agregó una dificultad que ninguna ecuación de desempeño podía eliminar. Una conversación puede resultar significativa para quien participa en ella sin que el programa haya construido una representación profunda de su interlocutor. Las personas completamos el sentido, interpretamos silencios y atribuimos intenciones. DENDRAL ofreció un contraste: un sistema muy especializado, poco interesado en parecer humano, podía ayudar a formular hipótesis científicas precisamente porque incorporaba restricciones de un dominio bien delimitado. Parecer inteligente y producir conocimiento útil no resultaron ser la misma propiedad.

Los llamados inviernos de la IA recordaron que los resultados técnicos viven en instituciones y presupuestos. Una teoría puede perder prestigio sin quedar refutada en todos sus usos. Un prototipo puede funcionar y, sin embargo, no convertirse en un producto sostenible. Una promesa puede exceder las posibilidades de una época y reabrirse después bajo otras condiciones. La historia se vuelve ininteligible si confundimos financiación, capacidad técnica, aprobación social y verdad científica como si fueran dimensiones equivalentes.

Las redes neuronales profundas reabrieron posibilidades de aprender representaciones internas que nadie había escrito una por una. Deep Blue y AlphaGo consiguieron victorias verificables en juegos de reglas estrictas mediante caminos técnicos distintos. ImageNet transformó la visión artificial al hacer posibles comparaciones sobre cantidades enormes de ejemplos, mientras dejaba abiertas preguntas sobre qué mundo representaban esos ejemplos. Los transformers reorganizaron el tratamiento de secuencias y abrieron nuevas escalas de modelización del lenguaje. Cada avance importó por su capacidad particular y por los problemas nuevos que introdujo. No hubo una sola línea de progreso que explicara retrospectivamente todo lo anterior.

Después llegó una interfaz que parecía eliminar las barreras entre una persona y todas esas capas de investigación. Bastaba escribir. Aquel gesto produjo posibilidades reales: trabajar con textos, explorar ideas, analizar materiales y realizar tareas que antes demandaban herramientas menos accesibles. También hizo más fácil confundir la naturalidad de una respuesta con la solidez de sus premisas. Si el lenguaje era el medio de acceso, podía convertirse al mismo tiempo en un velo. Cuanto más cómoda resultaba la conversación, más necesario se volvía preguntarse qué operación había ocurrido detrás de ella.

Nos acercamos así a una pregunta que no depende de resolver primero si una máquina tiene conciencia. Puede discutirse la experiencia subjetiva artificial desde la filosofía y la ciencia cognitiva sin que exista un consenso final. Pero para decidir si conviene utilizar un sistema en una investigación, en la educación o en una organización necesitamos criterios verificables de otro tipo. ¿Qué tarea resuelve? ¿Qué datos conoce? ¿Cómo se ha medido su desempeño? ¿Qué errores son posibles? ¿Qué ocurre cuando cambia el contexto? ¿Quién puede revisar una conclusión y corregir una decisión? Ninguna de esas preguntas requiere atribuirle al sistema una biografía humana.

Quizá el descubrimiento más desconcertante del recorrido sea que la palabra inteligencia no disminuyó su ambigüedad a medida que crecieron las capacidades de las máquinas. En ciertos ámbitos ganamos precisión: podemos definir error de clasificación, proporción de respuestas correctas, tiempo de ejecución o validez formal de una demostración. En otros, las capacidades nuevas volvieron más difíciles las categorías anteriores. ¿Es conocimiento una respuesta correcta cuyo origen no podemos reconstruir? ¿Es aprendizaje una mejora que desaparece fuera de la distribución conocida? ¿Es autonomía una tarea que el programa ejecuta sin intervención, aunque su propósito y sus permisos hayan sido fijados por personas?

Las preguntas no están diseñadas para conducir al escepticismo inmóvil. Una herramienta puede ser valiosa sin resolver todos los problemas filosóficos que suscita. Una investigadora puede utilizar una predicción como indicio, contrastarla con observaciones y llegar a una conclusión mejor de la que habría conseguido sin asistencia. Un equipo puede automatizar operaciones repetitivas y dedicar recursos a examinar excepciones, mejorar la accesibilidad o producir conocimiento nuevo. La diferencia está en cómo se organizan los controles, las responsabilidades y el aprendizaje de las personas que utilizan esos instrumentos.

La autonomía intelectual, por eso, no significa hacer todo a mano. Tampoco exige renunciar a sistemas complejos cuyos detalles ningún individuo puede dominar exhaustivamente. La ciencia nunca fue un ejercicio de autosuficiencia absoluta: depende de instrumentos, comunidades, protocolos, publicaciones y confianza distribuida. Pero esa confianza debe poder justificarse. No es la misma relación la que mantenemos con una idea sugerente, con un dato observado, con un experimento reproducible o con una conclusión que afecta derechos. Delegar algunas operaciones puede ampliar nuestro trabajo; delegar sin examen los criterios que vuelven defendible una decisión puede empobrecerlo.

El recorrido también permite reconocer el trabajo que las historias abreviadas suelen omitir: personas que programaron lenguajes, construyeron instrumentos, reunieron datos, anotaron imágenes y formularon objeciones que obligaron a cambiar de rumbo. Reconocer esas contribuciones modifica nuestro modo de repartir el mérito y de investigar las consecuencias de un fallo. Una historia de la inteligencia artificial necesita instituciones y prácticas además de nombres memorables.

El cierre de esta historia no exige elegir entre dos eslóganes. Sería insuficiente afirmar que toda inteligencia reside exclusivamente en quien utiliza la máquina: los sistemas han adquirido capacidades reales y transforman las prácticas humanas. También sería insuficiente concluir que el éxito de una demostración resuelve de una vez lo que significa comprender. Entre ambos extremos hay una tarea más interesante: describir las capacidades demostradas, identificar sus condiciones y conservar abiertas las preguntas que todavía no sabemos responder.

En el documento de Dartmouth había una confianza profunda en que describir una parte de la inteligencia con precisión permitiría construir procedimientos capaces de realizarla. Esa hipótesis fue fértil porque permitió experimentar. Su potencia no depende de que todas sus interpretaciones originales resultaran correctas. Dos siglos de historia computacional muestran que una máquina puede operar con símbolos, aprender parámetros, buscar demostraciones, comparar hipótesis y participar en tareas que antes parecían exclusivamente humanas. La variedad de esos logros impide reducirlos a un solo mecanismo. También impide seguir tratando la inteligencia como una propiedad misteriosa que aparece íntegra en cada nueva demostración.

El desafío que sigue es epistemológico. Un programa puede acertar una respuesta, construir una demostración formal o proponer una explicación compatible con observaciones. En cada caso, la

pregunta por la verdad tiene una forma diferente. Una demostración se examina paso a paso; una hipótesis exige evidencias que puedan contradecirla; una recomendación práctica incorpora consecuencias y valores que no caben enteramente en una función de pérdida. La historia de las máquinas nos ha enseñado a distinguir operaciones. El siguiente recorrido tendrá que preguntar qué significa saber algo gracias a ellas.

Regresemos una última vez al papel de 1955. Los firmantes no poseían una respuesta única, pero decidieron trabajar como si algunas dimensiones de la inteligencia pudieran transformarse en problemas de ciencia e ingeniería. Esa decisión dio lugar a descubrimientos, fracasos, métodos y controversias cuyo alcance ninguno de ellos podía conocer. Nuestro presente añade algo que aquellos investigadores no tuvieron: podemos interactuar cotidianamente con sistemas capaces de producir resultados que ellos apenas podían comenzar a imaginar. No tenemos, en cambio, permiso para dejar de preguntarnos por qué esos resultados merecen confianza.

La invención de la inteligencia artificial no terminó con una máquina que nos dijera qué pensar. Terminó, para este primer recorrido, con instrumentos que nos obligan a pensar mejor sobre lo que significa saber. Esa es la pregunta que sobrevivió. Y es la que abre el siguiente libro.

Notas finales por capítulo

Las notas acompañan afirmaciones históricas, resultados y controversias específicas. Se agrupan por capítulo para no interrumpir el hilo narrativo y remiten a la bibliografía general.

Prólogo · El verano que cabía en un papel

1. La propuesta fechada el 31 de agosto de 1955 y firmada por McCarthy, Minsky, Rochester y Shannon planificaba un estudio de dos meses durante el verano de 1956, con diez participantes previstos. Debe distinguirse el programa de investigación del alcance real del encuentro. Fuentes: F001 y F002. Volver al texto

Capítulo 1 · La máquina que podía escribir música

2. En las notas publicadas en 1843 junto con su traducción del texto de Menabrea, Lovelace distinguió funciones posibles de la máquina analítica y reflexionó sobre la música. Se trata de una formulación conceptual, no de un experimento musical ejecutado por una máquina construida. Fuente: F003. Volver al texto

3. La etiqueta «primera programadora» resume un debate historiográfico: Babbage había elaborado operaciones antes de 1843, y las notas de Lovelace tuvieron un papel singular en la publicación y explicación de esos procedimientos. Evitar presentarla como prioridad inequívoca no discutida. Fuentes para contraste historiográfico: F006 y F007. Volver al texto

Capítulo 2 · El hombre que cambió la pregunta

4. La predicción de Turing en 1950 se refería a una conversación de cinco minutos y a la probabilidad de identificación correcta por un interrogador promedio, bajo condiciones especificadas. No era una prueba universal de conciencia ni una predicción de inteligencia general. Fuente: F008. Volver al texto

5. Jones y Bergen (2026) estudiaron conversaciones simultáneas de cinco minutos con una persona y un sistema artificial. Bajo instrucciones para adoptar una personalidad humana, GPT-4.5 fue elegido como humano en el 73 % de los ensayos. El cuerpo del artículo asigna 36 % a GPT-4.5 sin personaje y 38 % a LLaMA sin personaje; su resumen presenta las tasas sin personaje en un orden incompatible. Esta discrepancia editorial no autoriza inferencias sobre conciencia. Fuente: F016. Volver al texto

Capítulo 3 · La neurona que se convirtió en una proposición

6. McCulloch y Pitts (1943) formalizaron redes de unidades idealizadas mediante lógica proposicional; sus supuestos de todo o nada no describen la totalidad de la neurofisiología real. El artículo desarrolla propiedades formales bajo condiciones explícitas. Fuentes: F023 y F024. Volver al texto

Capítulo 4 · El verano que no fue una epifanía

7. La invitación de John McCarthy a Ray Solomonoff, fechada en marzo de 1956 y conservada como facsímil, indicaba como fechas previstas el 18 de junio y el 17 de agosto de 1956. Es un plan de convocatoria, no un registro de asistencia diaria. El archivo Solomonoff conserva además informes de agosto y diciembre y cuadernos manuscritos; la reconstrucción de Grace Solomonoff contrasta duraciones y participantes. Fuentes: F001, F002, F031 y F032. Volver al texto

Capítulo 5 · El teorema que una máquina encontró

8. Newell, Shaw y Simon (1957) documentan ejecuciones de Logic Theory Machine en JOHNNIAC, con ejemplos de demostración y fracaso. Mencionan 38 teoremas disponibles antes de intentar el teorema 2.45; ese pasaje no determina por sí solo el denominador de 52. El recuento 38/52 corresponde a síntesis históricas posteriores de un conjunto delimitado y no se extrapola a matemática general. Fuente primaria: F036; contraste histórico: F115. Volver al texto

9. McMaster cataloga el envío de Herbert Simon a Bertrand Russell del 2/10/1956 (BRACERS 3085) y las respuestas del 2/11/1956 (BRACERS 3086) y del 21/09/1957 (BRACERS 80427). Los registros identifican remitentes, destinatarios y notas de contenido, pero no ofrecen transcripción pública íntegra. No se recrean conversaciones ni se atribuyen pasajes extensos no accesibles. Fuentes: F041 y F118; catálogo adicional: https://bracers.mcmaster.ca/3085. Volver al texto

Capítulo 6 · Aprender a ganar

10. Samuel desarrolló programas de damas que ajustaban valoraciones mediante la experiencia; la publicación de 1959 describió enfoques distintos de aprendizaje. Los resultados de demostración y posteriores partidas no deben generalizarse a aprendizaje autónomo de cualquier tarea. Fuentes: F045 y F046. Volver al texto

Capítulo 7 · La neurona que prometía reconocer el mundo

11. El perceptrón de Rosenblatt debe distinguirse como familia de modelos y como implementación experimental. El artículo de 1958 formuló una interpretación probabilística, mientras que el libro de 1962 desarrolló propiedades y límites formales. Fuentes: F048 y F049. Volver al texto

12. La crítica de Minsky y Papert (1969) examinó restricciones matemáticas de determinadas arquitecturas de perceptrón. La interpretación de que su libro causó por sí solo el abandono de las redes neuronales es una simplificación historiográfica. Fuentes: F053 y F054. Volver al texto

Capítulo 8 · La conversación que devolvía nuestras palabras

13. El artículo original de Weizenbaum (1966) describe reglas de descomposición y recomposición disparadas por palabras clave, contexto mínimo y guiones editables. La impresión de conversación no demuestra una comprensión general del lenguaje. Fuente: F057. Volver al texto

14. La reconstrucción histórica de Marino y colaboradores (2026) utiliza evidencia de código recuperado para examinar versiones de ELIZA y diferencias entre documentación y conversaciones difundidas. No deben atribuirse todas las funciones identificadas a cada versión histórica. Fuente: F117; complementar con F058–F060. Volver al texto

Capítulo 9 · DENDRAL: las hipótesis que nacían de un espectro

15. Schroll y colaboradores (1969) informan, para éteres alifáticos en una configuración experimental específica, una reducción de 989 estructuras teóricas a 10 candidatas utilizando datos de espectrometría de masas. No significa identificación inequívoca general ni tasa universal de acierto de DENDRAL. Fuente: F064. Volver al texto

16. El resumen original de Buchanan y colaboradores (1976), visible en la primera página publicada, describe pruebas con aminas alifáticas de baja resolución y esteroides estrogénicos de alta resolución, y comunica nuevas reglas para cetoandrostanos. Son afirmaciones de los autores dentro de esos dominios, no una validación general ni cifras de precisión verificadas con todo el desarrollo experimental. Fuente: F065. Volver al texto

Capítulo 10 · Los inviernos que nunca fueron uno

17. El informe Lighthill y la controversia británica de 1973 forman parte de la historia de la financiación y evaluación de IA. La contracción del apoyo no debe atribuirse a una causa única sin respaldo de archivos presupuestarios e institucionales. Fuentes: F067 y F069. Volver al texto

Capítulo 11 · Las representaciones que nadie programó una por una

18. La diferenciación inversa y la retropropagación tienen antecedentes en diversas disciplinas. La revisión histórica de Griewank (2012) documenta contribuciones previas a la popularización de los modelos conexionistas. Evitar atribuir una invención única sin matices. Fuentes: F075, F077 y F116. Volver al texto

Capítulo 12 · Dos tableros, dos inteligencias

19. AlphaGo Zero (Silver y colaboradores, 2017) fue entrenado mediante aprendizaje por refuerzo y autojuego sin partidas humanas como datos de entrenamiento. No debe trasladarse esa condición retrospectivamente al AlphaGo que jugó contra Lee Sedol en 2016. Fuente: F084. Volver al texto

Capítulo 13 · Un millón de imágenes no es el mundo

20. ImageNet combinó una base de imágenes anotadas con objetivos de clasificación definidos; deben distinguirse el proyecto original de 2009, las distintas versiones del conjunto y la competición ILSVRC. Fuente: F086 y descripción posterior F087. Volver al texto

21. En ILSVRC-2012, el equipo de Toronto obtuvo un error top cinco del 15,3 %, frente al 26,2 % del segundo equipo. Según la tabla 2 del artículo de Krizhevsky, Sutskever y Hinton, la cifra de 15,3 % corresponde a la combinación de siete redes preentrenadas con una colección más amplia de ImageNet, no al resultado de una sola red. Fuente: F088. Volver al texto

Capítulo 14 · La atención no apareció para conversar

22. Vaswani y colaboradores (2017) informaron 28,4 BLEU para WMT 2014 inglés→alemán en el PDF disponible del artículo y en la ficha de Google Research. La página de resumen de NeurIPS conserva, en cambio, 27,5 BLEU. Debe citarse la versión exacta y no equiparar automáticamente esas cifras. Fuente: F097. Volver al texto

23. Los pesos de atención no son, por sí solos, explicaciones causales de una predicción. Jain y Wallace (2019) aportaron contraejemplos; Wiegreffe y Pinter (2019) sostuvieron que la utilidad explicativa depende de definiciones y controles experimentales. Fuentes: F100 y F101. Volver al texto

Capítulo 15 · La interfaz que alteró la pregunta

24. ChatGPT se presentó públicamente el 30 de noviembre de 2022. Deben distinguirse sus funciones de lanzamiento de capacidades y herramientas incorporadas en etapas posteriores. Fuente: F102. Volver al texto

25. Chatterji y colaboradores (2025) publicaron How People Use ChatGPT como NBER Working Paper 34255, no como artículo arbitrado. El trabajo clasifica automáticamente mensajes de una muestra del producto de consumo, bajo procedimientos orientados a proteger la privacidad. Aaron Chatterji y Zoe Hitzig declararon su condición de empleados de OpenAI; esa vinculación debe considerarse al evaluar la independencia de los resultados. Fuente: F109. Volver al texto

26. Noy y Zhang (Science, 2023) estudiaron a 453 profesionales con tareas de escritura específicas; el tiempo promedio disminuyó 40 % y la calidad evaluada aumentó 18 % bajo esas condiciones. No generalizar la magnitud del efecto a todas las ocupaciones. Fuente: F110. Volver al texto

27. Brynjolfsson, Li y Raymond (The Quarterly Journal of Economics, 2025) analizaron 5.172 agentes de atención al cliente durante un despliegue escalonado de asistencia con IA: aproximadamente 15 % más casos resueltos por hora en promedio, con efectos heterogéneos. No representa una estimación universal de productividad. Fuente: F111. Volver al texto

28. El 88 % del AI Index 2026 de Stanford corresponde a organizaciones cuyos representantes declararon utilización de IA en al menos una función durante 2025, según encuestas empresariales. Es autorreporte en la población encuestada, no un censo mundial. Fuente: F112. Volver al texto

29. El capítulo Responsible AI del AI Index 2026 documenta un desfase entre la medición de capacidades y las evaluaciones de seguridad, equidad y gobernanza; las cifras de incidentes y benchmarks dependen de sus fuentes y definiciones operativas. Fuente: F113. Volver al texto

Bibliografía general de consulta

Esta bibliografía reúne fuentes citadas explícitamente en las notas y bibliografía general de consulta utilizada para contextualizar, contrastar o ampliar el recorrido histórico. Los códigos F permiten la trazabilidad interna. Se consolidaron entradas duplicadas y se aplicó un criterio Chicago Notes & Bibliography adaptado a artículos científicos, libros, archivos institucionales y recursos web.

F001 · McCarthy, J.; Minsky, M.; Rochester, N.; Shannon, C. (1955). A Proposal for the Dartmouth Summer Research Project on Artificial Intelligence. Texto conservado en Stanford. Fuente F001

F002 · McCarthy, J. y colaboradores (2006). Reproducción y nota introductoria de la propuesta de Dartmouth, AI Magazine, 27(4). DOI 10.1609/aimag.v27i4.1904. Fuente F002

F003 · Lovelace, A. A. (1843). Notes by the Translator, en Sketch of the Analytical Engine. Transcripción académica de York University. Fuente F003

F004 · Computer History Museum. The Engines y A Brief History. Dossier sobre los diseños de Charles Babbage. Fuente F004

F005 · Science Museum Group. Ada Lovelace, ficha de colección. Fuente F005

F006 · Hollings, C.; Martin, U.; Rice, A. (2017). The Lovelace–De Morgan mathematical correspondence: A critical re-appraisal. Historia Mathematica, 44(3), 202–231. DOI 10.1016/j.hm.2017.04.001. Fuente F006

F007 · Misa, T. J. (2015; versión consultable 2023). Charles Babbage, Ada Lovelace, and the Bernoulli Numbers. En Ada’s Legacy. Fuente F007

F008 · Turing, A. M. (1950). Computing Machinery and Intelligence. Mind 59(236), 433–460. DOI 10.1093/mind/LIX.236.433. Fuente F008

F009 · Clay Mathematics Institute. Ada Lovelace’s Mathematical Papers. Introducción a correspondencia y formación. Fuente F009

F010 · Science Museum Group. Notations of the Analytical Engine. Descripción archivística de 388 notaciones. Fuente F010

F011 · History of Science Museum (Oxford). Imagining AI – Babbage & Lovelace. Fuente F011

F012 · Turing, A. M. (1936; catalogación editorial también 1937). On Computable Numbers, with an Application to the Entscheidungsproblem. Proceedings of the London Mathematical Society, 42, 230–265. DOI 10.1112/plms/s2-42.1.230. Fuente F012

F013 · Stanford Encyclopedia of Philosophy (2023). The Church–Turing Thesis. Fuente F013

F014 · Turing, A. M. (1948). Intelligent Machinery. Informe del National Physical Laboratory, publicado posteriormente en compilaciones. Fuente F014

F015 · The Turing Digital Archive, King's College, Cambridge. Computing machinery and intelligence, archivo AMT/B/9. Fuente F015

F016 · Jones, C. R. y Bergen, B. K. (2026). Large language models pass a standard three-party Turing test. PNAS. DOI 10.1073/pnas.2524472123. Fuente F016

F017 · Turing, A. M. (1952). The Chemical Basis of Morphogenesis. Philosophical Transactions of the Royal Society B, 237(641), 37–72. DOI 10.1098/rstb.1952.0012. Fuente F017

F018 · Royal Society (2021). A Modern View on Turing's Theory of Pattern Formation. Fuente F018

F019 · The Turing Digital Archive, King's College, Cambridge. About Alan Turing. Fuente F019

F020 · UK Ministry of Justice (2013). Royal pardon for WW2 code-breaker Dr Alan Turing. Fuente F020

F021 · GCHQ (2019). Alan Turing. Historia institucional publicada por el organismo británico. Fuente F021

F022 · Stanford Encyclopedia of Philosophy. The Turing Test. Fuente F022

F023 · McCulloch, W. S. y Pitts, W. (1943). A Logical Calculus of the Ideas Immanent in Nervous Activity. Bulletin of Mathematical Biophysics 5, 115–133. DOI 10.1007/BF02478259. Fuente F023

F024 · McCulloch y Pitts (1943), reimpresión del artículo en Bulletin of Mathematical Biology 52(1–2), 99–115 (1990). Fuente F024

F025 · Abraham, T. H. (2002). (Physio)logical circuits: The intellectual origins of the McCulloch–Pitts neural networks. Journal of the History of the Behavioral Sciences 38(1), 3–25. DOI 10.1002/jhbs.1094. Fuente F025

F026 · Max Planck Institute for the History of Science. Theoretical Methods in Studies of the Nervous System, 1920–60. Fuente F026

F027 · Hodgkin, A. L. y Huxley, A. F. (1952). A quantitative description of membrane current and its application to conduction and excitation in nerve. Journal of Physiology 117, 500–544. DOI 10.1113/jphysiol.1952.sp004764. Fuente F027

F028 · Wiener, N. (1948). Cybernetics: Or Control and Communication in the Animal and the Machine. Edición original; catálogo Wellcome Collection. Fuente F028

F029 · Shannon, C. E. (1948). A Mathematical Theory of Communication. Bell System Technical Journal 27(3), 379–423; 27(4), 623–656. DOI parte I: 10.1002/j.1538-7305.1948.tb01338.x; parte II: 10.1002/j.1538-7305.1948.tb00917.x. Fuente F029

F030 · Abraham, T. H. (2004). Nicolas Rashevsky's Mathematical Biophysics. Journal of the History of Biology 37, 333–385. DOI 10.1023/B:HIST.0000038267.09413.0d. Fuente F030

F031 · Solomonoff, G. Ray Solomonoff and the Dartmouth Summer Research Project in Artificial Intelligence, 1956. Estudio histórico basado en el archivo Solomonoff. Fuente F031

F032 · Ray Solomonoff Archive. Dartmouth AI Archives: notas de actividades, informes y versiones de An Inductive Inference Machine. Fuente F032

F033 · Solomonoff, G. The Meeting of the Minds That Launched AI. IEEE Spectrum. Fuente F033

F034 · Newell, A.; Simon, H. A. (1956). Plans for the Dartmouth Summer Research Project on Artificial Intelligence, March 6, 1956. Copia alojada en MIT CSAIL. Fuente F034

F035 · Newell, A. y Simon, H. A. (1956). The Logic Theory Machine—A Complex Information Processing System. IRE Transactions on Information Theory 2(3), 61–79. DOI 10.1109/TIT.1956.1056797. Fuente F035

F036 · Newell, A.; Shaw, J. C.; Simon, H. A. (1957). Empirical Explorations of the Logic Theory Machine: A Case Study in Heuristic. Western Joint Computer Conference, 218–230. DOI 10.1145/1455567.1455605. Fuente F036

F037 · Newell, A. y Simon, H. A. (1970). Human Problem Solving, Historical Addendum, copia archivada en CMU. Fuente F037

F038 · Simon, H. A. (1997). Allen Newell. Biographical Memoirs 71, National Academy of Sciences, pp. 141 y ss. Fuente F038

F039 · Dick, Stephanie (2015). Of Models and Machines: Implementing Bounded Rationality. Isis 106(3), 623–634. DOI 10.1086/683527. Fuente F039

F040 · Computer History Museum. Timeline of Computer History, 1955: Logic Theorist. Fuente F040

F041 · Russell Archives, McMaster University. BRACERS 3085: Simon a Russell, 2/10/1956; BRACERS 3086: Russell a Simon, 2/11/1956. Registros catalográficos; no equivalen a cartas íntegramente transcritas. Fuente F041

F042 · Carnegie Mellon University Archives. Herbert A. Simon papers, colección 1998-01; registros Logic Theorist 8/12/1955 y 31/01/1956. Fuente F042

F043 · Newell, A. y Simon, H. A. (1976). Computer Science as Empirical Inquiry: Symbols and Search. Communications of the ACM 19(3), 113–126. Fuente F043

F044 · Shannon, C. E. (1950). Programming a Computer for Playing Chess. Philosophical Magazine 41(314), 256–275. DOI 10.1080/14786445008521796. Fuente F044

F045 · Samuel, A. L. (1959). Some Studies in Machine Learning Using the Game of Checkers. IBM Journal of Research and Development 3(3), 210–229. DOI 10.1147/rd.33.0210. Fuente F045

F046 · Samuel, A. L. (1959). Texto íntegro reproducido por UMBC. Fuente F046

F047 · IBM (s. f.; consulta 2026). The games that helped AI evolve. Archivo histórico corporativo. Fuente F047

F048 · Rosenblatt, F. (1958). The Perceptron: A Probabilistic Model for Information Storage and Organization in the Brain. Psychological Review 65(6), 386–408. DOI 10.1037/h0042519. Fuente F048

F049 · Rosenblatt, F. (1962). Principles of Neurodynamics: Perceptrons and the Theory of Brain Mechanisms. Spartan Books, 616 p. Fuente F049

F050 · Smithsonian National Museum of American History. Electronic Neural Network, Mark I Perceptron. Fuente F050

F051 · Cornell Chronicle (2019). Professor's perceptron paved the way for AI – 60 years too soon. Fuente F051

F052 · The New Yorker (1958). Rival. Sección periodística publicada el 29 de noviembre de 1958. Fuente F052

F053 · Minsky, M.; Papert, S. (1969). Perceptrons: An Introduction to Computational Geometry. MIT Press. Fuente F053

F054 · Olazaran, M. (1996). A Sociological Study of the Official History of the Perceptrons Controversy. Social Studies of Science 26(3). DOI 10.1177/030631296026003005. Fuente F054

F055 · Goodfellow, I.; Bengio, Y.; Courville, A. (2016). Deep Learning, capítulo 1, MIT Press. Fuente F055

F056 · IEEE (1960). Perceptron Simulation Experiments. Proceedings of the IRE 48(3), 301–309. DOI 10.1109/JRPROC.1960.287598. Fuente F056

F057 · Weizenbaum, J. (1966). ELIZA—A Computer Program For the Study of Natural Language Communication Between Man and Machine. Communications of the ACM 9(1), 36–45. DOI 10.1145/365153.365168. Fuente F057

F058 · MIT Distinctive Collections. Computer conversations, 1965: listado original del programa ELIZA en MAD-SLIP y guion DOCTOR. Fuente F058

F059 · Finding ELIZA, The versions (2026): arqueología de variantes 1965a, 1965b, 1966, 1967 y posteriores. Fuente F059

F060 · Finding ELIZA, The program (2026): reconstrucción de funciones, contador de memoria y editor CHANGE. Fuente F060

F061 · Weizenbaum, J. (1976). Computer Power and Human Reason: From Judgment to Calculation. W. H. Freeman. Fuente F061

F062 · Computer History Museum, Software Preservation Group. DENDRAL Project: documentación, código y bibliografía. Fuente F062

F063 · Carnegie Mellon University, AI Repository. DENDRAL and CONGEN: Molecular Structure Elucidation in Organic Chemistry. Fuente F063

F064 · Schroll, G. y cols. (1969). Applications of Artificial Intelligence for Chemical Inference. III. Aliphatic Ethers Diagnosed by Their Low-Resolution Mass Spectra and Nuclear Magnetic Resonance Data. JACS 91(26), 7440–7445. DOI 10.1021/ja01054a036. Fuente F064

F065 · Buchanan, B. G.; Smith, D. H.; White, W. C.; Gritter, R. J.; Feigenbaum, E. A.; Lederberg, J.; Djerassi, C. (1976). Applications of artificial intelligence for chemical inference. 22. Automatic rule formation in mass spectrometry by means of the META-DENDRAL program. Journal of the American Chemical Society 98(20), 6168–6178. DOI 10.1021/ja00436a017. Fuente F065

F066 · Lindsay, R. K.; Buchanan, B. G.; Feigenbaum, E. A.; Lederberg, J. (1993). DENDRAL: A case study of the first expert system for scientific hypothesis formation. Artificial Intelligence 61(2), 209–261. DOI 10.1016/0004-3702(93)90068-M. Fuente F066

F067 · University of Edinburgh, Artificial Intelligence Applications Institute. Lighthill Controversy Debate at the Royal Institution, junio de 1973; archivo de debate y reporte. Fuente F067

F068 · University of Edinburgh, School of Informatics. History of Artificial Intelligence at Edinburgh. Fuente F068

F069 · House of Lords, Artificial Intelligence Committee (2018). AI in the UK: ready, willing and able?, discusión histórica de Lighthill. Fuente F069

F070 · National Academy of Sciences / National Research Council (1966). Language and Machines: Computers in Translation and Linguistics (ALPAC). Fuente F070

F071 · Kirtchik, O. (2023). The Soviet scientific programme on AI: if a machine cannot ‘think’, can it ‘control’? BJHS Themes 8, 111–125. DOI 10.1017/bjt.2023.4. Fuente F071

F072 · Information Processing Society of Japan, Computer Museum. Start of the 5th Generation Computer Project. Fuente F072

F073 · Computer History Museum. Timeline of Computer History: AI & Robotics. Fuente F073

F074 · House of Lords, AI in the UK: ready, willing and able?, anexo histórico. Fuente F074

F075 · Rumelhart, D. E.; Hinton, G. E.; Williams, R. J. (1986). Learning representations by back-propagating errors. Nature 323, 533–536. DOI 10.1038/323533a0. Fuente F075

F076 · Hinton, G. E. (2014). Where Do Features Come From? Cognitive Science 38(6), 1078–1101. DOI 10.1111/cogs.12049. Fuente F076

F077 · Werbos, P. J. (1974). Beyond Regression: New Tools for Prediction and Analysis in the Behavioral Sciences. Tesis doctoral, Harvard University. Fuente F077

F078 · Hinton, G. E. (s. f.). Backpropagation Learning. Archivo de publicaciones de Geoffrey E. Hinton, University of Toronto. Fuente F078

F079 · Campbell, M.; Hoane, A. J.; Hsu, F.-h. (2002). Deep Blue. Artificial Intelligence 134 (1–2), 57–83. DOI 10.1016/S0004-3702(01)00129-1. Fuente F079

F080 · IBM. Deep Blue (historia institucional de IBM). Fuente F080

F081 · Silver, D. y colaboradores (2016). Mastering the game of Go with deep neural networks and tree search. Nature 529, 484–489. DOI 10.1038/nature16961. Fuente F081

F082 · Google DeepMind. AlphaGo, historia y documentación técnica institucional. Fuente F082

F083 · Hassabis, D. y equipo (2016). AlphaGo's ultimate challenge: a five-game match against Lee Sedol. Blog de Google, 8–15 de marzo de 2016. Fuente F083

F084 · Silver, D. y colaboradores (2017). Mastering the game of Go without human knowledge. Nature 550, 354–359. DOI 10.1038/nature24270. Fuente F084

F085 · American Physical Society (2002). 1996: Kasparov vs. Deep Blue. APS News. Fuente F085

F086 · Deng, J.; Dong, W.; Socher, R.; Li, L.-J.; Li, K.; Li, F.-F. (2009). ImageNet: A Large-Scale Hierarchical Image Database. CVPR, 248–255. DOI 10.1109/CVPR.2009.5206848. Fuente F086

F087 · Russakovsky, O. y colaboradores (2015). ImageNet Large Scale Visual Recognition Challenge. International Journal of Computer Vision 115, 211–252. DOI 10.1007/s11263-015-0816-y. Fuente F087

F088 · Krizhevsky, A.; Sutskever, I.; Hinton, G. E. (2012). ImageNet Classification with Deep Convolutional Neural Networks. Advances in Neural Information Processing Systems 25, tabla 2 (ILSVRC-2012). Fuente F088

F089 · Torralba, A.; Efros, A. A. (2011). Unbiased Look at Dataset Bias. CVPR, 1521–1528. DOI 10.1109/CVPR.2011.5995347. Fuente F089

F090 · Recht, B.; Roelofs, R.; Schmidt, L.; Shankar, V. (2019). Do ImageNet Classifiers Generalize to ImageNet? ICML / PMLR 97, 5389–5400. Fuente F090

F091 · ImageNet Project (17 septiembre 2019). Update on ImageNet fairness and representation. Fuente F091

F092 · Krizhevsky, A.; Sutskever, I.; Hinton, G. E. (2017). ImageNet classification with deep convolutional neural networks. Communications of the ACM 60(6), 84–90. DOI 10.1145/3065386. Fuente F092

F093 · Li, F.-F. (2015). How we are teaching computers to understand pictures. TED Global, conferencia. Fuente F093

F094 · Sutskever, I.; Vinyals, O.; Le, Q. V. (2014). Sequence to Sequence Learning with Neural Networks. Advances in Neural Information Processing Systems 27. Fuente F094

F095 · Bahdanau, D.; Cho, K.; Bengio, Y. (2015). Neural Machine Translation by Jointly Learning to Align and Translate. ICLR 2015; preprint 2014. Fuente F095

F096 · Luong, M.-T.; Pham, H.; Manning, C. D. (2015). Effective Approaches to Attention-based Neural Machine Translation. EMNLP, 1412–1421. DOI 10.18653/v1/D15-1166. Fuente F096

F097 · Vaswani, A.; Shazeer, N.; Parmar, N.; Uszkoreit, J.; Jones, L.; Gomez, A. N.; Kaiser, Ł.; Polosukhin, I. (2017). Attention Is All You Need. NeurIPS 30; arXiv:1706.03762. Resultados cotejados con la versión PDF y Google Research; resumen HTML de NeurIPS divergente. Fuente F097

F098 · Radford, A.; Narasimhan, K.; Salimans, T.; Sutskever, I. (2018). Improving Language Understanding by Generative Pre-Training. OpenAI, informe técnico. Fuente F098

F099 · Devlin, J.; Chang, M.-W.; Lee, K.; Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. NAACL, 4171–4186. DOI 10.18653/v1/N19-1423. Preprint de 2018. Fuente F099

F100 · Jain, S.; Wallace, B. C. (2019). Attention is not Explanation. NAACL, 3543–3556. DOI 10.18653/v1/N19-1357. Fuente F100

F101 · Wiegreffe, S.; Pinter, Y. (2019). Attention is not not Explanation. EMNLP-IJCNLP, 11–20. DOI 10.18653/v1/D19-1002. Fuente F101

F102 · OpenAI (30 noviembre 2022). Introducing ChatGPT. Publicación original de lanzamiento. Fuente F102

F103 · Brown, T. B., y col. (2020). Language Models are Few-Shot Learners. NeurIPS 33; arXiv:2005.14165. Fuente F103

F104 · Ouyang, L., y col. (2022). Training language models to follow instructions with human feedback. NeurIPS 35. Fuente F104

F105 · OpenAI (2023). GPT-4 Technical Report. arXiv:2303.08774. Fuente F105

F106 · OpenAI (13 mayo 2024). Hello GPT-4o. Fuente F106

F107 · OpenAI (11 marzo 2025). New tools for building agents. Fuente F107

F108 · OpenAI (17 julio 2025). Introducing ChatGPT agent. Fuente F108

F109 · Chatterji, A., Cunningham, T., Deming, D. J., Hitzig, Z., Ong, C., Shan, C. Y., Wadman, K. (2025). How People Use ChatGPT. NBER Working Paper 34255. DOI 10.3386/w34255. Fuente F109

F110 · Noy, S.; Zhang, W. (2023). Experimental evidence on the productivity effects of generative artificial intelligence. Science 381, 187–192. DOI 10.1126/science.adh2586. Fuente F110

F111 · Brynjolfsson, E.; Li, D.; Raymond, L. (2025). Generative AI at Work. Quarterly Journal of Economics 140(2), 889–942. DOI 10.1093/qje/qjae044. Fuente F111

F112 · Stanford HAI (2026). The 2026 AI Index Report, capítulo Economy. Fuente F112

F113 · Stanford HAI (2026). The 2026 AI Index Report, capítulo Responsible AI. Fuente F113

F114 · Tabassi, E. (2023). Artificial Intelligence Risk Management Framework (AI RMF 1.0). NIST AI 100-1, National Institute of Standards and Technology. DOI 10.6028/NIST.AI.100-1. Fuente F114

F115 · Newell, A.; Simon, H. A. (s. f.). The Logic Theorist. Borrador histórico de capítulo, archivo Carnegie Mellon University; sección “Design of the Experiments”. Fuente F115

F116 · Griewank, A. (2012). Who Invented the Reverse Mode of Differentiation? Documenta Mathematica, Extra Volume ISMP, 389–400. DOI 10.4171/DMS/6/38. Fuente F116

F117 · Marino, Mark C.; Weil, Peggy; Shrager, Jeff y cols. (2026). Conversations about conversational code: on the collaborative critical code studies reading of ELIZA. AI & Society 41, 7129–7142. DOI 10.1007/s00146-026-03086-7. Fuente F117

F118 · Bertrand Russell Archives, McMaster University. BRACERS 80427: Russell a Herbert A. Simon, 21/09/1957. Registro catalográfico. Fuente F118

Sobre la autora

Soy **María Inés García Betoño**, doctora en Ciencias Naturales.

Mi formación académica no empezó en informática. Durante buena parte de mi carrera trabajé en ciencias naturales, investigación, biodiversidad y posteriormente en sistemas de información geográfica, datos, accesibilidad, neurodivergencias y transformación digital. Pero la tecnología siempre estuvo ahí.

Siempre tuve curiosidad por saber qué estaba ocurriendo detrás de cada nuevo avance informático: cómo funcionaba, qué permitía hacer, qué cambiaba y, especialmente, qué nueva pregunta abría.

Hace algunos meses esa curiosidad tomó otra forma. Empecé a construir mi propia arquitectura de trabajo con inteligencia artificial.

No quería solamente utilizar una interfaz que respondiera preguntas. Quería construir un sistema que pudiera acompañar mi manera de investigar, relacionar ideas, escribir, cuestionar afirmaciones, encontrar conexiones y revisar mi propio pensamiento.

Para desarrollarlo utilicé también algo que ya tenía: décadas de producción propia. Textos científicos, trabajos académicos, materiales técnicos, divulgación, narrativa, documentos profesionales y muchas de las ideas que fui desarrollando a lo largo de mi carrera.

Con el tiempo aparecieron distintos agentes y modos de trabajo. Algunos investigan. Otros cuestionan. Algunos estructuran, editan o diseñan. Otros buscan inconsistencias. No son personas, por supuesto, ni una reproducción fiel de mí misma. Pienso en ellos como una emulación necesariamente imperfecta de determinadas

funciones de mi pensamiento, construida a partir de mis instrucciones, mis materiales, mis criterios y muchas horas de interacción.

Y entonces apareció *ARTIFICIALMENTE*.

La idea original no fue escribir una colección para publicar.

Fue **construirme una biblioteca para aprender**.

Quería volver al comienzo. Recuperar lógica, epistemología, matemática, programación, historia de la computación y fundamentos de inteligencia artificial. Quería entender mejor los modelos generativos, los agentes, la seguridad, la ética, la gobernanza y el problema del criterio humano frente a sistemas cada vez más capaces.

Pero no quería estudiar acumulando nuevamente certificados.

Durante mucho tiempo mi respuesta frente a cada nuevo interés fue estudiar otra carrera, otra especialización, otro curso o conseguir otro título. Llegó un momento en que entendí que necesitaba otra cosa.

Necesitaba construir conocimiento de una manera compatible con mi propia forma de aprender.

Soy autista y doble excepcional. Mi pensamiento tiende a conectar campos, volver sobre las mismas preguntas desde distintos ángulos, buscar patrones, profundizar mucho y necesitar comprender no sólo **qué** ocurre, sino también **por qué**, **de dónde viene** y **qué consecuencias podría tener**.

Por eso estos libros están construidos de esa manera.

A veces una idea reaparece. Una historia conduce a otra. Una respuesta abre nuevas preguntas. La tecnología se cruza con biodiversidad, neurodivergencias, GIS, accesibilidad, diversidad, equidad, inclusión o ciencia.

No son accidentes editoriales. Son parte de la forma en que conecto el mundo.

El proyecto terminó convirtiéndose en una colección de **quince volúmenes**. Empieza con la historia intelectual de la inteligencia artificial y avanza por epistemología, lógica, incertidumbre, aprendizaje automático, lenguaje, agentes, programación, diseño de sistemas, ética, seguridad, organizaciones y criterio, hasta llegar al último volumen, pensado como preparación para comprender el rol contemporáneo de un **Chief AI Officer**.

Tal vez sean quince.

Tal vez aparezcan más.

El criterio será siempre el mismo: que cada volumen no se limite a explicar herramientas, sino que obligue a preguntarnos qué estamos haciendo con ellas.

Porque uno de los temas que más me interesa en este momento es la **alfabetización en inteligencia artificial**.

Tenemos herramientas extraordinariamente poderosas disponibles para una parte cada vez mayor de la población. Pero tener acceso no equivale a comprenderlas.

Necesitamos aprender a utilizarlas, interrogarlas, verificar sus respuestas, reconocer sus límites, proteger nuestros datos, detectar errores y decidir cuándo confiar y cuándo no hacerlo.

Necesitamos alfabetización digital y alfabetización en datos.

Pero, sobre todo, vamos a necesitar **criterio**.

Y antes de intentar contribuir a la alfabetización de otras personas, sentí que tenía que empezar profundizando la mía.

De ahí nació esta biblioteca.

Cuando terminé el primer volumen y lo escuché completo pensé algo muy sencillo:

esto me sirvió muchísimo; tal vez también pueda servirle a alguien más.

Por eso decidí compartirlo.

La portada, la edición, parte de la investigación y buena parte del proceso de producción también fueron desarrollados junto con los agentes que forman parte de mi arquitectura de inteligencia artificial. Incluso eso forma parte del experimento.

Pinto acuarelas y podría haber realizado personalmente las ilustraciones. Tal vez algún día lo haga. Esta vez elegí trabajar de otra manera y explorar qué ocurría cuando mis ideas visuales pasaban por un sistema generativo que también había sido moldeado por cientos de horas de interacción.

La pregunta permanece abierta:

¿cuánto hizo la máquina y cuánto sigue siendo mío?

No tengo una respuesta definitiva.

Sé que las herramientas generaron palabras e imágenes. Pero también sé que detrás de cada decisión están mis preguntas, mis elecciones, mis conocimientos, mis obsesiones, mis valores, mi ética, mis correcciones y mi forma particular de mirar el mundo.

Quizás ésa sea una de las preguntas más interesantes de nuestro tiempo.

ARTIFICIALMENTE no intenta resolverla.

Intenta mantenerla viva.

Espero que encuentres algo en estas páginas que te resulte útil, hermoso, incómodo, estimulante o inesperado.

Pero, sobre todo, espero que encuentres una pregunta que no tenías antes de abrir el libro.

Porque sospecho que, frente al mundo que estamos construyendo, vamos a necesitar muchas cosas.

Más conocimiento.

Más alfabetización.

Más comunidad.

Más creatividad.

Más empatía.

Y, sobre todas ellas,

más criterio.

Gracias por leer

Si este libro te resultó valioso y querés contribuir voluntariamente a la continuidad de *ARTIFICIALMENTE*, podés hacerlo mediante el siguiente enlace.

La colaboración es completamente opcional y no condiciona el acceso a ningún contenido.

Aporte voluntario a ARTIFICIALMENTE